

Estudo de Controladores Inteligentes para Rastreio do Ponto de Máxima Potência de um Sistema Fotovoltaico

Maria Izabel da Silva Guerra

Orientador: Prof. Dr. Fábio Meneghetti Ugulino de Araújo

Tese de Doutorado apresentada ao Programa de Pós-Graduação em Engenharia Elétrica e de Computação da Universidade Federal do Rio Grande do Norte - UFRN (área de concentração: Engenharia Elétrica, Sistemas de Controle) como parte dos requisitos para obtenção do título de Doutora em Ciências.

**Universidade Federal do Rio Grande do Norte - UFRN
Sistema de Bibliotecas - SISBI
Catalogação de Publicação na Fonte. UFRN - Biblioteca Central Zila Mamede**

Guerra, Maria Izabel da Silva.

Estudo de Controladores Inteligentes para Rastreio do Ponto de Máxima Potência de um Sistema Fotovoltaico / Maria Izabel da Silva Guerra. - 2022.

187 f.: il.

Tese (doutorado) - Universidade Federal do Rio Grande do Norte, Centro de Tecnologia, Programa de Pós-Graduação em Engenharia Elétrica e de Computação, Natal, RN, 2022.

Orientador: Prof. Dr. Fábio Meneghetti Ugulino de Araújo.

1. RNA - Tese. 2. Fuzzy - Tese. 3. ANFIS - Tese. 4. MPPT - Tese. 5. Sistema fotovoltaico - Tese. 6. Conversor buck-boost - Tese. I. Araújo, Fábio Meneghetti Ugulino de. II. Título.

RN/UF/BCZM

CDU 621.311

Agradecimentos

Tão desafiador quanto escrever essa Tese, foi resumir em duas páginas os agradecimentos àqueles que, de alguma forma, ajudaram a trilhar o caminho que permitiu chegar até a conclusão desse projeto. Então, começo agradecendo a todos que direta ou indiretamente contribuíram para a minha formação acadêmica e pessoal.

Agradeço a Deus por me iluminar, dar força, resiliência e paciência para sempre seguir em frente com os meus objetivos. Também sou grata por Ele jamais me abandonar e permitir que eu desanimasse nos momentos de dificuldade.

Agradeço à minha família, em especial, aos meus pais, Carlos e Marlucia, que são os responsáveis pela formação do meu caráter. Obrigada por me ensinarem sempre com tanto amor e pautado nos ensinamentos de Deus, sobretudo, que “*devemos fazer o bem sem olhar a quem*”. Agradeço ainda por serem fortalezas e espelhos, não só para mim, como também para meus irmãos. Obrigada por serem meus maiores incentivadores, por mostrarem incansavelmente a importância da educação e por compreenderem todos os momentos que precisei ficar reclusa para me concentrar nos estudos.

Agradeço à Daniel, meu esposo, por todo amor, incentivo, companheirismo, paciência, apoio e zelo. Obrigada por acreditar em mim, segurar minha mão e embarcar comigo em mais essa aventura acadêmica. Obrigada por compreender os dias que precisei me ausentar para estar em Natal e, também, pelos dias que estava em casa, mas nem parecia que eu estava.

Agradeço, igualmente, ao presente que Deus confiou a mim e à Daniel, nosso Gustavo, que trouxe um novo colorido para nossas vidas. Mesmo antes de nascer, ele já é amado incondicionalmente e tem sido meu grande estímulo na reta final dessa caminhada.

Agradeço aos meus irmãos, Luiz e Carlos Júnior, e a minha cunhada, Ilayni, não apenas por pararem para escutar eu falar sobre o projeto da tese, mesmo sem fazer a menor ideia do que se trata, mas também pela parceria e amizade de toda a vida. CJ, te agradeço também por ter sido meu revisor oficial.

Gostaria de fazer um agradecimento especial ao meu orientador, professor Fábio Meneghetti. Obrigada por ter aceitado o desafio de me orientar e, acima de tudo, por ter acreditado em mim e que tudo daria certo, mesmo eu estando nessa ponte Mossoró/Natal. Agradeço ainda pela paciência, ensinamentos, esclarecimentos e disponibilidade, mesmo durante os períodos mais críticos do cenário epidemiológico que estamos vivendo.

Agradeço ainda à banca examinadora deste trabalho, professores André Maitelli, Andres Ortiz, João Teixeira Neto e Marcelo Guerra, pela disponibilidade, bem como pelas importantes observações discutidas durante a qualificação que contribuíram para a melhoria do projeto.

Agradeço aos meus amigos, que, para não ser injusta, represento-os por àqueles que foram meus companheiros de viagem durante essa jornada do doutorado. Meu muito obrigada à Romênia Gurgel, Samanta Holanda, Magno Medeiros e Ednardo Pereira. Obrigada por deixarem a viagem Mossoró/Natal mais leve e descontraída. Obrigada pelos laços de amizade fortalecidos, pela companhia, discussões sem fim, apoio e confiança.

Por fim, não gostaria apenas de agradecer, mas também de dedicar essa tese à minha amada tia-mãe-irmã Nara (*in memoriam*). Você foi responsável por uma parcela da minha firmeza e autoconfiança. Obrigada por todos as frases de incentivo nada clichê que você me dizia e que me fazia acreditar que eu era capaz, embora achasse que você exagerasse um pouco. Obrigada por me ensinar um pouco mais sobre fé, esperança, força e garra. Obrigada por tudo que fizestes por mim e sempre regado de tanto amor. Que minhas memórias nunca me permitam esquecer o quanto sou grata por você ter estado em minha vida.

Resumo

Os sistemas fotovoltaicos (FV) têm apresentado um crescimento na matriz elétrica mundial. Contudo, a natureza não linear dos arranjos FV e sua forte dependência das condições ambientais são fatores que diminuem o fornecimento da máxima potência que eles são capazes de oferecer e, consequentemente, reduz seu desempenho e atratividade comercial. Para minimizar esses problemas, técnicas de Rastreamento do Ponto de Máxima Potência (MPPT) têm sido estudadas ao longo dos anos. Dentre as diversas técnicas de controle que podem ser utilizadas para rastreio do ponto de máxima potência, àquelas que utilizam algoritmos inteligentes para controlar o chaveamento dos conversores CC-CC têm mostrado um alto potencial de uso. Assim sendo, o presente trabalho se propõe a desenvolver técnicas de MPPT baseadas nos algoritmos inteligentes Rede Neural Artificial (RNA), fuzzy e Sistema de Inferência Neuro-Fuzzy Adaptativo (ANFIS), para serem aplicados à sistemas FV que tem o *buck-boost* como conversor CC-CC. Três propostas de arquiteturas foram desenvolvidas para cada algoritmos. Elas foram comparadas entre si e com o algoritmo clássico Perturba e Observa (P&O). As propostas diferenciam-se pelas variáveis de entrada utilizadas, a saber: irradiância e temperatura do ambiente, para a proposta 1, com variáveis de entrada puramente ambiental; irradiância e potência de saída instantânea do arranjo FV, para a proposta 2, com variáveis de entrada que misturou parâmetros ambiental e elétrico; e potência de saída instantânea e do instante anterior do arranjo FV, para a proposta 3, que teve variáveis de entrada com parâmetros puramente elétrico. Essas propostas não são encontradas na literatura e por isso pode ser considerada um avanço para a ciência. Para auxiliar no estudo do desempenho dos algoritmos inteligentes, dois cenários de sistemas FV, compostos por arranjo FV, conversor *buck-boost*, MPPT e carga, foram modelados, o cenário 1 e o cenário 2. Os cenários se diferenciaram pela potência total do sistema. Ao término das análises, percebeu-se que os algoritmos inteligentes tiveram uma alta velocidade de rastreamento e foram mais estáveis que os algoritmos P&O. Os sistemas FV controlados pelos algoritmos inteligentes da proposta 1 apresentaram a maior eficiência em atingir o ponto de máxima potência, sendo os algoritmos ANFIS e RNA os maiores destaques. Na geração de energia, quando substituiu o P&O, a RNA conseguiu recuperar até 12,05% de energia. No estudo da proposta 2, os sistemas FV também tiveram bom desempenho, mas inferior aos algoritmos da proposta 1. A maior energia gerada também foi alcançada pelo RNA. Ele gerou 12,01% a mais de energia que o P&O. Na proposta 3, os algoritmos inteligentes tiveram sua eficiência comprometida. De todo modo, sob condição randômica, os algoritmos inteligentes ainda mostraram ser superior ao P&O no rastreamento do ponto de máxima potência, recuperando até 8,27% da energia gerada. Assim sendo, os algoritmos inteligentes, em especial a RNA e o ANFIS, mostraram a relevância do seu uso em aplicações fotovoltaicas, sobretudo em regiões com variações randômicas das condições do ambiente. Ademais, os algoritmos inteligentes propostos são mais atrativos à medida que a potência do sistema FV a ser utilizado é elevada.

Palavras-chave: RNA, Fuzzy, ANFIS, MPPT, Sistema Fotovoltaico, Conversor *buck-boost*.

Abstract

Photovoltaic (PV) systems have shown growth in the world's electrical matrix. However, the non-linear nature of PV arrays and their strong dependence on ambient conditions decrease the maximum power they can produce and, consequently, reduce their performance and commercial attractiveness. Maximum Power Point Tracking (MPPT) techniques have been studied over the years to minimize these problems. Among the various control techniques used to track the maximum power point, those that use intelligent algorithms to control the switching of DC-DC converters have shown a high potential for use. Therefore, the present work proposes to develop MPPT techniques based on Artificial Neural Network (ANN), fuzzy and Adaptive Neuro-Fuzzy Inference System (ANFIS) intelligent algorithms, to be applied to PV systems that have the buck-boost as a DC-DC converter. Three proposed architectures were developed for each algorithm. They were compared with each other and with the classic Perturb and Observe (P&O) algorithm. The proposals are distinguished by the input variables used, namely: irradiance and ambient temperature, for proposal 1, with purely ambient parameters as input variables; irradiance and instantaneous output power of the PV array, for proposal 2, with input variables that mixed ambient and electrical parameters; and instantaneous and previous instantaneous output power of the PV array, for proposal 3, with purely electrical parameters as input variables. These proposals are not found in the literature. Therefore can be considered a breakthrough for science. To assist in the study of the performance of the intelligent algorithms, two scenarios of PV systems were modeled. They are composed of PV array, buck-boost converter, MPPT, and load and identified as scenario 1 and scenario 2. The scenarios were differentiated by the total power of the system. At the end of the analyses, the intelligent algorithms had a high tracking speed and were more stable than the P&O algorithms. The PV systems controlled by the intelligent algorithms of Proposal 1 showed the highest efficiency in reaching the maximum power point. The ANFIS and ANN algorithms were more prominent. In power generation, ANN recovered up to 12.05% of the energy lost when using P&O. In the proposal 2 study, the PV systems also performed well, but it was lower than the proposal 1 algorithms. The highest power generated was also achieved by the ANN. It generated 12.01% more power than the P&O. In proposal 3, the intelligent algorithms had their efficiency compromised. Anyway, under random conditions, the intelligent algorithms still proved to be superior to P&O in tracking the maximum power point, recovering 8.27% of the generated power. Therefore, intelligent algorithms, especially ANN and ANFIS, have shown the relevance of their use in photovoltaic applications, especially in regions with random environmental conditions. Furthermore, the proposed intelligent algorithms are more attractive as the power of the PV system to be used is high.

Keywords: ANN, Fuzzy, ANFIS, MPPT, Photovoltaic System, Buck-boost converter

Sumário

Lista de Figuras	11
Lista de Tabelas	15
Lista de Abreviaturas.....	17
Lista de Símbolos	19
1. Introdução	22
1.1 Considerações iniciais	22
1.2 Revisão da literatura.....	29
1.3 Justificativa.....	35
1.4 Contribuições.....	38
1.5 Objetivos	39
1.6 Estrutura do Trabalho	40
2. Fundamentação Teórica.....	41
2.1 A energia solar fotovoltaica.....	41
2.2 Modelagens de células fotovoltaicas	42
2.3 Curvas características e parâmetros elétricos.....	46
2.4 Efeito das condições irradiância e temperatura de operação das células FV nos geradores fotovoltaicos	49
2.4.1 Irradiância solar.....	49
2.4.2 Temperatura de operação dos geradores fotovoltaicos	52
2.5 Influência das cargas nas curvas características I-V	54
2.6 Sistemas fotovoltaicos	57
2.6.1 Módulos fotovoltaicos	60
2.6.2 Conversor CC/CC	63
2.6.2.1 Conversores CC-CC buck-boost aplicados à sistemas fotovoltaicos	63

2.6.3 Rastreador do ponto de máxima potência	71
2.7 Técnicas de Rastreamento do ponto de máxima potência (MPPT)	72
2.7.1 Técnica clássica Perturba e Observa (P&O)	73
2.7.2 Técnicas de Inteligência Artificial (IA)	76
2.7.2.1 Rede Neural Artificial (RNA)	76
2.7.2.2 Lógica fuzzy (FL).....	83
2.7.3 Técnica otimizada baseada no Sistema de Inferência Neuro-Fuzzy Adaptativo (ANFIS).....	86
3. Materiais e Métodos	90
3.1 Caracterização do sistema FV real.....	91
3.2 Modelagem da célula e módulo FV	92
3.2.1 Parâmetros estimados por simulação.....	95
3.3 Modelagem do sistema fotovoltaico.....	97
3.3.1 Arranjo FV	97
3.3.2 Carga	98
3.3.3 Conversor CC-CC <i>buck-boost</i>.....	99
3.4 Levantamento do conjunto de dados e parâmetros avaliados	100
3.4.1 Resposta dinâmica.....	103
3.4.2 Geração de energia elétrica	105
3.4.2.1 Condição normal	105
3.4.2.2 Condição de sombreamento	106
3.4.2.3 Condição randômica	106
3.5 Modelagem do MPPT baseado na técnica clássica P&O	108
3.6 Modelagem do MPPT baseado na técnica RNA	109
3.6.1 Proposta 1 - Variáveis de entrada irradiação e temperatura ambiente.....	110
3.6.2 Proposta 2 - Variáveis de entrada irradiação e potência de saída instantânea do arranjo FV	112

3.6.3 Proposta 3 - Variáveis de entrada potência de saída instantânea e do instante anterior do arranjo FV	113
3.7 Modelagem do MPPT baseado na lógica <i>fuzzy</i>	115
3.7.1 Proposta 1 - Variáveis de entrada Irradiância e Temperatura ambiente.....	115
3.7.2 Proposta 2 - Variáveis de entrada irradiância e potência de saída instantânea do arranjo FV	118
3.7.3 Proposta 3 - Variáveis de entrada potência de saída instantânea e do instante anterior do arranjo FV	120
3.8 Modelagem do MPPT baseado na técnica otimizada ANFIS	122
3.8.1 Proposta 1 - Variáveis de entrada irradiância e temperatura ambiente.....	122
3.8.2 Proposta 2 - Variáveis de entrada irradiância e potência de saída instantânea do arranjo FV	125
3.8.3 Proposta 3 - Variáveis de entrada potência de saída instantânea e do instante anterior do arranjo FV	127
4. Resultados e Discussões.....	129
4.1 Análise e validação da modelagem do módulo FV.....	129
4.2 Análise do desempenho do algoritmo de controle P&O	131
4.2.1 Cenário 1	131
4.2.2 Cenário 2	134
4.3 Avaliação dos algoritmos de MPPT da proposta 1: variáveis de entrada irradiância e temperatura ambiente	139
4.3.1 Análise da resposta dinâmica.....	139
4.3.2 Análise da geração de energia do sistema FV.....	145
4.4 Avaliação dos algoritmos de MPPT da proposta 2: variáveis de entrada irradiância e potência de saída instantânea do arranjo FV	150
4.4.1 Análise da resposta dinâmica.....	150
4.4.2 Análise da geração de energia do sistema FV.....	156

4.5 Avaliação dos algoritmos de MPPT da proposta 3: variáveis de entrada potência de saída instantânea e do instante anterior do arranjo FV	160
4.5.1 Análise da resposta dinâmica.....	160
4.5.2 Análise da geração de energia do sistema FV.....	167
4.6 Comparativo com outros trabalhos.....	174
5. Conclusões	179
5.1 Sugestões para trabalhos futuros	182
Referências	183

Lista de Figuras

Figura 1.1. Produção total mundial de eletricidade e por fonte.....	22
Figura 1.2. Classificações básicas de técnicas de MPPT	25
Figura 1.3. Diagrama esquemático de várias técnicas de MPPT aplicado a sistemas FV.....	33
Figura 2.1. Estrutura de uma célula fotovoltaica a base de silício cristalino	42
Figura 2.2. Circuito equivalente do modelo de diodo único	43
Figura 2.3. Curva característica I-V para 1 até 36 células FV ligadas em série.....	45
Figura 2.4. Curva característica I-V de um gerador FV	46
Figura 2.5. Curva característica P-V de um gerador FV	48
Figura 2.6. Influência da variação da irradiância solar na curva característica I-V	51
Figura 2.7. Influência da variação da irradiância solar na curva característica P-V	51
Figura 2.8. Influência da variação da temperatura na curva característica I-V	53
Figura 2.9. Influência da variação da temperatura na curva característica P-V	54
Figura 2.10. Circuito composto por gerador FV e carga resistiva.....	55
Figura 2.11. Curvas características I-V do gerador FV e de cargas resistivas	55
Figura 2.12. Curvas características I-V de um gerador FV com variação de irradiância e de uma carga resistiva fixa	57
Figura 2.13. Esquema de um sistema FV isolado	58
Figura 2.14. Esquema de um SFCR	59
Figura 2.15. Componentes básicos de um módulo FV	61
Figura 2.16. Gerador fotovoltaico da célula ou ao arranjo	61
Figura 2.17. Curva-característica I-V de um arranjo FV com seis módulos e conexão mista	62
Figura 2.18. Circuito equivalente (a) do conversor CC-CC <i>buck-boost</i> e seu respectivo esquema com (b) a chave comutadora fechada e (c) a chave comutadora aberta	64
Figura 2.19. Comutação da chave de um conversor CC-CC <i>buck-boost</i> e o consequente comportamento da tensão e corrente no indutor, corrente e tensão no capacitor e na carga....	66
Figura 2.20. Região de operação da chave de um conversor <i>buck-boost</i> operando como MPPT	70
Figura 2.21. Funcionamento de um MPPT baseado no P&O	73
Figura 2.22. Fluxograma do algoritmo P&O como técnica de MPPT	74
Figura 2.23. Resposta de um sistema FV à diferentes constantes ΔD de um algoritmo P&O	75
Figura 2.24. Esquema de um neurônio artificial	77

Figura 2.25. Rede MLP	78
Figura 2.26. Fluxograma de treinamento de uma rede MLP	80
Figura 2.27. Ponto de mínimos locais associados à função erro	82
Figura 2.28. Estrutura de um controlador <i>fuzzy</i>	83
Figura 2.29. Funções de pertinência triangulares	84
Figura 2.30. Arquitetura ANFIS com cinco camadas	87
Figura 3.1. Etapas do procedimento metodológico	90
Figura 3.2. Modelagem da Equação (8) no <i>software Matlab/Simulink</i> [®]	93
Figura 3.3. Modelagem da Equação (4) no <i>software Matlab/Simulink</i> [®]	94
Figura 3.4. Algoritmo para definir os parâmetros n , R_S e R_P	96
Figura 3.5. Modelagem de um arranjo FV com 14 módulos FV.....	98
Figura 3.6. Modelagem do sistema FV	100
Figura 3.7. Modelagem de um módulo FV sem MPPT e carga	101
Figura 3.8. Conjunto de G e T_{AMB} para montagem do banco de dados	102
Figura 3.9. Potência de rastreio esperada pelos diferentes MPPT desenvolvidos para o (a) cenário 1, (b) e cenário 2 sob diferentes condições ambientais.....	103
Figura 3.10. Curva de potência <i>versus</i> tempo e localização dos pontos de extração dos parâmetros velocidade de convergência e oscilação em torno do MPP	104
Figura 3.11. Condição normal	106
Figura 3.12. Condição de sombreamento	106
Figura 3.13. Condição randômica.....	107
Figura 3.14. Influência da variável d no sinal do PWM.....	108
Figura 3.15. Algoritmo e sinal de controle do conversor <i>buck-boost</i> baseado no P&O	109
Figura 3.16. MPPT baseado na proposta 1 do algoritmo de controle RNA	110
Figura 3.17. MPPT baseado na proposta 2 do algoritmo de controle RNA	112
Figura 3.18. MPPT baseado na proposta 3 do algoritmo de controle RNA	114
Figura 3.19. MPPT baseado na proposta 1 do controlador <i>fuzzy</i>	115
Figura 3.20. MPPT baseado na proposta 2 do controlador <i>fuzzy</i>	118
Figura 3.21. MPPT baseado na proposta 3 do controlador <i>fuzzy</i>	120
Figura 3.22. MPPT baseado na proposta 1 do algoritmo de controle ANFIS	123
Figura 3.23. MPPT baseado na proposta 2 do algoritmo de controle ANFIS	125
Figura 3.24. MPPT baseado na proposta 3 do algoritmo de controle ANFIS	127

Figura 4.1. Comparativo entre as potências medidas experimentalmente e obtidas em simulação sob condições de (a) $G=294 \text{ W/m}^2$ e $T_{AMB}=23,86 \text{ }^{\circ}\text{C}$, (b) $G=303 \text{ W/m}^2$ e $T_{AMB}=31,74 \text{ }^{\circ}\text{C}$, (c) $G=548 \text{ W/m}^2$ e $T_{AMB}=24,65 \text{ }^{\circ}\text{C}$, (d) $G=868 \text{ W/m}^2$ e $T_{AMB}=31,46 \text{ }^{\circ}\text{C}$, (e) $G=957 \text{ W/m}^2$ e $T_{AMB}=31,41 \text{ }^{\circ}\text{C}$ e (f) $G=1134 \text{ W/m}^2$ e $T_{AMB}=30,17 \text{ }^{\circ}\text{C}$	130
Figura 4.2. P_{MPP} e a potência de saída do sistema FV do cenário 1 com MPPT baseado no P&O de diferentes passos (Δd)	132
Figura 4.3. Potência de saída dos sistemas FV do cenário 1 e sua barra de erro em relação ao P_{MPP} , quando aplicado diferentes passos (Δd) para o algoritmo de controle P&O e submetidos à (a) condição 1, (b) condição 2, (c) condição 3 e (d) condição 4 do ambiente	134
Figura 4.4. P_{MPP} e a potência de saída do sistema FV do cenário 2 com MPPT baseado no P&O com diferentes Δd	135
Figura 4.5. Potência de saída dos sistemas FV do cenário 2 e sua barra de erro em relação ao P_{MPP} , quando aplicado diferentes passos (Δd) para o algoritmo de controle P&O e submetidos à (a) condição 1, (b) condição 2, (c) condição 3 e (d) condição 4 do ambiente	137
Figura 4.6. Potência de saída ao aplicar os algoritmos da proposta 1 no cenário 1	140
Figura 4.7. Potência de saída ao aplicar os algoritmos da proposta 1 no cenário 2	141
Figura 4.8. Potência de saída dos sistemas FV do cenário 1 e sua barra de erro em relação ao P_{MPP} , quando aplicado os algoritmos de controle da proposta 1 e submetidos à (a) condição 1, (b) condição 2, (c) condição 3 e (d) condição 4 do ambiente.....	144
Figura 4.9. Potência de saída dos sistemas FV do cenário 2 e sua barra de erro em relação ao P_{MPP} , quando aplicado os algoritmos de controle da proposta 1 e submetidos à (a) condição 1, (b) condição 2, (c) condição 3 e (d) condição 4 do ambiente.....	144
Figura 4.10. Energia gerada pelo sistema FV do cenário 1 quando aplicado os algoritmos de controle da proposta 1.....	146
Figura 4.11. Energia gerada pelo sistema FV do cenário 2 quando aplicado os algoritmos de controle da proposta 1.....	148
Figura 4.12. Potência de saída ao aplicar os algoritmos da proposta 2 no cenário 1	151
Figura 4.13. Potência de saída ao aplicar os algoritmos da proposta 2 no cenário 2	152
Figura 4.14. Potência de saída dos sistemas FV do cenário 1 e sua barra de erro em relação ao P_{MPP} , quando aplicado os algoritmos de controle da proposta 2 e submetidos à (a) condição 1, (b) condição 2, (c) condição 3 e (d) condição 4 do ambiente.....	155

Figura 4.15. Potência de saída dos sistemas FV do cenário 2 e sua barra de erro em relação ao P_{MPP} , quando aplicado os algoritmos de controle da proposta 2 e submetidos à (a) condição 1, (b) condição 2, (c) condição 3 e (d) condição 4 do ambiente.....	155
Figura 4.16. Energia gerada pelo sistema FV do cenário 1 quando aplicado os algoritmos de controle da proposta 2.....	157
Figura 4.17. Energia gerada pelo sistema FV do cenário 2 quando aplicado os algoritmos de controle da proposta 2.....	158
Figura 4.18. Potência de saída ao aplicar os algoritmos da proposta 3 no cenário 1	161
Figura 4.19. Potência de saída ao aplicar os algoritmos da proposta 3 no cenário 2	162
Figura 4.20. Potência de saída dos sistemas FV do cenário 1 e sua barra de erro em relação ao P_{MPP} , quando aplicado os algoritmos de controle da proposta 3 e submetidos à (a) condição 1, (b) condição 2, (c) condição 3 e (d) condição 4 do ambiente.....	165
Figura 4.21. Potência de saída dos sistemas FV do cenário 2 e sua barra de erro em relação ao P_{MPP} , quando aplicado os algoritmos de controle da proposta 3 e submetidos à (a) condição 1, (b) condição 2, (c) condição 3 e (d) condição 4 do ambiente.....	166
Figura 4.22. Energia gerada pelo sistema FV do cenário 1 quando aplicado os algoritmos de controle da proposta 3.....	168
Figura 4.23. Potência de saída do sistema FV do cenário 1 quando aplicado os algoritmos de controle da proposta 3 e sob condição normal	168
Figura 4.24. Potência de saída do sistema FV do cenário 1 quando aplicado os algoritmos de controle da proposta 3 e sob condição de sombreamento	169
Figura 4.25. Potência de saída do sistema FV do cenário 1 quando aplicado os algoritmos de controle da proposta 3 e sob condição randômica.....	170
Figura 4.26. Energia gerada pelo sistema FV do cenário 2 quando aplicado os algoritmos de controle da proposta 3.....	171
Figura 4.27. Potência de saída do sistema FV do cenário 2 quando aplicado os algoritmos de controle da proposta 3 e sob condição normal	171
Figura 4.28. Potência de saída do sistema FV do cenário 2 quando aplicado os algoritmos de controle da proposta 3 e sob condição de sombreamento	172
Figura 4.29. Potência de saída do sistema FV do cenário 2 quando aplicado os algoritmos de controle da proposta 3 e sob condição randômica.....	173

Lista de Tabelas

Tabela 2.1. Matriz de base de regras de um controlador <i>fuzzy</i>	85
Tabela 2.2. Comparação entre sistemas <i>fuzzy</i> e neurais	86
Tabela 3.1. Características do módulo FV YL245P-29b.....	91
Tabela 3.2. Características do inversor <i>Sunny Boy</i> 3000HFUS	92
Tabela 3.3. Parâmetros estimados do módulo FV YL245P-29b	96
Tabela 3.4. Cenários projetados	98
Tabela 3.5. Resistência da carga de cada cenário.....	99
Tabela 3.6. Componentes do conversor <i>buck-boost</i> de cada cenário	99
Tabela 3.7. Parâmetros da RNA da proposta 1 modelada	111
Tabela 3.8. Parâmetros da RNA da proposta 2 modelada	113
Tabela 3.9. Parâmetros da RNA da proposta 3 modelada	114
Tabela 3.10. Base de dados do FLC da proposta 1.....	116
Tabela 3.11. Matriz de base de regras do FLC da proposta 1	117
Tabela 3.12. Parâmetros do FLC da proposta 1 modelado.....	117
Tabela 3.13. Base de dados do FLC da proposta 2 para o cenário 1	118
Tabela 3.14. Base de dados do FLC da proposta 2 para o cenário 2.....	119
Tabela 3.15. Matriz de base de regras do FLC da proposta 2	119
Tabela 3.16. Parâmetros do FLC da proposta 2	120
Tabela 3.17. Base de dados do FLC da proposta 3 para o cenário 1	121
Tabela 3.18. Base de dados do FLC da proposta 3 para o cenário 2	121
Tabela 3.19. Matriz de base de regras do FLC da proposta 3	121
Tabela 3.20. Parâmetros do FLC da proposta 3	122
Tabela 3.21. Erro de treinamento das MF do ANFIS da proposta 1, por tipo e por cenário..	123
Tabela 3.22. Base de dados do controlador ANFIS da proposta 1	124
Tabela 3.23. Parâmetros do ANFIS da proposta 1 modelado	124
Tabela 3.24. Erro de treinamento das MF do ANFIS da proposta 2, por tipo e por cenário..	125
Tabela 3.25. Base de dados do ANFIS da proposta 2 para o cenário 1	126
Tabela 3.26. Base de dados do ANFIS da proposta 2 para o cenário 2	126
Tabela 3.27. Parâmetros do ANFIS da proposta 2 modelado	126
Tabela 3.28. Erro de treinamento das MF do ANFIS da proposta 3, por tipo e por cenário..	127
Tabela 3.29. Base de dados do ANFIS da proposta 3	128

Tabela 3.30. Parâmetros do ANFIS da proposta 3 modelado	128
Tabela 4.1. Análise comparativa entre os resultados experimentais e simulados para validação do modelo do arranjo FV proposto.....	129
Tabela 4.2. Parâmetros ts e ΔP do P&O de diferentes passos aplicados no cenário 1	133
Tabela 4.3. Análise comparativa do parâmetro $e\%$ do P&O aplicado no cenário 1.....	133
Tabela 4.4. Parâmetros ts e ΔP do P&O de diferentes passos aplicados no cenário 2	136
Tabela 4.5. Análise comparativa do parâmetro $e\%$ do P&O aplicado no cenário 2.....	137
Tabela 4.6. Parâmetros ts e ΔP dos algoritmos da proposta 1 aplicados no cenário 1	142
Tabela 4.7. Parâmetros ts e ΔP dos algoritmos da proposta 1 aplicados no cenário 2	142
Tabela 4.8. Parâmetro $e\%$ calculado para os algoritmos de controle da proposta 1.....	143
Tabela 4.9. Parâmetros ts e ΔP dos algoritmos da proposta 2 aplicados no cenário 1	153
Tabela 4.10. Parâmetros ts e ΔP dos algoritmos da proposta 2 aplicados no cenário 2	154
Tabela 4.11. Parâmetro $e\%$ calculado para os algoritmos de controle da proposta 2.....	154
Tabela 4.12. Parâmetros ts e ΔP dos algoritmos da proposta 3 aplicados no cenário 1	164
Tabela 4.13. Parâmetros ts e ΔP dos algoritmos da proposta 3 aplicados no cenário 2	164
Tabela 4.14. Parâmetro $e\%$ calculado para os algoritmos de controle da proposta 3.....	165
Tabela 4.15. Resultados de trabalhos publicados que utilizaram os algoritmos inteligentes RNA, fuzzy ou ANFIS como controle do MPPT	175
Tabela 4.16. Resultados do estudo proposto	176

Lista de Abreviaturas

ABNT	Associação Brasileira de Normas Técnicas
ANFIS	Sistema de Inferência Neuro-Fuzzy Adaptativo (do inglês, <i>Adaptive Neuro Fuzzy Inference System</i>)
CC	Corrente Contínua
CC-CC	Corrente Contínua para Corrente Contínua
CO ₂	Dióxido de carbono
DPS	Processadores Digitais de Sinais (do inglês, <i>Digital Signal Processor</i>)
FIS	Sistema de Inferência Fuzzy (do inglês, <i>Fuzzy Inference System</i>)
FL	Lógica Fuzzy (do inglês, <i>Fuzzy Logic</i>)
FLC	Controlador Fuzzy (do inglês, <i>Fuzzy Logic Controller</i>)
FPGA	Arranjo de Portas Programáveis em Campo (do inglês, <i>Field Programmable Gate Array</i>).
FV	Fotovoltaico
GD	Gradiente Descendente
H	Alto (do inglês, <i>High</i>)
IA	Inteligência Artificial
IEA	Agência Internacional de Energia (do inglês, <i>International Energy Agency</i>)
IGBT	Transistor Bipolar de Porta Isolada (do inglês, <i>Insulated Gate Bipolar Transistor</i>)
I-V	Corrente <i>versus</i> Tensão
LO	Baixo (do inglês, <i>Low</i>)
LSE	Estimador de Mínimos Quadrados (do inglês, <i>Least-Squares Estimator</i>)
M	Médio
MCC	Modo de Condução Contínua
MCD	Modo de Condução Descontínua
MF	Função de pertinência (do inglês, <i>Membership Function</i>)
MH	Medianamente Alto (do inglês, <i>Medium High</i>)
ML	Medianamente Baixo (do inglês, <i>Medium Low</i>)
MLP	<i>Perceptron</i> de Múltiplas Camadas (do inglês, <i>Multilayer Perceptron</i>)
MOSFET	Transistor de Efeito de Campo Metal - Óxido – Semicondutor (do inglês, <i>Metal Oxide Semiconductor Field Effect Transistor</i>)

MPP	Ponto de Máxima Potência (MPP, do inglês, <i>Maximum Power Point</i>)
MPPT	Rastreamento do Ponto de Máxima Potência (do inglês, <i>Maximum Power Point Tracking</i>)
MSE	Erro Quadrático Médio (do inglês, <i>Mean Squared Error</i>)
NOCT	Temperatura Nominal de Operação da Célula FV (do inglês, <i>Nominal Operating Cell Temperature</i>)
P&O	Perturba e Observa
PI	Proporcional-Integral
PPGEEC	Programa de Pós-Graduação em Engenharia Elétrica e de Computação
P-V	Potência <i>versus</i> Tensão
PWM	Modulação por Largura de Pulso (do inglês, <i>Pulse Width Modulation</i>)
RNA	Rede Neural Artificial
SEPIC	Conversor com Indutância Simples no Primário (do inglês, <i>Single-Ended Primary-Inductor Converter</i>)
SFCR	Sistema Fotovoltaico Conectado à Rede
SPPM	Seguimento do Ponto de Potência Máxima
STC	Condições de Teste Padrão (do inglês, <i>Standard Test Conditions</i>)
T-S	Takagi-Sugeno
UFERSA	Universidade Federal Rural do Semi-Árido
UFRN	Universidade Federal do Rio Grande do Norte

Lista de Símbolos

Δd	Incremento ou valor de passo
Δi_L	<i>Ripple</i> ou Variação de pico a pico na corrente de saída
ΔP	Valor de pico a pico do sinal no regime permanente
Δt	Intervalo de tempo
ΔV_R	<i>Ripple</i> ou Variação de pico a pico na tensão de saída
A	Área total do gerador fotovoltaico
C	Capacitor
D	Ciclo de trabalho do conversor
dE	Derivada do erro
$d_j(k)$	Valor desejado para $Y_j(k)$
E	Erro devido à mudança da potência
$e\%$	Erro relativo percentual
$E(k)$	Erro quadrático entre duas épocas sucessivas
E_g	Energia do gap do semicondutor
E_M	Erro quadrático médio
f	Frequência de chaveamento
FF	Fator de Forma do sistema FV
G	Irradiância
$g(u)$	Função de ativação de u
G_{STC}	Irradiância solar nas condições de teste padrão
i_C	Corrente no capacitor
I_{CC}	Corrente de curto-circuito
I_D	Corrente do diodo
I_{FV}	Corrente de saída do arranjo FV
i_L	Corrente no indutor
I_{MPP}	Corrente do ponto de máxima potência
I_o	Corrente de saturação reversa do diodo
I_o'	Corrente de saturação reversa nominal do diodo nas STC
I_{PH}	Corrente fotogerada
I_R	Corrente da carga resistiva
I_{RP}	Corrente parasita do resistor paralelo

k	Constante de Boltzmann
k_i	Coeficiente de temperatura da corrente
k_v	Coeficiente de temperatura da tensão
L	Indutor
L_{min}	Indutância mínima necessária para o MCC
n	Fator de idealidade do diodo
$NOCT$	Temperatura nominal de operação da célula FV (do inglês, <i>Nominal Operating Cell Temperature</i>)
N_P	Número de células FV em paralelo
N_S	Número de células FV em série
p	Número de amostras do conjunto de treinamento
P_{FV}	Potência de saída dos arranjos FV
$P_{FV}(t)$	Potência de saída instantânea do arranjo FV.
$P_{FV}(t-1)$	Potência de saída do instante anterior do arranjo FV
P_{MAX}	Potência máxima calculada
P_{medido}	Potência medida no sistema real
P_{MPP}	Potência do ponto de máxima potência
$P_{MPP,simulação}$	Potência no ponto de máxima potência obtido na simulação
$P_{simulação}$	Potência estimada obtida na simulação
q	Carga do elétron
R	Carga
R^2	Regressão linear
R_{FV}	Resistência equivalente total vista nos terminais do arranjo FV
R_P	Resistência paralela
R_S	Resistência série
T	Período de chaveamento
T_{AMB}	Temperatura ambiente
T_C	Constante de tempo
T_{CELL}	Temperatura de operação da célula FV
ts	Tempo de acomodação
T_{STC}	Temperatura de operação do gerador FV nas condições de teste padrão
u	Potencial de ativação
v_D	Tensão sobre o diodo

V_F	Tensão da fonte
V_{FV}	Tensão de saída do módulo fotovoltaico
v_L	Tensão no indutor
V_{MPP}	Tensão do ponto de máxima potência
V_{OC}	Tensão de circuito aberto
V_R	Tensão na carga
W/m^2	Watt por metro quadrado
w_i	Peso sináptico i
W_p	Potência de pico
x_i	Sinais de entrada i
y	Sinal de saída do neurônio
$Y_j(k)$	Valor produzido pelo j-ésimo neurônio de saída da rede considerando a k-ésima amostra de treinamento
θ_{FV}	Ângulo de inclinação da curva característica I-V da carga vista pelo arranjo FV
ε	precisão requerida
η	Eficiência elétrica
θ	Limiar de ativação ou <i>bias</i>

1. Introdução

O presente capítulo inicia contextualizando a inserção da energia solar fotovoltaica no mundo e no Brasil na Seção 1.1. Em seguida, uma revisão da literatura é apresentada na Seção 1.2. Posteriormente, na Seção 1.3, é justificada a motivação que norteou o desenvolvimento da presente pesquisa, seguido dos objetivos, na Seção 1.5, e da explicação da estrutura do presente trabalho na Seção 1.6.

1.1 Considerações iniciais

Os avanços tecnológicos têm contribuído para que os serviços de eletricidade se tornem o centro da economia moderna. O aumento da renda familiar da população também está diretamente relacionado com a elevação do consumo de eletricidade. Como consequência, a demanda por energia elétrica apresenta um crescimento anual cada vez mais expressivo e é a segunda maior forma de energia de uso final consumida no mundo (IEA, 2021b).

Ao analisar a produção mundial de eletricidade ao longo dos últimos anos, observa-se um crescimento acima de 20% por década, mesmo com o declínio que ocorreu entre os anos de 2019 e 2020, mostrado na Figura 1.1. Esse declínio foi uma consequência dos bloqueios que existiram durante a pandemia do Covid-19 (IEA, 2021a).

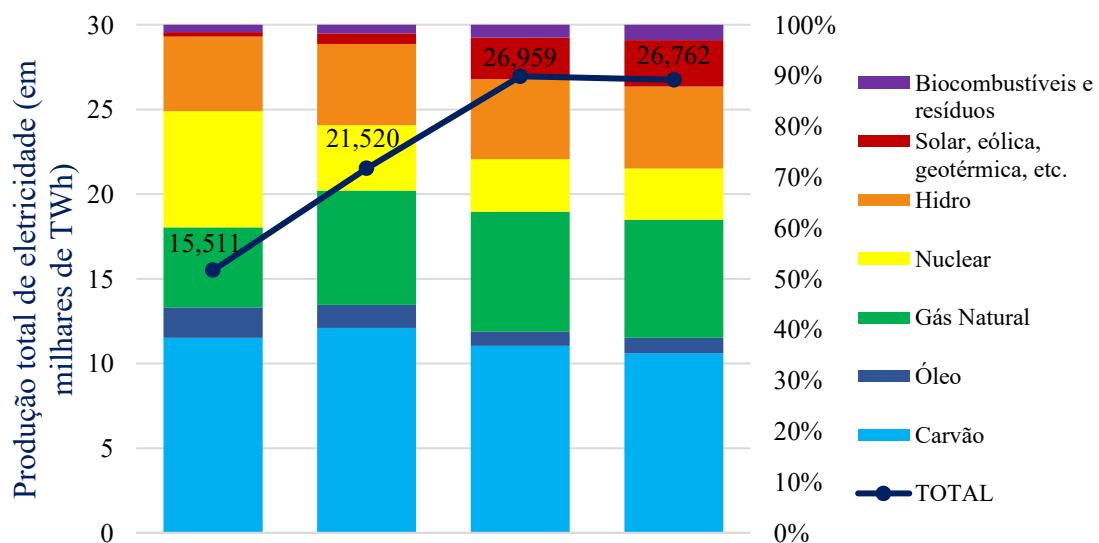


Figura 1.1. Produção total mundial de eletricidade e por fonte
Fonte: Adaptado de (IEA, 2021a)

Paralelo ao crescimento da produção mundial de eletricidade, na Figura 1.1 percebe-se um aumento na diversificação de fontes de energia, em especial as renováveis, e uma redução no uso de combustíveis fósseis.

De acordo com a Agência Internacional de Energia (IEA, do inglês, *International Energy Agency*), entre os anos de 2018 e 2019, a geração de eletricidade a partir da energia eólica e solar cresceram, respectivamente, 11,8% e 22,5%. Como resultado, as fontes de energia renováveis atenderam coletivamente a quase 65% do crescimento da demanda de eletricidade ao longo da última década (IEA, 2021a).

Esse percentual do uso das fontes renováveis deve aumentar ainda mais, visto que o setor da geração de energia elétrica continua investindo em fontes de energia renováveis com baixas emissões de poluentes, como a solar fotovoltaica e a eólica.

Focando no mercado fotovoltaico mundial, o relatório desenvolvido pela IEA (IEA, 2021b) mostra que, mesmo com a pandemia do Covid-19, houve um crescimento de 18,33% no mercado fotovoltaico (FV) no ano de 2020. Com o significativo aumento, o mercado fotovoltaico mundial passou a acumular 760,4 GW de capacidade instalada e tendo como líderes a China, a União Europeia e os Estados Unidos.

Ainda de acordo com a IEA (IEA, 2021b), embora não esteja entre os dez países com maior capacidade FV instalada, o Brasil acompanhou a tendência mundial e adicionou 3,1 GW de instalações FV no ano de 2020. Com isso, o Brasil esteve entre os dez países que mais aumentou a capacidade FV instalada no *ranking* mundial do ano de 2020.

O crescimento expressivo do mercado fotovoltaico ocorre devido a energia solar ser considerada promissora, segura e abundante. Além disso, a tecnologia FV tem vantagens como a ausência de custo com combustível, pouca manutenção, vida útil prolongada e operação silenciosa devido à ausência de partes móveis. Com isso, diversos países têm se atraído por essas vantagens e adotado políticas de incentivos (KUMAR; GUPTA; GUPTA, 2017).

Em contrapartida, a energia solar FV têm como desvantagens o alto capital inicial para instalar um sistema FV, o risco de os governos reduzirem os incentivos, a descontinuidade da fonte solar e a baixa eficiência da conversão de energia solar em eletricidade. Além disso, a geração de eletricidade através dos módulos FV apresenta um comportamento não linear em relação as mudanças de condições ambientais, sendo mais afetada pela irradiação e temperatura ambiente, assim como sofre influência da carga conectada ao sistema FV (LASHEEN; ABDEL-SALAM, 2018).

Para minimizar as desvantagens técnicas, estudos têm sido desenvolvidos e medidas têm sido adotadas a fim de se obter uma maior extração de eletricidade das instalações fotovoltaicas. Como exemplo de estudos e medidas, é possível citar as técnicas de detecção de falhas, os algoritmos de anti-ilhamento, o desenvolvimento de células cada vez mais eficientes, além das técnicas de rastreamento do ponto de máxima potência, que é o foco da presente pesquisa.

Conforme explicam Andrew-Cotter, Uddin e Amin (2019), existe um ponto ideal na curva característica de Potência *versus* Tensão (P-V), que corresponde à máxima potência fornecida pelos módulos FV, para uma dada irradiação e temperatura de operação das células FV. Esse Ponto de Máxima Potência (MPP, do inglês, *Maximum Power Point*) sofre variações não linear conforme há alterações nas condições ambientais. Dessa forma, para manter o sistema FV operando no MPP em qualquer condição ambiental, um sistema de controle é acoplado ao sistema FV e inserido entre os módulos FV e a carga.

Em geral, o sistema de controle é composto por um conversor de Corrente Contínua para Corrente Contínua (CC-CC) e um algoritmo de controle, juntos eles recebem o nome de técnica de Rastreamento do Ponto de Máxima Potência (MPPT, do inglês, *Maximum Power Point Tracking*). Lasheen e Abdel-Salam (2018) descrevem o MPPT como um controlador aplicado ao conversor CC-CC, cujo o objetivo é extrair, em tempo real, a máxima energia possível dos módulos FV e, consequentemente, elevar a eficiência elétrica do sistema FV.

Kumar, Gupta N. e Gupta V. (2017) complementam explicando que o MPPT é uma técnica estática de rastreamento elétrico que utiliza, principalmente, os parâmetros de tensão, corrente, temperatura e irradiação como alimentadores (ou entradas) de um algoritmo de controle e que são associados ao chaveamento do conversor CC-CC. Dessa forma, o MPPT não aumenta apenas a potência fornecida pelos módulos FV e a eficiência elétrica, mas também aumenta a vida útil do sistema fotovoltaico e reduz os *ripples* de corrente e tensão oriundos das variações nas condições ambientais (JOSHI; ARORA, 2017).

Assim sendo, muitas técnicas têm sido estudadas e desenvolvidas com a proposta de melhorar os algoritmos de MPPT para acompanhar com acurácia e rapidez o MPP, mesmo sob rápidas mudanças de condições ambientais. Esses estudos focam na otimização da técnica, no tipo de implementação escolhido (análogo ou digital), na quantidade de sensores utilizados, bem como na complexidade e aplicabilidade dos algoritmos escolhidos. Afinal, essas são características que podem afetar diretamente no tempo de resposta e eficiência do algoritmo de MPPT (HANZAEI; GORJI; EKTESABI, 2020).

Isso porque, há técnicas de MPPT que apresentam dificuldade em convergir com acurácia, demoram um longo tempo para convergir ou apresentam oscilações em torno do MPP, o que aumenta a perda de energia (FARAJDADIAN; HOSSEINI, 2019).

Dentro desse contexto, as técnicas de MPPT têm sido um dos componentes do sistema fotovoltaico que tem maior concentração de estudos nas últimas décadas. Atualmente, existem várias técnicas de MPPT por rastreamento elétrico que se diferenciam por suas peculiaridades, tais como: estratégia de controle, complexidade, número de sensores necessários, velocidade de convergência, precisão do rastreamento e custo (FARAJDADIAN; HOSSEINI, 2019).

Para auxiliar, Bollipo, Mikkili e Bonthagorla (2020), assim como Hanzaei, Gorji e Ektesabi (2020), dividiram as técnicas de MPPT em três categorias básicas, que foram denominadas da seguinte forma: técnicas clássicas, técnicas inteligentes e técnica otimizadas ou híbridas.

Em cada categoria, há subclassificações que já foram propostas, simuladas e/ou implementadas por algum pesquisador. A Figura 1.2 mostra as técnicas divididas em categorias e exemplifica-as com algumas de suas subclassificações encontradas na literatura.

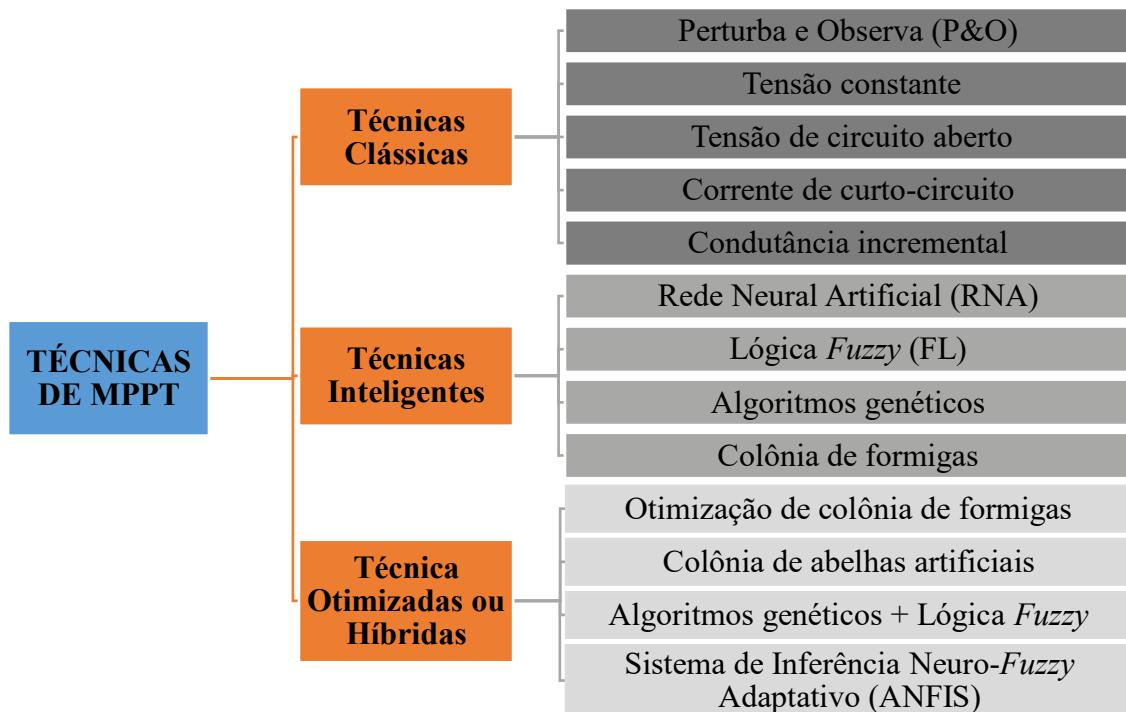


Figura 1.2. Classificações básicas de técnicas de MPPT
Fonte: Adaptado de (BOLLIPO; MIKKILI; BONTHAGARLA, 2020)

As técnicas clássicas da Figura 1.2 apresentam como principais características a baixa complexidade e maior facilidade de implementação. Por conta disso, até hoje são as mais usadas em sistemas FV. Os métodos corrente de curto-circuito e tensão de circuito aberto são técnicas

de MPPT indiretas que calculam a corrente e tensão, através da tensão de circuito aberto ou da corrente de curto-círcuito em um estado *offline*. Por outro lado, as técnicas Perturba e Observa (P&O) e condutância incremental são derivadas do método *hill climbing* e são consideradas técnicas de MPPT diretas ou *online* (HANZAEI; GORJI; EKTESABI, 2020).

Dentre todas as técnicas clássicas, a P&O é a técnica de MPPT mais utilizada no mercado, pois além de apresentar facilidade de implementação em circuitos analógicos ou digitais, é uma técnica que não exige conhecimento prévio das características dos módulos FV e tem baixo custo (LASHEEN; ABDEL-SALAM, 2018).

Como pontos negativos, a técnica P&O, assim como as demais técnicas clássicas, não proporcionam um rastreamento do MPP eficiente sob condições de irradiação não uniformes, e pode apresentar grandes oscilações em torno do MPP no estado estacionário dependendo da sua configuração, o que ocasiona perdas indesejadas de potência (GUPTA; CHAUHAN; PACHAURI, 2016). Para superar tais problemas, as técnicas inteligentes passaram a ser usadas.

Como o próprio nome sugere, as técnicas de MPPT inteligentes são aquelas que utilizam a Inteligência Artificial (IA), para auxiliar no rastreamento do MPP. As técnicas de IA são altamente bem sucedidas em sistemas não lineares, como é o caso do comportamento dos sistemas FV em relação às mudanças de condições ambientais, pois, depois de treinadas adequadamente, podem interpolar e extrapolar os dados aleatórios com alta precisão (IQBAL; ABU-RUB; AHMED, 2010).

Dentre as técnicas inteligentes listadas na Figura 1.2, a Rede Neural Artificial (RNA) e à baseada na Lógica *Fuzzy* (FL, do inglês, *Fuzzy Logic*) são as mais estudadas na literatura. Quando comparadas com as técnicas clássicas, elas mostraram uma melhor extração da máxima potência dos módulos FV, visto que foram capazes de trabalhar com os dados não lineares de modo rápido, flexível e confiável. Tais características são fundamentais para as situações de mudança rápida de condições ambientais, como quando ocorre o efeito borda de nuvem (YOUSSEF; EL-TELBANY; ZEKRY, 2017).

Todavia, uma desvantagem das técnicas inteligentes está na complexidade do algoritmo de controle, bem como na necessidade de um banco de dados extenso ou do conhecimento prévio do funcionamento do sistema. A técnica inteligente baseada na FL, por exemplo, apesar de não requerer conhecimento técnico, matemático e exato do modelo, necessita fortemente de experiências anteriores e informações sobre o sistema para garantir sua confiabilidade (FARAJDADIAN; HOSSEINI, 2019). Além disso, à medida que a complexidade dos sistemas é elevada, a criação das regras torna-se mais trabalhosa.

Por outro lado, a técnica inteligente RNA é baseada no processo de aprendizado de ambiente. Assim, carece de uma grande e seletiva quantidade de dados para treinar a rede e garantir que o sistema FV treinado rastreie o MPP com eficiência. Ademais, a RNA necessita de novos treinamentos sempre que os módulos FV apresentarem uma degradação significativa ou quando houver alteração no sistema, inclusive de localização geográfica (MELLIT; KALOGIROU, 2014).

A fim de minimizar as desvantagens encontradas nas técnicas inteligentes, os pesquisadores têm desenvolvido técnicas otimizadas, também denominadas por alguns autores como técnicas híbridas. As técnicas otimizadas visam combinar o bom desempenho que duas ou mais técnicas clássicas ou inteligentes têm em executar tarefas específicas.

Como exemplo, a técnica híbrida baseada no Sistema de Inferência Neuro-Fuzzy Adaptativo (ANFIS, do inglês, *Adaptive-Neuron Fuzzy Inference Systems*), citada na Figura 1.2, combina a lógica *fuzzy* com as RNAs. Por conta disso, autores como Uddin e Islam (2018) classificam o ANFIS como uma técnica híbrida e inteligente. Desta forma, o ANFIS também será abordado como um algoritmo inteligente na presente pesquisa.

Afinal, a técnica de MPPT baseada no ANFIS é a combinação de duas técnicas de IA. O algoritmo ANFIS tem a capacidade de combinar a aptidão em lidar com dados brutos de um sistema, através da computação paralela e das habilidades de aprendizagem das redes neurais, com o raciocínio em um nível mais alto, o conhecimento semelhante a humanos e as habilidades de explicação de um sistema *fuzzy*. Com isso, as redes neurais tornam-se mais transparentes e os sistemas baseados na lógica *fuzzy* tornam-se capaz de aprender, podendo se ajustar a novos ambientes (BELHACHAT; LARBES, 2017).

Além do algoritmo de controle, outro elemento que tem fundamental importância no rastreio do MPP é o conversor CC-CC, por isso sua escolha também deve ser cuidadosa. Como a região em que se encontra o sistema FV utilizado na presente pesquisa é caracterizada por apresentar um clima tropical seco e ensolarado, o conversor a ser usado precisa garantir que o MPP seja rastreado independentemente das condições ambientais. Em outras palavras, ele não pode ter uma região não operacional em sua curva característica de Corrente *versus* Tensão (I-V) para, só assim, garantir que a máxima energia seja transferida para a carga, seja qual for as condições ambientais que o sistema FV está submetido (ENRIQUE et al., 2007).

Dentre os conversores CC-CC mais comuns aplicados aos sistemas FV, tem-se o *buck*, o *boost* e o *buck-boost*. O conversor *buck* é utilizado quando necessita de uma tensão de saída menor que a de entrada. No entanto, esse conversor não pode rastrear o MPP sob altas

temperaturas e irradiações devido à curva da carga ficar em uma região não operacional da curva característica I-V, ou seja, em horários próximos ao meio-dia. O conversor *boost*, que trabalha para elevar a tensão de saída, não consegue rastrear o MPP sob baixas temperaturas e irradiações, isto é, no início da manhã ou em dias chuvosos (COELHO; DOS SANTOS; MARTINS, 2014).

Por outro lado, o conversor *buck-boost* pode aumentar ou diminuir a tensão de entrada para a tensão que se deseja obter em sua saída. Além disso, é um conversor capaz de rastrear o MPP independentemente das condições ambientais, visto que não possui região não operacional na sua curva característica I-V (RESHMA GOPI; SREEJITH, 2018). Dentro desse contexto, os conversores CC-CC *buck-boost* apresentam a peculiaridade esperada para o presente estudo.

Taghvaei *et al.* (2013) explicaram que há outros conversores que trabalham como o *buck-boost* na literatura e apresentam a mesma habilidade de rastreamento do MPP, como o Conversor com Indutância Simples no Primário (SEPIC, do inglês, *Single-Ended Primary-Inductor Converter*), o conversor *cuk* e o conversor *flyback*.

Entretanto, Reshma Gopi e Sreejith (2018) investigaram e concluíram que o conversor *flyback* é aplicado especialmente em sistemas FV de baixas potências e necessita de um transformador na sua arquitetura. Com relação aos conversores *cuk* e SEPIC, os autores explicaram que esses conversores possuem como aspecto negativo o maior número de componentes passivos em suas configurações, o que aumenta a complexidade do hardware.

Além disso, Taghvaei *et al.* (2013) afirmaram que, embora a corrente de entrada dos conversores *cuk* e SEPIC seja não pulsante e o conversor SEPIC tenha a vantagem de fornecer uma tensão não invertida à carga, o conversor *buck-boost* tem melhor desempenho, quando comparado com esses conversores *cuk* e SEPIC.

Diante do exposto, a presente pesquisa propõe-se a utilizar os algoritmos de controle inteligentes RNA, *fuzzy* e ANFIS, para auxiliar no rastreio do MPP de um sistema FV. Além disso, devido à menor complexidade e almejando garantir que a máxima energia seja transferida a carga, independente das condições ambientais em que serão testadas, o conversor *buck-boost* será utilizado para complementar o sistema de controle do sistema FV em estudo.

Definido os elementos dos sistemas de controle que serão desenvolvidos na presente pesquisa, a Seção 1.2 apresenta a revisão da literatura desenvolvida. Nessa Seção, é discorrido desde os primeiros projetos de MPPT aplicados à sistemas FV que utilizaram a RNA, o *fuzzy* ou o ANFIS como algoritmos de controle inteligentes, até os estudos mais recentes encontrados

no levantamento bibliográfico. Também foi dado uma maior ênfase aos trabalhos publicados que usaram o *buck-boost* como conversor CC-CC do seu sistema de controle.

1.2 Revisão da literatura

O termo Inteligência Artificial (IA) foi inserido no campo da pesquisa em 1956, por John McCarthy (MELLIT; KALOGIROU, 2014). Entretanto, foi apenas em 1994, quase quarenta anos depois, que ocorreu a publicação do primeiro projeto de técnica de MPPT usando um dos controladores inteligentes propostos na presente pesquisa.

Esse primeiro trabalho foi desenvolvido por Senju e Uezato (1994) e tinha como objetivo controlar o rastreio do MPP de um arranjo FV utilizando um controlador *fuzzy*. As entradas desse controlador eram dois valores relacionados ao erro. A primeira entrada era o erro (E) devido à mudança da potência e, a segunda, sua respectiva derivada (dE). O Ciclo de Trabalho (D) do conversor CC-CC *boost* do sistema FV foi usado como saída do controlador. Como resultado, o controlador *fuzzy* mostrou um desempenho superior ao do controlador baseado no método *hill climbing*.

No ano seguinte, ou seja, em 1995, o primeiro trabalho que utilizou uma rede neural como algoritmo de controle de rastreamento do MPP de um sistema FV também foi publicado. No trabalho de Hiyama, *et al.* (1995), a rede neural foi utilizada para identificar a tensão de operação ideal do sistema fotovoltaico a partir da tensão de circuito aberto de uma célula de monitoramento. Um controlador Proporcional-Integral (PI) foi responsável por reduzir o erro entre a tensão ideal informada pelo controlador RNA e a tensão lida na saída do arranjo FV. Ao término do estudo, os autores afirmaram que os resultados foram satisfatórios, visto que os valores atingidos foram próximos aos MPP, quase sem atrasos e sem sobressinais ou subsinais.

Sobre o primeiro projeto baseado no ANFIS para aplicações fotovoltaicas, ele foi publicado em 2003, uma década após Jang (1993) propor a união das técnicas inteligentes RNA e *fuzzy* adaptado por Takagi-Sugeno (T-S).

Os pesquisadores Khaehintung; Sirisuk e Kurutach. (2003) propuseram o desenvolvimento de um MPPT baseado no ANFIS composto por 2 entradas (cada entrada com 3 funções de pertinência), 9 regras *fuzzy* e 1 saída. As entradas eram erros associados a potência e a tensão fotovoltaica, e a saída do ANFIS era a taxa referente à mudança no ciclo de trabalho do dispositivo de comutação do conversor CC-CC *boost* do sistema FV. Os autores simularam,

testaram experimentalmente e compararam o sistema proposto com o P&O. Eles concluíram que o MPPT baseado no ANFIS superou o P&O em velocidade de convergência.

Quatro anos depois, Aldobhani (2008) e Aldobhani e John (2007, 2008) apresentaram um novo MPPT baseado no ANFIS, esse sendo o primeiro aplicado a um conversor CC-CC *buck-boost*. O ANFIS tinha a corrente de curto-círcuito (I_{CC}) e a tensão de circuito aberto (V_{OC}) do arranjo FV como entrada, e a tensão do ponto de máxima potência (V_{MPP}) do arranjo FV como saída. O treinamento foi realizado com 39 conjuntos de dados ambientais coletados anteriormente em campo. Além disso, durante o treinamento diferentes funções de pertinência e número de regras *fuzzy* foram testadas. Como resultado, os autores estimaram a V_{MPP} com erros abaixo de 2% e perceberam uma alta eficiência e baixa flutuação na saída, sobretudo quando o sistema foi treinado com 2 funções de pertinência por entrada e 4 regras *fuzzy*.

No ano seguinte, ou seja, em 2009, também foi projetado um sistema FV em que o MPPT baseado no ANFIS era aplicado a um conversor CC-CC *buck-boost*. Nesse estudo, os pesquisadores Otiene, Nyakoe e Wekesa (2009) admitiram as condições ambientais de irradiação (G) e temperatura ambiente (T_{AMB}) como entradas do ANFIS, e uma estimativa da V_{MPP} como saída. Para a entrada G foi atribuída 7 funções de pertinência gaussianas, ao passo que para a entrada T_{AMB} foram utilizadas apenas 3. Com relação a saída, a V_{MPP} estimada auxiliava no controle do ciclo de trabalho do comutador do conversor CC-CC. Após as simulações, os autores observaram qualitativamente que mais energia foi extraída do sistema FV, quando utilizado o MPPT baseado no ANFIS.

Posteriormente, Panda, Pathak e Srivastava (2011) compararam os algoritmos de controle P&O e *fuzzy* quando aplicados ao MPPT de um sistema FV. Ambos os algoritmos foram usados para controlar o chaveamento de um conversor *buck-boost* (NABIPOUR et al., 2017). O controlador *fuzzy* tinha como entrada dois valores relacionados ao erro (E), devido à mudança da potência, e sua respectiva derivada (dE), e o D do conversor CC-CC como saída. Os pesquisadores analisaram o tempo de resposta de cada algoritmo de controle e concluíram que o controlador P&O levou 167,6 ms para rastrear o MPP, enquanto o controlador *fuzzy* levou 12,2 ms. Ou seja, o controlador *fuzzy* reduziu 88,18% do maior tempo de rastreamento de potência que foi medido.

Em 2012, Chekired, Larbes e Mellit (2012) realizaram um estudo comparativo entre os algoritmos de controle ANFIS e *fuzzy*, entretanto, utilizando o conversor CC-CC *boost* como componente do sistema de controle. A arquitetura ANFIS foi modelada com 2 entradas (E e dE) e uma saída (D). Para cada uma das entradas, 5 funções de pertinência foram atribuídas,

totalizando 25 regras *fuzzy*. Após o treinamento e implementação, os autores constataram que o MPPT baseado no ANFIS teve melhor performance que o MPPT baseado na FL, especialmente sob rápidas mudanças ambientais. Em contrapartida, os autores afirmaram que a implementação do ANFIS foi mais complexa. Outro trabalho similar ao de Chekired, Larbes e Mellit (2012) só foi proposto por Haji e Genc (2020), e o ANFIS também mostrou ser superior.

Mais adiante, Shiau *et al.* (2014) estudaram diferentes topologias de conversor CC-CC *buck-boost* aplicadas a um sistema fotovoltaico, e usou o *fuzzy* como algoritmo de controle do MPPT. Todas as topologias foram analisadas com o auxílio do software Matlab/Simulink®. Assim como no trabalho de Panda, Pathak e Srivastava (2011), as entradas utilizadas foram 2 variáveis relacionados ao erro (E e dE), e a saída foi o ciclo de trabalho D do conversor CC-CC. Os autores não examinaram os parâmetros da resposta dinâmica, mas garantiram que todas as topologias de conversor *buck-boost* testadas alcançaram quase perfeitamente o MPP.

Também em 2014, Chekired *et al.* (2014) realizaram um estudo comparativo entre MPPT controlados pelos algoritmos inteligentes RNA, FL, ANFIS e algoritmos genéticos com FL. Nessa análise, o sistema FV utilizou o *buck* como conversor CC-CC do sistema de controle. Além disso, todos os algoritmos inteligentes projetados tinham 2 entradas (E e dE) e o ciclo de trabalho D do conversor *buck* como única saída. Ao término do experimento, os autores constataram que o MPPT baseando no ANFIS usou menos espaço de memória do Arranjo de Portas Programáveis em Campo (FPGA, do inglês, *Field Programmable Gate Array*). Entretanto, o ANFIS não conseguiu superar a técnica otimizada baseada nos algoritmos genéticos com FL, mesmo com seus bons resultados de velocidade de convergência ($\leq 15,88$ segundos) e eficiência em rastrear o MPP ($\geq 96,25\%$).

Paralelamente, Karanjkar *et al.* (2014) também usaram um sistema FV com conversor CC-CC *buck* e compararam o desempenho do MPPT quando usou os algoritmos de controle P&O, condutância incremental, FL, RNA e ANFIS em tempo real. No estudo, o ANFIS mostrou ser mais eficiente para rastrear o MPP (entre 87,15% e 93,31%) e apresentou menores erros em estado estacionário (3,55%). Em contrapartida, teve o maior sobressinal (6,56%) e tempo de acomodação (5,35 segundos) entre os algoritmos. O ANFIS e a RNA foram treinados com 7609 conjunto de dados e suas arquiteturas eram compostas por 2 entradas (tensão e corrente do arranjo FV), cada uma com 5 funções de pertinência, 25 regras *fuzzy* e 1 saída (D). Por outro lado, o controlador *fuzzy* tinha 2 entradas (E e dE) e uma única saída (D).

Em 2015, Arora e Gaur (2015) projetaram um Sistema Fotovoltaico Conectado à Rede (SFCR) com MPPT baseado no ANFIS e o compararam com um MPPT baseado na RNA. Além

do arranjo FV e do algoritmo de MPPT, o SFCR era composto por um conversor CC-CC *buck-boost*, um inversor, um transformador e acoplado à rede elétrica. O ANFIS usado na simulação foi treinado com um conjunto de 300.001 dados, os quais foram coletados de um MPPT baseado na condutância incremental, que foi simulado anteriormente. A arquitetura do ANFIS de Arora e Gaur (2015) possuía 2 entradas (E e dE), 9 funções de pertinência vinculadas a cada entrada, 81 regras fuzzy e o D como única saída. A RNA tinha a mesma saída do ANFIS, porém suas 2 entradas foram a tensão (V_{FV}) e corrente (I_{FV}) de saída do arranjo FV. Ao término da simulação, o SFCR com MPTT baseado no ANFIS apresentou uma velocidade de rastreamento de 0,115 segundos e uma eficiência em rastrear o MPP de 100%. Além disso, quando comparado com a RNA, o ANFIS precisou de menos tempo para rastrear o MPP, apresentou menor sobressinal e menores oscilações em torno do MPP.

Simultaneamente, Martin e Vazquez (2015) realizaram uma análise comparativa entre os algoritmos P&O, *fuzzy* e ANFIS, quando usados para extrair a potência máxima de um sistema FV sob condições ambientais variáveis. O sistema FV tinha um conversor *buck-boost* conectado a uma carga. Os autores realizaram análises simuladas e experimentais e obtiveram eficiência de 96% para o algoritmo P&O e 98,2% para os algoritmos de controle *fuzzy* e ANFIS.

No ano subsequente, em 2016, Makhlofi, Abdessemed e Khireddine (2016) desenvolveram um controlador RNA para compor, junto com o conversor CC-CC *buck-boost*, o MPPT de um sistema FV sob condições ambientais com variações rápidas. A estratégia proposta pelos autores consistia no uso dos algoritmos P&O (para mudanças lentas de irradiância) e RNA (para mudanças rápidas de irradiância), bem como no aprendizado *online* da RNA, que tinha a potência de saída do arranjo FV (P_{FV}) como única entrada, duas camadas ocultas e uma saída com o valor ideal do ciclo de trabalho D do conversor *buck-boost*. Observando os gráficos obtidos com a simulação, os autores concluíram que o algoritmo RNA melhorou as respostas do sistema fotovoltaico, pois reduziu o tempo para alcançar o MPP e eliminou as flutuações em torno deste ponto.

Também em 2016, Gupta, Chauhan e Pachauri (2016) observaram o grande números de trabalhos envolvendo técnicas de MPPT publicados e realizaram um extenso levantamento bibliográfico sobre essas técnicas de MPPT. Eles dividiram em classificações parecidas com as desenvolvidas por Bollipo, Mikkili e Bonthagorla (2020), exceto pelo ANFIS ter sido classificado como uma técnica baseada em IA, justificada pelo fato de ser a combinação de duas técnicas de inteligência artificial. Outros parecidos levantamentos foram desenvolvidos nos trabalhos de Hanzaei, Gorji e Ektesabi (2020), Yap, Sarimuthu e Lim (2020) e Villegas-

Mier, *et al* (2021). Gupta, Chauhan e Pachauri (2016) também projetaram e implementaram um sistema FV usando cada algoritmo de controle discutida no trabalho. Os componentes básicos utilizados no sistema FV foram o arranjo FV, o conversor CC-CC *buck-boost*, o algoritmo MPPT e a carga, conforme mostra o esquema da Figura 1.3.

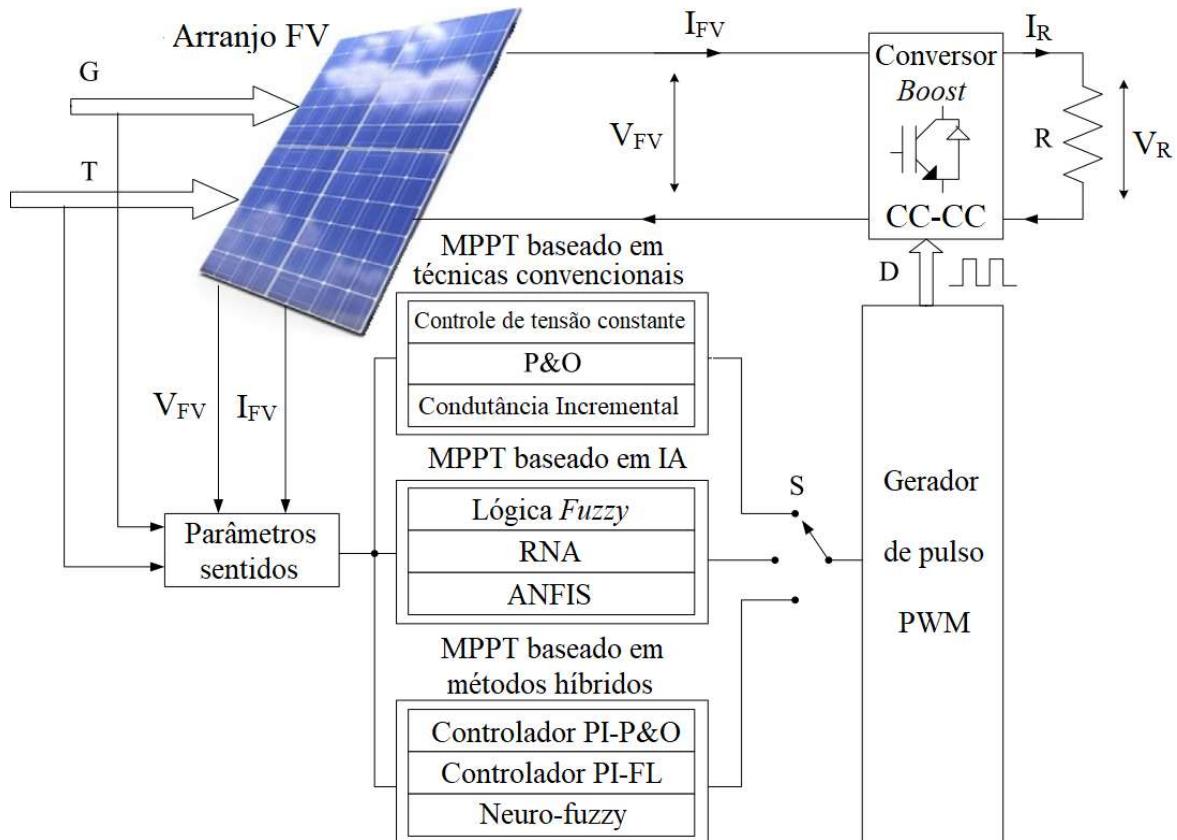


Figura 1.3. Diagrama esquemático de várias técnicas de MPPT aplicado a sistemas FV

Fonte: Adaptado de (GUPTA; CHAUHAN; PACHAURI, 2016)

No final do trabalho desenvolvido por Gupta, Chauhan e Pachauri (2016) e ilustrado na Figura 1.3, os autores observaram uma eficiência de 99,49% no MPPT quando controlado pelo ANFIS. Esse foi o melhor desempenho entre todas as técnicas desenvolvidas, bem como a melhor resposta dinâmica. Além disso, os autores concluíram que a técnica ANFIS tem a vantagem de poder ser utilizada tanto em sistemas isolados, como em SFCR, porém tem a desvantagem do alto custo e alta complexidade para implementação.

Segundo para 2017, Belhachat e Larbes (2017) estudaram o uso do MPPT baseado no ANFIS para detecção do MPP global sob condições de sombreamento parcial. Para isso, os pesquisadores utilizaram diferentes configurações de arranjo FV acoplado ao conversor CC-CC *buck-boost* e a uma carga. O ANFIS utilizado como algoritmo MPPT recebia a tensão (V_{FV}) e corrente (I_{FV}) de saída do arranjo FV como entrada e fornecia a potência de referência específica para cada configuração de arranjo FV. Essa potência era comparada com a real

potência de saída do arranjo FV (P_{FV}), e o erro entre elas era aplicado à um controlador PI, que produzia um sinal responsável pelo controle do ciclo de trabalho do conversor *buck-boost*. No final, os pesquisadores observaram um rastreamento rápido do MPP real e oscilações desprezíveis. Além disso, os resultados da simulação demonstraram que o algoritmo proposto rastreou com eficiência 99,92%, mesmo em condições de sombreamento parcial. Ademais, o ANFIS desenvolvido provou robustez contra mudanças repentinas no nível de irradiação durante o sombreamento parcial.

Concomitantemente, Desikan e Kalaichelvi (2017) estudaram diferentes arquiteturas de ANFIS como técnica de MPPT. Os autores variaram o número de entradas (2 ou 3 níveis de irradiação), bem como o número de funções de pertinência (3, 4 ou 5) associadas a cada entrada. O objetivo era prever a V_{MPP} na saída do ANFIS. Ao término do trabalho, os melhores resultados que os autores obtiveram foi uma eficiência no rastreamento de 99,106% (quando 2 funções de pertinência por entradas foram consideradas) e outra de 99,319% (quando 4 funções de pertinência por entrada foram utilizadas).

Posteriormente, em 2018, a simulação de um sistema fotovoltaico autônomo foi desenvolvida por Khanam e Foo (2018). Eles realizaram uma comparação entre o MPPT com os algoritmos P&O e RNA. Os resultados com o algoritmo de controle P&O mostraram um tempo de acomodação entre 62,78 e 72,13 ms. Os autores compararam os resultados do algoritmo de controle RNA com os do algoritmo P&O apenas qualitativamente. Eles afirmaram que a RNA fornece resultados mais precisos e rápidos do que o P&O, quando usada como um algoritmo de controle do MPPT (YAP; SARIMUTHU; LIM, 2020).

Logo em seguida, em 2019, um estudo comparativo entre os conversores *buck*, *boost* e *buck-boost* aplicados a um sistema fotovoltaico conectado a uma carga foi executado por Kumar, Rathor e Bahrani (2019). Os pesquisadores também compararam o *fuzzy* e o P&O como algoritmos de controle do MPPT. Eles concluíram que o conversor *buck-boost* ofereceu um melhor desempenho. Os algoritmos P&O e *fuzzy* alcançaram eficiência de 86% e 97%.

Paralelamente, Andrew-Cotter, Uddin e Amin (2019) construíram e analisaram um SFCR com um MPPT baseado no ANFIS. O ANFIS foi treinado para controlar o ciclo de trabalho do conversor CC-CC *buck-boost* a partir das entradas V_{FV} e I_{FV} , cada uma com 2 funções de pertinência do tipo gaussiana. O conjunto de dados usado no treinamento desse ANFIS foi extraído de um MPPT baseado no P&O e otimizado por uma técnica de enxame de partículas. Após implementação, os autores observaram que o MPPT baseado no ANFIS foi capaz de extrair efetivamente (97% de eficiência) e rapidamente a potência máxima do arranjo

FV sob condições de irradiação variável. Além disso, ao ser comparado com um MPPT baseado no P&O, o ANFIS ainda mostrou menores oscilações em torno do MPP.

Ainda mais recente, no ano de 2020, Islam *et al.* (2020) realizou uma comparação entre o desempenho de um conversor *boost* e um conversor *buck-boost* usado no rastreamento do MPP de um sistema FV com uma RNA como algoritmo de controle. De acordo com os autores, a RNA foi escolhida devido a rapidez e eficiência desse controlador, quando usa as condições ambientais irradiação (G) e temperatura ambiente (T_{AMB}) como variáveis de entrada e a tensão do MPP como saída. Ademais, os autores ressaltaram que não utilizaram condições atmosféricas variáveis para minimizar a complexidade do sistema. Ao término do estudo, Islam *et al.* (2020) afirmaram ter obtido desempenhos satisfatórios com ambos os conversores, mas o conversor *buck-boost* apresentou melhores resultados de produção.

Por fim, Rajavel e Rathina (2021) compararam separadamente os conversores *buck*, *boost* e *buck-boost* conectados a um sistema PV com MPPT baseado em FL. O erro e sua derivada foram as 2 variáveis de entrada, cada uma com 5 funções de pertinência. O ciclo de trabalho do conversor foi a variável de saída. Os autores analisaram os gráficos resultantes qualitativamente e concluíram que o conversor *buck-boost* provou ter melhor eficiência e um bom desempenho em comparação com os conversores *boost* e *buck*.

Finalizado o extenso levantamento de trabalhos que utilizaram a RNA, o *fuzzy* e o ANFIS como controladores do MPPT aplicados à sistemas FV, percebe-se o potencial dos algoritmos inteligentes. Sobretudo, devido à sua alta velocidade e precisão em rastrear o MPP de um arranjo FV, mesmo sob mudanças bruscas das condições ambientais, além da ausência de oscilações que garantem a estabilidade do sistema FV.

Assim sendo, a Seção 1.3 justifica o fator norteador em realizar o presente estudo e, posteriormente, a Seção 1.4 destaca as principais contribuições da pesquisa para a ciência. Em seguida, a Seção 1.5 descreve os objetivos para que a pesquisa seja desenvolvida. Finalmente, a Seção 1.6 apresenta a estruturação utilizada no trabalho.

1.3 Justificativa

A inserção de sistemas fotovoltaicos à matriz elétrica mundial tem apresentado um crescimento exponencial nos últimos anos, conforme apresentado na Seção 1.1. Entretanto, a natureza não linear dos arranjos FV em relação às condições ambientais e às alterações ambientais imprevisíveis são fatores que prejudicam na extração da máxima potência fornecida

pelos módulos FV. Consequentemente, há uma redução na eficiência do sistema FV em converter energia solar em energia elétrica.

Essa redução na eficiência dos sistemas FV se tornam ainda mais significativas à medida que a capacidade de geração de energia elétrica do sistema FV se eleva, como nas usinas FV¹. Por conta disso, técnicas de MPPT, minimamente mais eficientes que outras, podem significar recuperações expressivas de potência gerada. Por consequência, muitas técnicas de rastreamento de MPP têm sido estudadas até hoje sem atribuir como desvantagem o custo adicional de implementação e/ou a complexidade algorítmica da técnica desenvolvida.

Dessa forma, o presente trabalho se caracteriza por aplicar algoritmos inteligentes capazes de rastrear o ponto de máxima potência de sistemas fotovoltaicos sob condições variadas de irradiação e temperatura ambiente. Os algoritmos escolhidos foram: a RNA; o *fuzzy* e; o ANFIS, que é uma combinação desses dois primeiros algoritmos inteligentes.

Contudo, foi visto no levantamento bibliográfico que os algoritmos inteligentes apresentam variações em sua estrutura à medida que é alterada o número e tipo de entradas (ou de funções de pertinência associada a cada entrada), a saída que se pretende estimar ou o conversor CC-CC a ser controlado pelo algoritmo. Tais peculiaridades influenciam na complexidade de implementação, robustez do sistema, custo, velocidade de rastreio e eficiência em rastrear o MPP sob rápidas alterações ambientais (LASHEEN; ABDEL-SALAM, 2018).

Como discutido na Seção 1.1, os conversores CC-CC mais comuns usados em sistemas FV e citados nos trabalhos levantados da Seção 1.2, foram o *buck*, o *boost* e o *buck-boost*. Contudo, como o conversor CC-CC a ser utilizado no presente estudo precisa garantir que o MPP seja rastreado independentemente das condições ambientais, o conversor *buck-boost* foi escolhido para ser usado na presente pesquisa, pois apresentam as peculiaridades almejadas.

Doravante, observando os algoritmos inteligentes pelo tipo de saída que ele estima, os trabalhos levantados utilizaram como saída a V_{MPP} , a P_{MPP} ou o ciclo de trabalho D do comutador do conversor CC-CC do sistema FV. Porém, os trabalhos que utilizaram a estimativa da V_{MPP} ou P_{MPP} como saída do ANFIS precisaram da adição de um controlador PI para gerar o sinal que controla o ciclo de trabalho do conversor até que o MPP seja alcançado.

Lasheen e Abdel-Salam (2018) explicaram que o uso do controlador PI tornou-se popular devido à simplicidade de operação, facilidade de projeto e baixo custo, porém

¹ De acordo com Villalva e Gazoli (2012), a Agência Nacional de Energia Elétrica classifica os SFCR, conforme o seu tamanho, em três categorias, que são: microgeração (potência instalada até 100kW), minigeração (potência instalada entre 100kW e 1MW e usinas de eletricidade (potência acima de 1MW).

ressaltaram que, além de ser um elemento a mais no sistema FV, necessita de um método de estimativa acurado, capaz de sintonizar os ganhos (proporcional e integral) desse controlador. Os autores acrescentaram que o controlador PI pode não ter um bom funcionamento, pois, em sistemas FV, o MPPT trabalha com controle de natureza não linear e com condições ambientais imprevisíveis. Assim, usar o D da chave comutadora do conversor CC-CC como saída do algoritmo é mais atrativo e menos oneroso, por isso, será utilizado no presente estudo.

No que concerne o tipo e o número de entrada utilizadas nos algoritmos inteligentes, essas são características que influenciam diretamente na complexidade, robustez e custo do sistema. Afinal, à medida que se aumenta o número de entradas dos algoritmos inteligentes, maior será a estrutura da rede e mais sensores serão necessários. Além disso, caso o sistema FV não possua os sensores adequados para extrair a entrada desejada, eles precisarão ser adquiridos e seu valor deve ser adicionado ao custo total do sistema FV, que já é elevado.

Dados ambientais como G e T_{AMB} estão entre os parâmetros de entrada mais utilizados pelos algoritmos inteligentes, devido à grande influência que esses fatores têm sobre a energia entregue pelos módulos FV. Contudo, Dixit *et al.* (2019) frisam que, para o uso dessas variáveis, é de suma importância haver uma estação meteorológica próxima ao sistema FV, porém nem sempre existe essa estação. Outra solução seria adquirir os instrumentos de medição. Para extraír dados da irradiação, por exemplo, instrumentos como o piranômetro ou pireliômetro são fundamentais, mas devido ao alto custo e complexidade de utilização, nem sempre eles são adquiridos junto ao sistema FV.

Outro parâmetro de entrada muito utilizado nos estudos é a T_{CELL} , pois ela é uma das variáveis usadas como referência quando as curvas I-V dos módulos FV são traçadas. Contudo, conforme explica Masters (2004), um dos problemas de utilizar esse parâmetro de entrada está na dificuldade de acesso para realizar tal medição, pois não há sensor de temperatura na junção p-n das células FV e esse é o ponto adequado de medição.

Ademais, foi encontrado na literatura, algoritmos inteligentes que utilizavam entradas baseadas na razão entre a variação da potência e tensão instantânea produzidas pelo arranjo FV, sendo mais frequente no algoritmo *fuzzy*. Nessa situação, um erro é calculado e designado como uma das entradas. A outra entrada normalmente utilizada é a derivada desse erro. É válido ressaltar que ambas as entradas necessitam de um algoritmo a mais para o cálculo do erro.

Dessa forma, embora tenha a vantagem de utilizar os sensores de corrente e tensão já existentes no sistema FV, um problema em escolher as entradas ligadas ao erro está relacionada à necessidade de um esforço computacional a mais para o cálculo desse erro. Para minimizar

essa desvantagem, alguns autores optam por mesclar o uso direto de parâmetros elétricos, como V_{FV} , I_{FV} , ou até mesmo a potência instantânea atual e anterior do arranjo FV. Com isso, são eliminados o algoritmo e o esforço computacional a mais necessário para o cálculo do erro.

Por fim, a outra característica presente nos algoritmos inteligentes que se diferenciam entre os trabalhos levantados sobre rastreamento do MPP, é o número de funções de pertinência associadas a cada entrada do *fuzzy* e do ANFIS, bem como as funções de ativação, o número de camadas e neurônios que compõem a RNA. De acordo com Simões e Shaw (2007), a quantidade de funções e o seu tipo, assim como são escolhidos com base na experiência e na natureza do processo. Logo, por não ser uma escolha trivial, os autores indicam entre 2 e 7 funções de pertinência, mas ressaltam que quanto maior o número de funções, maior o esforço computacional, embora ocorra uma elevação na precisão do resultado. Com relação ao número de camadas e neurônios que estruturam uma RNA, elas são definidas durante o treinamento utilizando os dados amostrais de entrada e saída.

1.4 Contribuições

Diante do exposto na Seção 1.3, o presente trabalho propõe-se a treinar um sistema FV com MPPT controlado pelos algoritmos inteligentes RNA, *Fuzzy* e ANFIS. A saída escolhida para os algoritmos de controle é o ciclo de trabalho D da chave comutadora de um conversor CC-CC *buck-boost*. Como entrada, diferentemente do que comumente foi encontrado na literatura, serão analisadas três possibilidades de uso de parâmetros elétricos e/ou ambientais, mantendo apenas um total de duas variáveis de entrada.

Adicionalmente, o número e tipo de funções de pertinência de cada entrada, tal como o número de camadas e neurônios, serão ajustados conforme análise prévia do funcionamento do sistema FV utilizado. É importante ressaltar que os algoritmos inteligentes usados para auxiliar no rastreio do MPP precisa ter entradas que sejam capazes de controlar com rapidez e eficácia o ciclo de trabalho do conversor CC-CC que está conectado a ele. Por conseguinte, fazendo com que o sistema FV forneça a máxima potência à carga, independente das variações nas condições ambientais.

Posto isto, o desenvolvimento de algoritmos de controle inteligentes com diferentes variáveis de entrada que controlem o ciclo de trabalho de um conversor CC-CC *buck-boost* aplicados ao MPPT de um sistema fotovoltaico, bem como um estudo comparativo entre esses

algoritmos representa um avanço nas pesquisas a respeito de técnicas inteligentes de MPPT aplicadas à sistemas fotovoltaicos.

1.5 Objetivos

O presente estudo tem como objetivo geral desenvolver algoritmos de controle inteligentes para auxiliar no rastreamento do MPP e serem aplicados à sistemas FV, que tem o *buck-boost* como conversor CC-CC, sobretudo para minimizar os efeitos negativos que as alterações ambientais de irradiância e temperatura ambiente causam ao sistema FV durante a geração de energia elétrica.

Para que o objetivo geral seja atendido, pontua-se os objetivos específicos da pesquisa:

- Definir e modelar as células e o arranjo FV utilizando o modelo de diodo único;
- Desenvolver um algoritmo para extração dos parâmetros do módulo FV que não estão disponíveis na folha de dados do fabricante;
- Através do modelo simulado, levantar um banco de dados das máximas potências fornecidas pelo arranjo FV à medida que é alterada a irradiância e temperatura ambiente;
- Dimensionar e modelar dois cenários de sistemas fotovoltaicos compostos pelo arranjo FV conversor CC-CC *buck-boost* e pela carga, mas sem técnica de MPPT;
- Modelar e simular sistemas FV com adição da técnica de MPPT baseada nos algoritmos inteligentes RNA, *fuzzy* e ANFIS, e considerando os parâmetros ambientais de irradiância e temperatura ambiente como variáveis de entrada;
- Projetar e simular os algoritmos inteligentes RNA, *fuzzy* e ANFIS para serem aplicados no MPPT de um sistema FV, considerando o parâmetro ambiental irradiância e o parâmetro elétrico potência instantânea do arranjo FV como variáveis de entrada dos algoritmos inteligentes;
- Desenvolver a modelagem e simulação de MPPTs controlados pelos algoritmos inteligentes RNA, *fuzzy* e ANFIS, aplicados à um sistema FV e que utilizam os parâmetros elétricos potência instantânea e potência do instante anterior do arranjo FV como variáveis de entrada do algoritmo;
- Realizar uma análise comparativa entre as respostas do algoritmo clássico P&O e dos algoritmos inteligentes simulados, quando utilizaram os parâmetros ambientais de irradiância e temperatura ambiente como variáveis de entrada;
- Comparar as respostas do algoritmo clássico P&O e dos algoritmos inteligentes

simulados, quando fizeram uso do parâmetro ambiental irradiação e o parâmetro elétrico potência instantânea do arranjo FV como variáveis de entrada;

- Analisar as respostas oriundas dos algoritmos inteligentes simulados, quando usaram os parâmetros elétricos potência instantânea e potência do instante anterior do arranjo FV como variáveis de entrada, e confrontá-las com as respostas do algoritmo clássico P&O;
- Avaliar as respostas obtidas com os diferentes algoritmos inteligentes simulados e compará-los com outros trabalhos publicados.

1.6 Estrutura do Trabalho

Neste tópico é apresentado como encontra-se organizado os capítulos desse trabalho, assim como uma breve descrição dos principais assuntos abordados em cada um deles.

- No **Capítulo 2** é realizada a fundamentação teórica composta pelos conceitos básicos que servem como base para o desenvolvimento da pesquisa;
- No **Capítulo 3** a metodologia adotada para realização deste trabalho é descrita. Nela, serão detalhados os procedimentos e técnicas utilizados em cada etapa;
- No **Capítulo 4** são apresentados os resultados obtidos após o desenvolvimento dos projetos detalhados no Capítulo 3, bem como algumas discussões cabíveis ao estudo;
- No **Capítulo 5** é apresentado as conclusões obtidas com o estudo e algumas sugestões de trabalhos futuros que podem ser desenvolvidos;

2. Fundamentação Teórica

A fundamentação teórica apresenta os conceitos básicos que auxiliam no direcionamento da pesquisa. Inicialmente, uma contextualização sobre a energia solar fotovoltaica é realizada. Posteriormente, é explicado a modelagem de células fotovoltaicas utilizando o modelo de diodo único. Depois, as curvas características e os parâmetros elétricos dos geradores FV são mostrados, seguido da influência que as condições atmosféricas e as cargas podem gerar sobre essas curvas características.

Em seguida, o presente capítulo apresenta os elementos básicos que compõem um sistema fotovoltaico, com destaque nos conversores CC-CC e nas técnicas de rastreamento do ponto de máxima potência. Por fim, como o objetivo da presente pesquisa é utilizar controladores inteligentes, é explicado a aplicação da rede neural artificial, lógica *fuzzy* e do ANFIS como algoritmo inteligente em sistemas de controle, sobretudo aplicado à sistemas fotovoltaicos.

2.1 A energia solar fotovoltaica

O efeito fotovoltaico, descoberto por Alexandre Edmond Becquerel em 1839, é o princípio básico da geração da energia solar fotovoltaica. Becquerel percebeu que ao iluminar uma solução ácida, uma diferença de potencial surgia entre os eletrodos imersos nessa solução (XIAO, 2017).

Contudo, em virtude da produção de eletricidade gerada pelas células eletroquímicas de Becquerel ser baixa, foi apenas na década de 1950 que os estudos voltados para a energia solar fotovoltaica cresceram. Pois, conforme explicado por Xiao (2017), nessa época foram descobertos alguns materiais semicondutores que produziam tensões e correntes mais expressivas a partir do efeito fotovoltaico, como o silício.

Até os dias atuais, o silício tem sido a matéria prima mais comum na fabricação dos componentes que produzem eletricidade a partir do efeito fotovoltaico. Isso ocorre devido as suas características de absorção terem uma boa combinação com o espectro solar e também pela tecnologia de fabricação do silício ser bem desenvolvida (LUQUE; HEGEDUS, 2003).

O elemento fundamental na conversão direta da energia da irradiância solar em energia elétrica é a célula fotovoltaica. Sua estrutura interna é formada pela união de um semicondutor com duas camadas dopadas, uma do tipo N e outra do tipo P, que possuem propriedades

elétricas diferentes. A Figura 2.1 mostra uma célula FV à base de silício cristalino, composta pelas duas camadas de material semicondutor (denominados de junção p-n), uma grade de contatos metálicos frontais, uma revestimento antirreflexo e uma base metálica.

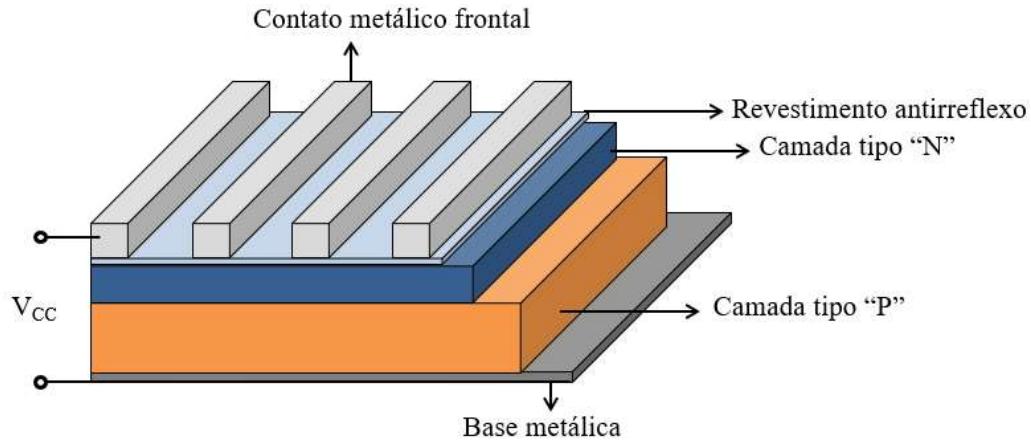


Figura 2.1. Estrutura de uma célula fotovoltaica a base de silício cristalino

Fonte: Autoria própria

Quando a célula FV da Figura 2.1 está exposta a luz solar, elétrons do semicondutor se desprendem e circulam em torno de um circuito fechado para chegarem até as lacunas da outra camada do semicondutor, ou seja, há geração de corrente elétrica e diferença de potencial. Villalva, Gazoli e Ruppert Filho (2009) reforçam que quanto maior a incidência solar e a capacidade de absorção do semicondutor, maior será o fluxo de elétrons. Porém, quando não há irradiação solar, a célula FV não produz eletricidade.

Um diodo semicondutor também possui uma junção p-n, além disso tem como função separar seus transportadores e conduzi-los em forma de corrente elétrica em uma direção específica. Por conta disso, Luque e Hegedus (2003) explicam que uma célula FV é um diodo semicondutor que foi projetado para absorver e converter a energia do sol em energia elétrica.

Sabendo disso, o circuito equivalente de diodo único é utilizado para modelar e representar as características elétricas das células FV à base de silício cristalino. Essa modelagem é fundamental para analisar a resposta de uma célula FV às variações de condições ambientais e mudanças na carga conectadas a elas, e por isso é abordada na Seção 2.2.

2.2 Modelagens de células fotovoltaicas

O modelo ideal de uma célula fotovoltaica cristalina é composto por uma fonte de corrente em paralelo com um diodo retificador (representando a participação da junção p-n sem

a presença de luz solar). Porém, esse modelo não leva em consideração as imprecisões e imperfeições (ALONSO, 2017).

Por isso, na prática, o circuito equivalente que representa uma célula FV tem uma resistência em série e outra em paralelo para representar as possíveis perdas (XIAO, 2017).

A resistência série (R_S) representa as perdas de condução nos contatos metálicos, como corrosão e queimaduras, e àquelas devido às características intrínsecas do material semicondutor, como as regiões dopantes. A resistência paralela (R_P), também conhecida como resistência *shunt*, corresponde às perdas devido às correntes parasitas por conta de impurezas e/ou defeitos existentes na estrutura da célula, como pontos de curto-círcuito na junção p-n (PINHO; GALDINO, 2014).

A Figura 2.2 mostra o circuito equivalente do modelo de diodo único.

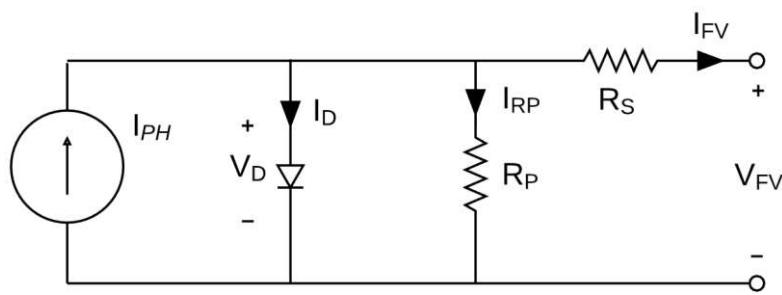


Figura 2.2. Circuito equivalente do modelo de diodo único
Fonte: Adaptado de (MASTERS, 2004)

Aplicando a lei de Kirchhoff das correntes no circuito da Figura 2.2, obtém-se a corrente elétrica de uma célula FV (I_{FV}) expressa na Equação (1).

$$I_{FV} = I_{PH} - I_D - I_{RP} \quad (1)$$

Onde:

I_{FV} = Corrente elétrica de uma célula FV (A);

I_{PH} = Corrente fotogerada (A);

I_D = Corrente do diodo (A);

I_{RP} = Corrente parasita do resistor paralelo (A).

A corrente fotogerada (I_{PH}) da Equação (1) corresponde a corrente gerada a partir dos fótons absorvidos da irradiância solar incidente pela célula FV, por isso ela é diretamente proporcional a irradiância (VILLALVA; GAZOLI; RUPPERT FILHO, 2009).

Com relação a corrente do diodo (I_D), ela tem natureza não linear e baseia-se na teoria de Shockley, como mostra a Equação (2) (VILLALVA; GAZOLI; RUPPERT FILHO, 2009).

$$I_D = I_o \cdot \left(e^{\frac{q \cdot v_D}{n \cdot k \cdot T_{CELL}}} - 1 \right) \quad (2)$$

Onde:

I_o = Corrente de saturação reversa do diodo (A);

q = Carga do elétron ($1,6 \times 10^{-19}$ C);

v_D = Tensão sobre o diodo (V);

n = Fator de idealidade do diodo (número adimensional geralmente entre 1 e 2);

k = Constante de Boltzmann ($1,38 \times 10^{-23}$ J/K);

T_{CELL} = Temperatura absoluta da célula FV (K);

A corrente de saturação reversa do diodo (I_o) da Equação (2) normalmente é determinada experimentalmente aplicando-se uma tensão à célula FV não iluminada.

Com relação a corrente parasita do resistor paralelo (I_{RP}) da Equação (1), ela representa as perdas do sistema e pode ser calculada pela Equação (3) (PINHO; GALDINO, 2014).

$$I_{RP} = \frac{V_{FV} + I_{FV} \cdot R_S}{R_P} \quad (3)$$

Onde:

V_{FV} = Tensão elétrica nos terminais de uma célula FV (V);

R_S = Resistência série do circuito equivalente da célula FV (Ω).

R_P = Resistência paralelo do circuito equivalente da célula FV (Ω).

Observando a Figura 2.2 e a Equação (3) percebe-se que a corrente parasita do resistor paralelo é a soma da tensão na resistência série com a tensão nos terminais da célula FV.

Villalva, Gazoli e Ruppert Filho (2009) explicam que modelos mais minuciosos têm sido propostos e utilizados para diferentes finalidades, como a inserção de um segundo diodo (em paralelo com o diodo da Figura 2.2) para representar o efeito da recombinação dos portadores na região de depleção. Porém, eles ressaltam que a simplicidade do modelo de diodo único contribui para o melhor ajuste dos parâmetros das equações, além de ser mais fácil e eficaz para simulações e ter boa precisão.

Diante do exposto, o circuito equivalente do modelo de diodo único, que é o mais utilizado para modelar e simular as células FV, será o modelo utilizado no presente estudo.

Porém, uma única célula FV não produz energia suficiente para aplicações práticas, pois a tensão produzida por uma única célula FV é inferior a 1 Volt (V). Por isso, geralmente é considerado um conjunto de células interconectados em série e/ou paralelo para a geração de energia, denominados de módulos ou módulos fotovoltaicos.

Assim, utilizando o modelo de diodo único e considerado a interconexão das células FV, a corrente gerada por um módulo FV pode ser expressa pela Equação (4).

$$I_{FV} = N_P \cdot I_{PH} - N_P I_o \cdot \left(e^{\frac{q(V_{FV} + I_{FV} \cdot R_S \cdot \frac{N_S}{N_P})}{n \cdot k \cdot T_{CELL} \cdot N_S}} - 1 \right) - \frac{V_{FV} + I_{FV} \cdot R_S \cdot \left(\frac{N_S}{N_P} \right)}{R_P \cdot \left(\frac{N_S}{N_P} \right)} \quad (4)$$

Onde:

N_P = Número de células FV em paralelo;

N_S = Número de células FV em série.

Na Equação (4), a tensão do diodo foi substituída pela tensão sobre o resistor paralelo, uma vez que são iguais. A corrente fotogerada pelo módulo e a corrente de saturação do diodo são diretamente proporcionais ao número de células em paralelo, ao passo que o número de células FV em série influencia na parcela da Equação (4) referente à corrente de saturação do diodo e à corrente do resistor paralelo (VILLALVA; GAZOLI; RUPPERT FILHO, 2009).

Observando a Equação (4), percebe-se que não é simples isolar a corrente de saída da célula ou do módulo FV em um dos lados da expressão. Por conta disso, essa equação não pode ser resolvida analiticamente. Desse modo, é comum construir as curvas características de Corrente versus Tensão (I-V) e Potência versus Tensão (P-V) das células ou dos módulos FV tomando suas próprias tensões de saída como referência, conforme é mostrado na Figura 2.3 e discutido na Seção 2.3.

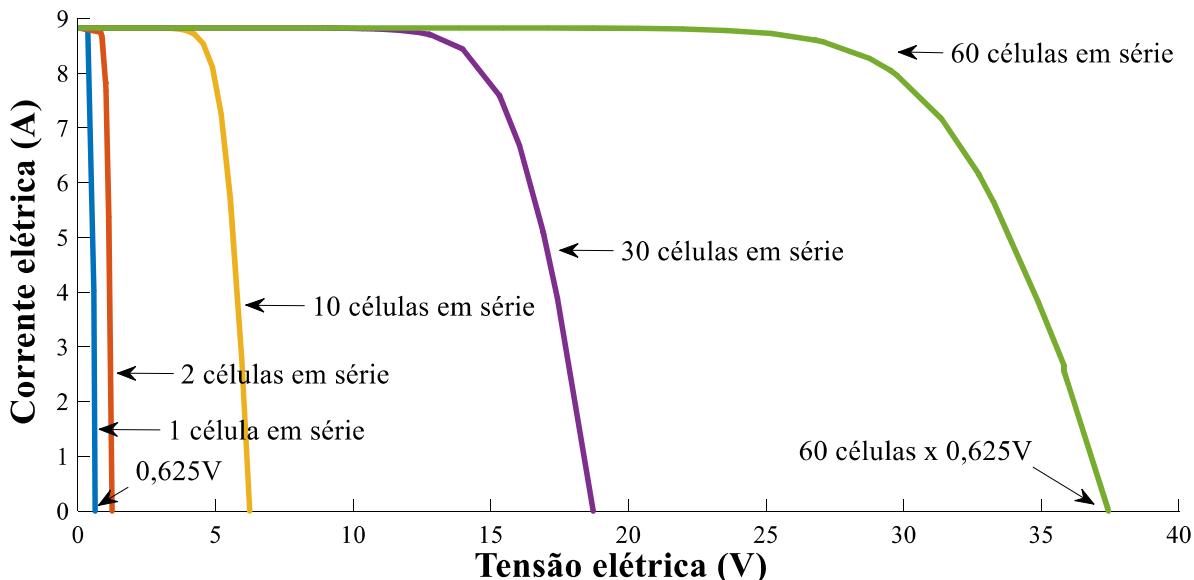


Figura 2.3. Curva característica I-V para 1 até 36 células FV ligadas em série
Fonte: Autoria própria

Como uma célula FV apresenta curva característica I-V semelhante ao de um módulo FV, para fins de terminologia, a Seção 2.3 trata as células e os módulos fotovoltaicos como geradores fotovoltaicos. Pois, conforme é explicado pela Associação Brasileira de Normas

Técnicas (ABNT, 2013) na sua NBR 10899, o gerador FV é uma nomenclatura adequada para abordar sobre dispositivos que utilizam o efeito fotovoltaico para converter a luz do sol em eletricidade, como as célula e os módulos FV.

2.3 Curvas características e parâmetros elétricos

A corrente e a tensão de saída dos geradores fotovoltaicos não apresentam valores constantes durante a geração de eletricidade, visto que dependem da intensidade de radiação solar (ou irradiação), bem como da capacidade de conversão fotovoltaica das células. Desse modo, é possível afirmar que a corrente de saída de um gerador FV está em função da sua tensão de saída ($I_{FV} = f(V_{FV})$) e vice-versa ($V_{FV} = f(I_{FV})$).

Assim, é preciso variar linearmente a tensão da carga desde a condição de curto-círcuito, quando a corrente é máxima e a tensão é zero ($I_{FV} = I_{CC}$ e $V_{FV} = 0$), até a condição de circuito aberto, quando a corrente é zero e a tensão é máxima ($I_{FV} = 0$ e $V_{FV} = V_{OC}$). Para fins de simulação, essa variação pode ser obtida utilizando uma fonte de tensão crescendo em forma de rampa na saída do gerador FV (AGUIAR, 2018).

Fazendo isso, a curva característica I-V de um gerador FV, semelhante à da Figura 2.4, é traçada.

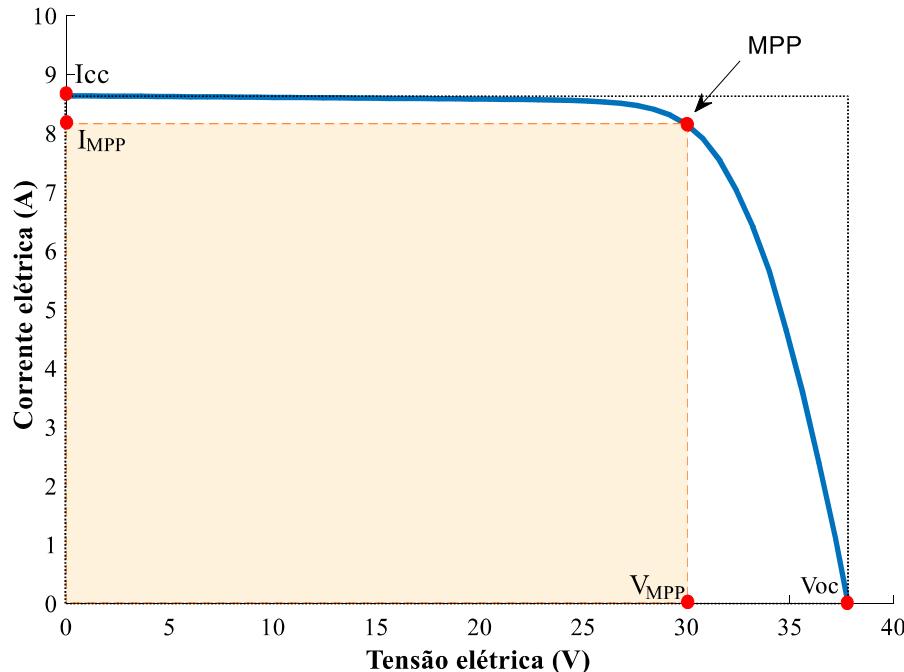


Figura 2.4. Curva característica I-V de um gerador FV

Fonte: Autoria própria

A partir da curva característica I-V da Figura 2.4 é possível apontar os principais parâmetros elétricos que caracterizam os geradores fotovoltaicos, a saber: corrente de curto-circuito (I_{CC}), tensão de circuito aberto (V_{OC}), corrente do ponto de máxima potência (I_{MPP}), tensão do ponto de máxima potência (V_{MPP}) e ponto de máxima potência (MPP).

A corrente de curto-circuito (I_{CC}), como o próprio nome sugere, acontece quando os terminais do gerador FV estão curtos circuitados. Nessa condição, a tensão entre os terminais é zero e a corrente gerada é máxima. Por outro lado, na tensão de circuito aberto (V_{OC}), a tensão entre os terminais do gerador é máxima e a corrente é zero, pois não há circulação de corrente quando os terminais do gerador FV estão abertos.

O ponto de máxima potência é considerado o ponto ideal de atuação dos geradores fotovoltaicos, pois tanto a corrente quanto a tensão estão próximos de seus valores máximos, por isso são denominados de corrente do ponto de máxima potência (I_{MPP}) e tensão do ponto de máxima potência (V_{MPP}).

Adicionalmente, com os dados obtidos com a curva característica I-V ainda é possível calcular o fator de forma (FF) do sistema FV e a eficiência elétrica (η). O fator de forma, também denominado de fator de preenchimento, expressa o quanto a curva característica I-V se aproxima de um retângulo e pode ser calculada através da razão entre a máxima potência do gerador FV e o produto da corrente de curto circuito com a tensão de circuito aberto, como mostra a Equação (5) e é ilustrado pelos retângulos pontilhados da Figura 2.4 (ABNT, 2013).

$$FF = \frac{V_{MPP} \cdot I_{MPP}}{V_{OC} \cdot I_{CC}} \cdot 100\% \quad (5)$$

Onde:

FF = Fator de forma ou Fator de preenchimento (%);

V_{MPP} = Tensão do ponto de máxima potência (V);

I_{MPP} = Corrente do ponto de máxima potência (A);

V_{OC} = Tensão de circuito aberto do gerador fotovoltaico (V);

I_{CC} = Corrente de curto-circuito do gerador FV (A).

Embora a Equação (5) esteja relacionada com tensões e correntes do gerador FV, as resistências em série e em paralelo são os parâmetros mais relevantes na variação do FF , visto que quanto menor a resistência série e maior a resistência paralela (ou resistência *shunt*), maior a qualidade do gerador FV e mais próximo de um retângulo estará o fator de forma (PINHO; GALDINO, 2014).

No que tange a eficiência elétrica, ela representa a efetividade no processo de conversão da energia solar em energia elétrica do gerador FV. Ela pode ser calculada através da razão

entre a potência máxima produzida pelo gerador fotovoltaico e a potência da energia solar que incide sobre esse gerador FV, ou seja, o produto da irradiância solar com a área total do gerador FV, conforme observa-se na Equação (6) (PINHO; GALDINO, 2014).

$$\eta = \frac{V_{MPP} \cdot I_{MPP}}{A \cdot G} \cdot 100\% = \frac{P_{MPP}}{A \cdot G} \cdot 100\% \quad (6)$$

Onde:

η = Eficiência elétrica do gerador fotovoltaico (%);

A = Área total do gerador fotovoltaico (m^2);

G = Irradiância solar (W/m^2);

P_{MPP} = Potência do ponto de máxima potência (W).

A partir da curva característica I-V da Figura 2.4 também é possível traçar a curva da potência em função da tensão de um gerador fotovoltaico, denominada de curva característica P-V e mostrada na Figura 2.5.

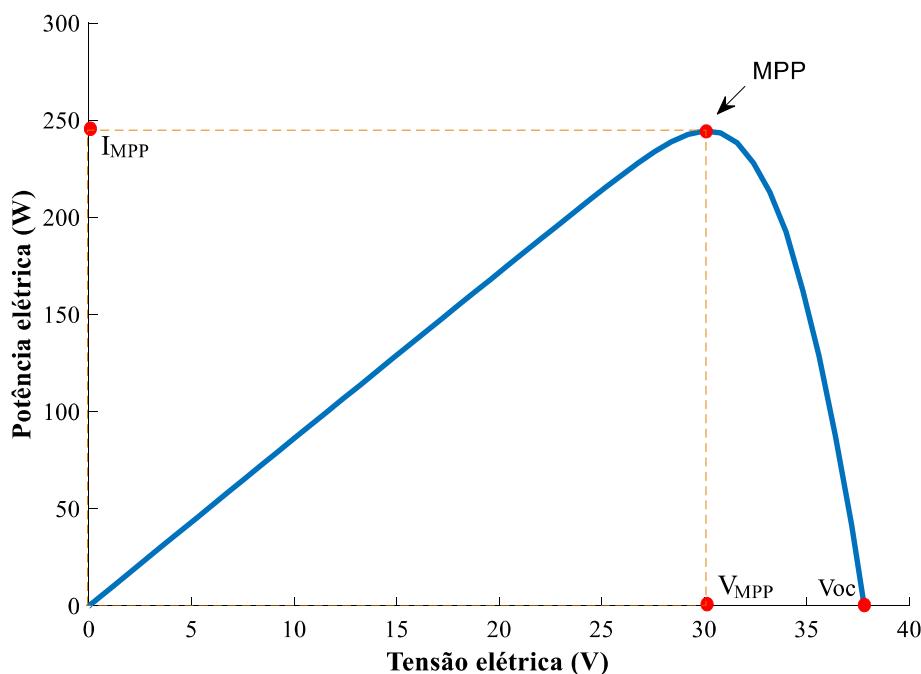


Figura 2.5. Curva característica P-V de um gerador FV

Fonte: Adaptado de Pinho e Galdino (2014)

Analizando a curva característica P-V da Figura 2.5, verifica-se o comportamento da potência fornecida por um gerador FV ao ser variado sua tensão de saída ($P_{FV} = f(V_{FV})$). Além disso, na curva característica P-V também é possível extrair os principais parâmetros elétricos de um gerador fotovoltaico, assim como na curva característica I-V.

Entretanto, as curvas características I-V e P-V e, consequentemente, os parâmetros elétricos citados na presente seção, são elementos que variam conforme há alterações nas

condições ambientais, especialmente irradiação solar, e na temperatura de operação dos geradores FV. Essas alterações também influenciam na corrente fotogerada e na corrente de saturação reversa do diodo citadas na Seção 2.2 (AYOP; TAN, 2018).

Sabendo disso, analisar as condições ambientais e a temperatura de operação do gerador FV são fundamentais para se obter uma modelagem precisa. Isso posto, a Seção 2.4 aborda sobre o efeito que tais condições provocam na produção de energia de um gerador FV.

2.4 Efeito das condições irradiação e temperatura de operação das células FV nos geradores fotovoltaicos

A produção de energia elétrica a partir de geradores FV depende diretamente da existência de incidência solar. Porém, as condições ambientais instantâneas também influenciam diretamente na eletricidade gerada, especialmente devido as significativas variações ao longo do dia e das estações do ano. Logo, a natureza intermitente da energia solar fotovoltaica sempre deve ser levada em consideração (ALONSO, 2017).

Por conta disso, dois importantes fatores que influenciam na geração de energia a partir de geradores fotovoltaicos são abordados nas Subseções 2.4.1 e 2.4.2, que são, irradiação solar e temperatura de operação dos geradores fotovoltaicos, respectivamente.

2.4.1 Irradiância solar

Primeiramente, é fundamental diferenciar os termos técnicos irradiação solar e radiação solar. Conforme esclarecido por Xiao (2017), a radiação solar é um termo geral referente a energia radiante emitida pelo Sol, seja em uma superfície ou difundida pela atmosfera. No caso da irradiação solar (G), termo da presente seção, ela representa a densidade da radiação solar incidente em uma certa superfície. Em outras palavras, ela pode ser considerada como a força da radiação solar e sua unidade de medida é o watt por metro quadrado (W/m^2) (XIAO, 2017).

Agora, relembrando que na ausência de luz solar um gerador fotovoltaico não produz eletricidade, mas à medida que a irradiação solar é recebida pelas células FV, mais corrente é gerada devido ao efeito fotovoltaico. Então, é possível afirmar que a corrente fotogerada (I_{PH}) é proporcional à irradiação solar (ALONSO, 2017).

Além disso, Pinho e Galdino (2014) complementam afirmando que em virtude da corrente produzida pelo gerador FV (I_{FV}) está diretamente relacionada com a corrente

fotogerada, então ela também varia linearmente com à irradiação solar. Por isso, os autores concluem que a corrente de curto-círcuito (I_{CC}), que é a máxima corrente que pode ser gerada nos terminais de um gerador FV, também é proporcional à irradiação solar.

Dessa forma, a Equação (7) expressa a relação da I_{PH} com a irradiação solar e a corrente de curto-círcuito (AYOP; TAN, 2018; VILLALVA; GAZOLI; RUPPERT FILHO, 2009).

$$I_{PH} = \frac{G}{G_{STC}} \cdot [I_{CC} + k_i \cdot (T_{CELL} - T_{STC})] \quad (7)$$

Onde:

G = Irradiância solar instantânea (W/m^2);

G_{STC} = Irradiância solar nas condições de teste padrão (W/m^2), ou seja, 1000 W/m^2 ;

k_i = Coeficiente de temperatura da corrente (A/K);

T_{CELL} = Temperatura instantânea de operação do gerador FV (K);

T_{STC} = Temperatura de operação do gerador FV na condição de teste padrão (K), ou seja, 298K .

Normalmente, os parâmetros I_{CC} e k_i da Equação (7) são obtidos através de análises laboratoriais realizadas no gerador FV sob Condições de Teste Padrão (STC²) e fornecidos pelo fabricante na folha de dados do equipamento.

A corrente I_{PH} da Equação (7) também sofre influência da variação na temperatura de operação do gerador FV, que naturalmente eleva-se com o aumento da irradiação e da temperatura ambiente (XIAO, 2017). É válido ressaltar que a influência da temperatura de operação do gerador FV é pequena quando comparada com a da irradiação solar.

Com relação a influência da irradiação solar na Equação (7), ela também pode ser vista na curva característica I-V e curva características P-V de um gerador fotovoltaico, como mostra respectivamente a Figura 2.6 e Figura 2.7, que fixaram a temperatura do gerador FV e variaram os níveis de irradiação solar.

² A Condição de Teste Padrão (STC, do inglês, *Standard Test Conditions*) é utilizado para avaliar a capacidade de conversão de energia de uma célula ou módulo fotovoltaico sob as condições de ambiente controlado com espectro de radiação semelhante ao do Sol, irradiação de 1000W/m^2 , temperatura da célula em 25°C e massa de ar de 1,5, conforme especificado na IEC 60904-3 (ABNT, 2013).

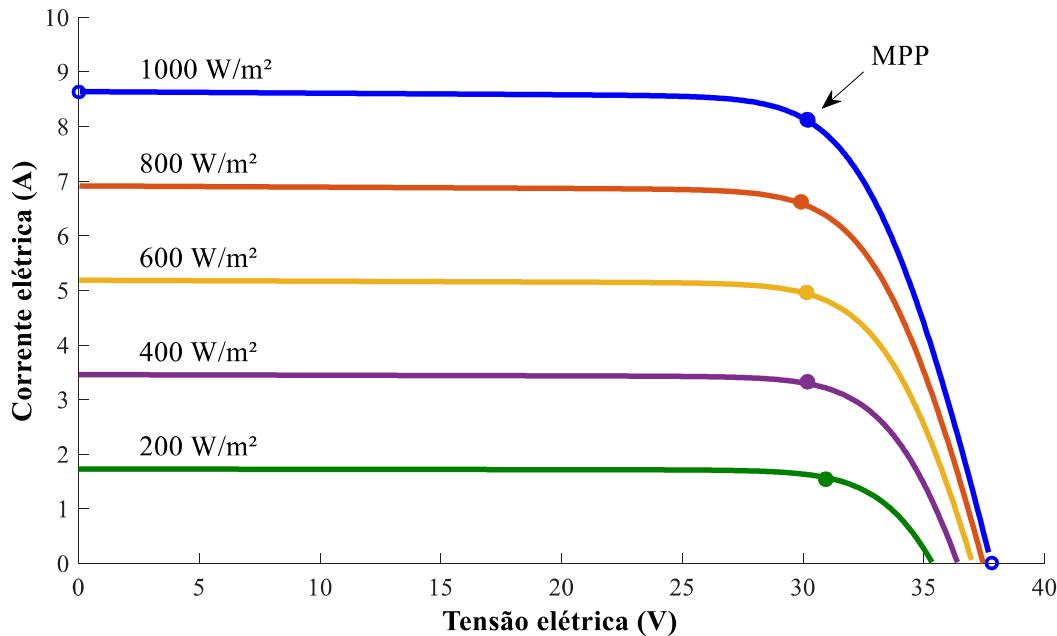


Figura 2.6. Influência da variação da irradiância solar na curva característica I-V
Fonte: Autoria própria

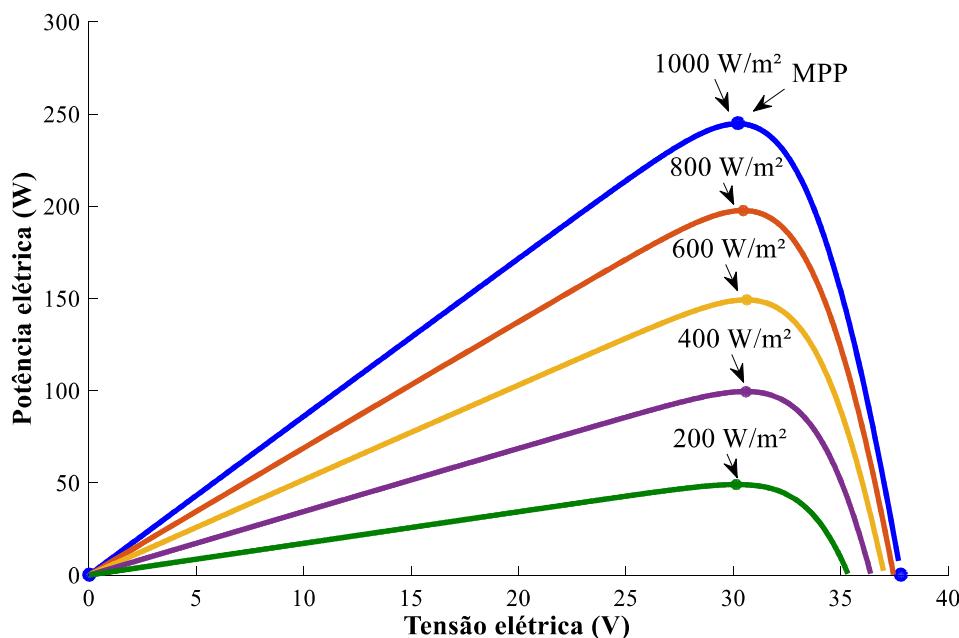


Figura 2.7. Influência da variação da irradiância solar na curva característica P-V
Fonte: Autoria própria

Observando a Figura 2.6 e Figura 2.7, percebe-se que, ao elevar os níveis de irradiância solar, a corrente de saída do gerador FV e o ponto de máxima potência crescem proporcional à essa variação. Por outro lado, a tensão de saída do gerador quase não se altera.

O fator que causa alterações significativas na tensão de saída do gerador FV é sua temperatura de operação. Devido a sua influência, tanto na corrente fotogerada como na tensão

de saída do gerador FV, o parâmetro temperatura de operação do gerador FV é abordada na Subseção 2.4.2.

2.4.2 Temperatura de operação dos geradores fotovoltaicos

A temperatura de operação dos geradores fotovoltaicos (T_{CELL}) é um parâmetro que sofre influência das condições ambientais, tais como, irradiância, temperatura ambiente, umidade e velocidade do vento. Dentro desse contexto, Pinho e Galdino (2014) afirmam que a irradiância solar e a temperatura ambiente são dois fatores que afetam significativamente nessa temperatura de operação dos geradores FV. Isso ocorre, pois ao aumentar a irradiância incidente e/ou a temperatura ambiente, a temperatura dos geradores FV também se elevam e, consequentemente, tende a reduzir a sua eficiência.

Ao operar no campo, por exemplo, os geradores FV trabalham em condições diferentes das STC, por conta disso a condição de T_{CELL} à 25 °C é rara de ser alcançada na prática. Normalmente, os geradores FV trabalham com temperaturas mais elevadas, mesmo sob baixas irradiancias, o que corresponde a perdas na geração, redução de eficiência, danos ao gerador FV e comprometimento da vida útil (PINHO; GALDINO, 2014; XIAO, 2017).

Khatib e Elmenreich (2016) explicam que a temperatura de operação de um gerador FV pode ser calculada usando a temperatura ambiente (T_{AMB}), o valor da temperatura nominal de operação da célula FV ($NOCT^3$) e a irradiância solar através da Equação (8).

$$T_{CELL} = T_{AMB} + \frac{G}{800} \cdot (NOCT - 20) \quad (8)$$

Onde:

T_{CELL} = Temperatura de operação do gerador FV (°C);

T_{AMB} = Temperatura ambiente (°C);

$NOCT$ = Temperatura nominal de operação da célula (°C).

Conforme a Equação (8), percebe-se que ao elevar a temperatura ambiente, a temperatura de operação dos geradores FV também sofrem um aumento.

Pinho e Galdino (2014) complementam que, quando ocorre o aumento da temperatura de operação dos geradores FV, também há redução na eficiência dos geradores FV, pois a

³ NOCT (do inglês *Nominal Operating Cell Temperature*) é estabelecida como a temperatura atingida pelas células fotovoltaicas que estão trabalhando em circuito aberto em um gerador FV sob condições de irradiância de 800W/m², T_{AMB} de 20°C e velocidade do vento de 1m/s².

tensão de saída desses geradores FV diminui significativamente com o aumento da temperatura, ao passo que a corrente fotogerada da Equação (7) tem uma elevação quase desprezível.

A elevação da T_{CELL} também tem efeito na corrente de saturação reversa do diodo, como mostra a Equação (9) (VILLALVA; GAZOLI; RUPPERT FILHO, 2009).

$$I_o = I_o' \cdot \left(\frac{T_{CELL}}{T_{STC}} \right)^3 \cdot \left(e^{\frac{q \cdot E_g}{n \cdot k} \left(\frac{1}{T_{STC}} - \frac{1}{T_{CELL}} \right)} \right) \quad (9)$$

Onde:

E_g = Energia do gap do semicondutor (1,12 eV para o silício policristalino);

I_o' = Corrente de saturação reversa nominal do diodo nas STC (A).

A corrente de saturação reversa nominal do diodo nas STC (I_o'), presente na Equação (9), também sofre efeito quando o gerador FV opera em temperaturas diferentes das STC. Por isso, Ishaque, Salam e Syafaruddin (2011), assim como Villalva, Gazoli e Ruppert Filho (2009) substituíram I_o' pela Equação (10).

$$I_o' = \frac{I_{CC} + k_i \cdot (T_{CELL} - T_{STC})}{e^{\left(\frac{q \cdot N_s \cdot [V_{OC} + k_v (T_{CELL} - T_{STC})]}{n \cdot k \cdot T_{CELL} \cdot N_s} \right)} - 1} = \frac{I_{CC} + k_i \cdot (T_{CELL} - T_{STC})}{e^{\left(\frac{q \cdot [V_{OC} + k_v (T_{CELL} - T_{STC})]}{n \cdot k \cdot T_{CELL}} \right)} - 1} \quad (10)$$

Onde:

k_v = Coeficiente de temperatura da tensão (V/K);

Graficamente, o efeito da temperatura de operação da células do gerador FV na curva característica I-V e curva característica P-V podem ser visto fixando a irradiância solar e variando a T_{CELL} , como é mostrado na Figura 2.8 e Figura 2.9, respectivamente.

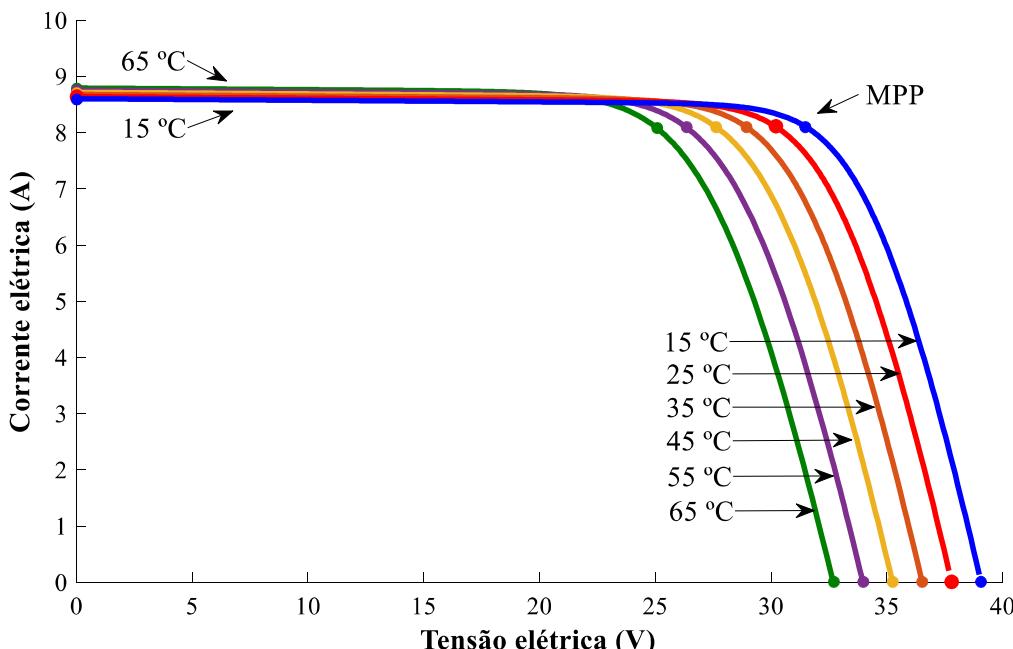


Figura 2.8. Influência da variação da temperatura na curva característica I-V
Fonte: Autoria própria

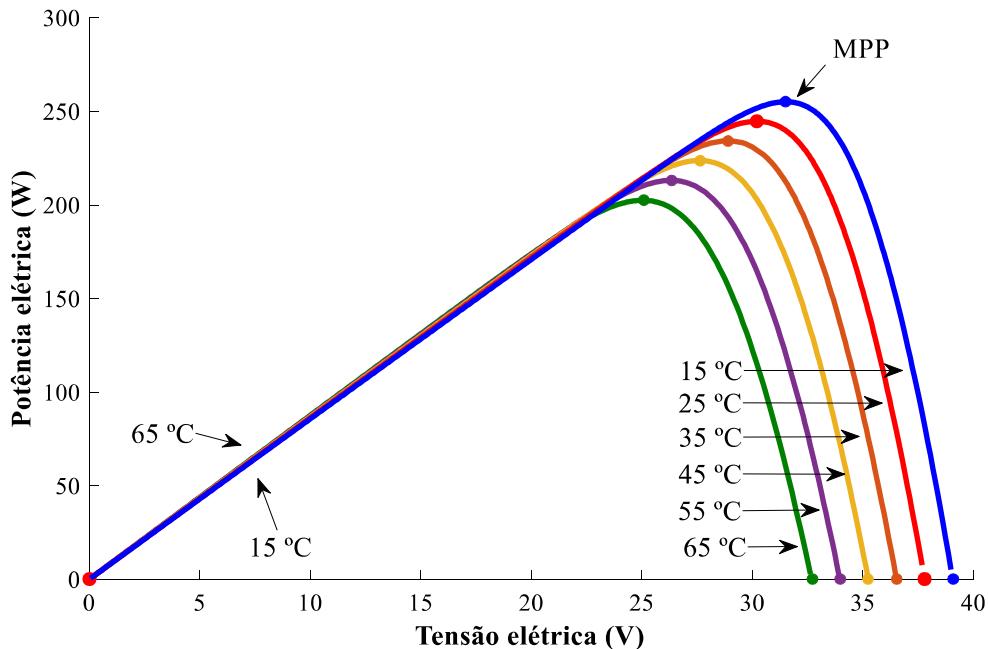


Figura 2.9. Influência da variação da temperatura na curva característica P-V
Fonte: Autoria própria

Na Figura 2.8 e Figura 2.9, percebe-se que a V_{OC} e, consequentemente, a V_{MPP} diminuem à medida que a T_{CELL} aumenta. Com relação a I_{CC} e a corrente do ponto de máxima potência (I_{MPP}), elas sofrem um pequeno aumento com a elevação da temperatura. Porém, como o aumento do I_{MPP} é consideravelmente menor que a redução sofrida pelo V_{MPP} , então MPP também diminui com o aumento da T_{CELL} .

É válido ressaltar que uma curva característica I-V ou P-V não mostra exatamente onde o gerador FV está operando, mas sim uma combinação de tensões e correntes do gerador FV sob as variadas condições de irradiância solar e temperatura. Isto porque, o ponto real de operação depende da carga acoplada ao gerador FV. Sabendo disso, a Seção 2.5 trata sobre o comportamento que as cargas ligadas ao gerador FV provocam nas curvas características I-V.

2.5 Influência das cargas nas curvas características I-V

As cargas têm curvas características I-V da mesma forma que os geradores fotovoltaicos. A inclinação da curva característica I-V de uma carga resistiva é baseada na primeira lei de Ohm e pode ser representada pela Equação (11).

$$I_R = \left(\frac{1}{R}\right)V_R \quad (11)$$

Onde:

I_R = Corrente da carga resistiva (A);

R = Resistência da carga (Ω);

V_R = Tensão da carga resistiva (V).

Quando uma carga é acoplada a um gerador FV, a corrente e a tensão fornecidas à carga são oriundas do gerador FV. Sabendo disso, é possível traçar as curvas características I-V de ambos os componentes em um mesmo gráfico. Masters (2004) explica que o ponto de interseção entre as duas curvas irá corresponder ao ponto de operação do sistema.

A Figura 2.10 ilustra uma carga resistiva variável acoplada ao gerador FV e a Figura 2.11 mostra a curva característica I-V de ambos os componentes em um mesmo gráfico.

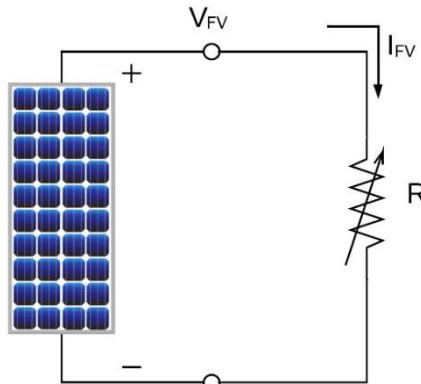


Figura 2.10. Circuito composto por gerador FV e carga resistiva
Fonte: Autoria própria

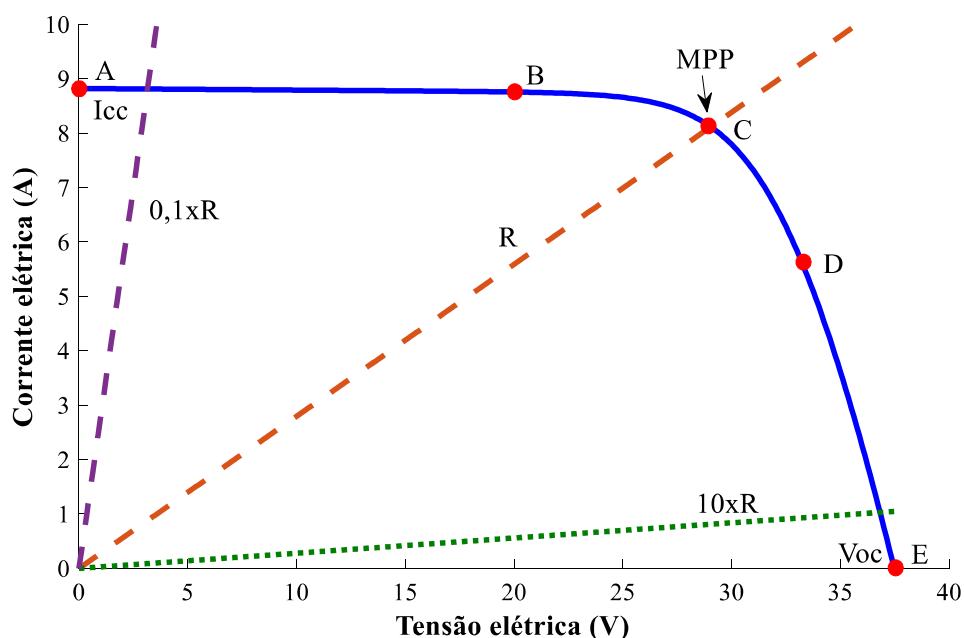


Figura 2.11. Curvas características I-V do gerador FV e de cargas resistivas
Fonte: Autoria própria

Na Figura 2.11, além da curva característica I-V do gerador FV (em azul), três curvas I-V da carga resistiva variável foram traçadas. A curva em laranja representa a carga com resistência R . A curva caraterística em roxo é traçada considerando que a carga foi ajustada para uma resistência 10 vezes menor que a da carga R . Por fim, na curva em verde, a resistência é 10 vezes maior que a da carga R .

A partir de tais ajustes foi possível observar que uma variação na resistência da carga da Figura 2.10 proporciona um variação na inclinação da curva característica I-V do resistor da Figura 2.11. Consequentemente, há um deslocamento no ponto de operação do circuito ao longo da curva característica I-V do gerador FV.

Ainda analisando a Figura 2.11, percebe-se que quando a resistência da carga é muito pequena, o gerador FV (e, por conseguinte, o circuito) opera na região AB da curva característica I-V do gerador, logo se comportando como uma fonte de corrente constante. Em contrapartida, quando a resistência é muito grande, o gerador FV trabalha na região DE e tem comportamento parecido com uma fonte de tensão constante. Por fim, para que o circuito trabalhe em sua máxima potência, a resistência deve ser exatamente R (KALOGIROU, 2014).

Essa resistência R , que resulta na máxima transferência de potência do circuito, pode ser calculada inserindo a potência e a tensão ponto de máxima potência na Equação (12).

$$R = \frac{V_{MPP}^2}{P_{MPP}} \quad (12)$$

Os valores de potência e tensão de máxima potência para o cálculo da Equação (12) devem ser os medidos nas STC, ou seja, 1000 W/m² de irradiância, temperatura de operação da célula em 25 °C e massa de ar de 1,5 (MASTERS, 2004).

Porém, quando a resistência da carga é fixada a partir dos valores em STC, a garantia de potência máxima extraída também só é possível sob essas condições. Assim, à medida que houver variações ambientais, o ponto de operação do circuito sai do MPP, como mostra a Figura 2.12.

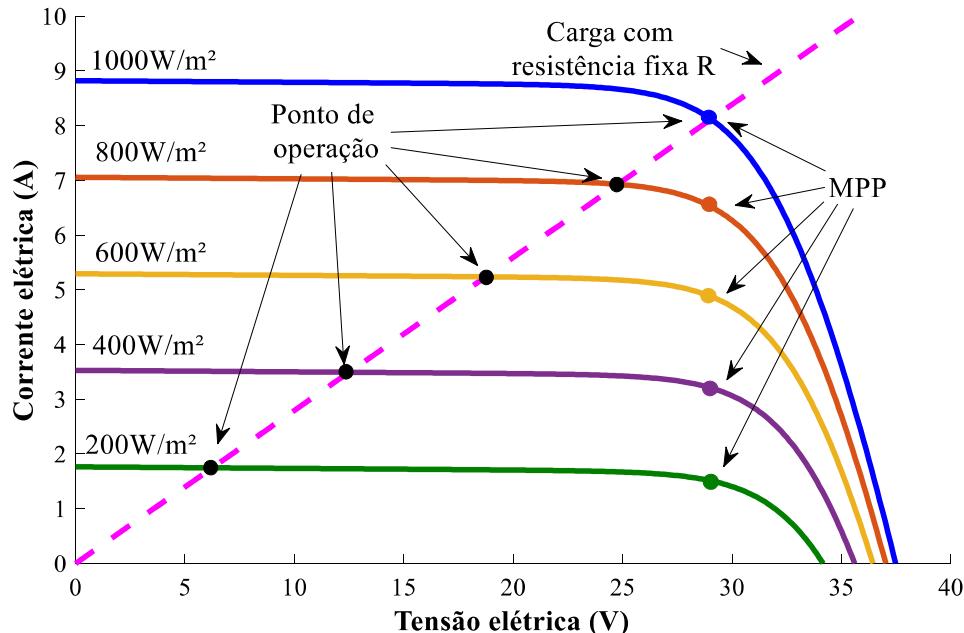


Figura 2.12. Curvas características I-V de um gerador FV com variação de irradiância e de uma carga resistiva fixa

Fonte: Adaptado de (MASTERS, 2004)

Com o ponto de operação do circuito saindo do MPP (como mostra a Figura 2.12), a eficiência do gerador FV tende a cair. Então, para tentar manter o gerador fornecendo a sua máxima energia à carga, ou seja, tentar manter o circuito operando no MPP, mais componentes são acrescidos entre o gerador e a carga. Logo, ao conjunto dos elementos conectados desde o gerador até a carga, dar-se o nome de sistema fotovoltaico e eles são apresentados na Seção 2.6.

2.6 Sistemas fotovoltaicos

Os sistemas que convertem a irradiação solar em eletricidade podem ter diferentes aplicações, desde o fornecimento de energia diretamente para pequenas cargas, como em um simples sistema de bombeamento de água, até à integração com a rede elétrica, através das grandes usinas solares.

De modo geral, os sistemas fotovoltaicos podem ser classificados de acordo com a sua aplicabilidade e divididos em duas principais categorias: sistemas isolados e sistemas conectados à rede elétrica (PINHO; GALDINO, 2014).

Os sistemas FV isolados, também denominados de sistemas FV autônomos, operam independente à rede elétrica, pois geralmente estão localizados onde o acesso à rede elétrica é difícil ou inexistente. Eles podem ser compostos simplesmente pelos módulos fotovoltaicos e a carga, como em sistemas de irrigação. Mas, em situações mais completas, também podem ter

um bloco do condicionamento de potência e um bloco de armazenamento integrado ao sistema, principalmente quando precisa-se de energia elétrica nos períodos em que não há geração fotovoltaica (SMETS et al., 2016).

A Figura 2.13 ilustra o esquema de um sistema FV isolado comumente utilizado e identifica os principais componentes presentes.

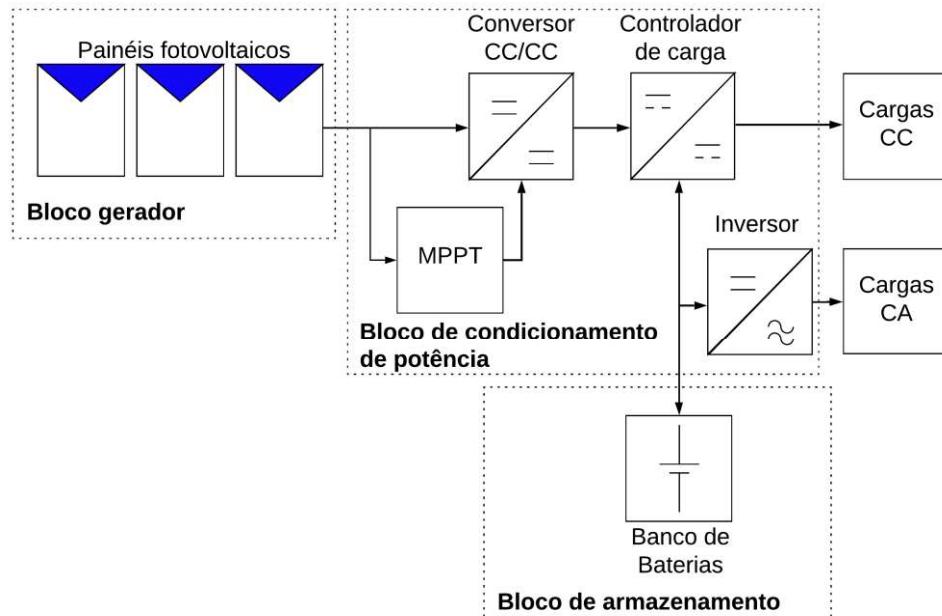


Figura 2.13. Esquema de um sistema FV isolado
Fonte: Adaptado de (PINHO; GALDINO, 2014)

Na configuração do sistema FV isolado mostrado na Figura 2.13, a existência do banco de baterias obriga a inserção do controlador de cargas no bloco de condicionamento de potência para regular o carregamento e descarregamento das baterias. Com relação as cargas, também presentes no esquema da Figura 2.13, Smets et al. (2016) explicam que elas servem para alertar que o sistema deve ser dimensionado para atender à todas as cargas conectadas e considerado todas as condições ambientais relevantes.

Em se tratando dos Sistemas Fotovoltaicos Conectados à Rede (SFCRs), eles são caracterizados por estarem conectados à rede elétrica e produzirem energia elétrica para ser consumida diretamente pela carga ou para ser injetada na rede de eletricidade, podendo assim ser utilizada por qualquer unidade consumidora conectada ao sistema de distribuição (PINHO; GALDINO, 2014).

Em geral, o SFCR diferencia-se do sistema FV isolado pela ausência do bloco de armazenamento e, consequentemente, do controlador de cargas, pois na insuficiência ou falta

da energia do sol, a rede elétrica pode fornecer eletricidade à carga. A Figura 2.14 mostra o esquema mais comum de um SFCR.

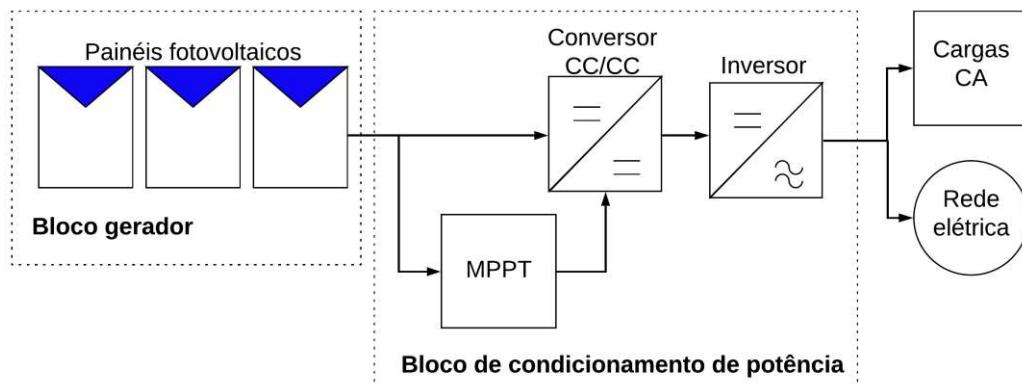


Figura 2.14. Esquema de um SFCR
Fonte: Adaptado de (PINHO; GALDINO, 2014)

O SFCR da Figura 2.14 pode receber energia da rede elétrica quando o bloco gerador fornece menos energia do que a carga precisa. Em contrapartida, quando os módulos FV geram mais energia que o necessário, o excesso pode ser enviado à rede. Assim, é possível afirmar que um SFCR opera em paralelo com a rede elétrica e por esse motivo são considerados uma fonte complementar ao sistema elétrico em que ele está conectado (PINHO; GALDINO, 2014).

Masters (2004) ainda explica que os SFCR apresentam diversas vantagens frente aos sistemas FV isolados e, por isso, estão se tornando cada vez mais populares no mundo. A ausência do bloco de armazenamento, por exemplo, retira a parcela mais onerosa de um sistema FV, aumentando sua simplicidade e, consequentemente, elevando sua confiabilidade.

Adicionalmente, devido à grande variação de potência que pode ser instalada, é possível integrar um SFCR a edificações com espaço limitado nos centros urbanos ou projetar uma usina solar quando há maior área territorial. Com tantos aspectos positivos, os SFCRs têm mostrado um crescimento cada vez mais acelerado e uma potência instalada mais expressiva que os sistemas isolados (PEARSALL, 2017).

Ao comparar a Figura 2.13 com a Figura 2.14, percebe-se que os princípios e elementos básicos dos sistema FV são parecidos, tendo apenas alguns componentes adaptativos para atender à requisitos específicos.

Pinho e Galdino (2014) generalizam que um sistema FV é composto por um bloco gerador, que contém os arranjos fotovoltaicos, o cabeamento elétrico e a estrutura de suporte. Há também o bloco de condicionamento de potência, constituído pelos conversores CC-CC, rastreadores do MPP, inversores, controladores de carga (quando há sistema de

armazenamento) e dispositivos de proteção, supervisão e controle. E, por último, tem o bloco de armazenamento que são formados pelos acumuladores elétricos (banco de baterias).

Como o presente trabalho foca no estudo do Rastreamento do Ponto de Máxima Potência (MPPT), as principais características dos componentes arranjos fotovoltaicos, conversor CC/CC e rastreador do MPP são apresentadas nas subseções subsequentes, iniciando pelos módulos fotovoltaicos na Subseção 2.6.1.

2.6.1 Módulos fotovoltaicos

Uma célula fotovoltaica individual tem aplicações limitadas por conta da sua baixa potência. Devido a disso, o elemento fundamental para aplicações fotovoltaicas é o módulo fotovoltaico, que também é conhecido como painel FV.

Villalva e Gazoli (2012) explicam que o módulo FV é um conjunto empacotado de células FV conectadas normalmente em série e montadas sobre uma estrutura rígida protetora. Atualmente, devido ao avanço dos SFCRs, há módulos FV com 36, 48, 54, 60 e até 72 células conectadas em série com o objetivo de produzir maiores tensões (XIAO, 2017).

Porém, devido a fragilidade dessas células FV, os módulos FV mais comuns têm as células FV e suas conexões elétricas prensadas dentro de lâminas plásticas, denominadas de encapsulamento. Além disso, o módulo FV é coberto por uma lâmina de vidro e envolvido pela caixa protetora, composta por uma moldura e um fundo de alumínio. Por último, na parte traseira do módulo é conectado a caixa de junção, onde ficam os diodos *bypass*⁴ e os cabos elétricos com conectores padronizados que facilitam a rápida conexão entre os módulos FV (VILLALVA; GAZOLI, 2012).

A Figura 2.15 mostra os componentes básicos de um módulo FV típico.

⁴ O diodo *bypass*, também chamados de diodo de desvio, é um componente usado para evitar os efeitos destrutivos dos pontos de aquecimentos que surgem quando há uma geração de energia desequilibrada entre as células FV conectadas em série. Os diodos são instalados em paralelo com um conjunto de células FV conectados em série (XIAO, 2017).

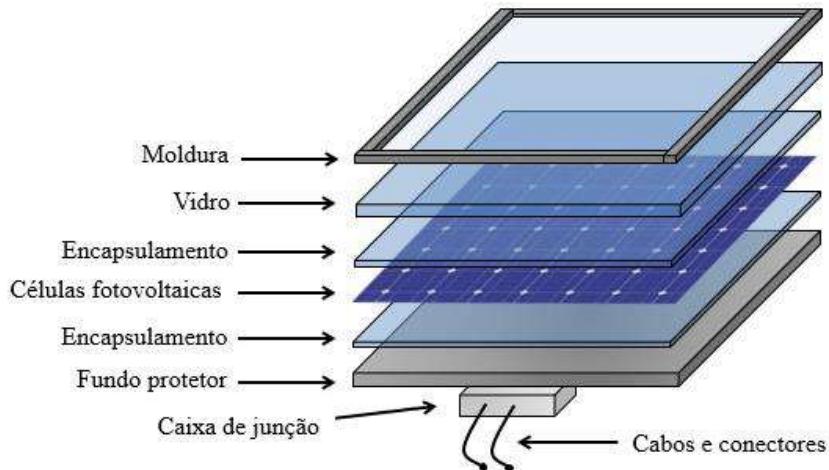


Figura 2.15. Componentes básicos de um módulo FV

Fonte: Adaptado de (SMETS et al., 2016)

Os módulos fotovoltaicos, mostrados na Figura 2.15, podem ser conectados em série para aumentar sua tensão ou em paralelo para aumentar sua corrente, assim como ocorre com as células FV (MASTERS, 2004). A conexão em série de módulos FV para aumentar a tensão é conhecida como *string* e a conexão em paralelo dos *strings* para elevar a corrente, chama-se de arranjo fotovoltaico. Como resultado, tem-se um sistema com mais potência gerada (XIAO, 2017). O esquema da Figura 2.16 ilustra a diferença entre os termos células, módulos, *strings* e arranjos fotovoltaicos.

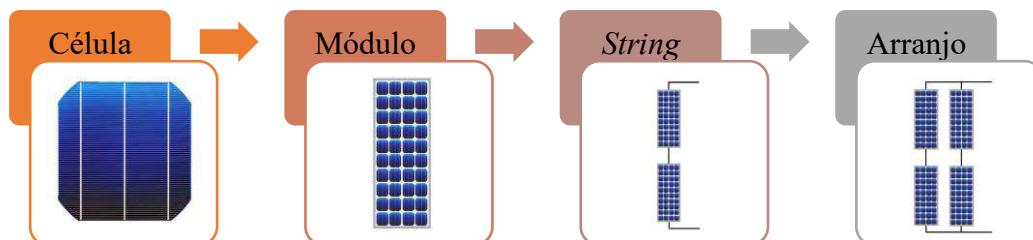


Figura 2.16. Gerador fotovoltaico da célula ou ao arranjo

Fonte: Autoria própria

A quantidade de módulos FV empregados em um arranjo FV depende da quantidade de energia elétrica que se pretende produzir. Villalva e Gazoli (2012) explicam que, para os sistemas FV serem conectados à rede, por exemplo, eles devem operar com tensões mais elevadas, por isso os módulos FV são conectados em série.

Por outro lado, na situação que deseja-se aumentar a potência elevando a corrente elétrica e mantendo a tensão total do sistema igual a tensão em cada módulo FV, Villalva e Gazoli (2012) esclarecem que os módulos FV devem ser conectados em paralelo. Normalmente isso ocorre em sistemas fotovoltaicos isolados, pois operam com baixas tensões.

Outra configuração dos módulos FV é a associação mista, ou seja, um arranjo FV composto por associações em série e em paralelo. Nessa configuração os terminais do arranjo FV fornecem uma tensão equivalente a soma das tensões dos módulos FV em série (curva em amarelo) e a corrente total sendo a soma das correntes dos módulos FV em paralelo (curva em roxo). A Figura 2.17 representa a curva característica I-V de um bloco gerador com associação mista composta por dois *strings* (com três módulos em série) em paralelo.

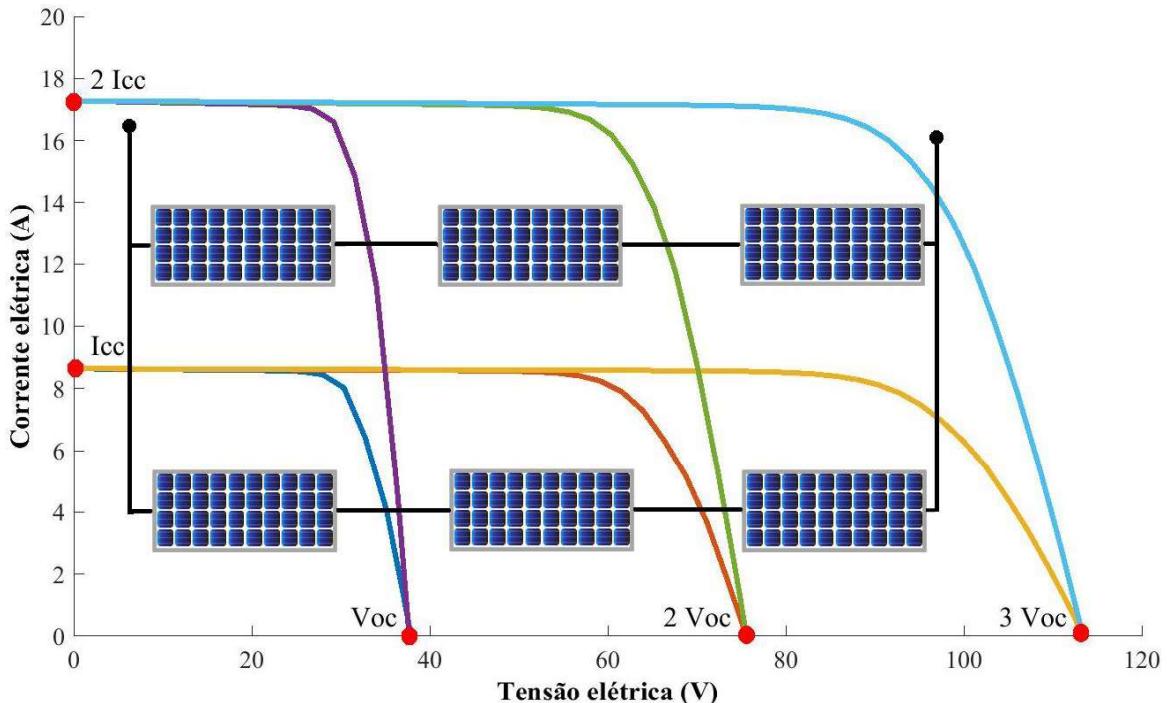


Figura 2.17. Curva-característica I-V de um arranjo FV com seis módulos e conexão mista
Fonte: Adaptado de (PINHO; GALDINO, 2014)

No arranjo da Figura 2.17, a potência total produzida será o produto da tensão total e corrente total do ponto de máxima potência, ou seja, o joelho da curva característica I-V em azul no gráfico. Essa potência total do arranjo FV é a responsável por definir a potência gerada pelo sistema FV e serve como base para os cálculos de dimensionamento. Ela é descrita pelo fabricante como a potência de pico (W_p) do sistema FV.

De forma similar aos geradores FV, as curvas características I-V e P-V de um arranjo fotovoltaico determinam as principais características de um sistema FV completo quando submetido as STC, conforme tratada na Seção 2.3. Essas características são consideradas informações técnicas e devem estar presente na folha de dados do fabricante, pois servem de referência para dimensionar os demais componentes do sistema, como o conversor CC/CC, discutido na Subseção 2.6.2.

2.6.2 Conversor CC/CC

Os conversores de energia CC-CC são dispositivos eletrônicos utilizados para transformar uma tensão contínua de um nível para outro. No caso dos sistemas fotovoltaicos, os conversores CC-CC são utilizados para adequar o nível de tensão e entregá-la adequadamente ao componente à jusante, que normalmente é o inversor ou o controlador de carga (SMETS et al., 2016).

Com relação a aplicabilidade, os conversores CC-CC podem ser utilizados em sistemas FV isolados, SFCRs e ainda em sistemas híbridos, ou seja, sistemas em que a geração de energia ocorre através da energia solar fotovoltaica e qualquer outra fonte de energia elétrica (RAJESH; CAROLIN MABEL, 2015).

Usualmente, os conversores CC-CC apresentam três tipologias básicas, que são classificadas de acordo com a tensão de saída. Quando deseja-se abaixar o nível de tensão, o conversor CC-CC utilizado no sistema FV é o conversor *buck*. Para o caso de elevação do nível de tensão, utiliza-se o conversor *boost*. Mas, nas situações em que deseja-se variados níveis de tensão a partir de uma única entrada, como na presente pesquisa, o conversor que deve ser instalado no sistema é o *buck-boost* ou outros, como o Conversor com Indutância Simples no Primário (SEPIC, do inglês, *Single-Ended Primary-Inductor Converter*), o conversor cük e o conversor *flyback* (PINHO; GALDINO, 2014).

As três tipologias básicas dos conversores CC-CC apresentam uma dinâmica complexa. Então, como o objetivo da presente pesquisa não é otimizar esse componente, a Subseção 2.6.2.1 aborda apenas o funcionamento básico do conversor utilizado no presente estudo, ou seja, o conversor *buck-boost*.

É válido ressaltar que todas as deduções matemáticas por trás das equações apresentadas poderão ser melhores exploradas em Ahmed (2000), Hart (2012), e Coelho e Martins (2012).

2.6.2.1 Conversores CC-CC *buck-boost* aplicados à sistemas fotovoltaicos

Devido a sua capacidade de combinar os conceitos dos conversores *buck* e *boost*, os conversores *buck-boost* conseguem fornecer uma tensão de saída menor, igual ou maior que a tensão de entrada. Além disso, apresentam uma inversão de polaridade na tensão de saída.

A Figura 2.18a mostra o circuito equivalente do conversor *buck-boost* composto pelo dispositivo de chaveamento, o diodo, um indutor (L) e um capacitor (C), estrategicamente inseridos entre a fonte (representada por V_F) e a carga (R).

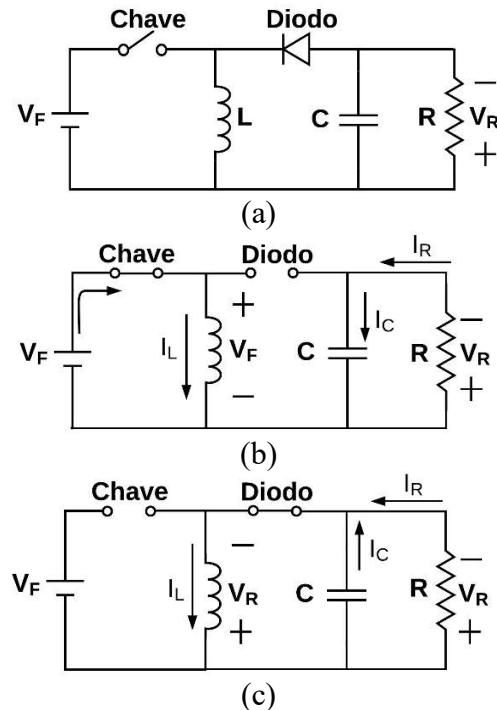


Figura 2.18. Circuito equivalente (a) do conversor CC-CC *buck-boost* e seu respectivo esquema com (b) a chave comutadora fechada e (c) a chave comutadora aberta
Fonte: Adaptado de (HART, 2012)

No circuito da Figura 2.18a, a chave tem a função de ficar abrindo e fechando para que pequenas correntes fluam no circuito até que a carga atinja a tensão desejada. O capacitor, com sua capacidade de armazenamento de energia, é responsável por manter uma tensão de saída suave enquanto a chave é comutada.

McEvoy, Markvart e Castañer (2012) esclarecem que a chave é fechada e aberta ciclicamente por um período de tempo “ T ”. Essa frequência de chaveamento tem relação com o tipo de chave usada. Portanto, a escolha do dispositivo de chaveamento adequado e o controle da frequência de chaveamento são importantes durante a montagem do sistema FV.

Em geral, os dispositivos de chaveamento mais utilizados são os transistores de potência, principalmente o Transistor de Efeito de Campo Metal-Óxido – Semicondutor (MOSFET, do inglês *Metal Oxide Semiconductor Field Effect Transistor*) e o Transistor Bipolar de Porta Isolada (IGBT, do inglês *Insulated Gate Bipolar Transistor*).

Para comutadores MOSFET, por exemplo, o comum é uma frequência de chaveamento até 100 kHz, ao passo que para comutadores IGBT, a frequência de chaveamento chega até a

50 kHz. A escolha do dispositivo de comutação também tem relação com a potência máxima suportada por cada elemento, o MOSFET pode ser usado em sistemas com até *quilo-watt* de potência, ao passo que o IGBT é recomendado para sistemas acima de *quilo-watt* de potência.

Sobre o funcionamento do conversor *buck-boost*, McEvoy, Markvart e Castañer (2012) explicam que quando a chave é fechada (Figura 2.18b), o diodo fica reversamente polarizado. Como consequência, a corrente de entrada flui sobre o indutor crescendo gradativamente. Paralelamente, o capacitor, se carregado, serve de fonte de tensão para a carga e permite que uma corrente flua sobre essa carga.

No segundo momento, quando a chave é aberta, como mostrado na Figura 2.18c, a fonte é desconectada, o diodo se polariza diretamente e a corrente passa a fluir através do indutor, capacitor, diodo e da carga. Nessa situação, a energia do indutor é transferida para a carga fazendo com que a corrente nesse indutor caia gradativamente até que se reinicie um novo ciclo.

Caso a corrente chegue a zero antes do início do novo ciclo, diz-se que o conversor *buck-boost* está operando no Modo de Condução Descontínuo (MCD). Mas, se a chave fechar novamente antes de a corrente zerar, diz-se que o conversor *buck-boost* está trabalhando no Modo de Condução Contínua (MCC).

Para melhor entendimento, a Figura 2.19 ilustra graficamente a comutação da chave (em função do seu ciclo de trabalho) de um conversor *buck-boost* trabalhando em MCC, bem como o consequente comportamento da tensão no indutor (v_L), tensão na carga (v_R) e das correntes no indutor (i_L), resistor (i_R) e capacitor (i_C).

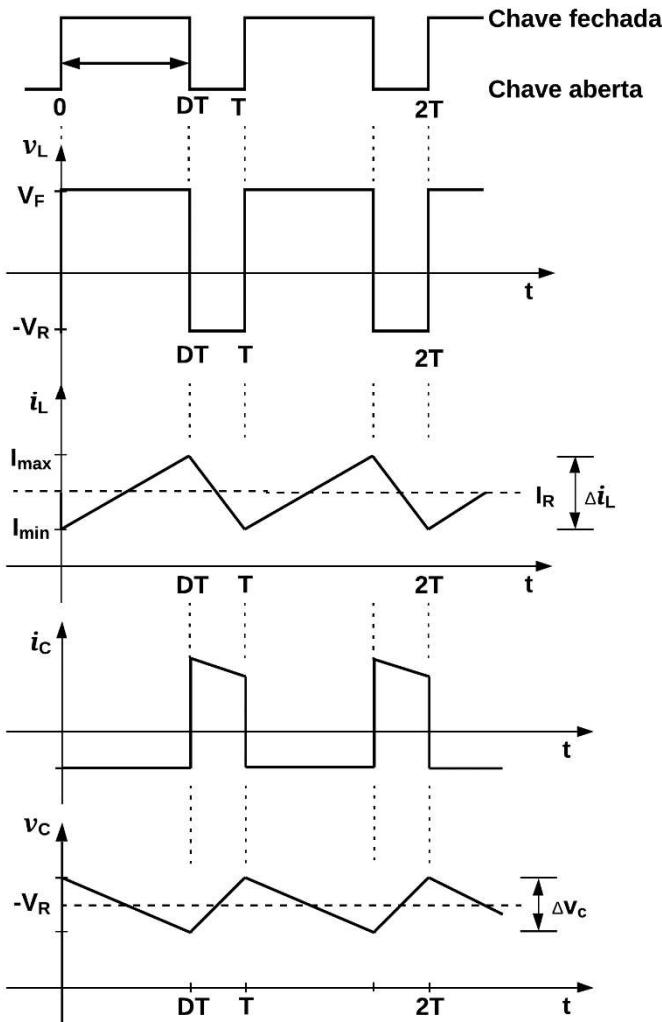


Figura 2.19. Comutação da chave de um conversor CC-CC *buck-boost* e o consequente comportamento da tensão e corrente no indutor, corrente e tensão no capacitor e na carga.

Fonte: Adaptado de (AHMED, 2000)

Analizando a Figura 2.19, observa-se que a corrente no indutor cresce linearmente enquanto o indutor permanece conectado à tensão da fonte (mostrando que está em estágio de carregamento). Em contrapartida, ela decresce quando a fonte é desconectada e o indutor passa a se comportar como fonte de tensão para a carga e ambos ficam com a mesma tensão.

Observando ainda o comportamento do capacitor da Figura 2.19, a corrente i_C permanece praticamente constante durante o tempo que a chave fica fechada, visto que sua capacidade é tão grande que a carga não consegue descarregá-la, embora sua tensão v_C caia linearmente. Por outro lado, quando a chave abre, o indutor volta a carregar o capacitor. Assim, a corrente do capacitor decresce gradualmente, ao mesmo tempo que a tensão aumenta.

Para o conversor *buck-boost*, Ahmed (2000) e Hart (2012) afirmam que o valor médio da corrente do indutor corresponde ao valor da corrente da carga, ao passo que a tensão na carga

é igual a tensão no capacitor. Dessa forma, é possível controlar a tensão na carga apenas variando o Ciclo de Trabalho (D), também denominado de taxa de trabalho.

O Ciclo de Trabalho (D) corresponde a fração de período de chaveamento em que a chave permanece fechada, independentemente se o conversor está trabalhando no MCC ou MCD (HART, 2012).

Sabendo disso e realizando as devidas manipulações matemáticas, os autores encontram uma relação entre o ciclo de trabalho da chave comutadora e as tensões de entrada e saída do conversor *buck-boost*, expresso pela Equação (13).

$$V_R = -V_F \left(\frac{D}{1 - D} \right) \quad (13)$$

Onde:

V_R = Tensão na carga, que corresponde a tensão de saída (V);

V_F = Tensão da fonte, que corresponde a tensão de entrada (V);

D = Ciclo de trabalho da chave comutadora do conversor CC-CC, que varia entre 0 e 1.

É válido ressaltar que, normalmente, a frequência de operação da chave (ou seja, o período) é mantida constante e a largura do pulso é que varia em função de D . Esse processo é conhecido como Modulação por Largura de Pulso (PWM, do inglês *Pulse Width Modulation*). (MCEVOY; MARKVART; CASTAÑER, 2012).

Pela Equação (13), percebe-se que a tensão de saída do conversor *buck-boost* sempre terá a polaridade invertida com relação a fonte, similar ao visto na Figura 2.18. Também se nota que a magnitude da tensão de saída (que é similar a V_R) pode ser menor, igual ou maior que a tensão da fonte, dependendo do D da chave comutadora do conversor *buck-boost*.

Quando D é menor que 0,5, a saída é menor que a entrada, logo o conversor se assemelha ao *buck*. Se D for maior que 0,5, a tensão de saída será maior que a da fonte, similar ao conversor *boost*. Para a tensão de entrada ser igual a tensão de saída, o D deve ser exatamente 0,5.

Além do cálculo de D , no projeto de um conversor *buck-boost* também é importante dimensionar adequadamente os componentes L e C . Afinal, o indutor (L) determina se o conversor trabalhará no MCC ou MCD, bem como influencia na variação de pico a pico da corrente do indutor (Δi_L), ao passo que o capacitor (C) tem relação direta com a ondulação da tensão de saída (Δv_R), ou seja, a tensão no resistor (HART, 2012).

Assim, após calcular o D do conversor *buck-boost* e estabelecer a frequência de chaveamento (f) desejada, o valor mínimo de indutância que o indutor deve ter para que o conversor *buck-boost* trabalhe no MCC pode ser dimensionado pela Equação (14).

$$L_{\min} = \frac{(1 - D)^2 \cdot R}{2 \cdot f} \quad (14)$$

Onde:

L_{\min} = Indutância mínima necessária para o MCC (H);

R = Resistência da carga (Ω);

f = Frequência de chaveamento (Hz).

Além da Equação (14), Hart (2012) também apresentou a Equação (15), que é responsável por dimensionar o capacitor de modo a atender aos critério de ondulação máxima admissível na tensão de saída do conversor. Essas tensões podem ser diretamente relacionadas, pois, a tensão de saída do conversor é igual a tensão no capacitor.

$$C = \frac{D \cdot V_R}{R \cdot \Delta V_R \cdot f} \quad (15)$$

Onde:

C = Capacitância do capacitor (F);

L = Indutância do indutor (H);

ΔV_R = Variação de pico a pico na tensão de saída (V);

V_R = Tensão de saída (V).

Quando se trabalha com sistemas fotovoltaicos, McEvoy, Markvart e Castañer (2012) explicam que geralmente também é inserido um capacitor entre o arranjo fotovoltaico e o conversor CC-CC. Esse capacitor trabalha como um filtro e é responsável por extrair uma corrente razoavelmente constante do arranjo FV.

Em geral, a capacitância calculada na Equação (15) também pode ser usada como valor de referência para o capacitor inserido na entrada do conversor *buck-boost*. Porém, esse valor é apenas uma referência inicial de projeto, logo pode sofrer modificações.

Também quando aplicado à sistemas fotovoltaicos, Coelho e Martins (2012) explicam que os conversores CC-CC, cuja função é fornecer a máxima potência à carga independente das condições ambientais, precisam regular a impedância vista pela fonte de alimentação. Essa impedância tem relação com o D e a carga conectada na saída.

Para isso, é fundamental estabelecer os limites de operação do conversor *buck-boost*. Afinal, quando um MPP do arranjo FV não está dentro da região de operação do conversor, a utilização desse conversor para o MPPT não é suficiente para que o arranjo FV sempre opere com sua máxima eficiência.

Conceitualmente, a região de operação corresponde a área de varredura dentro da curva característica I-V de um arranjo FV que o conversor consegue trabalhar e fornecer a potência

desejada à carga. De modo geral, essa potência desejada é a máxima e, por isso, diz que o conversor trabalha como elemento do MPPT. Os limites dessa área está diretamente relacionado com o ângulo de inclinação da curva característica I-V da carga (COELHO; MARTINS, 2012).

Sabendo disso, para calcular os limites da região de operação de um conversor CC-CC, primeiramente é necessário analisar a interpolação entre as curvas características I-V do arranjo FV e da carga. Porém, nessa análise, deve ser considerada como carga, a resistência equivalente total vista nos terminais do arranjo FV (COELHO; MARTINS, 2012).

Para isso, os autores deduziram o valor dessa resistência considerando um sistema ideal, em que toda a potência fornecida pela fonte é absorvida pela carga. Com isso, a resistência equivalente total vista pelo arranjo FV foi obtida através de uma relação entre a resistência da carga e o ciclo de trabalho do conversor CC-CC, conforme mostra a Equação (16).

$$R_{FV} = \frac{(1 - D)^2 \cdot R}{D^2} \quad (16)$$

Onde:

R_{FV} = Resistência equivalente total vista nos terminais do arranjo FV (V).

Posteriormente, sabendo que a inclinação da curva característica I-V de uma carga é influenciada pelo seu valor da resistência, o ângulo de inclinação da curva característica I-V da carga vista pelo arranjo FV pode ser obtido pela Equação (17).

$$\theta_{FV} = \tan^{-1} \left(\frac{1}{R_{FV}} \right) = \tan^{-1} \left(\frac{D^2}{(1 - D)^2 \cdot R} \right) \quad (17)$$

Onde:

θ_{FV} = Ângulo de inclinação da curva característica I-V da carga vista pelo arranjo FV ($^{\circ}$).

Analizando a Equação (17), o ângulo de inclinação da curva característica I-V é influenciado pela carga e pelo ciclo de trabalho do conversor. Assim, sabendo que o D tem limites teóricos entre 0 e 1, o ângulo θ_{FV} será 0° , quando D for zero (limite inferior) e, 90° , quando D for 1 (limite superior). Desta forma, o ciclo de trabalho do conversor *buck-boost* consegue varrer todo o quadrante da Figura 2.20.

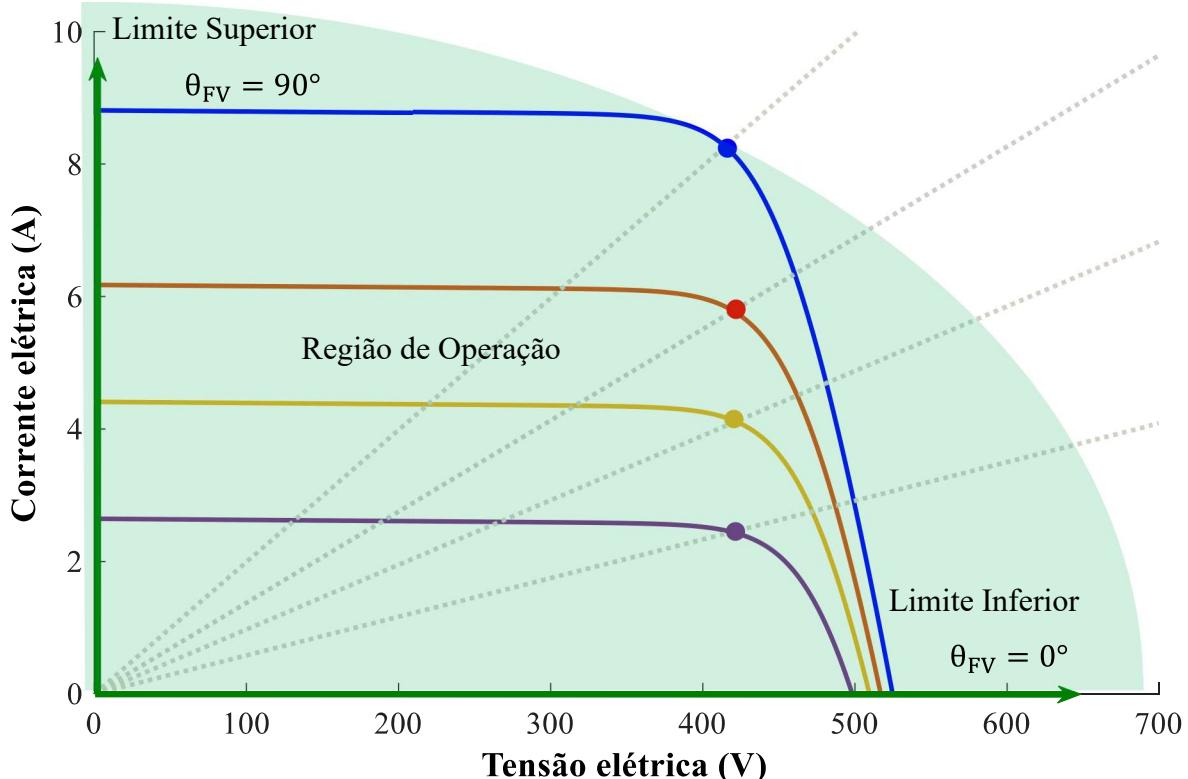


Figura 2.20. Região de operação do conversor *buck-boost* operando como MPPT
Fonte: Adaptado de (COELHO; MARTINS, 2012)

Como pode ser visto na Figura 2.20, o conversor *buck-boost* não possui região proibida. Por conta disso, utilizar esse conversor como elemento do MPPT permite que o sistema opere no MPP independente das condições de irradiância e temperatura de operação das células FV.

Porém, apenas estar dentro da região de operação não garante que o sistema esteja trabalhando no MPP, visto que, ao modificar a irradiância e a temperatura, o MPP também muda. Logo, para garantir que o MPP seja sempre alcançado, é fundamental que a carga vista pelo arranjo FV também possa variar de modo a garantir que a interceptação entre as curvas I-V seja sempre no MPP.

Devido a capacidade que o conversor CC-CC tem de variar a resistência equivalente total vista pelo arranjo FV (Equação (16)) e seu ângulo de inclinação (Equação (17)), é possível afirmar que o conversor usado no MPPT trabalha como uma resistência variável no sistema FV (CARVALHO NETO, 2016).

Sabendo ainda que o ângulo θ_{FV} varia com R e com D , então, caso a carga acoplada na saída seja fixa, o ciclo de trabalho do conversor é a variável responsável por garantir que a máxima potência gerada pelo arranjo FV seja fornecida à carga.

Desta forma, após apresentar o conversor CC-CC usado no presente trabalho e estabelecer a região em que eles podem atuar, conhecer as técnicas de controle que permitem variar o D do conversor até que o MPP seja interceptado pela carga também é necessário.

O controle do chaveamento desses dispositivos é normalmente realizado através de um sistema de controle associado ao conversor CC-CC. Juntos, eles são capazes de extraír a máxima potência que pode ser gerada pelos módulos FV e, desta forma, obter o melhor rendimento do sistema FV. O sistema de controle, conhecido como Rastreamento do Ponto de Máxima Potência (MPPT), é tratado na Subseção 2.6.3.

2.6.3 Rastreador do ponto de máxima potência

O rastreador do ponto de máxima potência, também conhecido como Seguidor do Ponto de Potência Máxima (SPPM), é responsável por garantir que os módulos FV operem em seu ponto de máxima potência independente das condições de operação, como as condições ambientais (VILLALVA; GAZOLI, 2012).

Conforme foi tratado na Seção 2.4, o ponto de operação em que é obtida a máxima potência dos módulos FV sofre variações com as mudanças ambientais, principalmente, com a irradiação solar e a temperatura. Então, para tentar manter os módulos FV operando na tensão que corresponde à tensão da máxima potência e elevar ao máximo a produção de energia, o sistema de MPPT, juntamente com seu rastreador, é utilizado como mecanismo de controle eletrônico que atua sob os conversores CC-CC, inversores ou controladores de carga. Sendo a primeira opção a mais comum (PINHO; GALDINO, 2014).

SMETS et al. (2016) ressaltam que o sistema de MPPT não é um componente real, mas sim, técnicas de controle que são implementadas no *driver* dos dispositivos de chaveamento em que ele atua através de um algoritmo. Essa implementação pode ser feita de forma analógica ou digital, sendo a segunda opção a mais comum, principalmente, através dos microprocessadores.

Pinho e Galdino (2014) ainda complementam que os algoritmos de controle do sistema de MPPT devem apresentar características de precisão (qualidade na medição de corrente e tensão), eficácia (capacidade de encontrar o MPP) e rapidez (adaptabilidade, com alta velocidade, às variações bruscas nas condições ambientais).

Por conta disso, muitas técnicas para rastrear o MPP têm sido desenvolvidas e estão sendo estudadas, sempre com o objetivo de otimizar a extração da potência dos módulos FV. Essas técnicas serão abordadas com maior detalhamento na Seção 2.7.

De modo geral, um algoritmo de controle do sistema de MPPT tem como entrada os dados instantâneos de tensão e corrente que os módulos FV estão operando, ou parâmetros como irradiação solar, temperatura de operação da célula e/ou temperatura ambiente. E, como saída, o sistema MPPT normalmente fornece a frequência de chaveamento do dispositivo em que ele atua, seja o conversor CC-CC (da Subseção 2.6.2), o controlador de carga ou o inversor.

Assim sendo, na literatura existem diversas técnicas para controlar o ciclo de trabalho do conversor CC-CC do sistema FV, cujo objetivo é atingir o MPP com maior velocidade e precisão, e menores oscilações em seu regime permanente. Isto posto, a Seção 2.7 apresenta algumas técnicas utilizadas para rastrear o ponto de máxima potência dos arranjos FV.

2.7 Técnicas de Rastreamento do ponto de máxima potência (MPPT)

O Rastreamento do Ponto de Máxima Potência (MPPT) permite que os arranjos FV forneçam toda a energia que são capazes de gerar independentemente das variações na irradiação e temperatura de operação das células FV. O sistema de MPPT é composto pelo conversor CC-CC (discutido na Subseção 2.6.2) e por uma técnica que controla o ciclo de trabalho da chave comutadora desse conversor CC-CC (KHATIB; ELMENREICH, 2016).

Coelho (2008) esclarece que, com o surgimento dos microcontroladores e Processadores Digitais de Sinais (DPS, do inglês, *Digital Signal Processor*), foi possível desenvolver técnicas mais complexas e capazes de melhorar a velocidade e a precisão do rastreamento. O autor ainda explica que as técnicas de MPPT podem ser aplicadas analiticamente ou digitalmente.

No modo analógico, normalmente amplificadores operacionais, circuitos lógico-digitais e circuitos integrados específicos são utilizados na implementação. O principal problema apontado para a implementação analógica está na necessidade da troca de componentes caso seja preciso alterar a técnica de rastreamento. Esse problema pode ser sanado ao optar pelo modo digital, pois a técnica de MPPT pode ser alterada apenas mudando o código fonte do *software* utilizado (COELHO, 2008).

Assim sendo, nas últimas décadas, muitas técnicas de controle que auxiliam no rastreamento do MPP foram desenvolvidas. De modo geral, elas se diferenciam em aspectos, como: número de sensores utilizados, complexidade, custo, velocidade e precisão em rastrear o MPP, estabilidade no regime permanente, popularidade e *hardware* necessário para implementação (SUMATHI; ASHOK KUMAR; SUREKHA, 2015).

Como o presente trabalho tem como objetivo desenvolver técnicas de MPPT baseada nos algoritmos inteligentes, as Subseções 2.7.1, 2.7.2 e 2.7.3 abordarão com maior profundidade, respectivamente, a técnica de MPPT clássica mais difundida (P&O), as duas técnicas de inteligência artificial mais discutidas na literatura (RNA e FL) e a técnica otimizada ANFIS, que é baseada na união dos algoritmos inteligentes RNA e FL.

2.7.1 Técnica clássica Perturba e Observa (P&O)

A técnica clássica Perturba e Observa (P&O) têm o algoritmo P&O compondo o sistema de controle do MPPT. Ela é a técnica mais utilizado devido a sua estrutura simples, baixo esforço computacional e seu bom desempenho quando a irradiação é constante (KHATIB; ELMENREICH, 2016). O algoritmo P&O atua perturbando o sistema FV através de um incremento na tensão do arranjo FV e observando o impacto na potência de saída. Se o aumento da tensão elevar a potência de saída, significa que o ponto de operação do sistema FV está mais baixo que o MPP. Logo, mais incremento na tensão será necessária para atingir o MPP.

Por outro lado, se ao elevar a tensão, a potência de saída cair, o algoritmo precisa decrementar a tensão para alcançar o MPP. A Figura 2.21 ilustra como o P&O atua na curva característica P-V de um arranjo FV e a Figura 2.22 mostra um fluxograma que resume o funcionamento do algoritmo da técnica P&O.

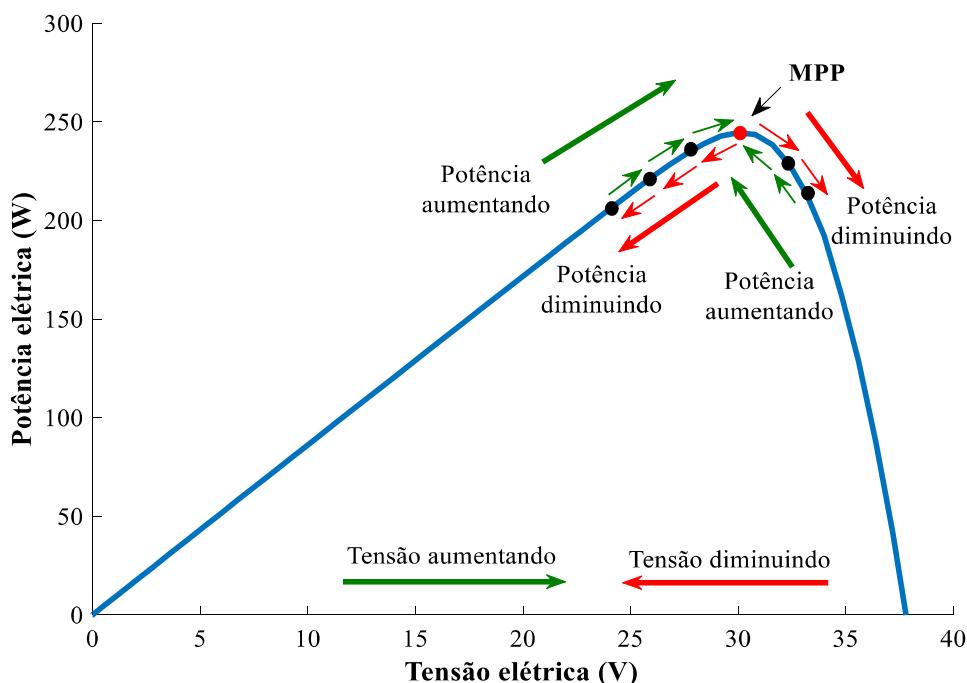


Figura 2.21. Funcionamento de um MPPT baseado no P&O

Fonte: Adaptado de (VILLALVA; GAZOLI, 2012)

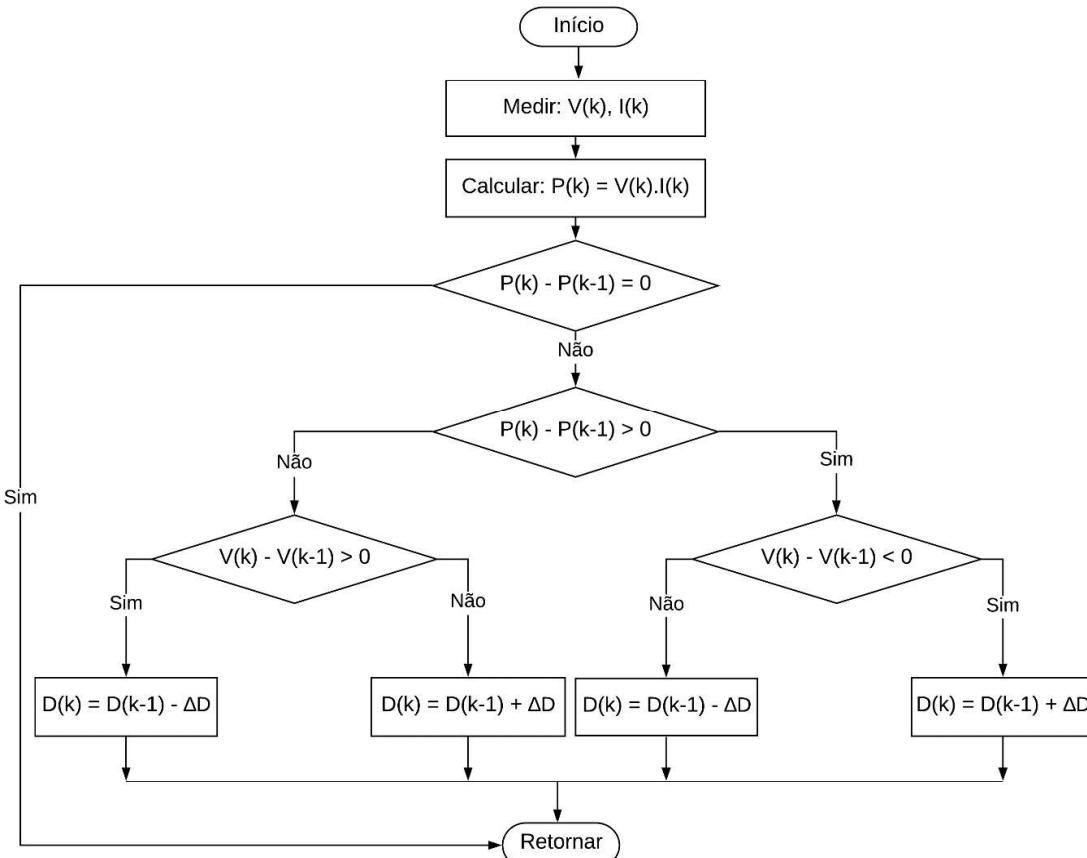


Figura 2.22. Fluxograma do algoritmo P&O como técnica de MPPT
Fonte: Adaptado de (YAHYOUI, 2018)

Analizando a Figura 2.22, nota-se que o P&O controla o sistema através do ciclo de trabalho do conversor CC-CC. O algoritmo inicia medindo a primeira amostra de tensão e corrente oriundas do arranjo FV, e calcula sua respectiva potência. Depois do primeiro incremento ΔD , uma segunda amostra de tensão e corrente é medida, e uma nova potência é calculada. Posteriormente, a diferença entre a potência da segunda e primeira amostra é calculada. Caso a diferença entre as potências seja positiva, significa que a potência aumentou, por isso a tensão deve continuar aumento, então mais uma vez é incrementando a constante ΔD no ciclo de trabalho do conversor CC-CC. Por outro lado, se a diferença entre as potências for negativa, entende-se que a potência reduziu, consequentemente, a tensão deve diminuir. Isso é feito através do decremento da constante ΔD no ciclo do trabalho do conversor CC-CC.

Khatib e Elmenreich (2016) explicam que a constante ΔD representa o passo de perturbação e sua escolha está diretamente relacionada ao que se almeja com o MPPT. Um grande passo, por exemplo, permite que o sistema FV tenha uma resposta que atinge o MPP rapidamente, mas que apresenta altas oscilações em torno dele. Por outro lado, um passo

pequeno proporciona uma resposta mais lenta, todavia com baixas oscilações em torno do MPP durante o regime permanente. A Figura 2.23 ilustra o efeito da constante ΔD na resposta de um sistema FV. A resposta em azul tem um ΔD muito menor que o ΔD da resposta em vermelho.

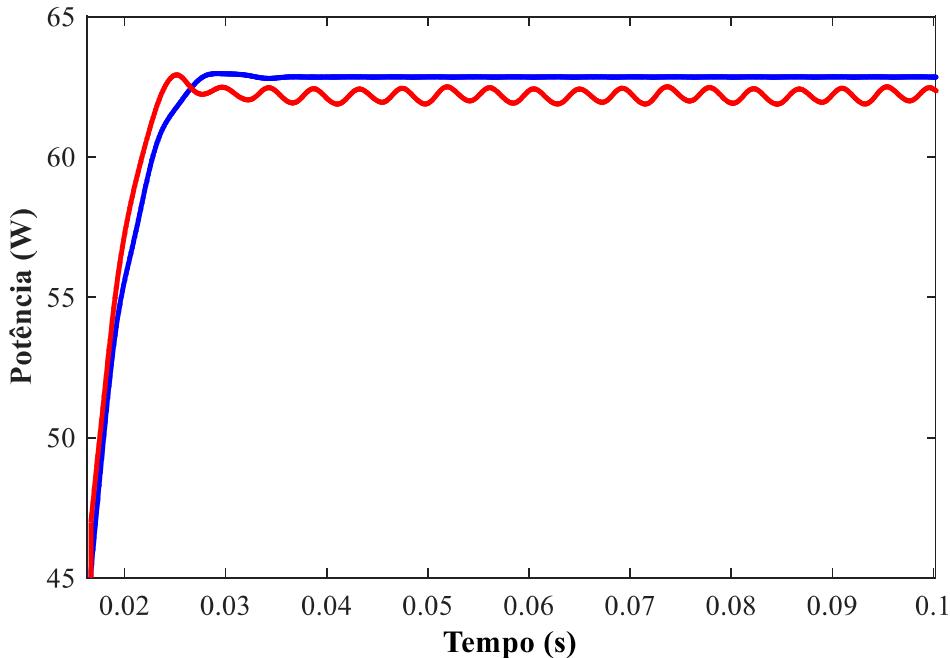


Figura 2.23. Resposta de um sistema FV à diferentes constantes ΔD de um algoritmo P&O
Fonte: Autoria própria

Devido a técnica clássica P&O basear-se no princípio de subida de morro (*hill climbing*⁵), suas duas grandes vantagens são sua simplicidade e não requer um conhecimento prévio das características do arranjo FV. Em contrapartida, apresenta como principal desvantagem a oscilação do ponto de operação em torno do MPP, o que desperdiça uma parcela da energia disponível pelo arranjo FV (YAHYAOUI, 2018).

Um segundo ponto negativo apontado por Smets *et al.* (2016) é a dificuldade que o método tem em rastrear o MPP sob mudanças rápidas de irradiação. Os autores explicam que caso a irradiação sofra variação no intervalo entre duas amostragens, o algoritmo pode falhar dependendo do ΔD atribuído, visto que pode não conseguir entender que não foi sua perturbação que possibilitou a elevação ou redução da potência, mas sim a condição do ambiente. Com isso, um falso comando é dado pelo algoritmo e o ponto de operação, no lugar de se aproximar, irá se afastar do MPP.

⁵ Otimização matemática que busca a melhora de um sistema incrementando a variável de processo. Se o incremento produzir uma melhor solução, ele é repetido até que não seja possível encontrar mais melhorias. É válido ressaltar que na literatura há alguns autores que definem o *Hill Climbing* como uma técnica diferente da P&O. Como a discussão não é o foco do presente trabalho, considera-se a relação entre as técnicas (SILVA, 2019).

Embora os problemas apresentados não invalidem o P&O de ser usada como algoritmo de controle do MPPT, outras técnicas foram desenvolvidas e elas foram capazes de minimizar as desvantagens supracitadas. Um exemplo são as técnicas que utilizam a inteligência artificial discutidas na Subseção 2.7.2.

2.7.2 Técnicas de Inteligência Artificial (IA)

Nos últimos anos, os algoritmos baseados na Inteligência Artificial (IA) têm se difundido no âmbito da energia fotovoltaica, seja para projetar, modelar, prever ou otimizar o sistema de energia. Isso se deve ao fato da IA apresentar técnicas capazes de lidar com a não linearidade, complexidade e incertezas dos sistemas, muitas vezes através de soluções robustas e de baixo custo (SUMATHI; ASHOK KUMAR; SUREKHA, 2015).

Os autores ainda acrescentam que, dentre as aplicabilidades dos algoritmos de IA, o seu uso para rastreamento de MPP em sistemas fotovoltaicos é muito utilizado, sendo a RNA e a lógica *fuzzy* os sistemas inteligentes mais populares.

Sabendo disso, as Subseções 2.7.2.1 e 2.7.2.2 tratam respectivamente da RNA e FL como algoritmos de controle do MPPT aplicados à sistemas FV.

2.7.2.1 Rede Neural Artificial (RNA)

A Rede Neural Artificial (RNA) é um modelo computacional que tem a habilidade de realizar cálculos comuns utilizando como referência o sistema nervoso dos seres vivos e o cérebro humano. Em outras palavras, esse modelo usa um processo de aprendizagem para entender sobre seu ambiente apenas utilizando informações anteriores aplicados em neurônios artificiais (SUMATHI; ASHOK KUMAR; SUREKHA, 2015).

Esses neurônios artificiais utilizados em uma RNA são não lineares e realizam atividades simples, como coletar os sinais existentes em suas entradas, agrupá-los conforme sua função de operação e desenvolver uma resposta considerando sua função de ativação. Em geral, a resposta fornecida pelo neurônio são saídas contínuas (SILVA; SPATTI; FLAUZINO, 2016). A Figura 2.24 ilustra o esquema de um neurônio artificial inserido na RNA e composto por sete elementos básicos.

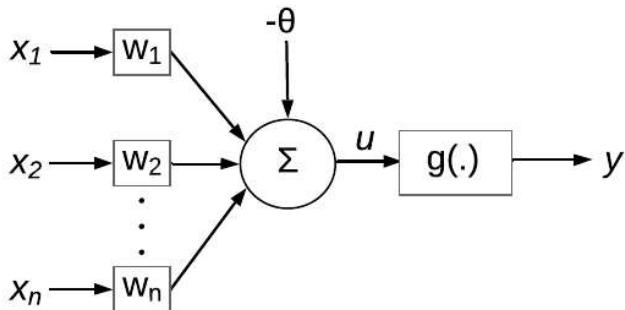


Figura 2.24. Esquema de um neurônio artificial

Fonte: Adaptado de (SILVA; SPATTI; FLAUZINO, 2016)

No neurônio artificial da Figura 2.24, os sinais de entrada recebidos do meio externo são representados pelo conjunto $\{x_1, x_2, \dots, x_n\}$. Esses sinais são multiplicados pelos pesos sinápticos correspondentes $\{w_i\}$, quantificando assim a relevância de cada entrada. Em seguida, o potencial de ativação $\{u\}$ pode ser obtido através da soma ponderada de todas as entradas, subtraído do limiar de ativação $\{\theta\}$, também conhecido como *bias*. Posteriormente, uma função de ativação ($g(u)$) é aplicada ao potencial de ativação para, finalmente, limitar a saída $\{y\}$ do neurônio (SILVA; SPATTI; FLAUZINO, 2016).

As Equação (18) e Equação (19) simplificam o resultado produzido por um neurônio artificial.

$$u = \sum_{i=1}^n w_i \cdot x_i - \theta \quad (18)$$

Onde:

u = Potencial de ativação;

w_i = Peso sináptico i ;

x_i = Sinal de entrada i ;

θ = Limiar de ativação.

$$y = g(u) \quad (19)$$

Onde:

y = Sinal de saída;

$g(u)$ = Função de ativação de u

Silva, Spatti e Flauzino (2016) esclarecem que uma RNA é composta por um conjunto de neurônios, que são organizados conforme propósito de uso. Eles ainda explicam que a maneira como os neurônios estão organizados um em relação ao outro, por exemplo, define a arquitetura da RNA. Por outro lado, a topologia da RNA é estabelecida por meio dessa arquitetura, do número de neurônios existentes em cada camada, bem como pela função de

ativação logística utilizada, sendo as funções logística, gaussiana, linear e tangente hiperbólica as mais comuns. Outra característica de uma RNA é o algoritmo de aprendizagem utilizado, pois ele sintoniza a rede de maneira que as respostas sejam próximas dos valores pretendidos.

A arquitetura, a topologia e o algoritmo de aprendizagem são aspectos que definem as características específicas de cada rede, por isso sua escolha varia conforme a aplicabilidade. No caso do uso da RNA como algoritmo de MPPT, as principais características almejadas são sua capacidade de aprendizagem com exemplos, ou seja, por experimentação, por sua habilidade de generalização, pela adaptabilidade e por sua tolerância à falhas (SILVA, 2019).

Assim, dentre as arquiteturas apresentadas na literatura, a arquitetura RNA mais utilizada como algoritmo de MPPT é uma *feedforward* (alimentação à frente) de camadas múltiplas, especificadamente, a rede *Perceptron* de Múltiplas Camadas (MLP, do inglês, *Multilayer Perceptron*).

A estrutura básica de uma MLP é composta por, pelo menos, três camadas, que são: a camada de entrada; a camada escondida ou oculta; e a camada de saída. A Figura 2.25 ilustra uma rede MLP generalista.

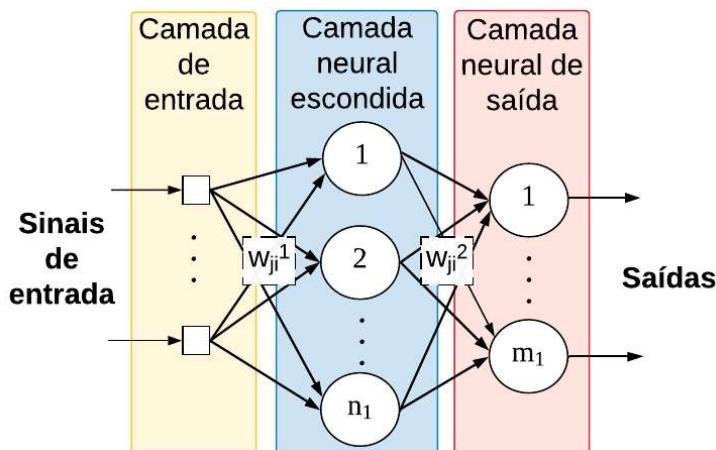


Figura 2.25. Rede MLP

Fonte: Adaptado de (SILVA; SPATTI; FLAUZINO, 2016)

A camada de entrada da Figura 2.25 é responsável pelo recebimento de informações oriundas do meio externo e posterior normalização para melhorar a eficiência computacional do algoritmo de aprendizagem. Já na camada escondida é onde ocorre quase todo o processo de aprendizagem, pois é nessa camada que ficam os neurônios artificiais (Figura 2.24) incumbidos de codificar e formar uma caracterização própria do ambiente em que o sistema encontra-se. É válido ressaltar que quanto mais complexo o sistema, mais neurônios e/ou mais camadas escondidas terão a rede e, consequentemente, mais complexo fica o algoritmo. Por fim, na camada de saída, os resultados da rede são produzidos e apresentados (SIMÕES; SHAW, 2007).

Ainda na Figura 2.25, o w_{ji}^1 e w_{ji}^2 , que aparecem no esquema, representam as matrizes de peso, responsável por quantificar os pesos sinápticos e limiares entre neurônios de duas camadas distintas. Esses pesos devem ser ajustados até as saídas produzirem uma solução generalizada que representem o sistema física estudado (SILVA; SPATTI; FLAUZINO, 2016).

No caso da rede MLP, o ajuste dos pesos e do limiar de ativação de cada um dos neurônios são feitos através de um processo de treinamento supervisionado utilizando um algoritmo de aprendizagem, como o *backpropagation*, que também é denominado de algoritmo de retroprogramação do erro ou regra Delta generalizada. O treinamento supervisionado é caracterizado por ter amostras de sinais de entrada e de suas respectivas saídas. Nesse caso, a rede será considerada treinada quando a defasagem entre as respostas produzidas pela RNA e as desejadas baseadas nas amostras estão dentro de um valor aceitável.

Especificadamente com o algoritmo *backpropagation*, primeiramente os sinais de uma amostra são inseridos nas entradas da rede e propagadas por cada camada até a saída ser produzida. Essa etapa é definida como *forward* (propagação adiante). Sequencialmente, ocorre a fase *backward* (propagação reversa), em que o sinal de volta é propagado para diminuir o erro. Assim sendo, nessa etapa, cada resposta produzida pelas saídas é comparada com as respectivas respostas desejadas. Com isso, os erros quadráticos obtidos entre as respostas e a repetição sucessiva das etapas permitirão sintonizar os pesos e limiares da rede MLP.

A repetição encerra quando o algoritmo converge (Equação (22)), ou seja, quando o erro quadrático médio entre duas épocas sucessivas for suficientemente pequeno (Equação (20) e Equação (21)) e atenda a precisão requerida para o sistema.

$$E(k) = \frac{1}{2} \sum_{j=1}^{m_1} (d_j(k) - Y_j(k))^2 \quad (20)$$

Onde:

$E(k)$ = Erro quadrático entre duas épocas sucessivas;

$Y_j(k)$ = Valor produzido pelo j-ésimo neurônio de saída da rede considerando a k-ésima amostra de treinamento;

$d_j(k)$ = Valor desejado para $Y_j(k)$.

$$E_M = \frac{1}{p} \sum_{k=1}^p E(k) \quad (21)$$

Onde:

E_M = Erro quadrático médio atual entre duas épocas;

p = Número de amostras do conjunto de treinamento.

$$|E_M^{atual} - E_M^{anterior}| \leq \varepsilon \quad (22)$$

Onde:

ε = precisão requerida;

E_M^{atual} = Erro quadrático médio atual entre duas épocas, calculado usando a Equação (21);

$E_M^{anterior}$ = Erro quadrático médio anterior entre duas épocas, calculado usando a Equação (21).

Silva, Spatti e Flauzino (2016) explicam que o algoritmo *backpropagation* converge lentamente, pois ajustam os valores das matrizes de peso através do método de descida no gradiente da função erro quadrático de primeira ordem. Por isso, é comum o método de Levenberg-Marquardt ser utilizado para acelerar o processo de repetição do algoritmo *backpropagation* e reduzir o esforço computacional, visto que ele é um método gradiente de segunda ordem baseado no método dos mínimos quadrados para modelos não lineares.

Na Figura 2.26, um fluxograma do processo de treinamento da rede MLP é mostrado.

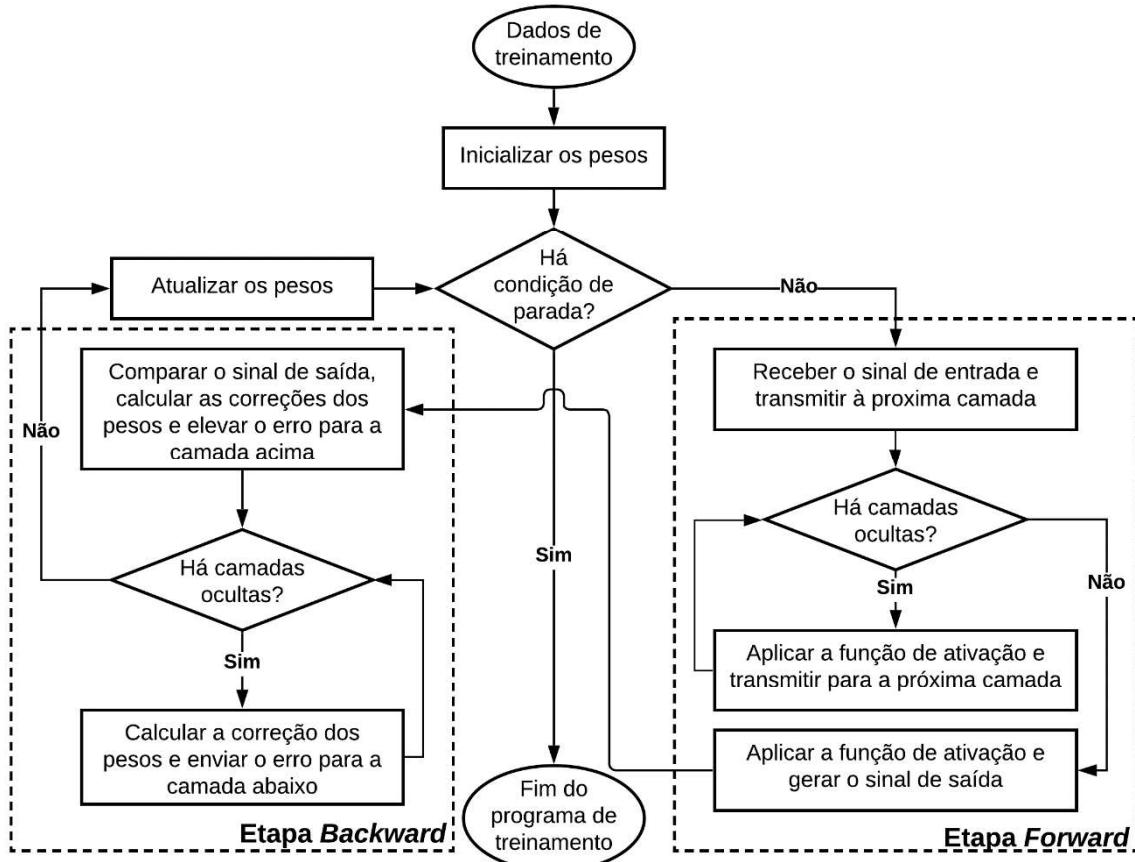


Figura 2.26. Fluxograma de treinamento de uma rede MLP

Fonte: Adaptado de (SILVA, 2019)

Embora não apresentado no fluxograma da Figura 2.26, Silva, Spatti e Flauzino (2016) ressaltam que a variável época também pode ser um critério de parada do algoritmo, sobretudo

quando o erro desejado torna-se inatingível. A época representa o número de vezes que o algoritmo de aprendizagem precisou realizar as suas duas etapas (*forward* e *backward*) para ajustar suas matrizes de peso até a rede ser considerada treinada.

Quando utilizado como algoritmo MPPT de sistemas FV, Sumathi, Ashok Kumar e Surekha (2015) informam que as RNA são bem adaptadas à serem implementadas em microcontroladores. Além disso, por serem extremamente paralelas, são capazes de executar rapidamente várias operações simultâneas. Assim, quando bem treinadas, o MPPT baseado na RNA apresenta alta velocidade de rastreamento, alta precisão, boa eficiência e menores flutuações que o P&O nas mudanças das condições ambientais (RIZZO; SCELBA, 2015).

No entanto, antes do treinamento, é necessário determinar os parâmetros da RNA. Primeiramente, as variáveis de entrada da rede MLP devem ser escolhidas e elas podem ser dados ambientais, como irradiação e temperatura ambiente; dados do arranjo FV, como T_{CELL} , I_{FV} e V_{FV} ; ou a combinações de qualquer uma dessas. Posteriormente, determina-se a saída, que normalmente está relacionado à sinais de referência, como o ciclo de trabalho do conversor CC-CC ou a V_{MPP} do arranjo FV (SUMATHI; ASHOK KUMAR; SUREKHA, 2015).

Após estabelecido os dados de entrada e saída, e conhecendo os critérios de projeto pretendidos, o programador pode determinar os parâmetros da RNA, tais como: número de camadas ocultas, número de neurônios, funções de ativação e critério de parada do algoritmo. Tais parâmetros influencia diretamente na qualidade de treinamento da rede, ou seja, quanto rápido e próximo ao MPP o ponto operacional do sistema FV consegue alcançar (SUMATHI; ASHOK KUMAR; SUREKHA, 2015).

Rezvani *et al.* (2015) acrescentam que a qualidade de treinamento de uma RNA também são fortemente dependentes do número e da seleção preliminar dos dados de treinamento, visto que o aprendizado de uma rede ocorre através de experimentação. Com isso, para uma boa precisão, muitos dados de treinamento são requeridos. Todavia, nem sempre isso é possível e um problema de imprecisão do MPP pode surgir.

Acerca do treinamento, um inconveniente do uso da RNA como algoritmo de MPPT está no fato da maioria dos sistemas FV terem características peculiares. Dessa maneira, cada sistema FV terá uma RNA treinada especificadamente para ela, normalmente não podendo ser reaproveitada para outro sistema. Além disso, como os módulos FV se degradam com um tempo, a RNA precisa ser retreinada periodicamente para que a precisão do MPPT seja garantida (SUMATHI; ASHOK KUMAR; SUREKHA, 2015).

Um outro problema que uma RNA pode apresentar é generalizar sua saída erroneamente. Esse infortúnio ocorre quando, durante seu treinamento, a matriz de pesos da RNA é direcionada para um ponto de mínimo local inapropriado. A presença de pontos de mínimos locais existe devido a superfície de erro da rede MLP não ser linear (SILVA; SPATTI; FLAUZINO, 2016).

A Figura 2.27 ilustra a superfície de erro de uma RNA com pontos de mínimos locais. Percebe-se que, se a rede tiver sua matriz de pesos iniciada em $W^{(a)}$, a tendência de convergência seria para o ponto de mínimo $p^{(1)}$. Mas, caso começasse em $W^{(b)}$, a convergência tenderia para $p^{(2)}$. Isto significa que a tendência de convergência para um ponto de mínimo específico depende, principalmente, da posição espacial em que a matriz de pesos W foi iniciada.

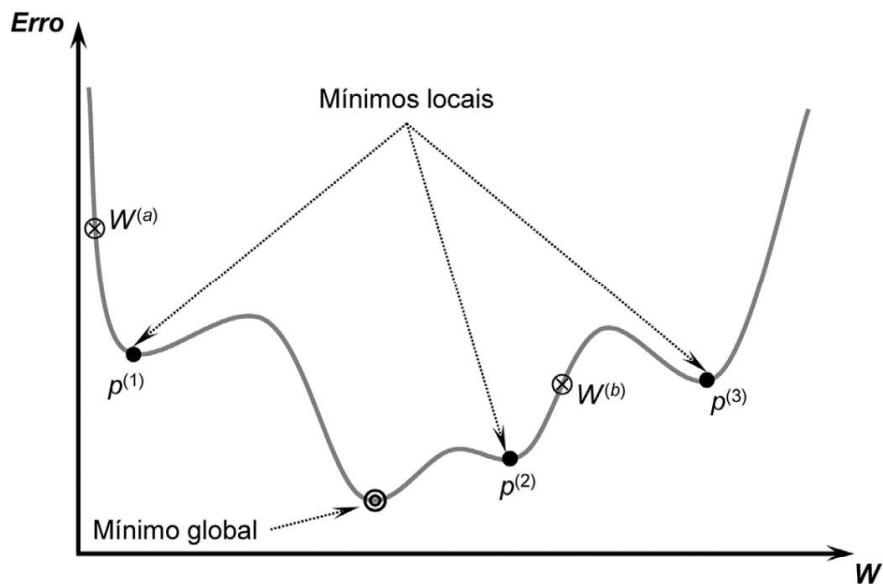


Figura 2.27. Ponto de mínimos locais associados à função erro
Fonte: Adaptado de (SILVA; SPATTI; FLAUZINO, 2016)

Como solução para o problema de mínimos locais indesejados, Silva, Spatti e Flauzino (2016) aconselham treinar a topologia de rede escolhida mais de uma vez. Afinal, dependendo das posições espaciais da matriz de peso (em alguns casos geradas aleatoriamente), a rede pode convergir para o mínimo global ou para mínimos locais mais próximos possíveis do global e, então, ter uma melhor representação do comportamento do processo.

Assim, caso o problema de mínimos locais seja sanado, a RNA utilizada como algoritmo de controle consegue convergir para o mínimo global e, consequentemente, o correto MPP é encontrado mesmo em situações em que o arranjo FV está sombreado, por exemplo.

Finalmente, Simões e Shaw (2007) frisam que, após treinada à RNA, outro estorvo detectado é a impossibilidade de traçar o modo que a rede chegou àquela solução e, assim, não

ser capaz de interpretar as causas de um comportamento particular da rede ou ajustar manualmente a estrutura dessa rede. Tais dificuldades, na maioria das vezes, não aparecem quando a lógica *fuzzy*, da Subseção 2.7.2.2, é usada como algoritmo de controle do MPPT.

2.7.2.2 Lógica *fuzzy* (FL)

A FL, também conhecida como lógica nebulosa ou teoria das possibilidades, é um método capaz de inserir a forma humana de pensar em um sistema de controle. Para isso, a FL tem como principal aspecto a capacidade de manusear informações imprecisas através de exemplos semânticos, ou seja, ela transforma expressões verbais, vagas, imprecisas e qualitativas em valores numéricos (SIMÕES; SHAW, 2007).

Assim sendo, quando aplicado à sistemas FV como algoritmo de controle do MPPT, a FL se destaca por trabalhar com entradas imprecisas, não precisar de um modelo matemático preciso e ser capaz de lidar com a não linearidade do sistema FV (YAHYAOUI, 2018).

Simões e Shaw (2007) dividem um controlador baseado na lógica *fuzzy*, mais conhecidos como Controlador *Fuzzy* (FLC, do inglês *Fuzzy Logic Controller*), em quatro estágios, a saber: fuzificação (ou codificação), base de conhecimento, procedimento de inferência e desfuzificação (ou decodificação). A Figura 2.28 resume a estrutura de um FLC.

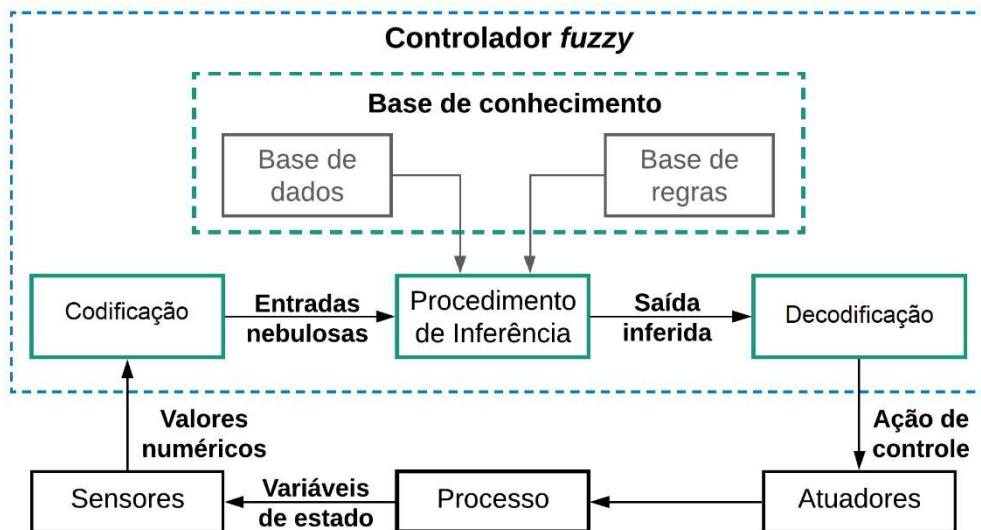


Figura 2.28. Estrutura de um controlador *fuzzy*

Fonte: Adaptado de (SANDRI; CORREA, 1999)

Na codificação, os dados numéricos, normalmente provenientes de sensores ou dispositivos computacionais, são convertidos em conhecimentos linguísticos. Um fator de escala normalmente é utilizado para transformar esses valores reais de entrada em níveis

difusos, como LO (Baixo, do inglês, *Low*), ML (Medianamente Baixo, do inglês, *Medium Low*), M (Médio), MH (Medianamente Alto, do inglês, *Medium High*) e H (Alto, do inglês, *High*) (SIMÕES; SHAW, 2007).

Quando a lógica *fuzzy* é utilizada como algoritmo de controle do MPPT, as variáveis de entrada mais comuns de serem utilizadas são o erro e a mudança de erro, que é uma relação entre a P_{FV} e V_{FV} . Porém, também há na literatura autores que utilizam as condições ambientais, outros parâmetros do arranjo FV ou uma combinação de ambos, assim como relatado na técnica de RNA (SUMATHI; ASHOK KUMAR; SUREKHA, 2015).

Todavia, Kamarzanan e Tan (2014) ressaltam que o número de variáveis linguísticas atribuídas tem relação direta com a precisão da saída desejada. Isto é, quanto maior o número de variáveis linguísticas, mais estável e preciso é a resposta. Em contrapartida, maior o esforço computacional requerido e mais lenta torna-se a resposta.

O segundo estágio, que é a base de conhecimentos, é responsável por definir o modelo do sistema a ser controlado. Ela é composta pela base de dados e base de regras *fuzzy*. Na base de dados ficam guardadas as definições sobre discretização e normalização dos universos de discurso, bem como as funções de pertinência atribuídas as variáveis *fuzzy*.

As Funções de Pertinência (MF, do inglês *Membership Function*) geralmente variam entre trapezoidal, triangular e gaussiana, sendo sua escolha à critério do projetista. A Figura 2.29 exemplifica uma associação realizada entre variáveis de entrada ou de saída, com funções de pertinência triangulares e o universo de discurso dessa entrada ou saída.

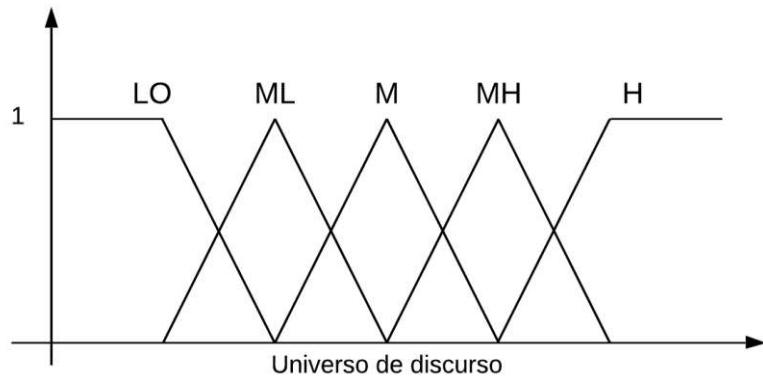


Figura 2.29. Funções de pertinência triangulares
Fonte: Adaptado de (SIMÕES; SHAW, 2007)

Após estruturada a base de dados, à base de regras *fuzzy* pode ser desenvolvida. É nela que o ajuste do algoritmo pode ser realizado, visto que ela é montada a partir de uma estrutura de regra do tipo **Se** <premissa> **Então** <conclusão>. A Tabela 2.1 ilustra uma tabela de regras com duas variáveis de entrada e cinco funções de pertinência associada à cada entrada.

Tabela 2.1. Matriz de base de regras de um controlador *fuzzy*

Entrada 1 Entrada 2 \	LO	ML	M	MH	H
LO	LO	LO	ML	ML	ML
ML	ML	M	M	M	MH
M	ML	M	M	MH	MH
MH	ML	M	MH	MH	H
H	ML	MH	MH	H	H

Fonte: Adaptado de (SIMÕES; SHAW, 2007)

Para entender o funcionamento de uma matriz de regra é necessário observar o exemplo da matriz de regra da Tabela 2.1. Considerando que a Entrada 1 seja MH e a Entrada 2 seja LO, a saída do controlador *fuzzy* deverá estar dentro do intervalo que corresponde a MF ML.

Após estabelecida a base de dados e a base de regras *fuzzy*, essas são juntamente testadas na fase do procedimento de inferências. Nessa etapa são simuladas tomadas de decisões humanas a partir da base de conhecimento, ou seja, ações de controle são criadas a partir de um conjunto de entradas *fuzzy*. Sabendo disso, Sandri e Correa (1999) reforçam a importância de haver um número de regras que garantam pelo menos uma ação para qualquer entrada.

Ademais, quando a lógica *fuzzy* é utilizada como algoritmo de controle do MPPT de um sistema FV, o mecanismo de inferência normalmente utilizado na fase do procedimento de inferências é o Mamdani (KAMARZAMAN; TAN, 2014).

Com relação à última etapa do FLC, a decodificação, ela é responsável por traduzir o valor da variável linguística de saída inferida pelas regras *fuzzy* em um valor discreto, também utilizando funções de pertinência, ou seja, é feito o processo inverso da fuzificação. Simões e Shaw (2007) explicam que o objetivo da desfuzificação é obter um único valor numérico que melhor represente os valores *fuzzy* de saída que foram inferidos.

Quando o *fuzzy* é aplicado a sistemas FV como algoritmo de controle do MPPT, Kamarzaman e Tan (2014) informam que geralmente essa saída é o ciclo de trabalho do PWM que controla o conversor CC-CC, sempre com o objetivo de rastrear o MPP do arranjo FV.

Depois de montar a estrutura do FLC da Figura 2.28 e inseri-lo como algoritmo de controle do MPPT de sistemas FV, autores como Kamarzaman e Tan (2014); e Sumathi, Ashok Kumar e Surekha (2015) explicaram que os FLC mostraram ter um bom desempenho em condições atmosféricas variáveis, rapidez em convergir o MPP, facilidade de ajuste dos parâmetros, capacidade de trabalhar com entradas imprecisas, alta precisão e eficiência.

Entretanto, eles ressaltaram que a eficácia do controlador está diretamente relacionada com o conhecimento do projetista, da montagem adequada da base de dados e da tabela de base de regras. Ou seja, na ausência de um projetista com conhecimento sobre o sistema, utilizar a lógica *fuzzy* pode ser complexo.

Assim, unificar a habilidade em trabalhar com dados numéricos da RNA com o raciocínio *fuzzy* tem sido atrativo para os pesquisadores. Afinal, o ANFIS pode ser capaz de construir um sistema nebuloso utilizando um conjunto de exemplos no lugar do conhecimento de um especialista, bem como resolver os questionamentos acerca do número de camadas e nós a serem utilizados por uma RNA, e o tipo de conhecimento que pode ser extraído da rede.

Para resumir, a Tabela 2.2 faz uma comparação entre as principais características apontadas pelos que usam sistemas neurais e aqueles que usam a lógica *fuzzy*.

Tabela 2.2. Comparação entre sistemas *fuzzy* e neurais

Característica	Sistemas <i>fuzzy</i>	Sistemas neurais
Aquisição de conhecimento	Conhecimento humano	Dados numéricos
Método de treinamento	Interação/indução	Algoritmo/ajuste de pesos
Tipo de incertezas	Qualitativa/quantitativa	Quantitativa
Raciocínio	Busca heurística	Computação paralela
Interface linguística	Explícita	Não evidente
Tolerância a falhas	Não evidente	Muito alta
Robustez	Muita alta	Muito alta

Fonte: (SIMÕES; SHAW, 2007)

Simões e Shaw (2007) explanam que combinar as características das duas técnicas mostradas na Tabela 2.2 pode sanar ou minimizar os aspectos negativos que ainda existe ao utilizar sistemas inteligentes como algoritmo de controle de MPPT aplicado à sistemas FV. Assim sendo, a Subseção 2.7.3 aborda sobre a técnica otimizada ANFIS, que unifica os dois algoritmos inteligentes: *fuzzy* e RNA.

2.7.3 Técnica otimizada baseada no Sistema de Inferência Neuro-*Fuzzy* Adaptativo (ANFIS)

Os sistemas neuro-fuzzy foram introduzidos no âmbito de sistema de controle com o objetivo de melhorar a capacidade de aprendizado, facilitando a construção da base de dados e base de regras do controlador *fuzzy*. Afinal, na lógica *fuzzy*, as funções de pertinência são construídas por especialistas através de tentativa e erro, e tem sua complexidade aumentada

quando o número de entradas, saídas ou variáveis linguísticas aumenta, não existindo uma maneira automatizada de construir essas funções de pertinência. (SIDDIQUE; ADELI, 2013).

Dentre os vários tipos de sistemas que combinam redes neurais e lógica *fuzzy*, o ANFIS é um tipo de inteligência híbrida que pode ser usado para controlar qualquer sistema em que a RNA e o FLC podem ser aplicados. Nele, o Sistema de Inferência *Fuzzy* (FIS, do inglês, *Fuzzy Inference System*) é incorporado em uma arquitetura especial de RNA para que um algoritmo de aprendizagem possa ser aplicado ao controlador *fuzzy* (SIDDIQUE; ADELI, 2013).

Jang (1993) foi o criador do ANFIS e define-o como uma classe de redes adaptativas que são funcionalmente equivalentes a um FIS. Uma rede adaptável é uma estrutura de rede composta por nós interconectados por *links* direcionáveis, em que parte ou todos os nós são adaptáveis, isto é, a saída de cada nó depende dos parâmetros intrínsecos a esse nó e é a regra de aprendizado que determina como cada parâmetro deve ser alterado para minimizar os erros.

No ANFIS, a aprendizagem usando nós adaptativos ocorrem em duas camadas, 1 e 4, por isso ela pode ser dividida em dois tipos: aprendizagem das funções de pertinência antecedentes e aprendizagem dos parâmetros consequentes (SIDDIQUE; ADELI, 2013).

A arquitetura básica de um algoritmo ANFIS contém cinco camadas, conforme é mostrada na Figura 2.30. Para fins de exemplificação, foram utilizadas duas variáveis de entrada (X e Y), cada uma associada à duas funções de pertinência; e uma de saída (Z).

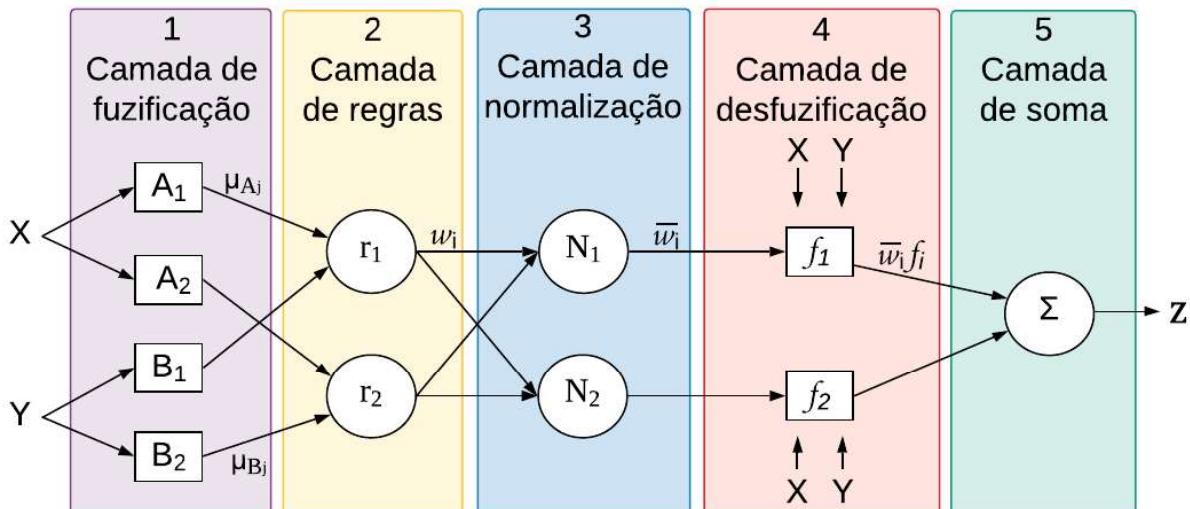


Figura 2.30. Arquitetura ANFIS com cinco camadas
Fonte: Adaptado de (JANG, 1993)

A primeira camada da Figura 2.30 é a de fuzificação. Nela, os nós são do tipo adaptativo, por isso está no formato retangular. Essa camada é responsável por transformar a entrada (X e Y) em variáveis linguísticas (A_1 , A_2 , B_1 e B_2) utilizando os rótulos linguísticos

(grande ou pequeno, por exemplo) e qualquer uma das funções de pertinência descritas na Subseção 2.7.2.2 (μ_{A_j} e μ_{B_j}).

Posteriormente, o processo de inferência é realizado na segunda camada. Logo, o número de regras *fuzzy* corresponde ao número de nós presentes na camada 2. Os nós (r_1 e r_2) são fixos, por isso estão na forma circular, e são responsáveis por determinar o peso de cada regra utilizando a Equação (23).

$$w_i = \mu_{A_i}(X) \cdot \mu_{B_i}(Y); i = 1, 2 \quad (23)$$

Onde:

w_i = Força de disparo ou peso do nó i .

A terceira camada é a camada da normalização. Ela também é composta por nós fixos e nela, os graus de ativação oriundos das regras da segunda camada são normalizados por meio da Equação (24).

$$\overline{w}_i = \frac{w_i}{\sum_{i=1}^2 w_i}; i = 1, 2 \quad (24)$$

Onde:

\overline{w}_i = Força de disparo normalizado do nó i .

Na quarta camada, um novo processo de treinamento é realizado. Por isso, nessa camada, os nós são adaptáveis e representados por uma função linear, conforme Equação (25).

$$f_i = p_i X + q_i Y + r_i; i = 1, 2 \quad (25)$$

Onde:

{ p_i, q_i, r_i } = Conjunto de parâmetros consequente.

O conjunto de parâmetros consequente da Equação (25) deve ser otimizado pelo processo de treinamento até que seja encontrado uma correlação adaptativa entre o resultado da terceira camada e a função da Equação (25). Para isso, cada nó da quarta camada calcula um valor ponderado da parte consequente de cada regra usando a Equação (26).

$$\overline{w}_i f_i = \overline{w}_i (p_i X + q_i Y + r_i); i = 1, 2 \quad (26)$$

Por fim, a quinta camada é responsável por produzir a saída geral através da soma de todos os valores da regra de disparo, como mostra a Equação (27)

$$Z = \sum_{i=1}^2 \overline{w}_i f_i \quad (27)$$

Jang (1993) explica que um ANFIS construído com essas camadas é uma rede adaptativa equivalente a um FIS do tipo 3, ou seja, do tipo Takagi e Sugeno (T-S). Ele também elucida a importância de treinar a rede após a escolha dos parâmetros construtivos.

Dixit *et al.* (2019) esclarecem que esse treinamento é do tipo híbrido, pois é feito em duas etapas que são repetidas até o critério de parada ser atingido. A primeira etapa é a passagem *forward*. Ela é responsável por estimar os parâmetros consequentes (Camada 4) utilizando o Estimador de Mínimos Quadrados (LSE, do inglês, *Least-Squares Estimator*) enquanto os antecedentes se mantêm fixos (Camada 1).

Depois, na segunda etapa, ocorre a passagem *backward*. Nessa etapa, o erro (diferença entre a saída desejada e a saída real) é retropropagado para a primeira camada e os parâmetros antecedentes são regulados pelo método de Gradiente Descendente (GD), ao passo que os consequentes permanecem fixos.

Esse treinamento híbrido do algoritmo ANFIS é considerado eficiente, pois permite que o controlador ANFIS, explorando o conjunto de dados de entrada-saída, determine automaticamente os melhores parâmetros de associação e bases de regras associadas ao FIS que são capazes de mapear o sistema a ser controlado. Entretanto, Siddique e Adeli (2013) ressaltam que um ajuste fino das funções de pertinência pode ser necessário se o conjunto e dados de entrada e saída for grande.

Quando aplicado à sistemas fotovoltaicos, Dixit *et al.* (2019) enaltecem a capacidade do ANFIS em rastrear o MPPT se comparado aos algoritmos MPPT clássicos. Entretanto, devido à sua complexidade, os autores explicam que a implementação do ANFIS como algoritmo de controle é mais interessante à medida que aumenta o porte do sistema FV. Adicionalmente, os autores informaram ser mais comum o uso de parâmetros elétricos extraídos dos sensores acoplados ao arranjo FV como entrada e o ciclo de trabalho do conversor CC-CC como saída do controlador ANFIS.

Todavia, como detalhado no Capítulo 1, o uso do ANFIS como algoritmo de controle do MPPT ainda é recente, especialmente quando comparado às outras técnicas de MPPT discutidas no presente capítulo. Por conta disso, estudar o comportamento dos algoritmos inteligentes, incluindo o ANFIS, utilizando diferentes portes de sistemas FV, bem como diferentes combinações de parâmetros de entrada, torna-se de grande valia para a ciência.

Desta forma, após explicar os principais conceitos acerca de sistemas FV e das técnicas de MPPT, o Capítulo 3 fica responsável por apresentar a metodologia e materiais utilizados para que o objetivo do presente trabalho seja alcançado.

3. Materiais e Métodos

Neste tópico serão descritos os materiais e metodologias utilizados para o desenvolvimento dos algoritmos inteligentes com as diferentes propostas de variáveis de entrada, que serão posteriormente utilizados para controle do MPPT e aplicados à um sistema FV. O fator norteador do presente estudo é avaliar a capacidade dos algoritmos inteligentes RNA, *fuzzy* e ANFIS em controlar o chaveamento de conversor CC-CC *buck-boost* e minimizar os efeitos negativos que as alterações ambientais, especialmente irradiação e temperatura ambiente, causam na geração de energia de um sistema FV.

Desta forma, a Figura 3.1 mostra as etapas dos procedimentos metodológicos utilizados para o desenvolvimento da pesquisa.

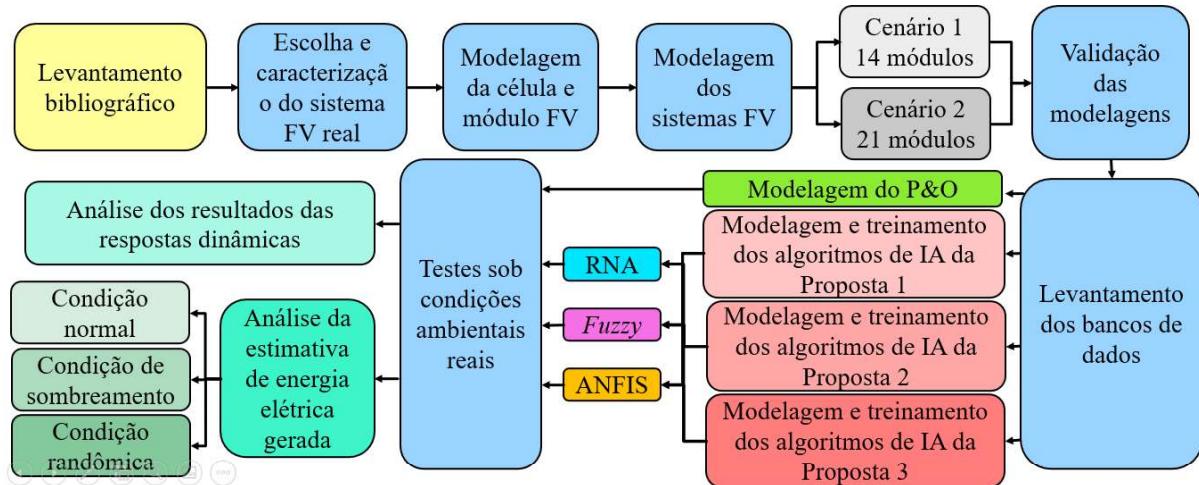


Figura 3.1. Etapas do procedimento metodológico

Fonte: Autoria própria

Como é detalhado na Figura 3.1, após o levantamento bibliográfico realizado no Capítulo 2, o Capítulo 3 inicia caracterizando o sistema FV real que, subsequentemente, será utilizado como referência para realizar a modelagem da célula e do módulo fotovoltaico. Depois, a descrição e modelagem de todos os componentes do sistema FV utilizado no estudo é feita. Posteriormente, os modelos serão validados, contudo, seus resultados serão apresentados apenas no Capítulo 4. Com a modelagem validada, o Capítulo 3 explica como foi obtido o conjunto de dados a ser utilizado no treinamento dos algoritmos de controle do MPPT, bem como explica os parâmetros que serão utilizados para realizar a análise comparativa entre as técnicas. Por fim, o presente Capítulo encerra descrevendo as propostas de arquiteturas de cada algoritmo inteligente utilizado no MPPT e seu respectivo desenvolvimento. As propostas mudam com base na mudança de variáveis de entrada.

3.1 Caracterização do sistema FV real

Devido à complexidade cada vez mais elevada das estruturas aplicadas no âmbito da Eletrônica de Potência, a simulação tem sido uma ferramenta crucial nas pesquisas, pois auxiliam na comprovação e validação das diferentes teorias desenvolvidas. Assim sendo, o presente estudo utiliza o *software* Matlab/Simulink® para desenvolver a modelagem de sistemas fotovoltaicos e de suas técnicas de rastreamento de máxima potência.

Todavia, como explicado na Seção 2.7, os algoritmos de controle do MPPT baseados em técnicas inteligentes e aplicados à sistemas FV são modelados exclusivamente para o sistema ao qual foi treinado para controlar.

Desta forma, para modelar o sistema FV do presente estudo foi utilizado como referência, um SFCR monofásico real, localizado no interior do estado do Rio Grande do Norte, na cidade de Mossoró, especificadamente no *campus* leste da Universidade Federal Rural do Semi-Árido (UFERSA).

Esse sistema tem 3 kWp de potência instalada e é composto por 14 módulos FV conectados em série (com o objetivo de obter uma tensão nominal de 525V), um inversor fotovoltaico, o quadro de comandos e proteção, e o sistema de medição bidirecional.

Os módulos fotovoltaicos utilizados, modelo YL245P-29b, é do fabricante Yingli Solar. Ele é constituído por 60 células FV de silício multicristalino, todas conectadas em série, totalizando uma potência de saída de 245 W_p. Além disso, possuem eficiência elétrica de 15,1% (YINGLI SOLAR, 2015).

A Tabela 3.1 apresenta os parâmetros que serão utilizados no decorrer da modelagem e simulação do sistema FV. Todos os valores foram extraídos da folha de dados do fabricante.

Tabela 3.1. Características do módulo FV YL245P-29b

Parâmetros elétricos para STC		Características térmicas e físicas	
Parâmetro	Folha de dados	Parâmetro	Folha de dados
P_{MPP}	245 W	$NOCT$	46 °C
V_{MPP}	29,6 V	k_i	0,004415 A/K
I_{MPP}	8,28 A	k_v	-0,12480 V/K
V_{OC}	37,5 V	N_s	60
I_{CC}	8,83 A	N_p	1

Fonte: Adaptado de (YINGLI SOLAR, 2015)

No caso do inversor, cuja responsabilidade é transformar a corrente contínua em alternada, seu modelo é o *Sunny Boy 3000HFUS*, da marca SMA. Com o auxílio da folha de dados do fabricante, todos os parâmetros pertinentes ao projeto são descritos na Tabela 3.2. Esses dados serão posteriormente utilizados nas subseções 3.3.2 e 3.3.3.

Tabela 3.2. Características do inversor *Sunny Boy 3000HFUS*

Parâmetro	Folha de dados	Parâmetro	Folha de dados
Potência Nominal	3000 W	<i>Ripple</i> máximo da corrente	10%
Tensão nominal CC	480 V	<i>Ripple</i> máximo da tensão	10%
Eficiência	96,6%	Número de MPPT	1

Fonte: Adaptado de (SMA, 2008)

O inversor fotovoltaico, com as características descritas na Tabela 3.2, também tem uma tecnologia capaz de fornecer e armazenar dados importantes, como potência de saída, em tempo real. Esses dados foram compilados, acrescentando dos valores de irradiação e temperatura ambiente obtidos junto à estação meteorológica Espaço ASA/UFERSA, também localizada na UFERSA (ROCHA; GUERRA; VALE, 2020). O conjunto de dados criado auxiliará na validação do modelo FV que será desenvolvido no presente estudo.

É válido ressaltar que, para obter à temperatura dos módulos FV, a Equação (8) foi utilizada na modelagem devido à ausência de dados referente à temperatura das células FV dos módulos fotovoltaicos da usina em estudo. Como visto na Subseção 2.4.2, a Equação (8) é consolidada e amplamente utilizada na literatura, uma vez que é capaz de obter valores aproximados da temperatura de operação das células FV apenas utilizando dados fornecidos pelo fabricante dos módulos fotovoltaicos e àqueles obtidos junto à estação meteorológica Espaço ASA/UFERSA. Desta forma, a qualidade dos dados não é comprometida e a validação do modelo permanece fidedigna.

Depois de apresentar o sistema FV de referência e conhecer os principais parâmetros pertinentes ao projeto, a Seção 3.2 descreve a primeira modelagem necessária no projeto do sistema FV, que se trata da modelagem da célula e, posteriormente, do módulo FV.

3.2 Modelagem da célula e módulo FV

A modelagem da célula e do módulo FV do presente estudo foi realizada baseando-se no modelo de diodo único, amplamente discutido na Seção 2.2. Primeiramente, a Equação (8)

foi projetada no *software* Matlab/Simulink®, como mostra a Figura 3.2. Essa Equação estabelece a influência que a irradiância (G) e temperatura ambiente (T_{AMB}) tem sobre a T_{CELL} .

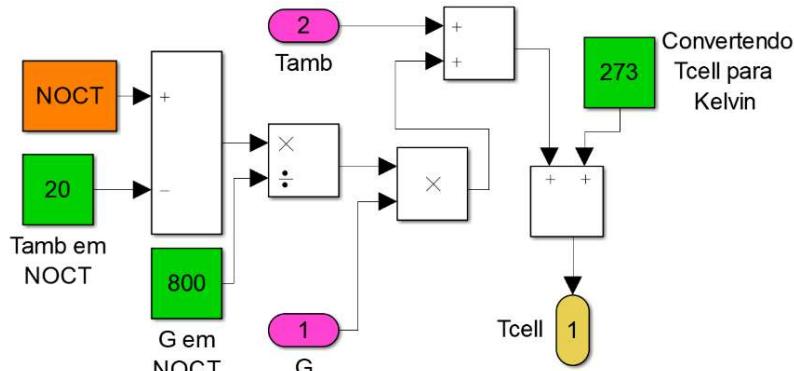


Figura 3.2. Modelagem da Equação (8) no *software* Matlab/Simulink®
Fonte: Autoria própria

Na Figura 3.2, os blocos em rosa representam as variáveis de entrada, o bloco amarelo é a variável de saída, os blocos verdes referem-se às constantes presentes na Equação (8), os blocos em brancos são operadores matemáticos e o bloco laranja diz respeito a um parâmetro intrínseco ao gerador FV utilizado na simulação, e que pode ser extraído da folha de dados do fabricante, por isso será definido mais adiante. É válido enfatizar que, para todas as equações modeladas, o padrão de cores será mantido.

De modo análogo ao procedimento da Equação (8), a equação da corrente fotogerada (I_{PH}), ou seja, Equação (7), da corrente I_o' , detalhada na Equação (10) e da corrente I_o na Equação (9) foram modeladas no *software* Matlab/Simulink®.

Após a modelagem das equações (7), (8), (9) e (10), elas foram compactas em máscaras, identificadas separadamente em blocos azuis e inseridas na Equação (4), que representa as células FV considerando o modelo de diodo único. Nessa modelagem, a saída são as interconexões de uma célula ou módulo FV, que podem ser utilizadas para fins de medição ou para um possível projeto de arranjo FV. A Figura 3.3 ilustra a modelagem da Equação (4).

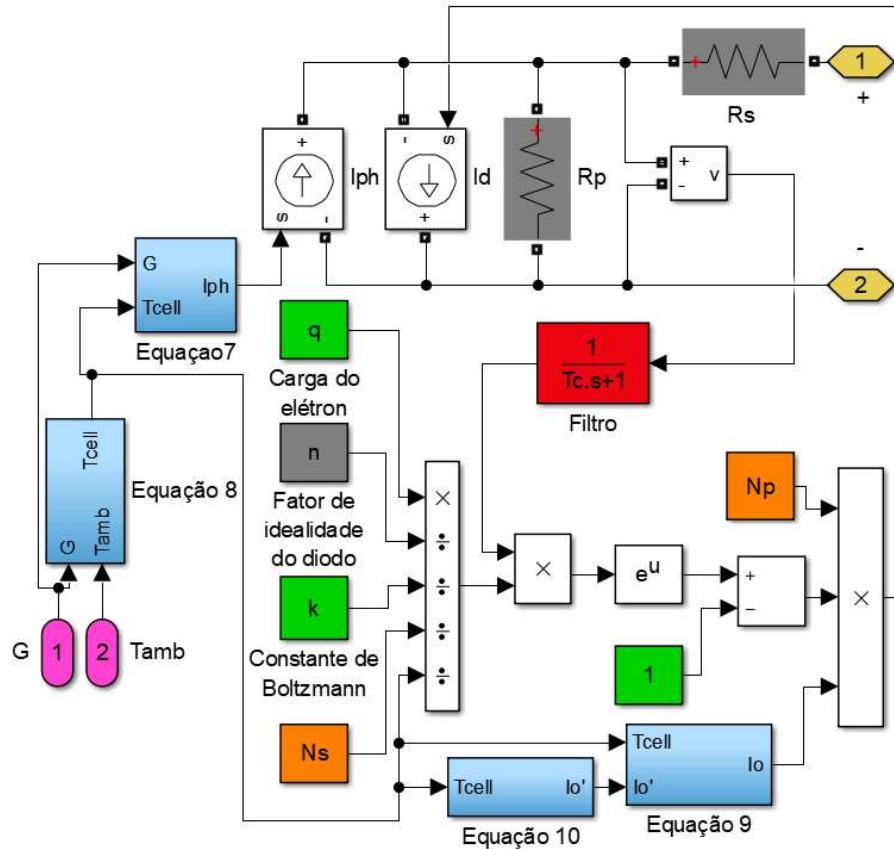


Figura 3.3. Modelagem da Equação (4) no software Matlab/Simulink®
Fonte: Autoria própria

Na Figura 3.3, caso os valores de N_S e N_P sejam iguais a 1, a modelagem refere-se a uma célula FV. Assim, para que o modelo seja remetido a um módulo FV é necessário conhecer o número de células em série e paralelo desse módulo FV. Esses dados normalmente são extraídos da folha de dados do fabricante, como àqueles mostrados na Tabela 3.1.

Também na Figura 3.3 nota-se a presença de um bloco cinza. Ela representa o fator de idealidade do diodo, que é um parâmetro presente nas equações (4), (9) e (10), mas que normalmente não é informado pelo fabricante dos geradores FV, por isso precisam ser estimados utilizando uma simulação paralela. Essa simulação será posteriormente explicada na Subseção 3.2.1.

Além disso, no projeto da Figura 3.3 foi inserido um filtro passa-baixas de primeira ordem com o intuito de evitar o erro oriundo da realimentação que existe na Equação transcendental (4). Esse filtro é responsável por transformar a solução do modelo da Figura 3.3 em um tempo discreto que garanta que todas as equações citadas sejam resolvida e seus resultados armazenados antes de um novo *looping* acontecer. Para isso, a constante de tempo (T_C) escolhida será igual ao tempo de amostragem definido para as simulações.

Após projetar a célula e/ou módulo FV, a extração dos parâmetros é essencial para que a modelagem seja finalizada e, posteriormente, a simulação seja realizada. Tais parâmetros serão retirados da folha de dados do fabricante (Tabela 3.1) ou estimados por simulação.

Como os parâmetros n , R_P e R_S , presentes na Equação (4), não são encontrados na Tabela 3.1, eles precisaram ser medidos com auxílio de sensores ou estimados por um método iterativo. No presente trabalho, foi utilizado o consolidado método desenvolvido por Villalva, Gazoli e Ruppert Filho (2009), explicado na Subseção 3.2.1

3.2.1 Parâmetros estimados por simulação

Villalva, Gazoli e Ruppert Filho (2009) desenvolveram um eficiente modelo capaz de estimar o par de R_P e R_S que garantam que a máxima potência calculada através do modelo seja igual à máxima potência fornecida pelo fabricante na folha de dados.

Para isso, os autores estabelecem que o fator de idealidade do diodo (n) deve estar no intervalo compreendido entre 1 e 1,5. O valor exato de n fica a critério do projetista, que tem como referência a necessidade de aproximar os resultados do modelo com os valores fornecidos pelo fabricante.

Após escolher n , as resistências R_P e R_S são encontradas através do método iterativo de Newton-Rapshon, com o auxílio das Equação (28).

$$R_P = \frac{V_{MPP} \cdot (V_{MPP} + I_{MPP} \cdot R_S)}{V_{MPP} \cdot I_{ph} - V_{MPP} \cdot I_0 \cdot \left(e^{\frac{q \cdot (V_{MPP} + I_{MPP} \cdot R_S)}{n \cdot k \cdot T_{CELL} \cdot N_s}} \right) + V_{MPP} \cdot I_0 - P_{MPP}} \quad (28)$$

A Equação (28) foi deduzida a partir da Equação (4). Nela é considerado que não há células conectadas em paralelo no módulo FV, ou seja, N_P é 1. Além disso, foi assumido como tensão (V_{FV}) e corrente de saída (I_{FV}), à máxima fornecida pelo módulo FV.

Adicionalmente, como os valores de R_P e R_S são desconhecidos, para que a iteração aconteça, Villalva, Gazoli e Ruppert Filho (2009) recomendam iniciar o método iterativo considerando R_S igual a zero e ir incrementando esse valor a cada iteração. Com relação a R_P , eles estipulam um valor inicial calculado através da Equação (29).

$$R_{P,mín} = \frac{V_{MPP}}{I_{CC} - I_{MPP}} - \frac{V_{OC} - V_{MPP}}{I_{MPP}} \quad (29)$$

O valor mínimo da R_P expressa a inclinação da reta traçada entre o ponto da corrente de curto-circuito (I_{CC}) e o MPP na curva I-V. Villalva, Gazoli e Ruppert Filho (2009) reforçam

que esse valor de R_P (assim como o de R_S) é uma estimativa inicial, ou seja, seu valor real ainda é desconhecido e deve ser obtido por meio do método iterativo ilustrado na Figura 3.4.

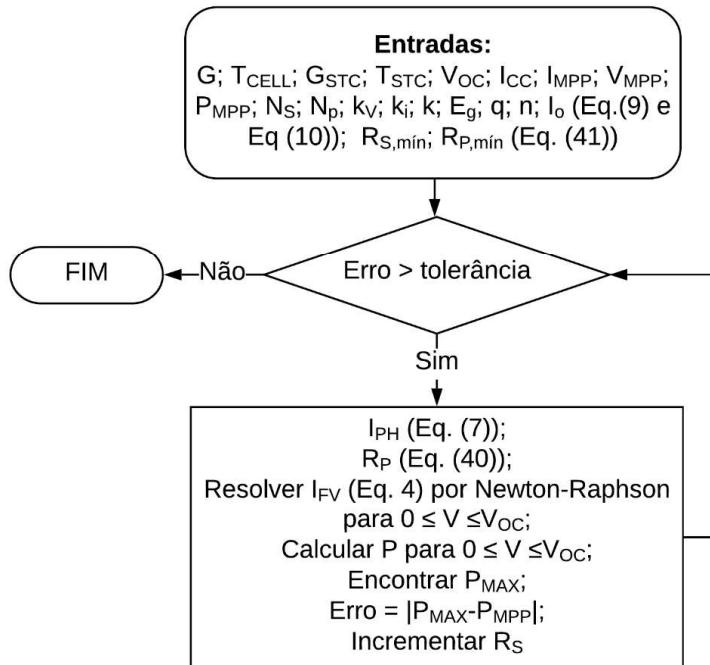


Figura 3.4. Algoritmo para definir os parâmetros n , R_S e R_P

Fonte: Adaptado de (VILLALVA; GAZOLI; RUPPERT FILHO, 2009)

Analizando a Figura 3.4, o algoritmo encerra a iteração quando a diferença entre a potência máxima calculada (P_{MAX}) e a potência máxima fornecida pela folha de dados do fabricante (P_{MPP}) é zero ou menor que a tolerância estabelecida.

Quando finalizado o processo iterativo, os valores de n , R_S e R_P , que são necessários para a modelagem do módulo FV, podem ser extraídos. A Tabela 3.3 mostra os valores dos parâmetros estimados pelo algoritmo da Figura 3.4.

Tabela 3.3. Parâmetros estimados do módulo FV YL245P-29b

Parâmetro	Valores Estimados
n	1
R_S	0,411 Ω
R_P	404,1 Ω

Fonte: Autoria própria

Encerrada a extração de todos os parâmetros necessários para modelar, simular e traçar as curvas característica do módulo FV, o sistema FV utilizado no presente estudo pode ser desenvolvido. O projeto realizado é descrito na Seção 3.3.

3.3 Modelagem do sistema fotovoltaico

O presente estudo visa desenvolver um MPPT composto por um conversor CC-CC *buck-boost* e um algoritmo de controle inteligente para compor o sistema FV a ser modelado. Como observado na Seção 2.6, o MPPT é um componente do bloco de condicionamento de potência que está presente tanto nos sistemas FV isolados, como nos conectados à rede.

Também foi observado no referencial teórico, mais especificamente na Subseção 2.7.3, que a implementação de algoritmos inteligentes se torna mais atrativa à medida que aumenta o porte do sistema FV em virtude da sua complexidade.

Isso posto, visando focar no estudo dos MPPT inteligentes, serão modelados dois cenários de sistemas fotovoltaicos na presente seção. Eles serão constituídos de um arranjo FV, o conversor *buck-boost*, a carga e um algoritmo de controle. Cada cenário é diferenciado pelo número de módulos FV presentes no sistema, ou seja, pela potência gerada, como será explicado na Subseção 3.3.1. É válido ressaltar que os diferentes algoritmos de controle desenvolvidos serão tratados em uma seção a parte.

3.3.1 Arranjo FV

Para o projeto do arranjo fotovoltaico foi necessário, inicialmente, realizar a modelagem do módulo FV descrita na Seção 3.2. Em seguida, foi estabelecido que o cenário 1 terá 14 módulos FV e características de projeto similares ao do sistema FV real descrito na Seção 3.1. Esta escolha baseia-se na necessidade de validar a modelagem da Seção 3.2, bem como para nortear a escolha e dimensionamento dos componentes de ambos os cenários.

Por outro lado, o cenário 2 utiliza 21 módulos FV. Ele é um cenário hipotético e tem como objetivo analisar o comportamento do rastreio do MPP baseado nos algoritmos inteligentes, à medida que é aumentado o número de módulos FV.

Assim, com o auxílio das portas de conexão positiva e negativa (em amarelo na Figura 3.3), cada módulo (bloco em azul) foi interligado através de conexões em série, como exemplifica o arranjo de 14 módulos da Figura 3.5. Ainda é mostrado na Figura 3.5 que, após finalizar as conexões entre os módulos FV, o arranjo FV é reduzido à um única máscara para melhorar a visualização e montagem do sistema FV.

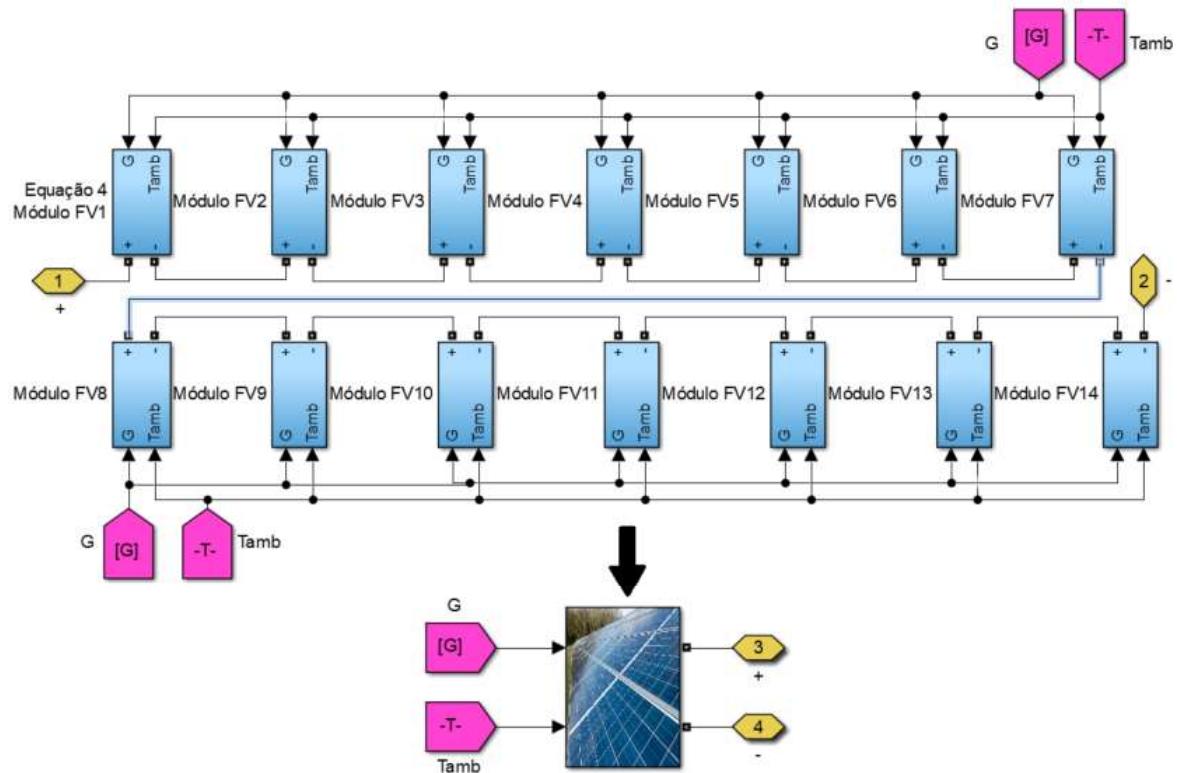


Figura 3.5. Modelagem de um arranjo FV com 14 módulos FV

Fonte: Autoria própria

Todos os dois cenários tiveram uma modelagem por conexão série, similar à da Figura 3.5, diferenciando-se pelo número de módulos FV utilizados. A Tabela 3.4 mostra os cenários, descrevendo o número de módulos FV adotados, a potência máxima, V_{MPP} e I_{MPP} nas STC.

Tabela 3.4. Cenários projetados

Cenário	Número de módulos FV	Potência (W _P)	V _{MPP} (V)	I _{MPP} (A)
1	14	3430	414,4	8,28
2	21	5145	621,6	8,28

Fonte: Autoria própria

Depois de modelar o arranjo FV de cada cenário a ser estudado, a Subseção 3.3.2 calcula a carga que deve ser acoplada ao sistema FV.

3.3.2 Carga

No presente estudo, será utilizada uma carga fixa para ser acoplada na saída do conversor CC-CC *buck-boost* de cada cenário. Para dimensionar essa carga, foi utilizado como referência a potência máxima desejada nas STC (Tabela 3.4), bem como a tensão nominal

estabelecida pelo inversor como sua entrada CC (Tabela 3.2). Afinal, a tensão de entrada do inversor deve ser igual a tensão de saída do conversor *buck-boost*.

No cenário 1, a tensão nominal de saída do conversor e a P_{MPP} serão exatamente iguais ao da Tabela 3.2 e Tabela 3.4, respectivamente. Porém, para o cenário 2, a tensão de saída e a potência do MPP precisaram ser estimadas a partir de uma relação de proporção entre o número de módulos do cenário e os dados da Tabela 3.2 e Tabela 3.4. Desta forma, para auxiliar no dimensionamento da resistência da carga, a Equação (12) também foi usada.

A Tabela 3.5 exibe os valores da tensão sobre a carga estimados, bem como as resistências da carga calculadas para os respectivos cenários.

Tabela 3.5. Resistência da carga de cada cenário

Cenário	V_R (V)	Resistência da carga (Ω)
1	480,0	67,15
2	720,0	100,72

Fonte: Autoria própria

Depois do dimensionamento da carga, o conversor CC-CC *buck-boost* também deve ser projetado. A escolha de cada componente do conversor será discutida na Subseção 3.3.3.

3.3.3 Conversor CC-CC *buck-boost*

Os elementos que compõem um conversor CC-CC *buck-boost*, bem como as equações para dimensionamento foram explicadas na Subseção 2.6.2.1. Desta forma, a presente subseção dimensiona os componentes que devem ser utilizados em cada cenário respeitando todos os critérios de projeto.

Para ambos os cenários foi considerado uma frequência de chaveamento (f) de 50 kHz, um período (T) de 20 μ s e um *ripple* máximo admissível (ou variação de pico a pico), na corrente (Δi_L) e na tensão de saída (ΔV_R), igual ou menor aos inseridos na Tabela 3.2, ou seja, 10%. A Tabela 3.6 exibe os valores escolhidos para serem utilizados em cada cenário respeitando os valores mínimos estabelecidos na Subseção 2.6.2.1.

Tabela 3.6. Componentes do conversor *buck-boost* de cada cenário

Parâmetro	Cenário 1	Cenário 2
L	5,6 mH	9,1 mH
C_1 e C_2	20 μ F	16 μ F

Fonte: Autoria própria

Após o dimensionamento apresentado na Tabela 3.6, o conversor *buck-boost* é modelado e acoplado a carga calculada na Subseção 3.3.2. A Figura 3.6 ilustra o sistema FV modelado, em que todos os componentes dimensionados na Tabela 3.5 e Tabela 3.6 estão diferenciados por blocos em marrom. Os blocos em roxo correspondem a sensores de tensão (V_{FV}) e corrente (I_{FV}) na saída do arranjo FV, que serão utilizados em um momento posterior, como entrada dos algoritmos de controle.

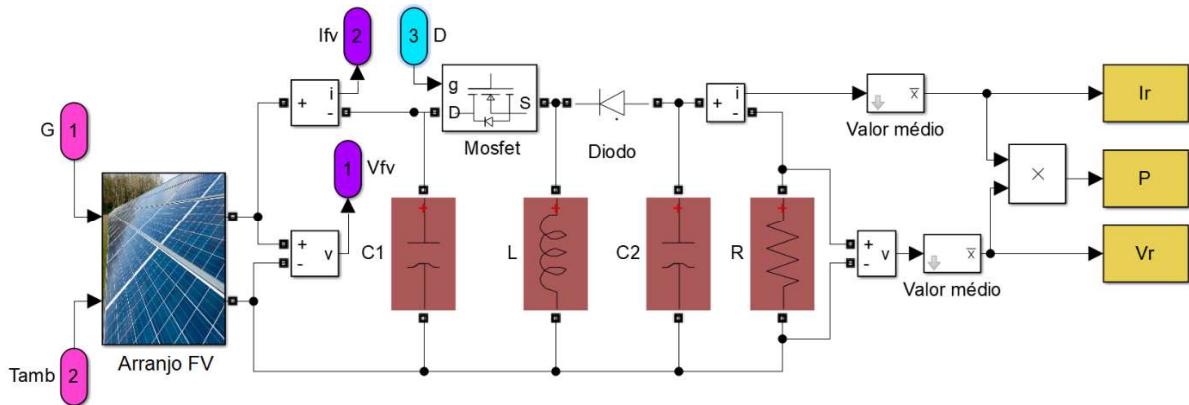


Figura 3.6. Modelagem do sistema FV

Fonte: Autoria própria

A saída P da Figura 3.6 corresponde a potência de saída do sistema FV. Para ela ser máxima, o conversor *buck-boost* dimensionado deve ser capaz de fazer com que a carga vista pelo arranjo FV tenha um ângulo de inclinação, que garanta que o ponto de operação do sistema FV coincida com o MPP em qualquer situação de G e T_{AMB} inseridos na entrada. Isso é feito através do adequado chaveamento do MOSFET realizado por D (bloco em azul claro), que é controlado pelo algoritmo de controle a ser modelado.

Porém, antes da modelagem do algoritmo de controle, é necessário validar o modelo de módulo FV desenvolvido, bem como levantar o conjunto de dados a ser utilizados no treinamento dos algoritmos inteligentes propostos no presente estudo. A Seção 3.4 descreve como tais atividades foram executadas.

3.4 Levantamento do conjunto de dados e parâmetros avaliados

O conjunto de dados é utilizado para auxiliar no treinamento dos algoritmos de controle que são baseados na inteligência artificial. Como explicado na Subseção 2.7.2, a qualidade do treinamento de um algoritmo inteligente está relacionada com a seleção preliminar dos dados de treinamento, seja obtido experimentalmente ou simulados.

Quando os dados de treinamento são obtidos experimentalmente, o algoritmo treinado tem uma eficiente utilização restrita à localidade onde o sistema foi experimentado. Assim, com o intuito de possibilitar que o sistema FV modelado na Seção 3.3 seja utilizado em diferentes localidades, o banco de dados da presente pesquisa foi levantado por meio de simulação.

Todavia, é necessário primeiramente validar o modelo desenvolvido. Isso é feito comparando os valores dos parâmetros G , T_{AMB} e P_{MPP} compilados experimentalmente do sistema real (da Seção 3.1), com os valores obtidos ao simular o cenário 1.

Para extrair os parâmetros G , T_{AMB} e P_{MPP} por simulação, foi necessário reproduzir o arranjo fotovoltaico (Subseção 3.3.1) do cenário 1, sem considerar qualquer outro componente do sistema FV da Figura 3.6 acoplado a esse arranjo FV, como ilustra Figura 3.7.

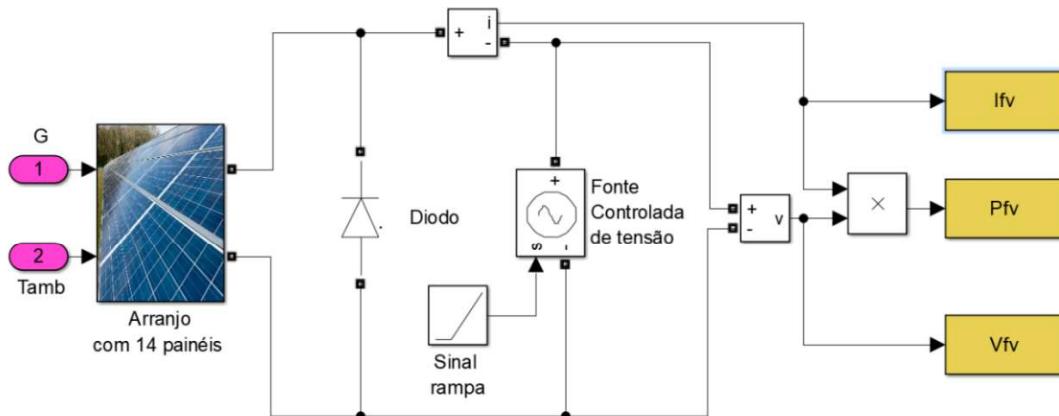


Figura 3.7. Modelagem de um módulo FV sem MPPT e carga
Fonte: Autoria própria

Na Figura 3.7, o arranjo FV é conectado a uma fonte de tensão em rampa, em paralelo com um diodo. Essa fonte de tensão em rampa garante a elevação da tensão a cada *looping* da Equação transcendental (4), permitindo assim, que as curvas características I-V e P-V sejam traçadas e a P_{MPP} de qualquer condição de G e T_{AMB} seja extraída.

A comparação entre os valores obtidos na simulação (utilizando o arranjo FV da Figura 3.7) e os valores medidos no sistema FV real (descrito na Seção 3.1), foi realizada através do erro relativo percentual, utilizando a Equação (30) (JUSTO et al., 2018).

$$e\% = \frac{|P_{MPP,\text{simulação}} - P_{\text{medido}}|}{P_{\text{medido}}} \cdot 100 \quad (30)$$

Onde:

$e\%$ = Erro relativo percentual (%);

$P_{MPP,\text{simulação}}$ = Potência no ponto de máxima potência obtido na simulação (W);

P_{medido} = Potência medida no sistema real (W).

Depois de validar o modelo de arranjo FV desenvolvido, o conjunto de dados composto pelas variáveis G , T_{AMB} , P_{MPP} , V_{MPP} e I_{MPP} também pôde ser extraído da simulação da Figura 3.7. Para isso, foi variando-se G de 100 W/m² até 1100 W/m², com um passo de 100 W/m². Ademais, a T_{AMB} também foi alterada, com valores entre 15 °C até 45 °C, e utilizando um incremento de 5 °C. A Figura 3.8 ilustra os valores de G e T_{AMB} que o sistema FV foi submetido para que a compilação dos dados fosse realizada.

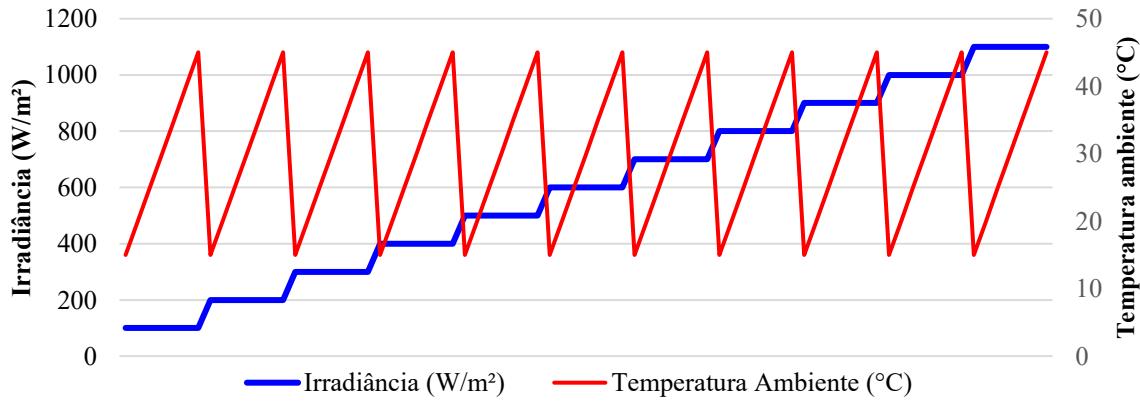


Figura 3.8. Conjunto de G e T_{AMB} para montagem do banco de dados
Fonte: Autoria própria

É importante reforçar que o uso das variáveis ambientais G e T_{AMB} , mostradas na Figura 3.8 e usada como base para a montagem do banco de dados, auxiliará na verificação do comportamento do sistema FV, quando submetido a variações dessas condições ambientais, que são consideradas as que mais afetam na mudança do MPP do sistema FV, conforme discutido na Seção 2.4. A irradiância (G) influencia diretamente na corrente produzida pelo arranjo FV, ao passo que a T_{AMB} afeta diretamente na temperatura dos módulos FV (calculada através da Equação (8)), que, consequentemente, influencia na tensão de saída do arranjo FV.

Em seguida, também foi anexado ao conjunto de dados a V_R e o D do conversor, que são calculados por meio das Equação (12) e Equação (13), respectivamente. Ao término, um total de 77 conjuntos de dados foram obtidos.

É válido ressaltar que cada cenário tem seu próprio conjunto de dados. Por conta disso, a modelagem da Figura 3.7 se repetiu alterando apenas o número de módulos do arranjo FV, determinado na Tabela 3.4. Posteriormente, o sistema FV que equivale ao cenário 2 foi submetido aos valores hipotéticos de G e T_{AMB} da Figura 3.8.

Após montar o banco de dados dos cenários propostos no presente estudo, os algoritmos inteligentes, que serão utilizados para controlar o D do conversor CC-CC, foram desenvolvidos.

Para auxiliar na análise comparativa entre as técnicas de MPPT modeladas, cada um dos algoritmos foi adequadamente acoplado aos sistemas FV modelados na Seção 3.3. Em seguida, cada novo sistema FV foi submetido a condições ambientais idênticas e as mesmas análises foram realizadas. Para a avaliação da resposta dinâmica, a Subseção 3.4.1 explica as condições que os sistemas FV foram submetidos e os parâmetros de resposta avaliados. Uma explicação similar é feita na Subseção 3.4.2 para a análise da energia gerada por cada sistema FV.

3.4.1 Resposta dinâmica

Para auxiliar na análise comparativa da resposta dinâmica, o sistema FV com sua respectiva técnica modelada e treinada foram submetidos a quatro situações de condições ambientais, a saber: condição 1 utilizando G igual a 303 W/m^2 e T_{AMB} sendo 24°C ; condição 2 com G igual a 631 W/m^2 e T_{AMB} igual a 32°C ; condição 3 considerando G sendo 957 W/m^2 e T_{AMB} sendo 32°C ; e, por fim, na condição 4 o G foi definido em 548 W/m^2 e T_{AMB} sendo 24°C . Todos os valores foram escolhidos empiricamente e considerando o efeito borda de nuvem.

A Figura 3.9 mostra as P_{MPP} de cada cenário. A P_{MPP} corresponde a potência de rastreio esperada por cada MPPT modelado, quando submetido as condições ambientais estabelecidas.

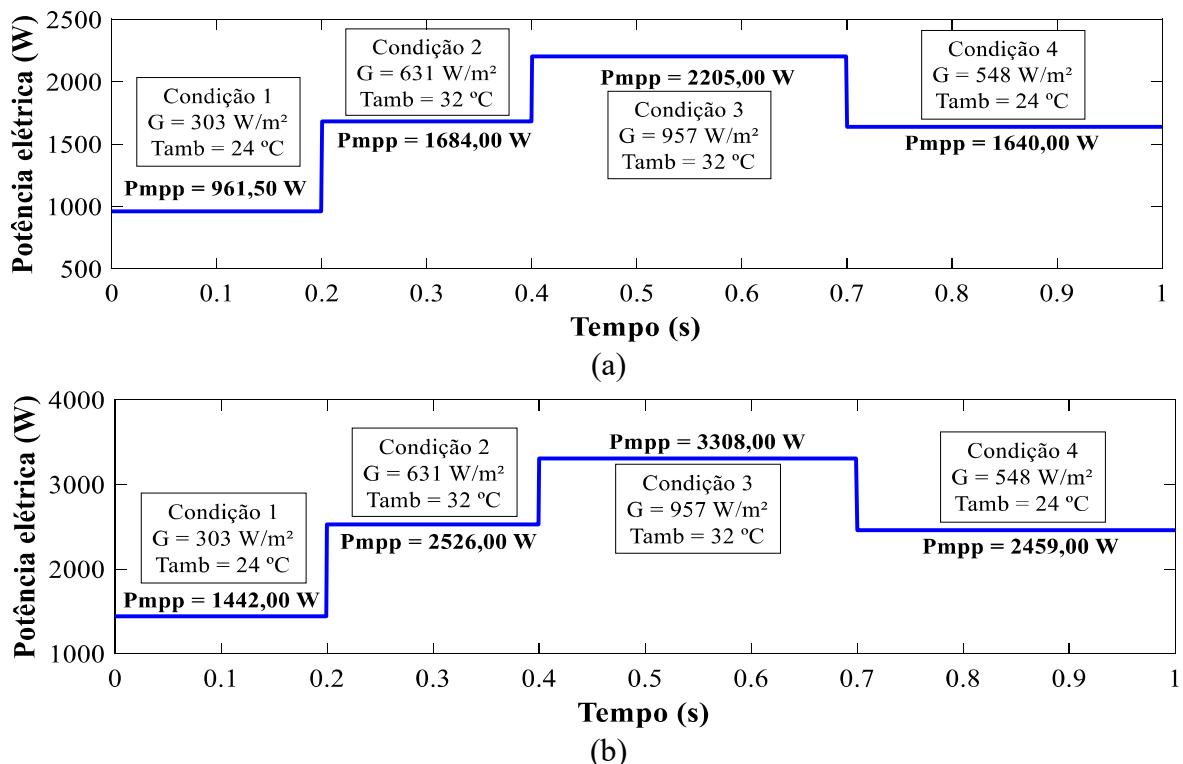


Figura 3.9. Potência de rastreio esperada pelos diferentes MPPT desenvolvidos para o (a) cenário 1, (b) e cenário 2 sob diferentes condições ambientais

Fonte: Autoria própria

Após estimar a potência desejada sob cada condição ambiental, torna-se fundamental verificar os parâmetros técnicos que irão auxiliar na análise do desempenho de cada modelo proposto e desenvolvido. Afinal, o presente estudo se dispõe a desenvolver três diferentes propostas de arquiteturas para cada algoritmo inteligente e avaliar o desempenho de cada uma delas como algoritmo de controle do MPPT de um sistema FV.

Dessa forma, os parâmetros extraídos da resposta dinâmica do sinal de saída do sistema FV serão verificados. Os parâmetros escolhidos para o estudo da resposta dinâmica foram: velocidade de convergência, precisão no rastreamento e oscilação em torno do MPP do sinal de saída. Essa avaliação deve ser feita com todas as propostas, em ambos os cenários e considerando todas as situações ambientais discutidas na presente seção.

Os parâmetros velocidade de convergência e oscilação em torno do MPP são verificados com o auxílio de um gráfico da potência *versus* tempo traçado no *software Matlab®*, como ilustra a Figura 3.10.

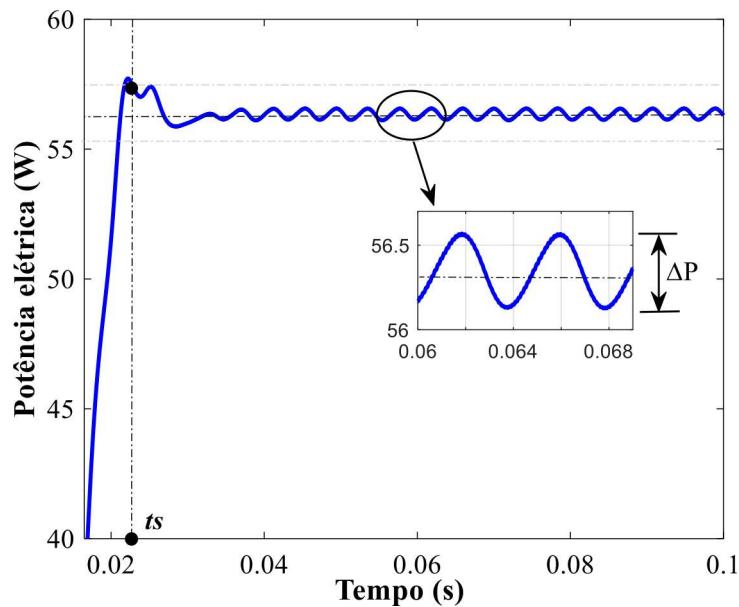


Figura 3.10. Curva de potência *versus* tempo e localização dos pontos de extração dos parâmetros velocidade de convergência e oscilação em torno do MPP

Fonte: Autoria própria

A velocidade de convergência diz respeito ao tempo que o sistema leva para alcançar seu regime permanente, por isso, o tempo de acomodação (ts) foi o parâmetro escolhido. O ts trata-se do tempo que uma resposta leva para atingir e permanecer dentro de uma faixa de $\pm 2\%$ ou $\pm 5\%$ do valor final. No presente estudo será considerada uma faixa de $\pm 5\%$ do valor final.

A oscilação em torno do MPP (ΔP) corresponde ao valor de pico a pico do sinal quando esse encontra-se no regime permanente. Em percentual, a oscilação em torno do MPP é obtida através da razão entre o valor de pico a pico e o valor médio da potência no regime permanente.

Por fim, o parâmetro utilizado para verificar a eficiência do rastreamento é o erro calculado usando a Equação (30). Ele compara o valor médio da potência obtido no regime permanente com o P_{MPP} do conjunto de dados.

Posteriormente, o presente trabalho avaliará a energia gerada pelo sistema FV de cada cenário, quando acoplado a cada algoritmo de controle modelado. A Subseção 3.4.2 explica o desenvolvimento dessa avaliação.

3.4.2 Geração de energia elétrica

A análise da energia gerada por cada sistema FV ajuda a estimar a possível recuperação de energia que o sistema FV pode ter, caso realize uma substituição no algoritmo de controle do MPPT que compõe o sistema.

Para isso, em ambos os cenários, o sistema FV será acoplado a cada algoritmo modelado. Posteriormente, eles serão submetidos a três condições ambientais reais da cidade de Mossoró ($5^{\circ}11'17''$ S, $37^{\circ}20'39''$ O), pois é a cidade em que o sistema FV real e a estação meteorológica Espaço ASA/UFERSA estão localizadas (discutidas na Seção 3.1). Mossoró está localizada no interior do estado do Rio Grande do Norte, próximo a linha do Equador e tem como característica um clima semiárido, seco e ensolarado.

As três condições ambientais usadas no presente estudo foram extraídas de dias diferentes de medição e denominadas de condição normal (Subseção 3.4.2.1), condição de sombreamento (Subseção 3.4.2.2) e condição randômica (Subseção 3.4.2.3). Os três dias de coleta de dados extraíram, a cada cinco minutos, valores de irradiância e temperatura ambiente da estação meteorológica Espaço ASA/UFERSA, especificamente entre às 6:00h e 16:00h.

3.4.2.1 Condição normal

A primeira condição ambiental foi definida como condição normal. Ela representa um dia tipicamente ensolarado da cidade de Mossoró que, em condições normais, tem sol forte e céu limpo. Assim sendo, a irradiância aumenta até próximo ao meio-dia (12:00h), ultrapassando 1000 W/m². Depois do meio-dia, a irradiância diminui até o pôr do sol. Por outro lado, a temperatura ambiente só aumenta ao longo desse típico dia ensolarado.

A Figura 3.11 ilustra a variação de G e T_{AMB} da condição normal.

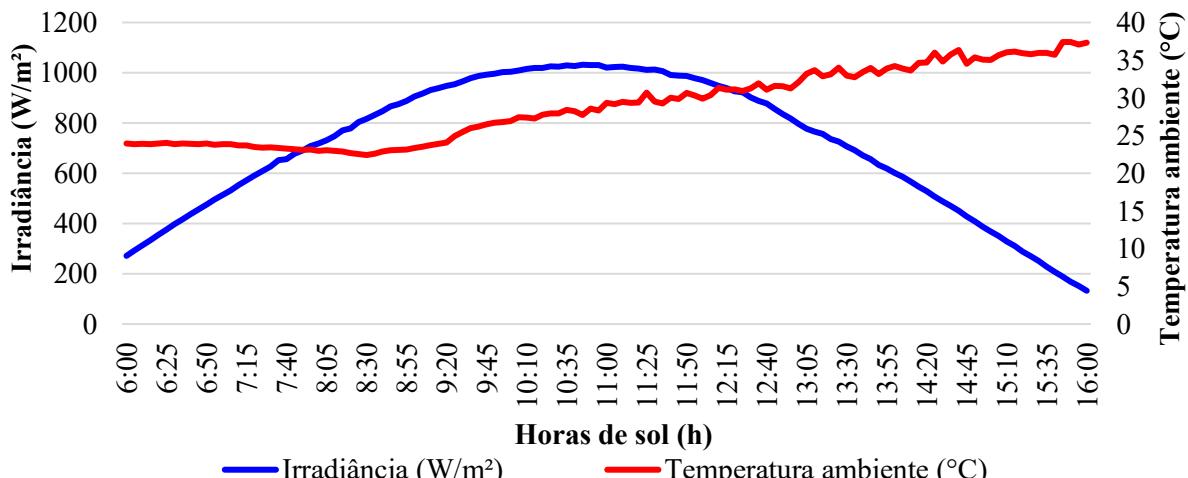


Figura 3.11. Condição normal

Fonte: Autoria própria

3.4.2.2 Condição de sombreamento

Na condição de sombreamento, o comportamento da temperatura ambiente se assemelha ao da condição normal, descrita na Subseção 3.4.2.1. Por outro lado, a irradiância sofre uma queda brusca próxima às 11:00h, conforme mostra a Figura 3.12. A mudança repentina nos níveis de irradiância é, normalmente, uma consequência da passagem de nuvens. Outra característica de destaque observada na Figura 3.12 é a baixa irradiância até próximo às 06:50h.

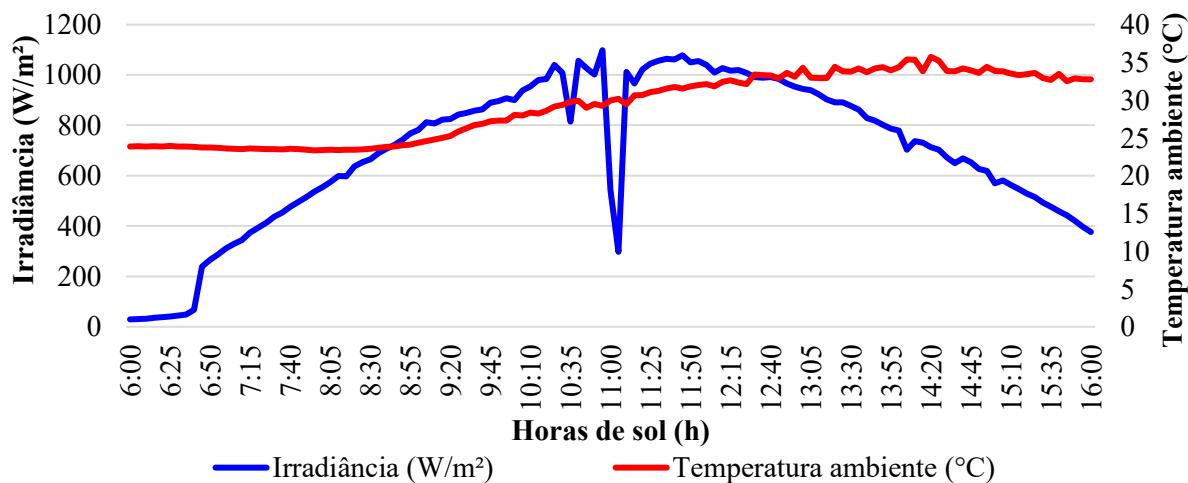


Figura 3.12. Condição de sombreamento

Fonte: Autoria própria

3.4.2.3 Condição randômica

A terceira condição do ambiente, denominada de condição randômica, é definida como a situação na qual a irradiância solar muda, aleatoriamente, ao longo do dia. Esse caso

normalmente ocorre nos períodos chuvosos da cidade. Com relação a temperatura ambiente, ela mantém o comportamento de apenas elevar-se ao longo do dia, como mostra a Figura 3.13.

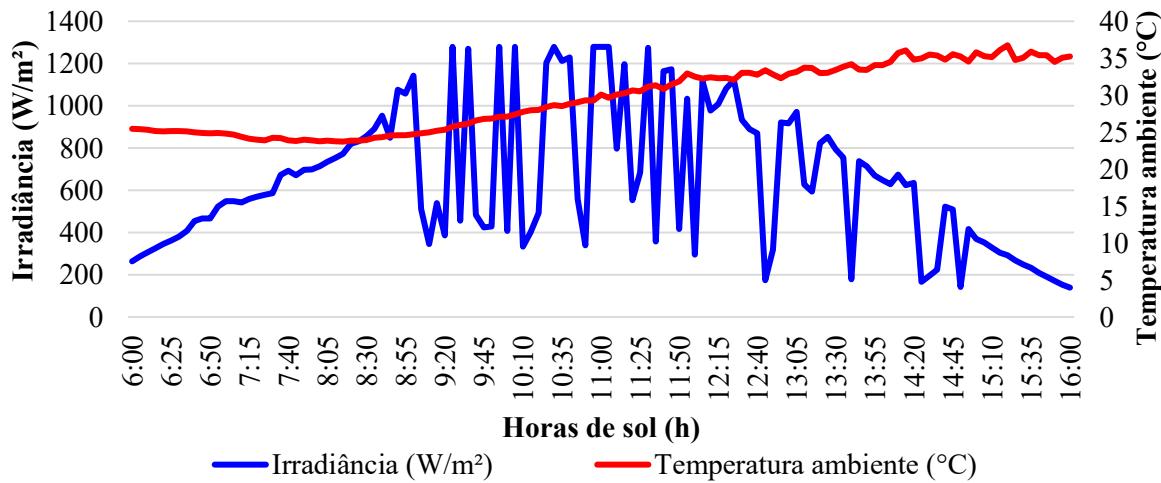


Figura 3.13. Condição randômica

Fonte: Autoria própria

Sabendo os valores de irradiância e temperatura ambiente de cada intervalo de medição apresentadas nas subseções 3.4.2.1, 3.4.2.2 e 3.4.2.3, é possível estimar a potência gerada.

De posse da potência, a energia gerada por cada sistema FV modelado, ao longo das dez horas e para cada condição ambiental, pode ser calculada usando a Equação (31).

$$\text{Energia} = \sum P_{\text{simulação}} \cdot \Delta t \quad (31)$$

Onde:

Energia= Energia gerada (kWh);

P_{simulação} = Potência estimada obtida na simulação (kW);

Δt = Intervalo de tempo (h).

Ao término da estimativa da energia gerada por cada sistema FV utilizando a Equação (31), uma análise comparativa entre os algoritmos quando usados para controlar o MPPT de sistemas FV é viável de ser realizado.

Após realizar o levantamento de dados necessários para o treinamento dos algoritmos inteligentes propostos e compreendendo os parâmetros a serem avaliados, o presente trabalho inicia a modelagem separadamente do MPPT baseado em cada algoritmos de controle, começando pelo P&O, apresentado na Seção 3.5.

3.5 Modelagem do MPPT baseado na técnica clássica P&O

O MPPT baseado no método clássico P&O foi modelado no *software Matlab/Simulink®* para um posterior comparativo com as técnicas RNA, FL e ANFIS, que são o foco da pesquisa.

Desta forma, baseando-se na teoria explicada na Subseção 2.7.1 e na Figura 2.22, o P&O foi modelado com o auxílio do bloco *chart*, presente na biblioteca do Matlab/Simulink®.

Na modelagem do P&O, as variáveis P_{FV} e V_{FV} correspondem às entradas. Essas variáveis são extraídas da saída do arranjo FV do sistema mostrado na Figura 3.6. Todavia, antes de serem inseridas no algoritmo P&O, as variáveis P_{FV} e V_{FV} precisam ser discretizadas. Em todos os cenários, a discretização é feita através do bloco amostrador e considerando uma taxa de amostragem igual ao período T do chaveamento do conversor. Adicionalmente, a fim de evitar um erro inicial na simulação, foram considerados valores iniciais para as variáveis de entrada (P_{FV} e V_{FV}) de 40W e 10V, respectivamente.

No projeto do P&O também foi estabelecida uma variável de saída d , com valor inicial de 0,1 e três diferentes valores de passo (Δd), a saber: 0,0010; 0,0015 e 0,0020. Esse d define a largura do pulso que o PWM precisa ter para controlar com êxito o chaveamento do conversor. A Figura 3.14 ilustra a influência da variável d no sinal do PWM. O sinal de referência do PWM é um dente de serra. Pela Figura 3.14 percebe-se que d pode variar de -1 a 1.

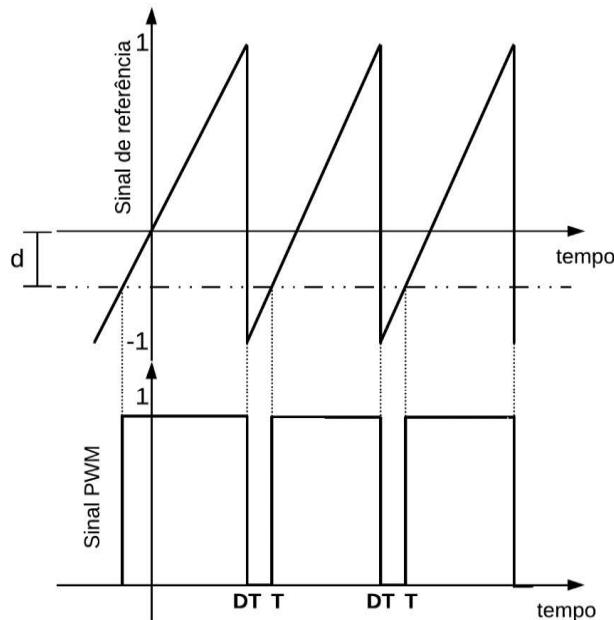


Figura 3.14. Influência da variável d no sinal do PWM
Fonte: Autoria própria

Em se tratando da modelagem, para se ter um ciclo de trabalho do PWM (ou sinal PWM) similar ao da Figura 3.14, um bloco comparador é utilizado no Matlab/Simulink®. O bloco

serve para garantir que todo o sinal, oriundo do sinal de referência e que se encontra acima ou igual a variável de saída do P&O, tenha um nível lógico alto (1) no PWM. Por outro lado, todo sinal de referência abaixo da variável d corresponde ao nível lógico baixo (0) do PWM. Como consequência, o MOSFET do conversor *buck-boost* irá conduzir no nível lógico alto (chave fechada) e deve parar de conduzir no nível lógico baixo (chave aberta).

A Figura 3.15 mostra o PWM modelado (sinal de referência e comparador) e ligado ao bloco *chart* do P&O, com suas respectivas entradas discretizadas.

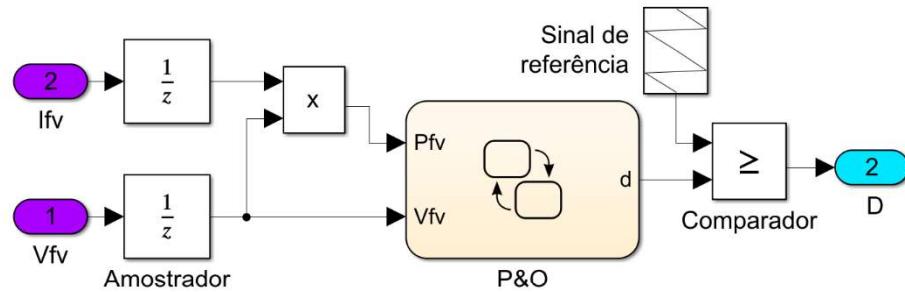


Figura 3.15. Algoritmo e sinal de controle do conversor *buck-boost* baseado no P&O
Fonte: Autoria própria

Os sinais de entrada (I_{FV} e V_{FV}) da Figura 3.15 são extraídos da saída do arranjo FV da Figura 3.6, em roxo nas duas figuras. E a saída D , em azul, corresponderá a entrada D indicada no MOSFET da Figura 3.6 de mesma cor.

Diante do exposto, é possível afirmar que o algoritmo P&O controla o ciclo de trabalho do conversor *buck-boost* com o intuito de extrair a máxima potência do arranjo FV. E, para isso, é utilizado as leituras da I_{FV} e V_{FV} como entradas do algoritmo.

Para avaliar o desempenho do MPPT que é baseado no algoritmo P&O, os parâmetros de velocidade de convergência, precisão no rastreamento e oscilação em torno do MPP são verificados. Essa avaliação é feita nos dois cenários modelados e considerando três valores de passos (Δd), que são: 0,0010; 0,0015 e 0,0020.

Depois de modelar o algoritmo P&O, a Seção 3.6 apresenta o desenvolvimento da modelagem do algoritmo de controle baseado na técnica inteligente RNA.

3.6 Modelagem do MPPT baseado na técnica RNA

Quando se trata do MPPT modelado utilizando os algoritmos de controle baseado na inteligência artificial, foi estabelecida uma estrutura com duas variáveis de entrada, e o ciclo de trabalho do conversor D como única variável de saída.

De modo geral, três diferentes propostas de duplas de variáveis foram modeladas e treinadas como entrada do algoritmo RNA, bem como dos algoritmos *fuzzy* e ANFIS, a saber: proposta 1 - G e T_{AMB} ; proposta 2 - G e potência de saída instantânea do arranjo FV ($P_{FV}(t)$); e proposta 3 - $P_{FV}(t)$ e potência de saída do instante anterior ($P_{FV}(t-1)$) do arranjo FV.

É importante frisar que, dentre os parâmetros ambientais que afetam na geração de eletricidade de um sistema FV, a dupla G e T_{AMB} foi escolhida como entradas, pois são os parâmetros que apresentam maior impacto nessa geração, seja direta ou indiretamente, como discutido na Seção 2.4.

Por outro lado, para a dupla de variáveis de entrada que trabalha apenas com parâmetros elétricos, foi selecionada a potência de saída do arranjo FV, pois essa é a variável mais influenciada pelas mudanças ambientais, bem como pelas modificações no MPPT.

Por fim, a dupla G e $P_{FV}(t)$ também foi proposta, pois mescla entre a condição ambiental e o parâmetro elétrico que mais afetam na geração de energia elétrica de um sistema FV, ou seja, eles oferecem maior sensibilidade ao MPPT e, consequentemente, ao sistema.

Devido as particularidades durante a modelagem e o treinamento da RNA usando cada uma das duplas de variáveis de entrada, elas foram divididas em subseções. A primeira delas é a proposta 1, que considera as variáveis de entrada G e T_{AMB} e está detalhada na Subseção 3.6.1.

3.6.1 Proposta 1 - Variáveis de entrada irradiação e temperatura ambiente

Antes de iniciar o treinamento do algoritmo inteligente RNA, foi necessário modelar o MPPT que considera as variáveis irradiação (G) e temperatura ambiente (T_{AMB}) como entrada, e o ciclo de trabalho (D) do conversor como saída da RNA da proposta 1. A Figura 3.16 mostra essa modelagem.

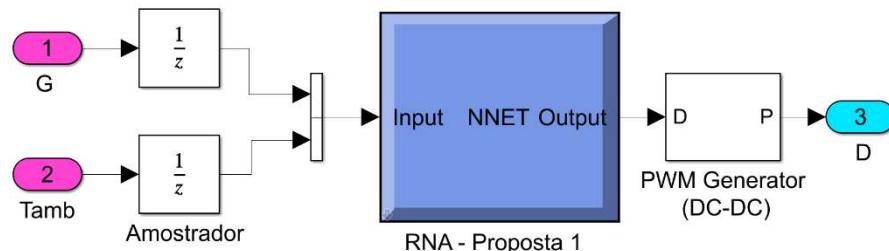


Figura 3.16. MPPT baseado na proposta 1 do algoritmo de controle RNA
Fonte: Autoria própria

Na Figura 3.16, as variáveis de entrada G e T_{AMB} , inseridas como entrada da RNA, são as mesmas que o sistema FV da Figura 3.6 está submetido. Todavia, essas variáveis precisam

ser discretizadas através do bloco amostrador e considerando uma taxa de amostragem similar ao período T de chaveamento, que foi usado para o sinal de referência do PWM.

Adicionalmente, a saída D da RNA foi conectada ao bloco do gerador PWM. O bloco *PWM Generator (DC-DC)* é um gerador PWM, que tem como entrada o ciclo de trabalho D , responsável por definir a largura de pulso do PWM. Como saída, ele tem o sinal (alto e baixo) que controla o chaveamento do conversor *buck-boost*. Desta forma, a saída desse bloco, que corresponde a saída do MPPT e está destaca em azul na Figura 3.16, é conecta à entrada D do sistema FV da Figura 3.6, ou seja, ele será o sinal de controle do chaveamento do MOSFET.

Após montar o MPPT, a RNA da proposta 1, que corresponde ao algoritmo de controle do sistema, precisa ser treinada. Para isso, foram utilizadas as 77 amostras do conjunto de dados compilados na Seção 3.4. Das 77 amostras, 70% delas foram utilizadas para o treinamento da rede, 15% para o teste e 15% para validar o treinamento feito.

A Tabela 3.7 mostra, em resumo, os parâmetros de treinamento da RNA da proposta 1. Os parâmetros dessa RNA foram utilizados em ambos os cenários descritos na Seção 3.3. Além disso, a Tabela 3.7 apresenta os dados de número de iterações (épocas), do Erro Quadrático Médio (MSE, do inglês, *Mean Squared Error*) e da regressão linear (R^2), que foram obtidos após o treinamento de cada uma das redes

Tabela 3.7. Parâmetros da RNA da proposta 1 modelada

Parâmetros	Dados utilizados	
	Cenário 1	Cenário 2
Tipo de rede	MLP (<i>Feed-forward backprop</i>)	
Algoritmo de treinamento	Levenberg-Marquardt	
Entradas	$[G \ T_{AMB}]$	
Saída	$[D]$	
Número de camadas	2	
Número de neurônios	(5, 1)	
Funções de ativação	(tansig, pureline)	
Número de conjunto de dados	77	
Épocas	9	6
MSE	$2,4677 \cdot 10^{-8}$	$4,3752 \cdot 10^{-9}$
R^2 total	1	1

Fonte: Autoria própria

Com os dados da Tabela 3.7, nota-se que apenas 5 neurônios na primeira camada e menos de 10 iterações foram suficientes para a RNA da proposta 1 conseguiu obter uma

regressão linear igual a 1, ou seja, a rede conseguiu obter uma equação fidedigna ao conjunto de dados compilado.

Em seguida, o algoritmo RNA da proposta 2, que considera o parâmetro ambiental G e o parâmetro elétrico $P_{FV}(t)$ como entradas, tem sua modelagem explicada no Subseção 3.6.2.

3.6.2 Proposta 2 - Variáveis de entrada irradiância e potência de saída instantânea do arranjo FV

Na presente subseção, o MPPT baseado na RNA da proposta 2 considera as variáveis irradiância (G) e potência de saída instantânea do arranjo FV ($P_{FV}(t)$) como entrada, e o ciclo de trabalho (D) do conversor como saída. A Figura 3.17 mostra essa modelagem.

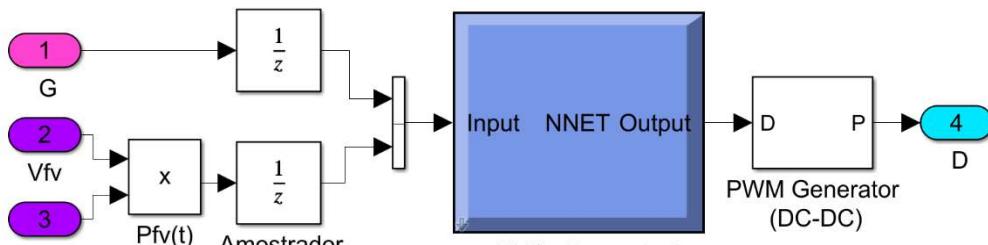


Figura 3.17. MPPT baseado na proposta 2 do algoritmo de controle RNA
Fonte: Autoria própria

De modo análogo ao MPPT da Subseção 3.6.1, as variáveis de entrada foram discretizadas considerando a mesma taxa de amostragem, ou seja, o período T de chaveamento definido para o sinal de referência do PWM. É importante ressaltar, que a variável $P_{FV}(t)$ é oriunda das variáveis tensão (V_{FV}) e corrente (I_{FV}) elétricas extraídas dos sensores instalados na saída do arranjo FV da Figura 3.6.

Ademais, a RNA da proposta 2 também tem o ciclo de trabalho D do conversor CC-CC como saída, que foi conectada ao bloco do gerador PWM.

Depois da modelagem do MPPT, o algoritmo inteligente RNA da proposta 2 foi treinado utilizando as 77 amostras do conjunto de dados compilados na Seção 3.4. Assim como no treinamento da Subseção 3.6.1, 70% das amostras foram utilizadas para o treinamento da rede, 15% para o teste e 15% para a validar o treinamento finalizado.

A Tabela 3.8 sintetiza os parâmetros utilizados para o treinamento da RNA da proposta 2 de ambos os cenários, bem como os dados que foram obtidos posterior ao treinamento.

Tabela 3.8. Parâmetros da RNA da proposta 2 modelada

Parâmetros	Dados utilizados	
	Cenário 1	Cenário 2
Tipo de rede	MLP (<i>Feed-forward backprop</i>)	
Algoritmo de treinamento	Levenberg-Marquardt	
Entradas	$[G \ P_{FV}(t)]$	
Saída	$[D]$	
Número de camadas	2	
Número de neurônios	(5, 1)	
Funções de ativação	(tansig, pureline)	
Conjunto de dados	77	
Iterações	6	227
R ² total	0,99997	1
MSE	$2,3053 \cdot 10^{-7}$	$2,3381 \cdot 10^{-8}$

Fonte: Autoria própria

Pela Tabela 3.8, observa-se que a RNA da proposta 2 conseguiu obter uma regressão linear (R^2) igual a 0,99997 para o cenário 1, após 6 iterações. Por outro lado, a RNA obteve uma equação fidedigna ao conjunto de dados para o cenário 2, ou seja, a R^2 foi igual a 1, depois de 227 iterações.

Finalizadas a modelagem e treinamentos das RNA da proposta 2, uma nova RNA foi desenvolvida. Agora, na proposta 3, é considerado apenas parâmetros elétricos como variáveis de entrada, especificamente, $P_{FV}(t)$ e $P_{FV}(t-1)$, como detalhada a Subseção 3.6.3.

3.6.3 Proposta 3 - Variáveis de entrada potência de saída instantânea e do instante anterior do arranjo FV

A proposta da presente subseção diz respeito a modelagem de um MPPT baseado no algoritmo inteligente RNA. Ele considera os parâmetros elétricos potência de saída do arranjo FV lida no instante atual ($P_{FV}(t)$) e a lida no instante anterior ($P_{FV}(t-1)$) como variáveis de entrada da RNA e permanece considerando o ciclo de trabalho (D) do conversor como saída. Para essa proposta, o MPPT foi projetado conforme mostra a Figura 3.18.

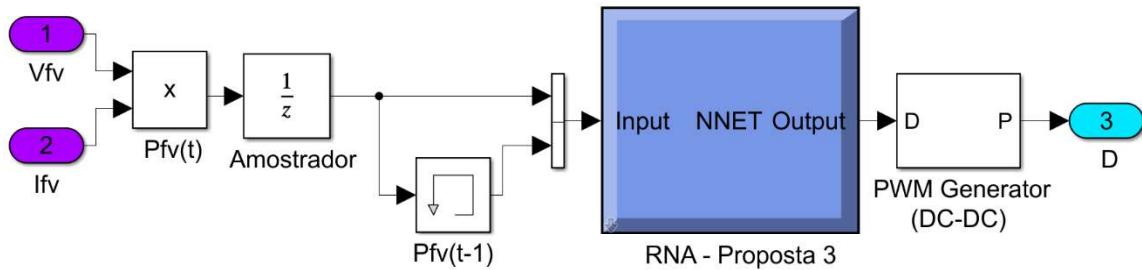


Figura 3.18. MPPT baseado na proposta 3 do algoritmo de controle RNA
Fonte: Autoria própria

Semelhante aos MPPT das subseções 3.6.1 e 3.6.2, as variáveis de entrada foram discretizadas considerando o período T como taxa de amostragem do amostrador.

Em seguida, a RNA da proposta 3 passou por um treinamento supervisionado para cada um dos cenários descritos na Seção 3.3. Nesse treinamento foram utilizados 77 conjuntos de dados amostrais compostos pela potência de saída do arranjo FV nas duas entradas e o ciclo de trabalho do conversor na saída. Assim como no treinamento das subseções 3.6.1 e 3.6.2, 70% das amostras foram usadas no treinamento da rede, 15% no teste e 15% na validação do treinamento realizado para a RNA da proposta 3.

Com o objetivo de extrair as melhores respostas na saída do sistema FV de cada cenário, algoritmos RNA com diferentes números de camada e funções de ativação foram modelados e testados. Assim, aqueles que obtiveram melhores resultados foram considerados para uso e posterior simulação. A Tabela 3.9 apresenta os principais parâmetros da RNA da proposta 3 que foi escolhido para o treinamento de cada cenário, assim como os dados obtidos após o treinamento das redes.

Tabela 3.9. Parâmetros da RNA da proposta 3 modelada

Parâmetros	Dados utilizados	
	Cenário 1	Cenário 2
Tipo de rede	MLP(<i>Feed-forward backprop</i>)	
Algoritmo de treinamento	Levenberg-Marquardt	
Entradas	$[P_{FV}(t) \ P_{FV}(t-1)]$	
Saída	$[D]$	
Número de camadas	3	2
Número de neurônios	(25, 15, 1)	(30, 1)
Funções de ativação	(tansig, pureline, pureline)	(pureline, tansig)
Conjunto de dados	77	
Iterações	6	
R ² total	0,94264	0,93058
MSE	$0,65202 \cdot 10^{-3}$	$1,453 \cdot 10^{-3}$

Fonte: Autoria própria

Pela Tabela 3.9, percebe-se que a RNA do cenário 1 necessitou de um maior número de camadas durante o treinamento, mas teve um maior R^2 . Por outro lado, a RNA do cenário 2 precisou de um menor número de camadas, mas teve menor R^2 e maior MSE.

Em ambos os cenários da Tabela 3.9, R^2 foi menor que 0,95, ou seja, a rede treinada não conseguiu encontrar uma equação matemática que representasse com total fidelidade a relação entre os dados de entrada e saída disponíveis no banco de dados.

Após a modelagem dos MPPT baseado na RNA, também foram desenvolvidos MPPT que são baseados na lógica *fuzzy*. Para fins comparativo, as três propostas desenvolvidas na Seção 3.6 também foram projetadas para o algoritmo de controle *fuzzy* na Seção 3.7.

3.7 Modelagem do MPPT baseado na lógica *fuzzy*

O MPPT baseado na lógica *fuzzy* (FL) é influenciado pelo conhecimento do projetista sobre o sistema a ser controlado, como explicado na Subseção 2.7.2.2. Sabendo disso, o presente trabalho desenvolveu três diferentes propostas de FLC que, assim como o algoritmo RNA, diferenciou-se pelos parâmetros escolhidos como duplas de variáveis de entrada.

As variáveis de entrada utilizadas nos FLCs foram: G e T_{AMB} na proposta 1, discutida na Subseção 3.7.1; G e $P_{FV}(t)$ na proposta 2, detalhada na Subseção 3.7.2; e $P_{FV}(t)$ e $P_{FV}(t-1)$ na proposta 3, explicada na Subseção 3.7.3.

3.7.1 Proposta 1 - Variáveis de entrada Irradiância e Temperatura ambiente

Para o desenvolvimento do MPPT baseado na lógica *fuzzy* da proposta 1, um esquema similar ao desenvolvido para a RNA da proposta 1 (Figura 3.16) foi modelado. Nesse caso, apenas o tipo de algoritmo de controle foi alterado, como mostra a Figura 3.19.

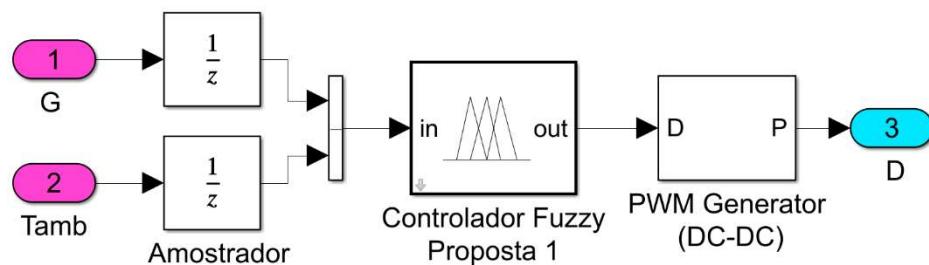


Figura 3.19. MPPT baseado na proposta 1 do controlador *fuzzy*
Fonte: Autoria própria

Semelhante as RNAs modeladas na Seção 3.6, na Figura 3.19, a taxa de amostragem do amostrador é igual ao período T de chaveamento que foi definido para o sinal de referência do PWM. O amostrador discretiza as variáveis de entrada antes da sua entrada no FLC.

Após projetar o MPPT da Figura 3.19, a modelagem do algoritmo inteligente *fuzzy* foi iniciada. Primeiro, foi observado o comportamento do sistema FV e percebeu-se que os dados de entrada e sua saída D correspondente eram iguais em ambos os cenários. Desta forma, para a proposta 1, foi pertinente modelar e testar um mesmo FLC para ambos os cenários.

Na modelagem do FLC da proposta 1 foram atribuídas 11 funções de pertinência triangulares para a variável de entrada G , 7 funções de pertinência triangulares para a variável de entrada T_{AMB} e 5 funções de pertinência triangulares para a variável de saída D . O intervalo de valores atribuídos para cada uma das funções de pertinência está descrito na Tabela 3.10.

Tabela 3.10. Base de dados do FLC da proposta 1

Entrada 1: G	Intervalo	Entrada 2: T_{AMB}	Intervalo
100	[100 100 200]	15	[15 15 20]
200	[100 200 300]	20	[15 20 25]
300	[200 300 400]	25	[20 25 30]
400	[300 400 500]	30	[25 30 35]
500	[400 500 600]	35	[30 35 40]
600	[500 600 700]	40	[35 40 45]
700	[600 700 800]	45	[40 45 45]
800	[700 800 900]	Saída: D	Intervalo
900	[800 900 1000]	LO	[0,2583 0,3 0,34]
1000	[900 1000 1100]	ML	[0,331 0,3897 0,41]
1100	[1000 1100 1100]	M	[0,4028 0,44 0,475]
-	-	MH	[0,47 0,5085 0,547]
-	-	H	[0,54 0,58 0,6195]

Fonte: Autoria própria

Em seguida, as regras *fuzzy* foram estabelecidas. Elas foram baseadas em um estudo do comportamento do sistema FV através do conjunto de dados compilado. A Tabela 3.11 apresenta as regras *fuzzy* que foram definidas após os ajustes realizados para que a variável de saída D se aproximasse, ao máximo, do seu valor de referência calculado no conjunto de dados.

Tabela 3.11. Matriz de base de regras do FLC da proposta 1

Entrada 2 Entrada 1 \	15	20	25	30	35	40	45
100	LO						
200	LO	ML	ML	ML	ML	ML	ML
300	ML	ML	ML	ML	M	M	M
400	M	M	M	M	M	M	M
500	M	M	M	M	MH	MH	MH
600	MH						
700	MH						
800	MH	MH	MH	H	H	H	H
900	H	H	H	H	H	H	H
1000	H	H	H	H	H	H	H
1100	H	H	H	H	H	H	H

Fonte: Autoria própria

Ao todo, 77 regras *fuzzy* foram inseridas no controlador *fuzzy* do tipo Mamdani utilizado como algoritmo de controle do MPPT. A Tabela 3.12 resume as características básicas que compõem o FLC da proposta 1 que foi modelado e, posteriormente, treinado e simulado (Figura 3.19) junto ao sistema FV de ambos os cenários (Figura 3.6).

Tabela 3.12. Parâmetros do FLC da proposta 1 modelado

Parâmetro	Dado utilizado
Tipo	Mamdani
Entradas	[$G\ T_{AMB}$]
Saída	[D]
Número de funções de pertinência de entrada	[11 7]
Número de funções de pertinência de saída	5
Número de regras	77
Tipo de função de pertinência de entrada	trimf
Tipo de função de pertinência de saída	trimf
Intervalo da Entrada 1	[100 1100]
Intervalo da Entrada 2	[15 45]
Intervalo da saída	[0,2582 0,6193]

Fonte: Autoria própria

Depois de modelado o algoritmo inteligente *fuzzy* da proposta 1, um novo FLC, que considera o parâmetro ambiental G e o parâmetro elétrico $P_{FV}(t)$, foi projetado e discutido na Subseção 3.7.2.

3.7.2 Proposta 2 - Variáveis de entrada irradiância e potência de saída instantânea do arranjo FV

O segundo MPPT baseado na FL que foi desenvolvido é denominado de proposta 2. Ele tem como variáveis de entrada o parâmetro ambiental G e o parâmetro elétrico $P_{FV}(t)$.

Seguindo o mesmo processo da Subseção 3.6.2, o MPPT foi modelado considerando as novas variáveis de entrada, porém, mantendo a mesma taxa de amostragem para discretizar as entradas, bem como o D do conversor CC-CC como saída, conforme ilustra a Figura 3.20.

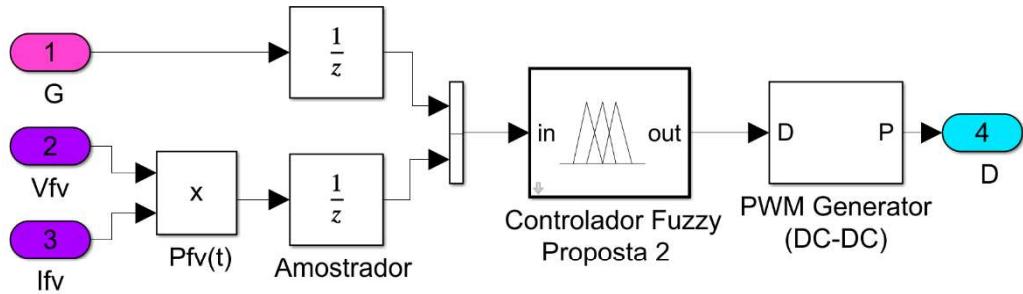


Figura 3.20. MPPT baseado na proposta 2 do controlador *fuzzy*
Fonte: Autoria própria

Posterior a modelagem da Figura 3.20, foi feito o FLC da proposta. Em cada cenário foi considerado 11 MF para a entrada G , 5 MF para a entrada $P_{FV}(t)$ e 5 MF para a saída D .

Desta forma, o FLC da proposta 2, usado como algoritmo de controle do MPPT da Figura 3.20, foi treinado e os intervalos de cada função de pertinência estão listados separadamente por cenário na Tabela 3.13 (cenário 1) e Tabela 3.14 (cenário 2).

Tabela 3.13. Base de dados do FLC da proposta 2 para o cenário 1

Entrada 1: G	Intervalo	Entrada 2: $P_{FV}(t)$	Intervalo
100	[100 100 200]	LO	[-419 259 919,2]
200	[100 200 300]	ML	[250,3 919,2 1588]
300	[200 300 400]	M	[919,2 1588 2257]
400	[300 400 500]	MH	[1588 2257 2926]
500	[400 500 600]	H	[2257 2926 3595]
600	[500 600 700]	Saída: D	
700	[600 700 800]	LO	[0,258 0,258 0,3486]
800	[700 800 900]	ML	[0,32 0,39 0,45]
900	[800 900 1000]	M	[0,38 0,45 0,5293]
1000	[900 1000 1100]	MH	[0,45 0,5 0,57]
1100	[1000 1100 1100]	H	[0,51 0,6196 0,6196]

Fonte: Autoria própria

Tabela 3.14. Base de dados do FLC da proposta 2 para o cenário 2

Entrada 1: G	Intervalo	Entrada 2: $P_{FV}(t)$	Intervalo
100	[100 100 200]	LO	[-628,4 375,1 1379]
200	[100 200 300]	ML	[375,5 1379 2382]
300	[200 300 400]	M	[1379 2382 3386]
400	[300 400 500]	MH	[2382 3386 4389]
500	[400 500 600]	H	[3386 4389 5392]
600	[500 600 700]	Saída: D	Intervalo
700	[600 700 800]	LO	[0,2579 0,2579 0,3485]
800	[700 800 900]	ML	[0,3199 0,3898 0,4498]
900	[800 900 1000]	M	[0,3798 0,4498 0,529]
1000	[900 1000 1100]	MH	[0,4498 0,4998 0,5697]
1100	[1000 1100 1100]	H	[0,5098 0,6193 0,6193]

Fonte: Autoria própria

Após a montagem da base de dados (Tabela 3.13 e Tabela 3.14), as regras *fuzzy* foram determinadas. Elas também foram embasadas no comportamento dos sistemas FV estudados. Para facilitar o entendimento das regras, a Tabela 3.15 apresenta a matriz de regra do FLC da proposta 2, que são iguais para ambos os cenários.

Tabela 3.15. Matriz de base de regras do FLC da proposta 2

Entrada 1	Entrada 2	LO	ML	M	MH	H
100	LO	LO	LO	LO	LO	LO
200	ML	ML	ML	ML	ML	ML
300	ML	ML	M	H	ML	
400	M	M	M	M	M	M
500	M	M	M	M	M	M
600	MH	MH	MH	MH	MH	MH
700	MH	MH	MH	MH	MH	MH
800	MH	MH	MH	MH	MH	MH
900	MH	MH	H	H	H	H
1000	H	H	H	H	H	H
1100	H	H	H	H	H	H

Fonte: Autoria própria

Depois de ser definido a matriz base de regra do FLC da proposta 2, que são compostas 55 regras *fuzzy*, o algoritmo de controle finaliza seu treinamento. Desta forma, o sistema FV de cada cenário pode ser simulado com seu respectivo FLC modelado. Para fins de simplificação,

os parâmetros básicos do FLC da proposta 2, discutidos na presente subseção, estão descritos, separadamente por cenário, na Tabela 3.16.

Tabela 3.16. Parâmetros do FLC da proposta 2

Parâmetros	Dados utilizados	
	Cenário 1	Cenário 2
Tipo	Mamdani	
Entradas	$[G P_{FV}(t)]$	
Saída	$[D]$	
Número de funções de pertinência de entrada	$[11\ 5]$	
Número de funções de pertinência de saída	$[5]$	
Tipo de funções de pertinência de entrada	trimf	
Tipo de funções de pertinência de saída	trimf	
Número de regras	55	
Intervalo da Entrada 1	$[100\ 1100]$	
Intervalo da Entrada 2	$[250,3\ 2926]$	$[375,5\ 4389]$
Intervalo da saída	$[0,2583\ 0,6195]$	$[0,2582\ 0,6193]$

Fonte: Autoria própria

Concluído o treinamento das FLC da proposta 2, um novo algoritmo inteligente *fuzzy* foi modelado e treinado. Ele é denominado de proposta 3 e considera os parâmetros elétricos $P_{FV}(t)$ e $P_{FV}(t-1)$ como variáveis de entrada, conforme detalha a Subseção 3.7.3.

3.7.3 Proposta 3 - Variáveis de entrada potência de saída instantânea e do instante anterior do arranjo FV

O terceiro MPPT baseado na lógica *fuzzy*, nomeado de proposta 3, foi desenvolvido considerando como variáveis de entrada apenas parâmetros elétricos, especificamente: potência de saída instantânea ($P_{FV}(t)$) e do instante anterior ($P_{FV}(t-1)$) do arranjo FV.

Nessa modelagem, a taxa de amostragem do amostrador foi mantida igual à da Subseção 3.7.2, assim como o uso do D do conversor CC-CC como saída, conforme ilustra a Figura 3.21.

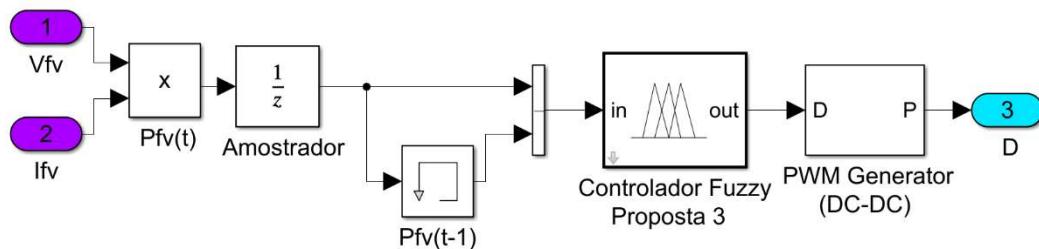


Figura 3.21. MPPT baseado na proposta 3 do controlador *fuzzy*
Fonte: Autoria própria

O FLC da proposta 3, mostrada na Figura 3.21, foi treinado logo após sua modelagem ser finalizada. Em cada cenário foi considerado 5 MF por entrada e 5 MF na saída. Ademais, como as duas variáveis de entrada eram potências de saída do arranjo FV e elas possuíam os mesmos valores, então o mesmo intervalo de MF foi considerado para ambas as entradas.

As Tabela 3.17 e Tabela 3.18 mostram, respectivamente, a base de dados dos algoritmos inteligentes *fuzzy* desenvolvidos para o cenário 1 e cenário 2.

Tabela 3.17. Base de dados do FLC da proposta 3 para o cenário 1

Função de pertinência	Entradas: $P_{FV}(t)$ e $P_{FV}(t-1)$	Saída: D
LO	[250,3 250,3 919,3]	[0,2583 0,2583 0,4195]
ML	[245,9 928,6 1575]	[0,2580 0,4010 0,5434]
M	[973,3 1600 2087]	[0,3850 0,4593 0,6190]
MH	[1513 2052 2673]	[0,4430 0,4818 0,6200]
H	[2467 2927 2927]	[0,5251 0,6200 0,9810]

Fonte: Autoria própria

Tabela 3.18. Base de dados do FLC da proposta 3 para o cenário 2

Função de pertinência	Entradas: $P_{FV}(t)$ e $P_{FV}(t-1)$	Saída: D
LO	[375,5 375,5 1379]	[0,2583 0,2583 0,4195]
ML	[376 1400 2370]	[0,2580 0,4010 0,5434]
M	[1460 2400 3130]	[0,3850 0,4593 0,6190]
MH	[2270 3078 4010]	[0,4430 0,4818 0,6200]
H	[3700 4390 4390]	[0,5251 0,6200 0,9810]

Fonte: Autoria própria

Analizando as Tabela 3.17 e Tabela 3.18, as saídas D possuem intervalos de MF iguais. Isso ocorre devido à proximidade entre os D calculados para ambos os cenários.

Posteriormente, com base no comportamento dos sistemas FV estudados, as regras *fuzzy* foram determinadas. A Tabela 3.19 representa a matriz de regra do FLC da proposta 3, que é composta por 25 regras *fuzzy*, e idênticas para ambos os cenários trabalhados.

Tabela 3.19. Matriz de base de regras do FLC da proposta 3

Entrada 2	LO	ML	M	MH	H
Entrada 1	LO	ML	M	MH	H
LO	LO	LO	LO	LO	LO
ML	ML	ML	ML	ML	H
M	M	MH	MH	MH	MH
MH	MH	MH	MH	H	H
H	H	H	H	H	H

Fonte: Autoria própria

Finalmente, para sintetizar os FLC modelados na presente subseção, os parâmetros básicos do FLC da proposta 3 estão descritos na Tabela 3.20 e divididos por cenário.

Tabela 3.20. Parâmetros do FLC da proposta 3

Parâmetros	Dados utilizados	
	Cenário 1	Cenário 2
Tipo	Mamdani	
Entradas	$[P_{FV}(t) \ P_{FV}(t-I)]$	
Saída	$[D]$	
Número de funções de pertinência de entrada	$[5 \ 5]$	
Número de funções de pertinência de saída	$[5]$	
Tipo de funções de pertinência de entrada	trimf	
Tipo de funções de pertinência de saída	trimf	
Número de regras	25	
Intervalo das entradas	$[250,3 \ 2926]$	$[375,5 \ 4389]$
Intervalo da saída	$[0,2583 \ 0,6195]$	

Fonte: Autoria própria

Seguindo o desenvolvimento proposto na presente pesquisa, após a modelagem dos algoritmos P&O, RNA e *fuzzy*, o projeto e desenvolvimento dos controladores de MPPT baseado nas três propostas de algoritmos ANFIS foram estudados na Seção 3.8.

3.8 Modelagem do MPPT baseado na técnica otimizada ANFIS

O MPPT baseado na técnica otimizada ANFIS foi modelado no *software* Matlab/Simulink®. Ele considerou uma única saída D e as mesmas três diferentes duplas de variáveis de entrada utilizadas nas seções 3.6 e 3.7. Assim sendo, a presente seção se dividiu nas subseções 3.8.1, 3.8.2 e 3.8.3 para realizar o treinamento dos três diferentes algoritmos de controle ANFIS.

3.8.1 Proposta 1 - Variáveis de entrada irradiância e temperatura ambiente

Antes de construir a arquitetura do algoritmo ANFIS da proposta 1, foi necessário modelar o MPPT do referido sistema FV. Como as variáveis estabelecidas como entrada do ANFIS da proposta 1 são os parâmetros ambientais G e T_{AMB} , eles precisaram ser discretizados utilizando uma taxa de amostragem igual ao período estabelecido para o PWM.

Análogo aos algoritmos das Subseções 3.6.1 e 3.7.1, a saída D do ANFIS foi utilizada como entrada do bloco *PWM Generator (DC-DC)*, como ilustra a Figura 3.22.

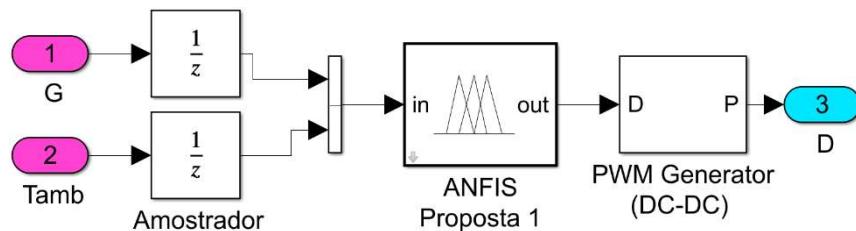


Figura 3.22. MPPT baseado na proposta 1 do algoritmo de controle ANFIS

Fonte: Autoria própria

As variáveis G e T_{AMB} da Figura 3.22 são as mesmas inseridas na entrada do arranjo FV da Figura 3.6. Com relação ao sinal de saída D , ele é utilizado como entrada do MOSFET da Figura 3.6 e serve para controlar o chavamento desse dispositivo.

Após montar o MPPT, a arquitetura ANFIS da proposta 1 foi construída e treinada utilizando os 77 conjuntos de amostras que compõem o banco de dados levantado na Seção 3.4. De início, foi considerado utilizar o mesmo número de MF definidos para o controlador *fuzzy* da Subseção 3.7.1, ou seja, 11 MF para G e 7 MF para T_{AMB} .

Porém, devido a facilidade em treinar um ANFIS, outros números de MF foram atribuídos, cujo objetivo foi encontrar o menor número de MF e, assim, reduzir a complexidade da arquitetura sem perder a eficiência do algoritmo ao rastrear o MPP. Como resultado, foi obtida uma arquitetura ANFIS com 5 MF por entrada e 25 regras *fuzzy*.

Depois de definir o número de MF do ANFIS da proposta 1, foi necessário estabelecer um tipo de MF, dentre os oito tipos presentes no *toolbox ANFIS Editor* do software Matlab®. Essa escolha foi realizada por meio do menor erro de treinamento obtido, ao utilizar como critérios de parada, um erro com tolerância zero ou um total de três iterações serem atingidas. A Tabela 3.21 mostra os erros atingidos e destaca, em vermelho, o tipo de MF escolhido e seus respectivos erros de treinamento por cenário.

Tabela 3.21. Erro de treinamento das MF do ANFIS da proposta 1, por tipo e por cenário

Tipos de MF	Cenário 1	Cenário 2	Tipos de MF	Cenário 1	Cenário 2
trimf	0,0040167	0,0039806	gauss2mf	0,0153730	0,0153210
trapmf	0,0141960	0,0141390	pimf	0,0182190	0,0181720
gbellmf	0,0098756	0,0098201	dsigmf	0,0122960	0,0122400
gaussmf	0,0071328	0,0070781	psigmf	0,0122950	0,0122400

Fonte: Autoria própria

Após o algoritmo ANFIS da proposta 1 ter sido treinado considerando cada tipo de MF, percebeu-se que, para ambos os cenários, o menor erro obtido foi com a MF triangular (*trimf*).

Desta forma, o tipo de MF escolhida para compor o ANFIS da proposta 1 de ambos os cenários foi a triangular. Os intervalos atribuídos por MF são mostrados na base de dados da Tabela 3.22. No caso da saída, foi definido uma MF constante.

Tabela 3.22. Base de dados do controlador ANFIS da proposta 1

Entrada 1: G	Intervalos	Entrada 2: T_{AMB}	Intervalos
LO	[-150 99,98 350]	LO	[7,5 15 22,5]
ML	[100 350 600]	ML	[15 22,5 30]
M	[350 600 850]	M	[22,5 30 37,5]
MH	[600 850 1100]	MH	[30 37,5 45]
H	[850 1100 1350]	H	[37,5 45 52,5]

Fonte: Autoria própria

É importante ressaltar que, em virtude de as variáveis de entrada serem condições do ambiente, elas são idênticas para ambos os cenários modelados na Seção 3.3. Assim, os intervalos das MF apresentados na Tabela 3.22 serão utilizados para ambos os cenários.

Por fim, a Tabela 3.23 resume os principais parâmetros estabelecidos para o ANFIS da proposta 1, quando utilizado como algoritmo de controle do MPPT dos dois cenários em estudo.

Tabela 3.23. Parâmetros do ANFIS da proposta 1 modelado

Parâmetro	Dado utilizado
Tipo	Sugeno
Entradas	$[G \ T_{AMB}]$
Saída	$[D]$
Número de funções de pertinência de entrada	[5 5]
Número de funções de pertinência de saída	25
Número de regras	25
Tipo de função de pertinência de entrada	trimf
Tipo de função de pertinência de saída	constante
Intervalo da Entrada 1	[100 1100]
Intervalo da Entrada 2	[15 45]
Intervalo da saída	[0,2582 0,6193]
Número de conjunto de dados	77
Treinamento	híbrido
Iterações	3

Fonte: Autoria própria

Ao término da modelagem e treinamento da arquitetura ANFIS da proposta 1 (Tabela 3.23), a Subseção 3.8.2 desenvolve o ANFIS da proposta 2.

3.8.2 Proposta 2 - Variáveis de entrada irradiância e potência de saída instantânea do arranjo FV

Na proposta 2, substituir o parâmetro ambiental T_{AMB} pelo parâmetro elétrico $P_{FV}(t)$ permite avaliar o parâmetro ambiental que mais interfere na geração de eletricidade, juntamente com o parâmetro elétrico que mais é afetado pelas condições do ambiente. Para isso, é necessário substituir uma das variáveis do ANFIS da Subseção 3.8.1. Consequentemente, o MPPT baseado no ANFIS precisa ser ajustado, como mostra a Figura 3.23.

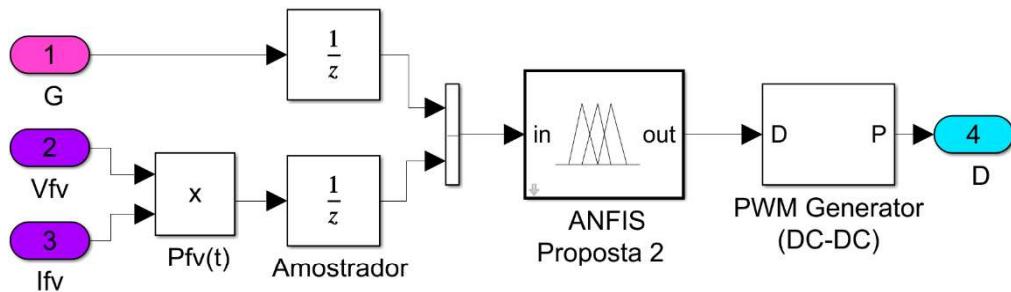


Figura 3.23. MPPT baseado na proposta 2 do algoritmo de controle ANFIS
Fonte: Autoria própria

Após a modelagem do MPPT baseado no ANFIS da proposta 2, as mesmas 77 amostras do conjunto de dados da Subseção 3.7.2 foram utilizadas para treinar o ANFIS de cada cenário. Ao todo, foi estabelecido 5 MF para cada entrada e 1 MF constante para a saída.

Igualmente à Subseção 3.8.1, o erro calculado durante o treinamento foi o critério utilizado para escolher o tipo de MF do ANFIS da proposta 2. Em ambos os cenários, o menor erro foi o da MF do tipo triangular, destacado em vermelho, como mostra a Tabela 3.24.

Tabela 3.24. Erro de treinamento das MF do ANFIS da proposta 2, por tipo e por cenário

Tipos de MF	Cenário 1	Cenário 2	Tipos de MF	Cenário 1	Cenário 2
trimf	0,00284630	0,0028439	gauss2mf	0,01371500	0,0136650
trapmf	0,01373990	0,0136876	pimf	0,01554600	0,0154950
gbellmf	0,00632679	0,0062763	dsigmf	0,00881300	0,0099430
gaussmf	0,00471468	0,0046757	psigmf	0,00880700	0,0099430

Fonte: Autoria própria

Os erros de treinamento da Tabela 3.24 foram alcançados na segunda iteração do treinamento do ANFIS. Ao escolher a MF triangular, os erros de 0,00284630 e 0,0028439 foram calculados, respectivamente, para o cenário 1 e cenário 2, quando considerou a tolerância do erro igual a zero e o número máximo de iterações igual a 10.

A Tabela 3.25 e Tabela 3.26 apresentam os intervalos obtidos para as MF triangulares de cada variável de entrada do ANFIS da proposta 2, respectivamente, por cada cenário.

Tabela 3.25. Base de dados do ANFIS da proposta 2 para o cenário 1

Entrada 1: G	Intervalos	Entrada 2: $P_{FV}(t)$	Intervalos
LO	[-150 99,97 350]	LO	[-418,6 250,3 919,2]
ML	[100 350 600]	ML	[250,3 919,2 1588]
M	[350 600 850]	M	[919,2 1588 2257]
MH	[600 850 1100]	MH	[1588 2257 2926]
H	[850 1100 1350]	H	[2257 2926 3595]

Fonte: Autoria própria

Tabela 3.26. Base de dados do ANFIS da proposta 2 para o cenário 2

Entrada 1: G	Intervalos	Entrada 2: $P_{FV}(t)$	Intervalos
LO	[-150 99,97 350]	LO	[-627,9 375,5 1379]
ML	[100 350 600]	ML	[375,5 1379 2382]
M	[350 600 850]	M	[1379 2382 3386]
MH	[600 850 1100]	MH	[2382 3386 4389]
H	[850 1100 1350]	H	[3386 4389 5392]

Fonte: Autoria própria

Além dos intervalos das MF mostrados nas Tabela 3.25 e Tabela 3.26, os parâmetros do ANFIS da proposta 2, expostos na Tabela 3.27, também precisaram ser estabelecidos.

Tabela 3.27. Parâmetros do ANFIS da proposta 2 modelado

Parâmetro	Dado utilizado
Tipo	Sugeno
Entradas	$[G \ P_{FV}(t)]$
Saída	$[D]$
Número de funções de pertinência de entrada	[5 5]
Número de funções de pertinência de saída	25
Número de regras	25
Tipo de função de pertinência de entrada	trimf
Tipo de função de pertinência de saída	constante
Número de conjunto de dados	77
Treinamento	Híbrido

Fonte: Autoria própria

Concluída a modelagem do ANFIS da proposta 2, que mesclou o uso de parâmetros ambiental e elétrico como variáveis de entrada, a Subseção 3.8.3 descreve a modelagem do ANFIS da proposta 3, que utiliza apenas parâmetros elétricos como variáveis de entrada.

3.8.3 Proposta 3 - Variáveis de entrada potência de saída instantânea e do instante anterior do arranjo FV

Na arquitetura ANFIS da proposta 3, os parâmetros $P_{FV}(t)$ e $P_{FV}(t-1)$ são utilizadas como entradas. Logo, é realizada uma nova modelagem do MPPT, como ilustra a Figura 3.24.

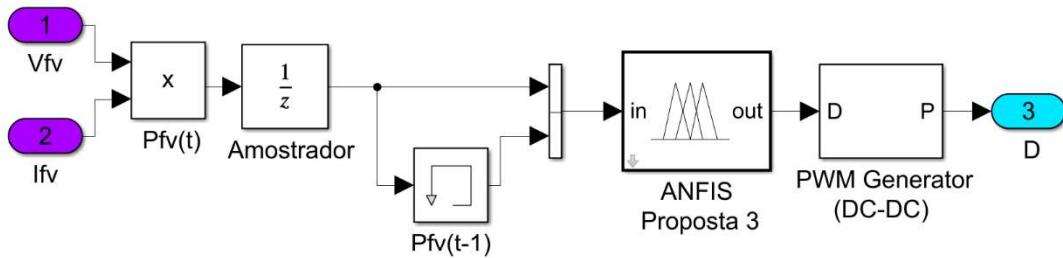


Figura 3.24. MPPT baseado na proposta 3 do algoritmo de controle ANFIS
Fonte: Autoria própria

Posterior a montagem do MPPT, o ANFIS de cada cenário precisou ser modelado com o auxílio das 77 amostras de P_{MPP} e D do conjunto de dados levantado na Seção 3.4. Para isso, foi determinado um total de 5 MF triangulares para cada entrada e uma MF constante na saída.

Após o treinamento do ANFIS da proposta 3, um erro de 0,031459 e 0,031467 foi obtido (destacado em vermelho), respectivamente, para o cenário 1 e cenário 2. A Tabela 3.28 mostra um comparativo entre os erros obtidos por cada tipo de MF.

Tabela 3.28. Erro de treinamento das MF do ANFIS da proposta 3, por tipo e por cenário

Tipos de MF	Cenário 1	Cenário 2	Tipos de MF	Cenário 1	Cenário 2
trimf	0,031459	0,031467	gauss2mf	0,034937	0,034913
trapmf	0,034441	0,034414	pimf	0,037020	0,037000
gbellmf	0,032098	0,032090	dsigmf	0,032410	0,031564
gaussmf	0,031666	0,031657	psigmf	0,032410	0,031564

Fonte: Autoria própria

Em seguida, foi observado a necessidade de realizar um ajuste fino manual no algoritmo ANFIS de ambos os cenários. O intuito era obter resultados ainda mais precisos.

Primeiramente, na base de regras, a regra *fuzzy* 19, que era “Se $\langle P(t) \text{ é } MH \text{ e } P(t-1) \text{ é } MH \rangle$ Então $\langle D \text{ é } MF19 \rangle$ ”, precisou ser alterada para “Se $\langle P(t) \text{ é } MH \text{ e } P(t-1) \text{ é } MH \rangle$ Então $\langle D \text{ é } MF20 \rangle$ ”. Para conhecimento, o ANFIS treinado atribuiu o valor de 0,5552 para a saída MF19 (em ambos os cenários) e o valor de 0,5696 (cenário 1) e 0,5686 (cenário 2) para a saída MF20. É importante ressaltar que apenas substituir os valores de cada MF de saída não trouxeram resultados satisfatórios para o controle do MPP, por isso a troca de MF foi necessária.

Em seguida, foi realizada uma alteração na base de dados, especificadamente no intervalo da MF “M” de ambas as entradas. O primeiro e terceiro valor aumentaram 2%, ao passo que o segundo valor precisou de uma elevação de 5,5%. Assim, o intervalo inicialmente treinado para a MF M do cenário 1 foi de [918,3 1588 2257], mas ele foi alterado para [937 1657 2302]. Para o cenário 2, a MF M era [1379 2382 3386] e mudou para [1407 2513 3454].

Com as alterações concluídas, a Tabela 3.29 apresenta os intervalos das MF de cada entrada do ANFIS da proposta 3. É importante frisar que a entrada 1 e entrada 2 de cada cenário têm os mesmos intervalos, pois ambas correspondem a potência de saída do arranjo FV.

Tabela 3.29. Base de dados do ANFIS da proposta 3

Cenário 1		Cenário 2	
Entradas: $P_{FV}(t)$ e $P_{FV}(t-1)$	Intervalos	Entradas: $P_{FV}(t)$ e $P_{FV}(t-1)$	Intervalos
LO	[-419 250 918,2]	LO	[-627,9 375,5 1379]
ML	[250,3 918,3 1588]	ML	[375,5 1379 2382]
M	[937 1675 2302]	M	[1407 2513 3454]
MH	[1588 2257 2926]	MH	[2382 3386 4389]
H	[2257 2926 3595]	H	[3386 4389 5392]

Fonte: Autoria própria

Depois de montar a Tabela 3.29 e ajustar a base de regras, a Tabela 3.30 mostra os parâmetros utilizados na configuração do ANFIS da proposta 3.

Tabela 3.30. Parâmetros do ANFIS da proposta 3 modelado

Parâmetro	Dado utilizado
Tipo	Sugeno
Entradas	[$P_{FV}(t)$ e $P_{FV}(t-1)$])
Saída	[D]
Número de funções de pertinência de entrada	[5 5]
Número de funções de pertinência de saída	25
Número de regras	25
Tipo de função de pertinência de entrada	trimf
Tipo de função de pertinência de saída	constante
Número de conjunto de dados	77
Treinamento	Híbrido

Fonte: Autoria própria

Finalmente, depois de todos os algoritmos de controle propostos no presente estudo terem sido modelados e treinados para ambos os cenários, todos os sistemas FV foram simulados. Sendo assim, o Capítulo 4 é responsável por apresentar e analisar os resultados obtidos com tais simulações sob as diferentes condições ambientais estabelecidas na Seção 3.4.

4. Resultados e Discussões

No Capítulo 4 serão apresentados e avaliados os principais resultados obtidos em cada etapa da metodologia. Além disso, uma análise comparativa entre as técnicas modeladas, treinadas e simuladas propostas será realizada. Finalmente, um estudo comparativo com outros trabalhos desenvolvidos e que utilizaram o *buck-boost* como conversor CC-CC será apresentado e discutido.

4.1 Análise e validação da modelagem do módulo FV

Comparar os resultados obtidos em simulação com os valores medidos experimentalmente, é fundamental para avaliar o quanto condizente com a realidade o modelo proposto se comporta. Nessa análise foram escolhidas aleatoriamente seis condições ambientais, e apenas o critério de irradiância crescente precisou ser garantido.

Dessa forma, sabendo que o sistema FV real contém um MPPT (Seção 3.1), foi admissível comparar o valor medido experimentalmente (sem qualquer sombreamento no arranjo FV) com o MPP da curva característica P-V do arranjo FV modelado. A Tabela 4.1 mostra o comparativo desses resultados.

Tabela 4.1. Análise comparativa entre os resultados experimentais e simulados para validação do modelo do arranjo FV proposto

Variáveis de entrada		Experimento	Modelo proposto	
G (W/m ²)	T_{AMB} (°C)	P_{medido} (W)	$P_{MPP,simulação}$ (W)	$e\%$
294	23,86	919,25	935,20	1,73
303	31,74	906,83	893,90	1,43
548	24,65	1664,60	1629,00	2,14
868	31,46	2099,38	2105,00	0,27
957	31,41	2198,76	2223,00	1,10
1134	30,17	2397,52	2438,00	1,69

Fonte: Autoria própria

Através da Tabela 4.1 é possível observar que, para todas as condições ambientais, o modelo proposto apresentou resultados próximos dos valores medidos experimentalmente. O modelo proposto no presente trabalho apresentou um erro relativo entre 0,27 % e 2,14 %. A Figura 4.1 mostra esse comparativo ilustrativamente.

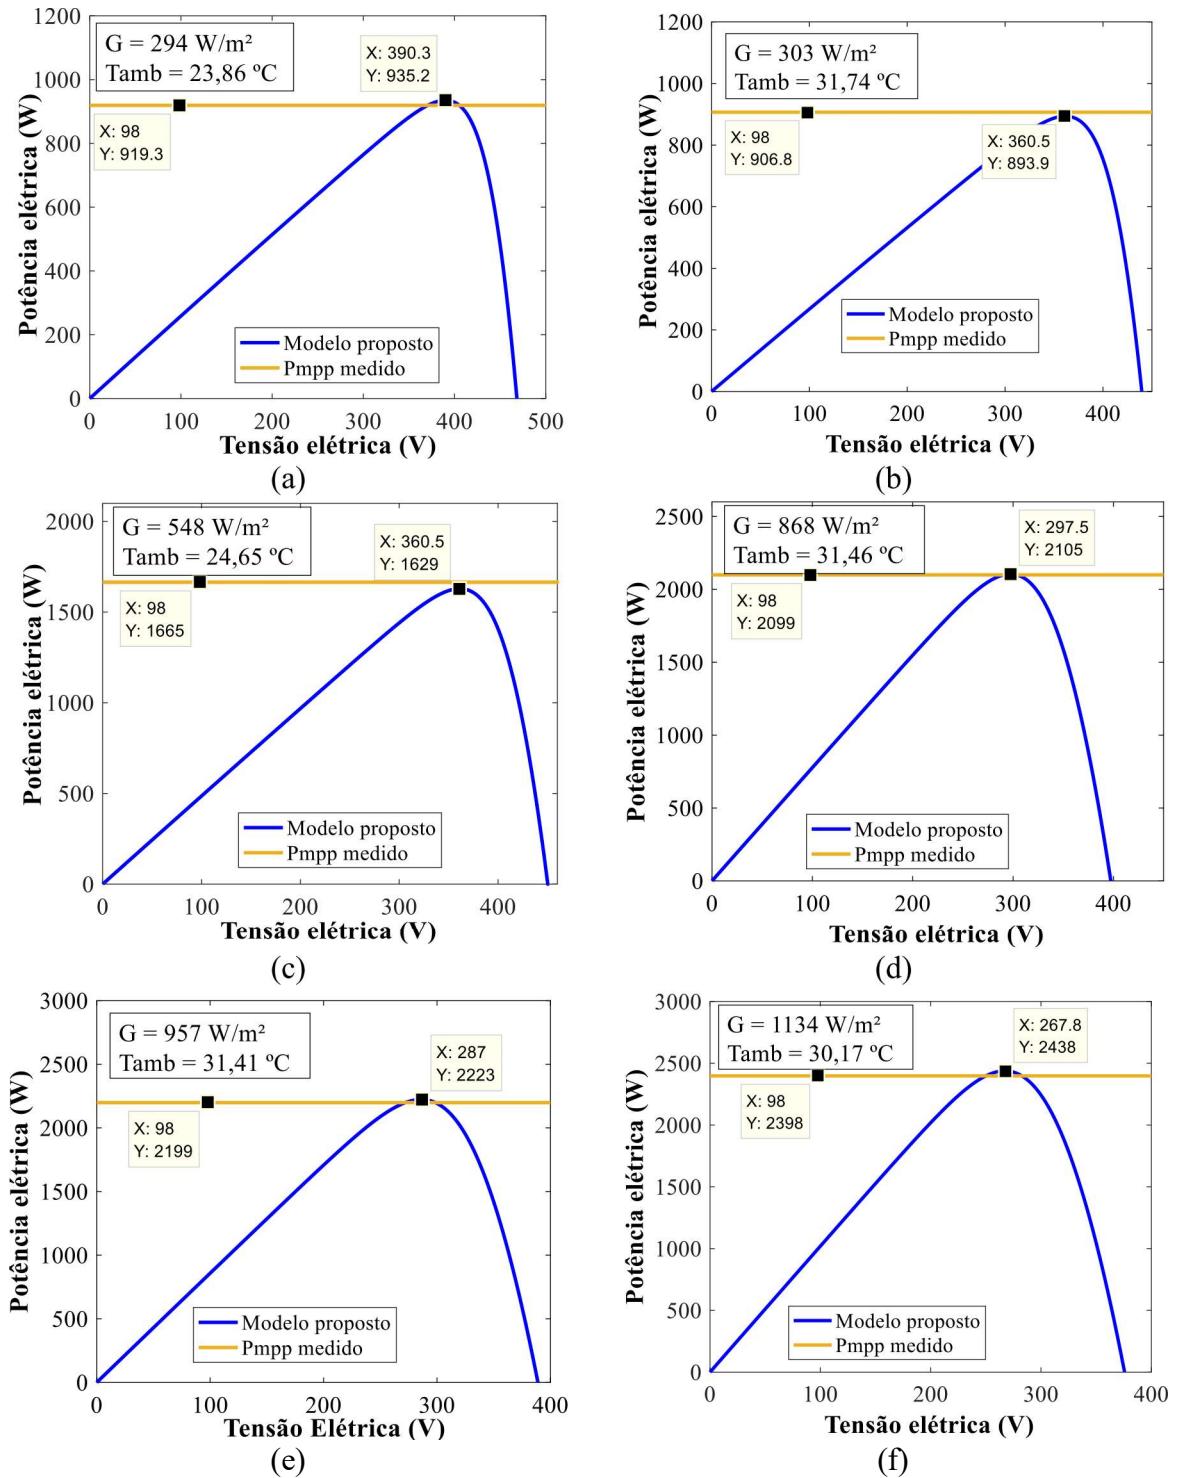


Figura 4.1. Comparativo entre as potências medidas experimentalmente e obtidas em simulação sob condições de (a) $G=294 \text{ W/m}^2$ e $T_{AMB}=23,86^\circ\text{C}$, (b) $G=303 \text{ W/m}^2$ e $T_{AMB}=31,74^\circ\text{C}$, (c) $G=548 \text{ W/m}^2$ e $T_{AMB}=24,65^\circ\text{C}$, (d) $G=868 \text{ W/m}^2$ e $T_{AMB}=31,46^\circ\text{C}$, (e) $G=957 \text{ W/m}^2$ e $T_{AMB}=31,41^\circ\text{C}$ e (f) $G=1134 \text{ W/m}^2$ e $T_{AMB}=30,17^\circ\text{C}$

Fonte: Autoria própria

Com os resultados obtidos na Tabela 4.1 e Figura 4.1 é pertinente afirmar que o modelo desenvolvido no presente trabalho tem resultados que condiz com a realidade. Por conta disso,

torna-se apropriado utilizar o modelo proposto para a montagem do conjunto de dados, bem como nas simulações posteriores.

A primeira das simulações realizadas foi o uso do algoritmo P&O, sob diferentes condições de passo, para controlar o chaveamento do conversor *buck-boost*. O objetivo é auxiliar no rastreamento do MPP dos arranjos FV em estudo, como explica a Seção 4.2.

4.2 Análise do desempenho do algoritmo de controle P&O

Um MPPT baseado na técnica clássica P&O foi testado para o cenário 1 e cenário 2 da Seção 3.3, e sob três diferentes passos (Δd), que são: 0,0010; 0,0015 e 0,0020.

Na avaliação de desempenho do algoritmo de controle P&O foi analisado a velocidade de convergência, a oscilação em torno do MPP no regime permanente e a eficiência do MPPT em rastrear o MPP. Isso foi feito, respectivamente, através de tempo de acomodação (ts), valor de pico a pico do sinal permanente (ΔP) e erro relativo percentual da resposta ($e\%$).

Para facilitar a análise, os desempenhos dos MPPT foram avaliados separadamente por cenário, como estabelecido na Subseção 3.3.1, isto é, na Subseção 4.2.1 é analisado o desempenho do cenário 1 e na Subseção 4.2.2 é avaliado o P&O como algoritmo do cenário 2.

4.2.1 Cenário 1

O cenário 1 diz respeito a um sistema FV composto por 14 módulos FV em série, que foi submetido a quatro diferentes condições ambientais (detalhadas na Seção 3.4) e que consideram o efeito borda de nuvem na mudança de irradiância. O sistema FV também foi simulado com os três diferentes valores de incremento atribuídos para o algoritmo P&O.

Independentemente do valor do incremento, para a condição 1 é esperada uma potência de 961,5 W. Na condição 2, a potência máxima que deve sair do arranjo FV é de 1684 W. Na condição 3, a potência desejada aumenta para 2205 W. E, por último, na condição 4, há uma queda brusca na irradiância, por isso espera-se uma potência de saída de 1640 W.

A Figura 4.2 mostra o comportamento do sistema FV do cenário 1 quando adotado, respectivamente, os passos 0,0010 (Δd_1), 0,0015 (Δd_2) e 0,0020 (Δd_3) para o algoritmo P&O. Simultaneamente, em azul, é mostrada a potência almejada em cada condição ambiental.

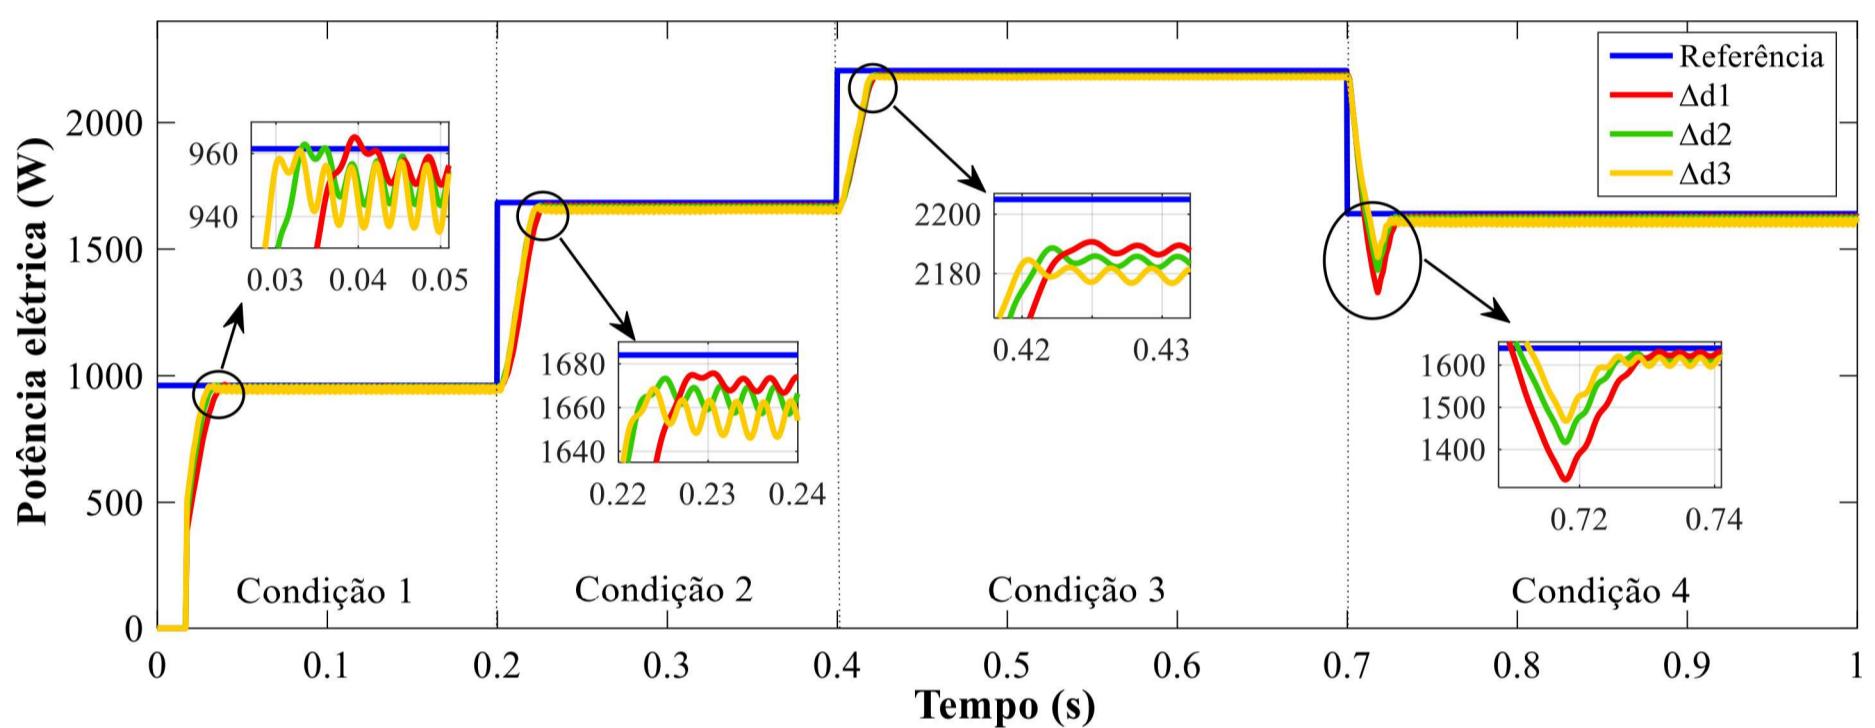


Figura 4.2. P_{MPP} e a potência de saída do sistema FV do cenário 1 com MPPT baseado no P&O de diferentes passos (Δd)
Fonte: Autoria própria

Em todos as condições de Δd da Figura 4.2, o sistema FV apresentou maior subsinal na transição da condição 3 para a condição 4, sendo o maior deles para o sistema com Δd igual a 0,0010. O subsinal é explicado pela variação mais brusca de irradiância que o sistema FV foi submetido. Também na Figura 4.2, percebe-se comportamento similares entre os três sinais do sistema FV, sendo observada pequenas diferenças apenas nas transições de condições ambientais ou ao ampliar os sinais no gráfico.

Assim, para auxiliar na análise comparativa, a Tabela 4.2 avalia a velocidade de rastreamento do MPPT através do ts , medida na transição das condições ambientais. Também é observada a estabilidade do sistema através do ΔP . Posteriormente, na Tabela 4.3 e Figura 4.3, a eficiência do algoritmo é analisada calculando o $e\%$, usando a Equação (30). Em todas as tabelas, será destacado em vermelho o algoritmo que teve melhor desempenho por parâmetro.

Tabela 4.2. Parâmetros ts e ΔP do P&O de diferentes passos aplicados no cenário 1

Condição ambiental	ts (ms)			ΔP (W)		
	Δd_1	Δd_2	Δd_3	Δd_1	Δd_2	Δd_3
Condição 1	33,12	29,17	26,7	10,850	16,390	22,310
Condição 2	21,90	18,70	18,2	7,562	12,020	18,640
Condição 3	16,60	16,00	15,2	3,350	5,865	6,471
Condição 4	25,20	22,10	19,9	11,080	18,010	23,360

Fonte: Autoria própria

A Tabela 4.2 mostra que, à medida que o incremento aumenta, o ts diminui, ou seja, o sistema FV atinge o regime permanente mais rapidamente. Isso justifica o fato de, na transição da condição 3 para a condição 4, o sistema com Δd igual a 0,0020 ter apresentado um menor subsinal que o sistema com Δd igual a 0,0010. Em contrapartida, a ΔP aumentou conforme o incremento foi elevando. Ambos os comportamentos são esperados para um sistema controlado por um algoritmo P&O, como explicado na Subseção 2.7.1 e notório na Figura 4.2.

Com relação a eficiência do algoritmo P&O, a Figura 4.2 mostra que a potência de saída atinge valores próximos ao MPP desejado. Isso é comprovado ao calcular o erro relativo, que são mostrados na Tabela 4.3 e Figura 4.3.

Tabela 4.3. Análise comparativa do parâmetro $e\%$ do P&O aplicado no cenário 1

Condição ambiental	P_{MPP} (W)	Δd_1		Δd_2		Δd_3	
		$P_{P&O}$ (W)	$e\%$	$P_{P&O}$ (W)	$e\%$	$P_{P&O}$ (W)	$e\%$
Condição 1	961,5	954,3	0,75	951,6	1,03	946,0	1,61
Condição 2	1684,0	1670,0	0,83	1664,0	1,19	1655,0	1,72
Condição 3	2205,0	2187,0	0,82	2184,0	0,95	2179,0	1,18
Condição 4	1640,0	1626,0	0,85	1618,0	1,34	1607,0	2,01

Fonte: Autoria própria

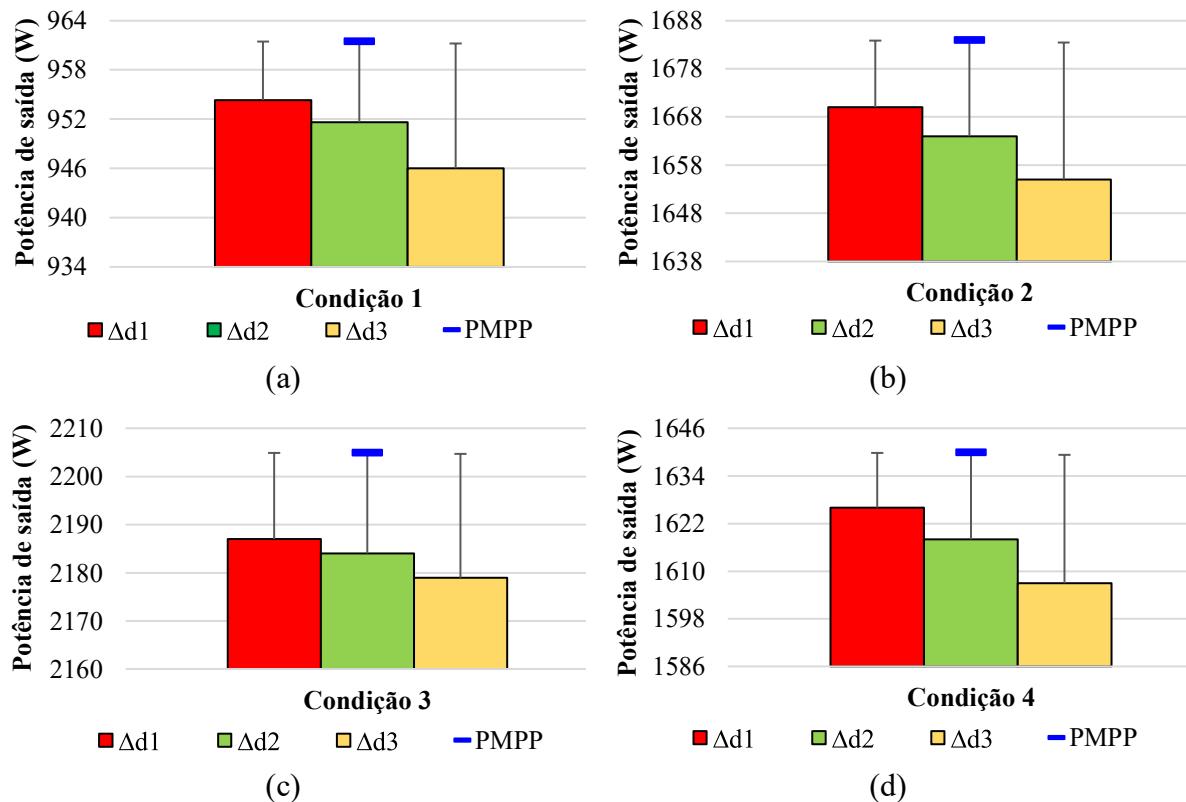


Figura 4.3. Potência de saída dos sistemas FV do cenário 1 e sua barra de erro em relação ao P_{MPP} , quando aplicado diferentes passos (Δd) para o algoritmo de controle P&O e submetidos à (a) condição 1, (b) condição 2, (c) condição 3 e (d) condição 4 do ambiente

Fonte: Autoria própria

A Tabela 4.3 e Figura 4.3 mostram que o erro relativo esteve entre 0,75% e 2,01%. Ainda foi observado que, à medida que o incremento aumentou, a precisão em detectar o MPP do sistema FV foi diminuindo. Além disso, para todos os valores de incremento, percebeu-se que o P&O teve mais dificuldade de detectar o MPP quando ocorreu a mudança mais brusca das condições ambientais, ou seja, na transição da condição 3 para a condição 4.

De modo análogo ao cenário 1, na Subseção 4.2.2 foi realizada a análise do cenário 2.

4.2.2 Cenário 2

O cenário 2 corresponde ao sistema FV composto por 21 módulos FV, ou seja, esse é o cenário de maior potência de saída prevista. Eles foram submetidos as mesmas condições ambientais do cenário 1 (discutido na Subseção 3.4.1) e foram utilizadas as mesmas variações de incremento, ou seja, 0,0010 (Δd_1), 0,0015 (Δd_2) e 0,0020 (Δd_3).

A Figura 4.4 mostra os resultados de simulação obtidos.

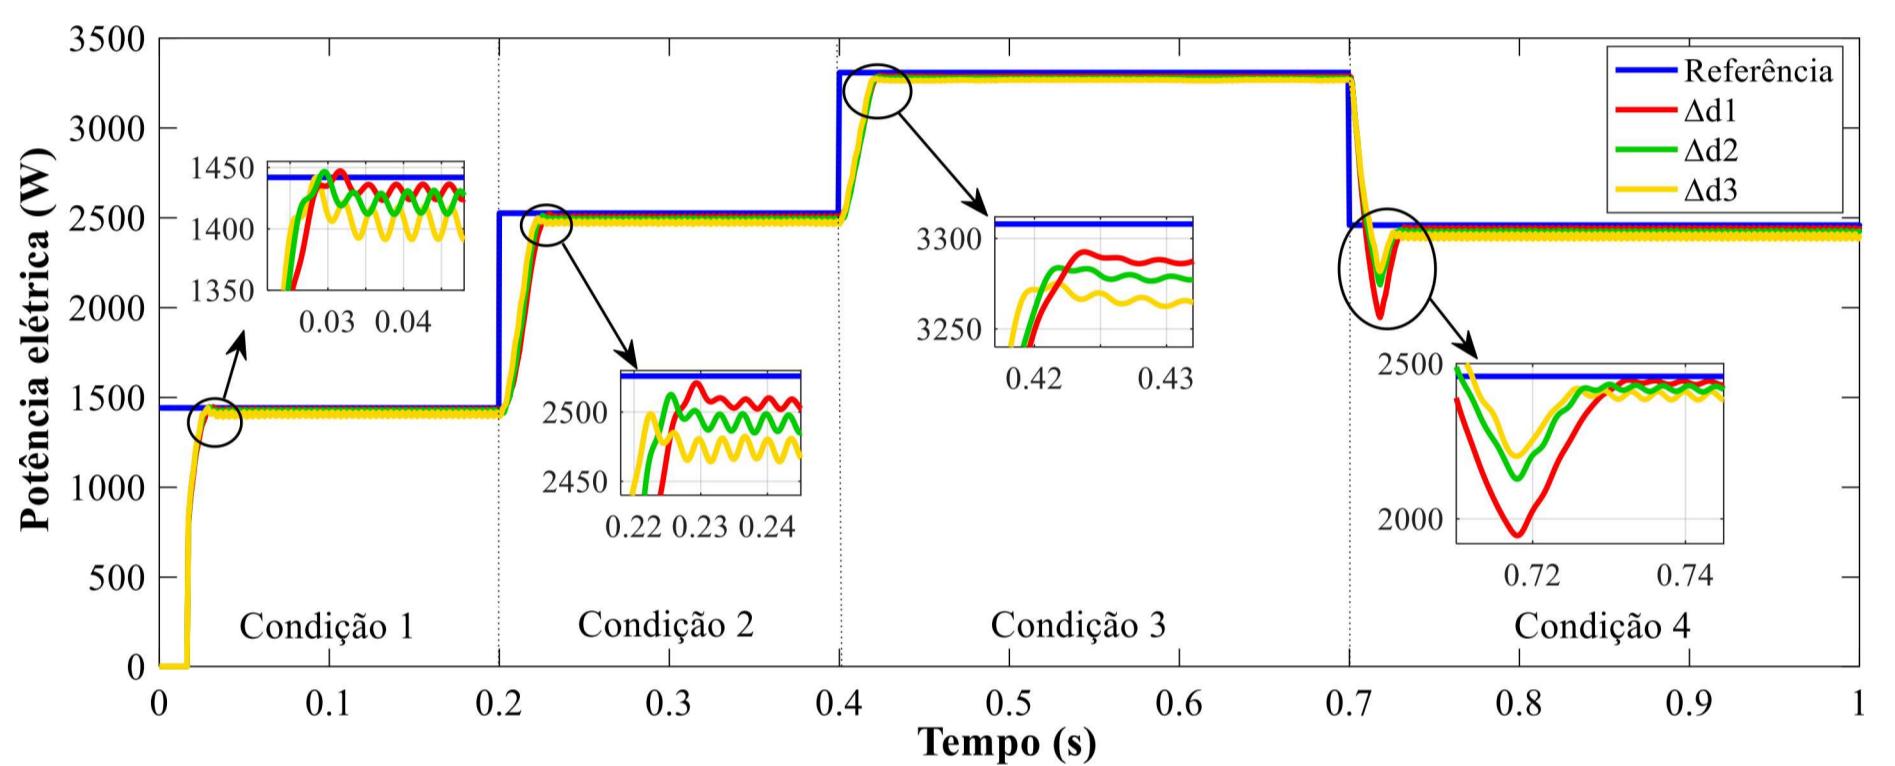


Figura 4.4. P_{MPP} e a potência de saída do sistema FV do cenário 2 com MPPT baseado no P&O com diferentes Δd
Fonte: Autoria própria

Embora submetido as mesmas condições da Subseção 4.2.1, as potências de saída esperadas no sistema FV do cenário 2 são diferentes, visto que há um aumento do número de módulos FV. Sabendo disso, e como mostrado em azul na Figura 4.4, para a condição 1 é desejada uma potência de saída de 1442 W. Na condição 2, a potência esperada é 2526 W, ao passo que na condição 3 é estimada uma potência de 3308 W. Finalmente, na condição 4, a potência de saída pretendida é de 2459 W.

Ainda observando a Figura 4.4, foi detectado o mesmo subsinal visto na Figura 4.2. Ele está localizado na transição da condição 3 para a condição 4. Essa é uma situação esperada, visto que o sistema foi submetido as mesmas condições de G e T_{AMB} em ambos os cenários.

Adicionalmente, foi notado valores oscilatórios em torno do MPP em todas as condições da Figura 4.4, sendo as menores oscilações perceptíveis na condição 3. Para aumentar o potencial de comparação, na Tabela 4.4 é apresentado os parâmetros ts e ΔP , ambos são importantes na análise de um MPPT, como discutido na Seção 3.4.

Tabela 4.4. Parâmetros ts e ΔP do P&O de diferentes passos aplicados no cenário 2

Condição ambiental	ts (ms)			ΔP (W)		
	Δd_1	Δd_2	Δd_3	Δd_1	Δd_2	Δd_3
Condição 1	25,68	24,72	23,98	13,160	18,970	25,010
Condição 2	22,00	20,00	17,90	9,485	14,490	18,320
Condição 3	16,50	16,50	15,10	2,215	4,280	6,552
Condição 4	26,40	22,50	20,70	13,460	22,400	27,250

Fonte: Autoria própria

Equivalente ao cenário 1 e condizente com a teoria do algoritmo P&O, o sistema FV do cenário 2 atingiu o regime permanente mais rapidamente à medida que o passo (Δd) foi aumentado, como mostra os dados da Tabela 4.4. Uma ressalva foi percebida na velocidade em se atingir o MPP da condição 3, pois nela, tanto o sistema FV com incremento de 0,0010 como aquele com incremento de 0,0015 tiveram o mesmo tempo de acomodação.

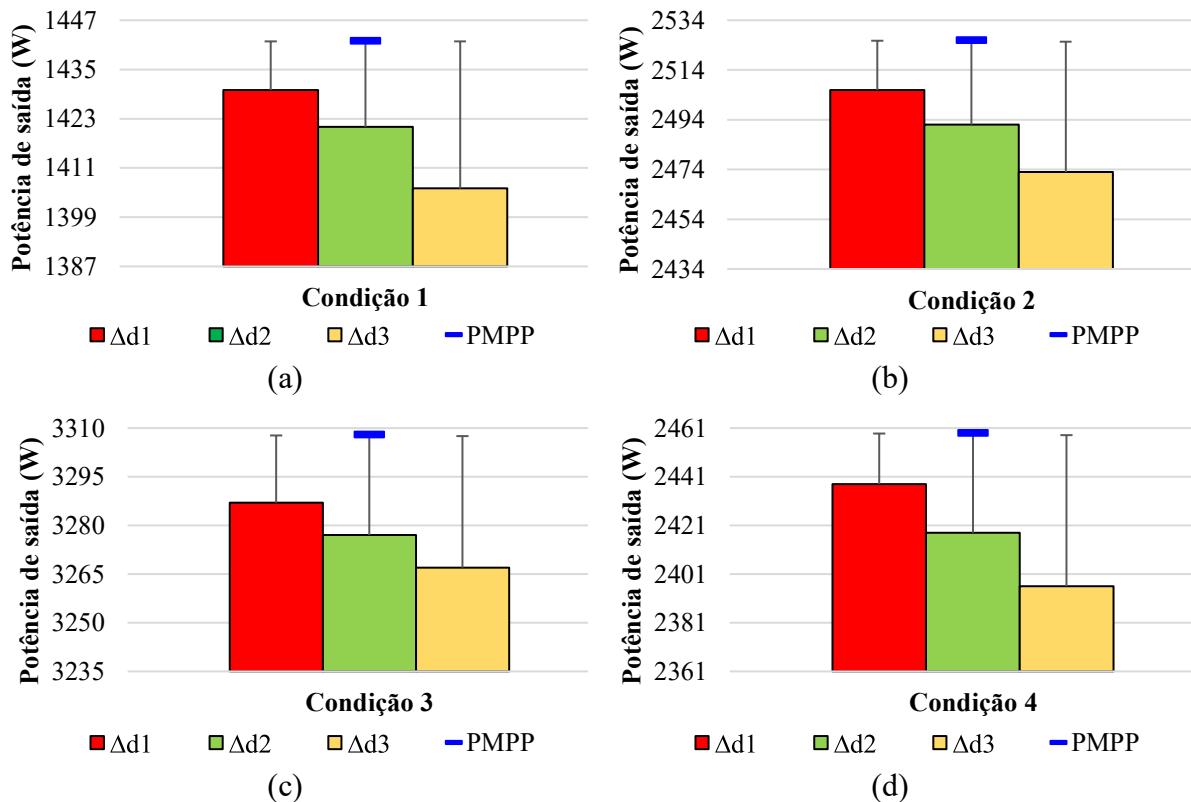
Acerca da oscilação em torno do MPP, ela aumentou com a elevação do incremento (Δd). Com os dados da Tabela 4.4 ainda foi possível comprovar que a menor oscilação em torno do MPP aconteceu na condição 3. Para essa condição foi detectado o menor ΔP , no valor de 2,215 W para o Δd_1 .

Além disso, para comparar a eficiência dos algoritmos P&O usando seus diferentes incrementos, o erro relativo foi calculado. A Tabela 4.5 e Figura 4.5 mostram os resultados obtidos.

Tabela 4.5. Análise comparativa do parâmetro $e\%$ do P&O aplicado no cenário 2

Condição ambiental	P_{MPP} (W)	Δd_1		Δd_2		Δd_3	
		$P_{P&O}$ (W)	$e\%$	$P_{P&O}$ (W)	$e\%$	$P_{P&O}$ (W)	$e\%$
Condição 1	1442	1430	0,83	1421	1,46	1406	2,50
Condição 2	2526	2506	0,79	2492	1,35	2473	2,10
Condição 3	3308	3287	0,63	3277	0,94	3267	1,24
Condição 4	2459	2438	0,85	2418	1,67	2396	2,56

Fonte: Autoria própria

Figura 4.5. Potência de saída dos sistemas FV do cenário 2 e sua barra de erro em relação ao P_{MPP} , quando aplicado diferentes passos (Δd) para o algoritmo de controle P&O e submetidos à (a) condição 1, (b) condição 2, (c) condição 3 e (d) condição 4 do ambiente

Fonte: Autoria própria

Observando a Tabela 4.5 e a Figura 4.5, nota-se que o erro aumenta com a elevação do incremento Δd , ou seja, o P&O diminui sua precisão em detectar o MPP. No geral, os erros calculados para o cenário 2 estivaram entre 0,63 % e 085 % quando Δd foi igual a 0,0010; entre 0,94 % e 1,67% para Δd igual a 0,0015; e entre 1,24 % e 2,56% com Δd igual a 0,0020. Para todos os valores de incremento, o sistema de controle foi mais preciso em detectar o MPP sob a maior condição de irradiação (condição 3) e, menos exato, quando ocorreu a mudança brusca de irradiação (condição 4).

A partir desse momento, passando a analisar ambos os cenários, através dos gráficos da Figura 4.2 e Figura 4.4, é possível verificar um comportamento similar entre os algoritmos P&O ao tentar rastrear o MPP.

Entretanto, avaliando separadamente, o sistema com Δd_1 igual a 0,0010 apresentou as menores ΔP no regime permanente e a maior precisão em detectar o MPP, embora o t_s tenha mostrado que ele demorou mais tempo para encontrar seu MPP. Por outro lado, o sistema com Δd_3 igual a 0,0020, teve as maiores ΔP e foi menos preciso em detectar o MPP, apesar de ter atingido seu regime permanente mais rapidamente.

Outro ponto de destaque foi a dificuldade em rastrear o MPP na mudança brusca da condição ambiental, ou seja, na transição da condição 3 para a condição 4. Nos dois cenários, a presença do maior subsinal no sistema FV com Δd_1 mostrou que ele teve mais dificuldade em rastrear o MPP nessa transição, quando comparado com os outros P&O analisados.

Desta forma, apesar do algoritmo P&O com Δd de 0,0010 ter apresentado menores erros, ou seja, seus valores médios no regime permanente se mantiveram mais próximos do MPP desejado, esses erros não são consideravelmente menores a ponto de justificar sua escolha. Isto porque, o algoritmo P&O com Δd de 0,0010 requer mais esforço computacional, uma vez que demanda um maior t_s para atingir o regime permanente, ou seja, para encontrar seu MPP.

Por outro lado, embora o algoritmo P&O com Δd de 0,0020 demande menos esforço computacional (maior rapidez), a redução na precisão e o considerável aumento na oscilação do MPP no regime permanente também não justifica sua escolha.

Assim sendo, sabendo que a escolha adequada do passo é intríseco ao projeto, ele deve ser escolhido pelo projetista de acordo com o que mais se enquadra com a situação de controle desejada. No presente estudo, como sua finalidade é ser comparado com os MPPT inteligentes modelados no Capítulo 3, será utilizado o algoritmo P&O com Δd de 0,0015, pois ele apresentou respostas dinâmicas aceitáveis e que intermediaram entre os outros dois algoritmos P&O avaliados.

Terminada a análise e escolha do incremento do algoritmo P&O, os MPPT baseados nos algoritmos inteligentes (RNA e fuzzy e ANFIS) foram subdivididos em 3 propostas, que se divergiram conforme os pares de variáveis de entrada modelados no Capítulo 3. Assim sendo, a Seção 4.3 avalia o sistema FV quando utiliza os algoritmos de controle da proposta 1, ou seja, as variáveis irradiação (G) e temperatura ambiente (T_{AMB}) como par de entrada dos algoritmos RNA, fuzzy e ANFIS.

4.3 Avaliação dos algoritmos de MPPT da proposta 1: variáveis de entrada irradiância e temperatura ambiente

A presente Seção analisa separadamente a resposta dinâmica (Subseção 4.3.1) e a geração de energia do sistema FV (Subseção 4.3.2), quando utiliza as variáveis G e T_{AMB} como entradas dos algoritmos inteligentes.

4.3.1 Análise da resposta dinâmica

Quando foi definido as condições ambientais G e T_{AMB} como variáveis de entrada, os primeiros MPPT baseados nas técnicas inteligentes foram simulados. Assim sendo, o sistema FV do cenário 1 e, posteriormente, do cenário 2 foram conectados individualmente a cada MPPT modelado e submetidos as variações de condições ambientais definidas na Figura 3.9 (Subseção 3.4.1).

A partir disso, o sinal da potência de saída do sistema FV do cenário 1 e do cenário 2 foram medidos, conforme mostra, respectivamente, as Figura 4.6 e Figura 4.7. Nas duas figuras, o sistema FV com RNA é mostrado em azul claro, o sistema FV com controlador *fuzzy* está em rosa e o sistema FV controlado pelo ANFIS está em laranja. Adicionalmente, para facilitar o estudo comparativo, a potência de saída do sistema FV com MPPT baseado no P&O também foi inserido (em verde) nas Figura 4.6 e Figura 4.7. Para complementar a análise, em azul, foi colocada a potência de saída almejada, que corresponde ao P_{MPP} de cada condição ambiental para seu respectivo cenário, similar ao mostrado na Figura 3.9.

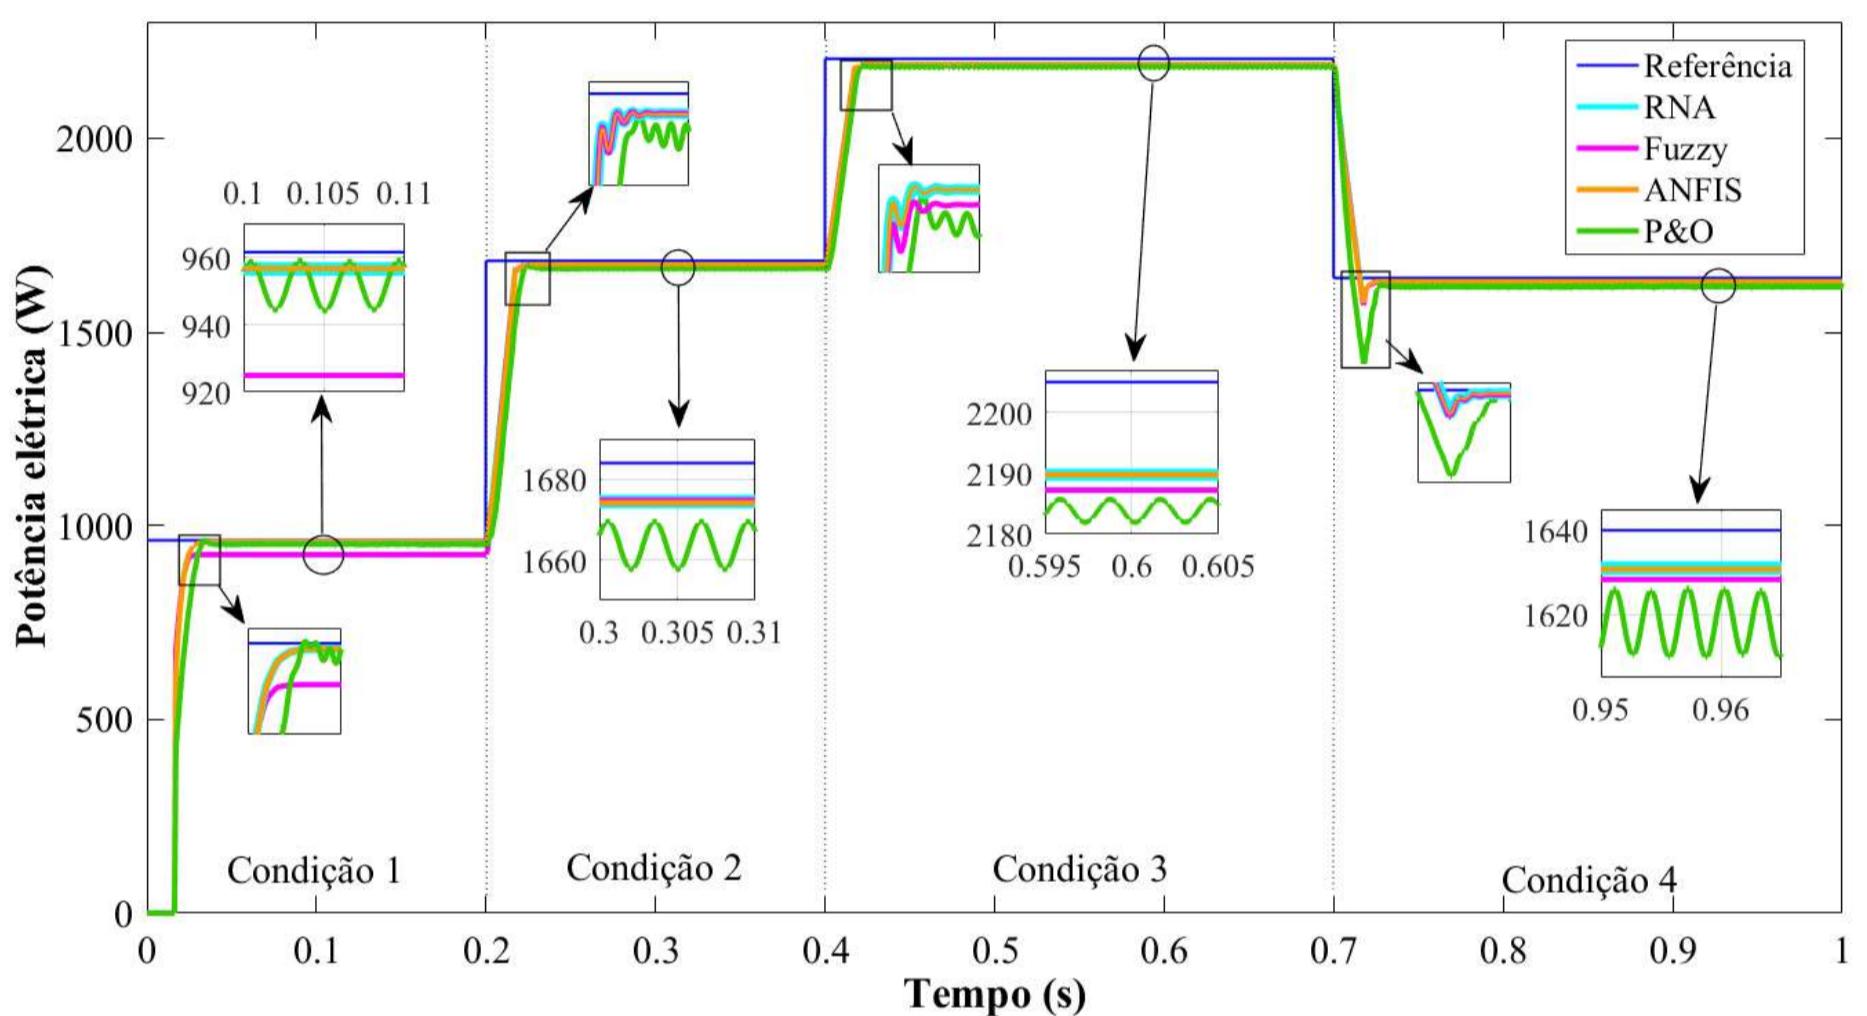


Figura 4.6. Potência de saída ao aplicar os algoritmos da proposta 1 no cenário 1
Fonte: Autoria própria

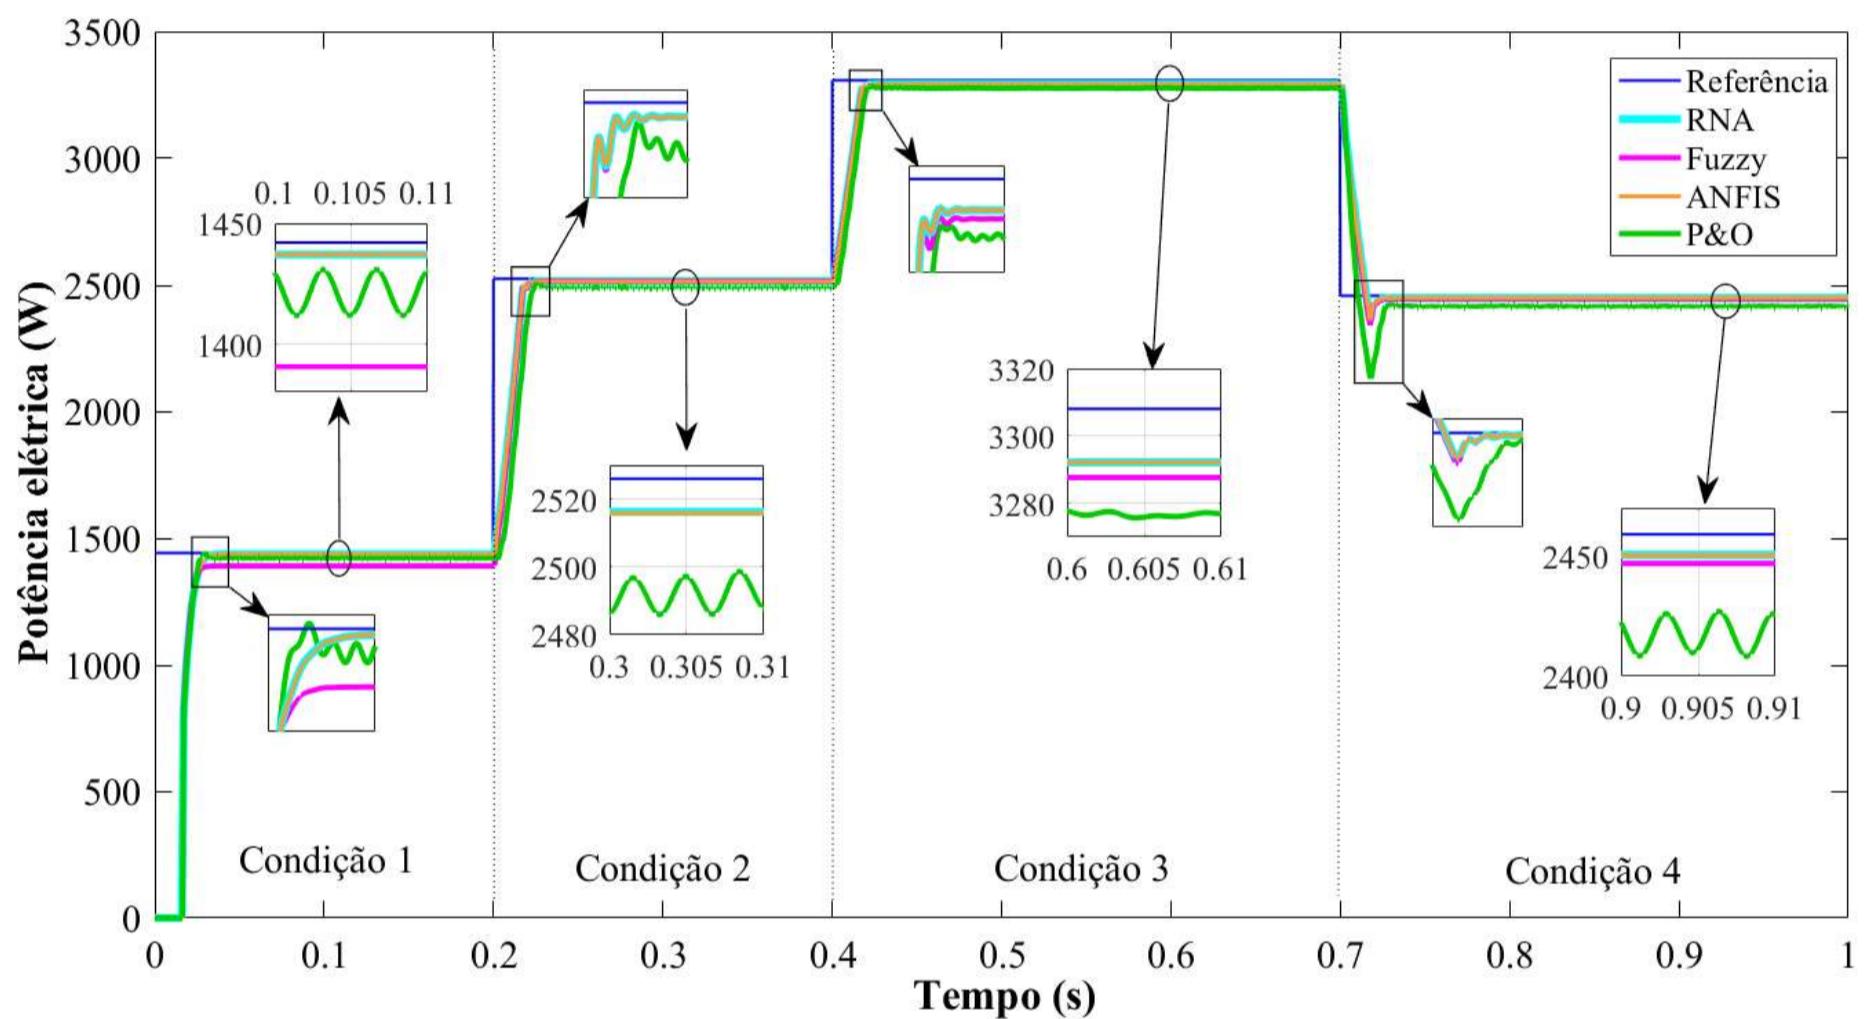


Figura 4.7. Potência de saída ao aplicar os algoritmos da proposta 1 no cenário 2
Fonte: Autoria própria

Para todos os algoritmos das Figura 4.6 e Figura 4.7, a presença de um subsinal na transição da condição 3 para a condição 4 foi observada, sendo o maior deles apresentado pelo algoritmo P&O. A mudança da condição 3 para a condição 4 é a transição mais brusca de condições ambientais, o que justifica a maior dificuldade do algoritmo em rastrear o MPP.

Ainda analisando as Figura 4.6 e Figura 4.7 é perceptível a sobreposição entre os algoritmos ANFIS e RNA nos dois cenários simulados. Desta forma, é possível afirmar que os algoritmos inteligentes RNA e ANFIS conseguiram, através do treinamento do conjunto de dados, obter uma correlação linear similar entre as variáveis de entrada e saída do seu banco de dados. Ademais, os dois algoritmos foram os mais rápidos em atingir o regime permanente.

Com relação ao sistema FV com MPPT controlado pelo algoritmo *fuzzy*, seu comportamento distinguiu dos controladores RNA e ANFIS, especialmente na condição 1 (em ambos os cenários). No que concerne o algoritmo P&O, ele foi aquele que teve seu sinal de saída mais distante da potência de referência. Além disso, foi observada a maior oscilação em torno do MPP, que ficou mais nítido quando os sinais da potência de saída foram ampliados.

Por outro lado, as oscilações em torno do MPP dos algoritmos inteligentes são quase imperceptíveis, mesmo com a ampliação de todos os sinais de saída durante o regime permanente. Desta forma, para uma melhor inspeção do desempenho do sistema FV, as Tabela 4.6 e Tabela 4.7 foram elaboradas, respectivamente, para os cenários 1 e 2. Nelas, constam os parâmetros ts e ΔP extraídos do sinal de saída de cada algoritmo.

Tabela 4.6. Parâmetros ts e ΔP dos algoritmos da proposta 1 aplicados no cenário 1

Condição ambiental	ts (ms)				ΔP (W)			
	P&O	RNA	FUZZY	ANFIS	P&O	RNA	FUZZY	ANFIS
Condição 1	29,17	23,44	22,24	23,54	16,390	0,00388	0,00227	0,00313
Condição 2	18,70	15,60	15,70	15,80	12,020	0,01023	0,00389	0,00953
Condição 3	16,00	14,10	14,10	14,30	5,865	0,01010	0,00528	0,01130
Condição 4	22,10	13,40	13,20	13,00	18,010	0,00369	0,00409	0,00414

Fonte: Autoria própria

Tabela 4.7. Parâmetros ts e ΔP dos algoritmos da proposta 1 aplicados no cenário 2

Condição ambiental	ts (ms)				ΔP (W)			
	P&O	RNA	FUZZY	ANFIS	P&O	RNA	FUZZY	ANFIS
Condição 1	24,72	25,58	23,98	25,58	18,970	0,00598	0,00561	0,00542
Condição 2	20,00	15,90	16,00	15,90	14,490	0,03930	0,01649	0,01620
Condição 3	16,50	14,40	14,40	14,40	4,280	0,01904	0,02229	0,01392
Condição 4	22,50	13,00	12,60	13,00	22,400	0,00523	0,00767	0,00484

Fonte: Autoria própria

As Tabela 4.6 e Tabela 4.7 mostram que o tempo de acomodação do algoritmo P&O foi maior do que todos os outros algoritmos de controle simulados (RNA, *fuzzy* e ANFIS), exceto na condição 1 do cenário 2. Isso comprova que o P&O é menos veloz em rastrear o MPP, como observado nas Figura 4.6 e Figura 4.7.

No geral, os algoritmos inteligentes tiveram tempos de acomodação próximos e mostraram ser pelo menos 2 ms mais rápidos do que o algoritmo P&O. A menor diferença entre os *ts* dos algoritmos ocorreram na mudança da condição 2 para a condição 3 (no cenário 1) e no início da condição 1 (no cenário 2).

As oscilações em torno do MPP (ΔP) dos algoritmos RNA, *fuzzy* e ANFIS foram quase indetectáveis nas Figura 4.6 e Figura 4.7. Isso é justificado por esses algoritmos terem apresentado uma variação inferior a 0,0001% do sinal medido no regime permanente, como pode ser visto nas Tabela 4.6 e Tabela 4.7. Por outro lado, o algoritmo P&O mostrou ΔP consideravelmente maiores, visto que atingiu oscilações entre 0,0653% e 0,8612% da potência de saída medida. Por conta disso, ao expandir o gráfico das Figura 4.6 e Figura 4.7, as flutuações do algoritmo P&O são visíveis, enquanto os sinais dos algoritmos inteligentes parecem não ter oscilações no regime permanente.

Outro parâmetro da resposta dinâmica avaliado é o erro percentual relativo ($e\%$). O erro foi calculado para cada algoritmo simulado e sob cada condição ambiental submetida. Ele avalia a eficiência que o algoritmo teve em rastrear o MPP almejado. Assim sendo, a Tabela 4.8 exibe os erros calculados para ambos os cenários, ao passo que as Figura 4.8 e Figura 4.9 ilustram os resultados obtidos para o cenário 1 e cenário 2, respectivamente.

Tabela 4.8. Parâmetro $e\%$ calculado para os algoritmos de controle da proposta 1

Condição ambiental	Cenário 1				Cenário 2			
	$e_{P\&O}\%$	$e_{RNA}\%$	$e_{FUZZY}\%$	$e_{ANFIS}\%$	$e_{P\&O}\%$	$e_{RNA}\%$	$e_{FUZZY}\%$	$e_{ANFIS}\%$
Condição 1	1,03	0,52	3,81	0,51	1,46	0,35	3,54	0,35
Condição 2	1,19	0,59	0,59	0,59	1,35	0,40	0,40	0,40
Condição 3	0,95	0,68	0,82	0,68	0,94	0,48	0,60	0,48
Condição 4	1,34	0,55	0,73	0,55	1,67	0,37	0,49	0,37

Fonte: Autoria própria

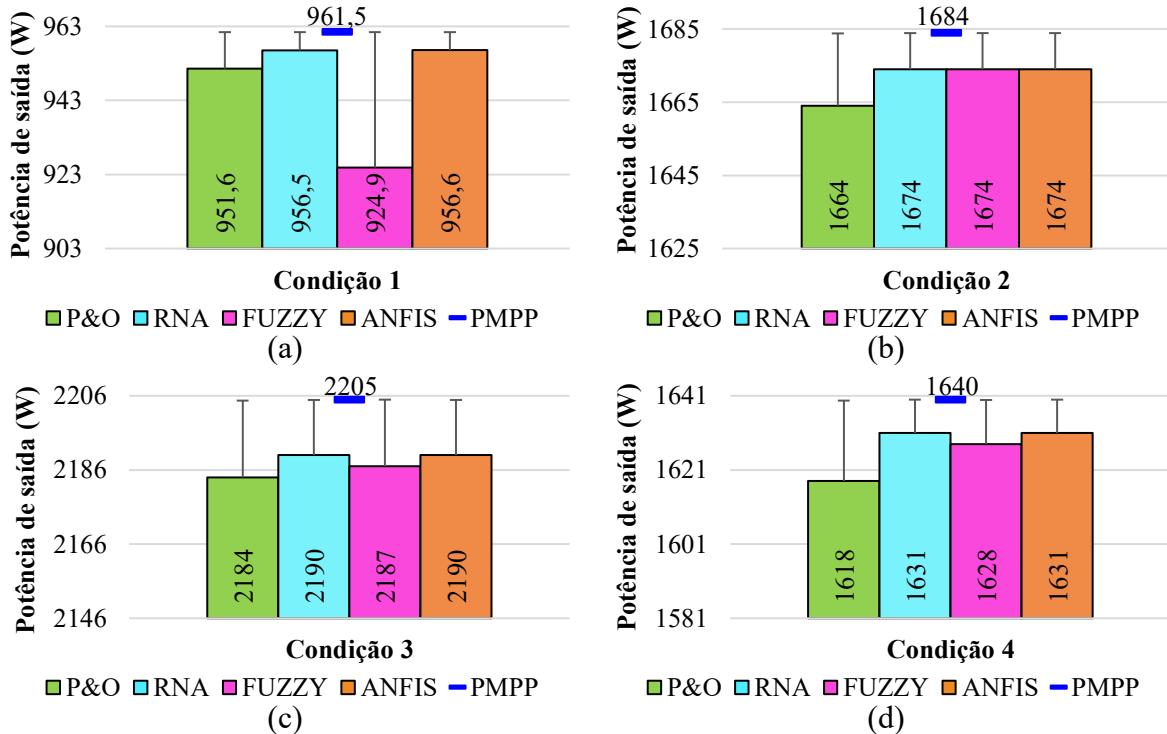


Figura 4.8. Potência de saída dos sistemas FV do cenário 1 e sua barra de erro em relação ao P_{MPP} , quando aplicado os algoritmos de controle da proposta 1 e submetidos à (a) condição 1, (b) condição 2, (c) condição 3 e (d) condição 4 do ambiente

Fonte: Autoria própria

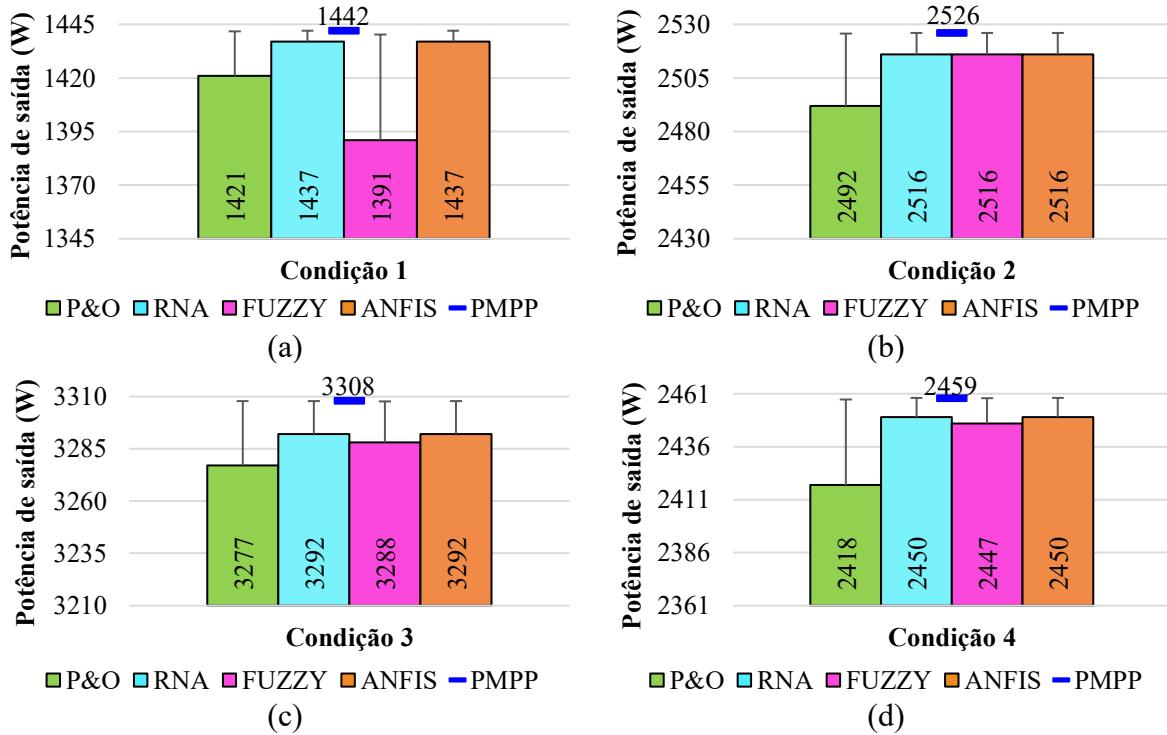


Figura 4.9. Potência de saída dos sistemas FV do cenário 2 e sua barra de erro em relação ao P_{MPP} , quando aplicado os algoritmos de controle da proposta 1 e submetidos à (a) condição 1, (b) condição 2, (c) condição 3 e (d) condição 4 do ambiente

Fonte: Autoria própria

A Tabela 4.8 mostrou que o algoritmo P&O teve, no geral, maiores $e\%$ dentre as técnicas de controle simuladas. Esse resultado condiz com o maior distância apresentada pelo sinal P&O em relação a potência almejada exibidas nas Figura 4.6 e Figura 4.7. Com isso, é possível afirmar que, além das maiores ΔP no regime permanente (Tabela 4.6 e Tabela 4.7), o sistema FV com o P&O controlando o MPPT tem menor eficiência ao rastrear o MPP.

Uma ressalva de menor eficiência se estende ao *fuzzy*. Ele foi o algoritmo que teve comportamento mais variado, como pode ser visto nas Tabela 4.8, Figura 4.8 e Figura 4.9. Na condição 1 de ambos os cenários, ele foi o algoritmo menos preciso, com erros superiores a 3,5% e desempenho inferior até ao P&O (Figura 4.8a e Figura 4.9a). Por outro lado, ele conseguiu obter uma eficiência similar a RNA e ao ANFIS na condição 2 (eficiência de 99,6%). Já na condição 3 (Figura 4.8c e Figura 4.9c) e condição 4 (Figura 4.8d e Figura 4.9d), o *fuzzy* teve desempenho inferior a RNA e ao ANFIS, mas mostrou ser superior ao P&O.

Assim sendo, para melhorar a eficiência desse controlador, especialmente sob baixas irradiações, é necessário que o projetista dedique um maior tempo conhecendo a planta e trabalhando no ajuste fino do controlador *fuzzy*.

Por outro lado, aos algoritmos RNA e ANFIS realizaram seu treinamento utilizando apenas o banco de dados da Seção 3.4 e conseguiram as melhores respostas. É importante frisar que, observando a Tabela 4.8, a eficiência de ambos os algoritmos foi idêntica, com erros percentuais entre 0,35% e 0,68%. A menor eficiência foi detectada na condição 3 do sistema FV do cenário 1 (99,32%) e a maior foi no cenário 2, sob a condição 1 (99,65%).

Após analisar as respostas dinâmicas dos algoritmos P&O, RNA, *fuzzy* e ANFIS, e sabendo que a resposta dinâmica influencia na energia gerada pelo sistema FV, então, estimar a geração de energia do sistema FV, quando cada um desses algoritmos de controle é aplicado, é tão importante quanto analisar a resposta dinâmica.

Isto posto, a Subseção 4.3.2 avalia a geração de energia do sistema FV sob as condições ambientais denominadas de condição normal (Subseção 3.4.2.1), condição de sombreamento (Subseção 3.4.2.2) e condição randômica (Subseção 3.4.2.3).

4.3.2 Análise da geração de energia do sistema FV

A avaliação da energia gerada pelos sistemas FV com seu respectivo algoritmo de controle foi realizada por meio de uma estimativa que considerou três dias com condições ambientais distintas, chamadas de condição normal (Subseção 3.4.2.1), condição de

sombreamento (Subseção 3.4.2.2) e condição randômica (Subseção 3.4.2.3). Além disso, foram consideradas dez horas de sol pleno em cada um dos dias, que perdurou das 6h às 16h.

A presente subseção realiza um estudo de recuperação de energia elétrica. Contudo, para saber a máxima produção de eletricidade que o sistema FV pode produzir, seria necessário conhecer o MPP de cada instante de condição ambiental ao longo do dia. Como cada condição do ambiente tem a irradiância e temperatura lida a cinco minutos, um total de 120 pontos de máxima potência (por condição) precisaria ser determinada. Logo, essa seria uma estimativa inviável de ser realizada.

Sabendo que nenhum dos algoritmos analisado atingiram o MPP almejado e visando facilitar o estudo comparativo, o algoritmo de controle clássico P&O foi utilizado como referência. Esta escolha é baseada na grande frequência que o P&O é escolhido para controlar o MPPT dos sistemas FV, como discutido na Subseção 2.7.1.

Assim, na presente análise, a energia gerada pelo sistema FV com o P&O corresponderá a uma geração de 100% de energia elétrica. Por outro lado, os sistemas FV com MPPT controlado pelos algoritmos inteligentes da proposta 1 mostraram se perderam, mantiveram ou recuperaram a energia gerada pelo P&O.

Desse modo, o termo recuperação refere-se a parcela da energia que ultrapassou à gerada pelo P&O e permitiu que o sistema FV tivesse uma produção mais próxima da máxima almejada.

A energia que estimou ser gerada pelos quatro sistemas FV do cenário 1, ao longo das 10 horas de sol e sob as mesmas condições ambientais, é mostrada na Figura 4.10.

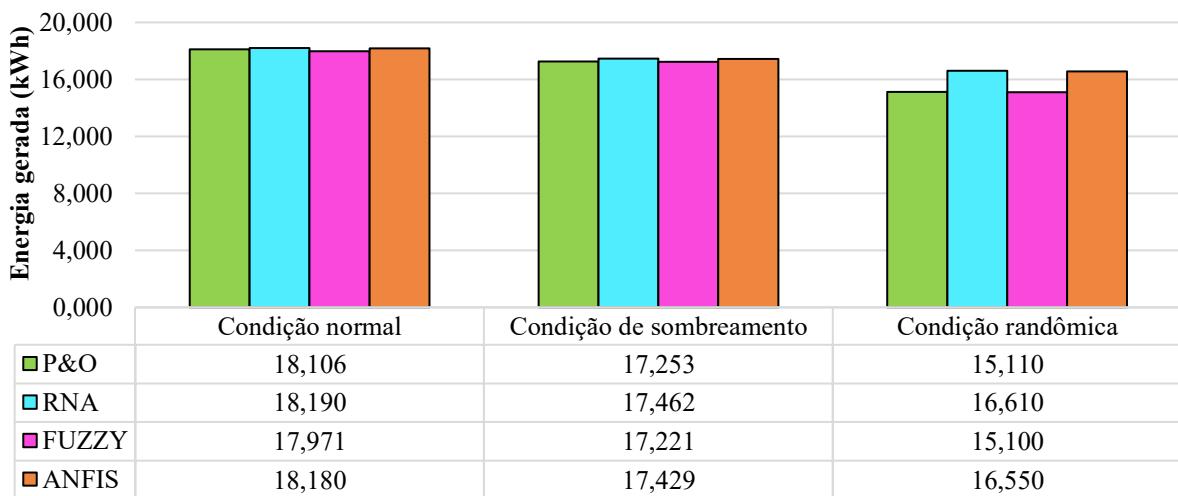


Figura 4.10. Energia gerada pelo sistema FV do cenário 1 quando aplicado os algoritmos de controle da proposta 1

Fonte: Autoria própria

Os resultados apresentados na Figura 4.10 mostra que, no cenário 1 e sob condição normal, a substituição do algoritmo P&O pela RNA proporciona um aumento de 84 Wh na energia gerada. Isso corresponde a uma recuperação de 0,464% na geração de energia. Caso a alteração seja realizada entre o algoritmo P&O e o ANFIS, a energia recuperada é 74 Wh que, em percentual, representam 0,408%.

Por outro lado, a mudança do algoritmo P&O pelo algoritmo inteligente *fuzzy* reduziu 135 Wh da energia produzida pelo sistema FV. Isso equivale a uma perda de 0,75%, quando comparada com a energia gerada pelo sistema com P&O.

Ainda observando a Figura 4.10, percebe-se que a energia produzida eleva-se 209 Wh, quando usa-se o algoritmo RNA no lugar do algoritmo P&O em condição de sombreamento. Em percentual, isso significa recuperar 1,21% da energia a ser gerada pelo sistema FV. Quando a troca é feita entre o P&O e o ANFIS, a recuperação de energia é de 176 Wh, ou seja, 1,02%.

Tal como ocorreu sob condição normal, quando, sob condição de sombreamento, o sistema FV muda o algoritmo de controle P&O pelo *fuzzy*, o sistema FV perde 0,19% da produção de energia elétrica, o que corresponde a 32 Wh. Um desempenho não satisfatório também é observado sob condição randômica. Ao utilizar o *fuzzy* para controlar o MPPT do sistema FV, esse apresentou uma redução de 10Wh da energia gerada, ou seja, caiu 0,04% da energia que produziu, quando o P&O controlou o MPPT.

Ainda avaliando a condição randômica da Figura 4.10, quando o P&O foi alterado para o algoritmo RNA, o desempenho foi satisfatório e ainda mais expressivo do que sob as outras duas condições. A energia gerada aumentou de 15,11 kWh para 16,61 kWh, ou seja, 9,9%.

O algoritmo ANFIS apresentou um desempenho tão bom quanto ao do algoritmo RNA. A geração de energia cresceu 9,53%, o que significa que a energia produzida passou de 15,110 kWh (com P&O) para 16,550 kWh (com o RNA da proposta 1) no cenário 1.

Em geral, na condição de sombreamento e randômica, a boa resposta dinâmica dos algoritmos inteligentes, em especial RNA e ANFIS, ajudaram a melhorar na produção de eletricidade. Isso acontece, pois suas maiores velocidades de rastreamento com alta precisão ajudam a encontrar o MPP mais rapidamente, mesmo sob mudanças repentinhas da irradiação.

De maneira análoga ao estudo da recuperação de energia realizado para o cenário 1, uma avaliação da energia gerada pelo sistema FV do cenário 2 é feita.

A Figura 4.11 apresenta a energia que estimou ser gerada pelo sistema FV do cenário 2, considerando os algoritmos inteligentes RNA, *fuzzy* e ANFIS da proposta 1 como

controladores do MPPT. A análise foi realizada sob as mesmas condições do cenário 1 e considerando as mesmas 10 horas de sol.

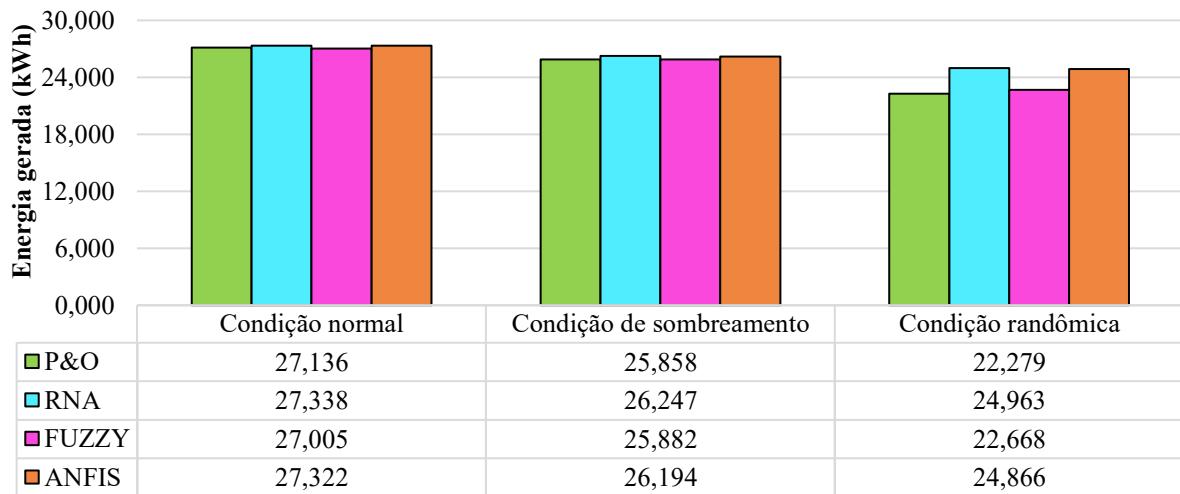


Figura 4.11. Energia gerada pelo sistema FV do cenário 2 quando aplicado os algoritmos de controle da proposta 1
Fonte: Autoria própria

Os resultados da Figura 4.11 mostram que a substituição do algoritmo P&O pelo ANFIS ocasiona um aumento de 186 Wh na energia gerada pelo sistema FV do cenário 2 sob condição normal. Em outras palavras, há uma recuperação na geração de energia de 0,68%. No caso de a troca ser entre o algoritmo P&O e o RNA, a energia recuperada é de 0,74%, ou seja, 202 Wh.

Em contrapartida, assim como ocorreu no cenário 1, caso o algoritmo P&O seja alterado pelo algoritmo *fuzzy*, a energia produzida pelo sistema FV do cenário 2 tem uma diminuição. Essa redução é de 131 Wh, que, em percentual, corresponde a uma perda de 0,48% da energia gerada pelo sistema FV quando usa o P&O.

Sob condição de sombreamento, a energia produzida pelo sistema FV com o algoritmo ANFIS tem uma elevação de 336 Wh quando comparado com o sistema FV controlado pelo P&O. Isso significa que o sistema FV recupera 1,3% da energia gerada com a troca do algoritmo de controle do MPPT. Quando a substituição é realizada entre o P&O e a RNA, a recuperação de energia é ainda maior, chegando a 389 Wh, ou seja, 1,5% de energia recuperada.

Diferentemente do que aconteceu sob condição normal, ao utilizar o algoritmo inteligente *fuzzy* no lugar do P&O, o sistema FV tem praticamente a mesma geração de energia elétrica. Nesse caso, há um aumento de apenas 20 Wh na energia gerada, que, em percentual, equivale a 0,09%. O melhor desempenho do algoritmo *fuzzy* é observado no sistema FV sob condição randômica (Figura 4.11). Nessa condição, ao utilizar o *fuzzy* para controlar o MPPT do sistema FV, a energia gerada aumentou 1,74%, ou seja, subiu 389 Wh.

Também foi observado resultados satisfatórios e mais expressivos, quando os algoritmos RNA e ANFIS substituíram o algoritmo clássico P&O, sob condição randômica. A energia gerada pelo sistema FV aumentou, respectivamente, 2.684 Wh e 2.587 Wh. Em percentual, o sistema FV do cenário 2 recuperou 12,04% ao utilizar a RNA, ao passo que retomou 11,61% da energia gerada ao usar o ANFIS.

Desta forma, é possível afirmar que as pequenas diferenças detectadas entre as respostas dinâmicas dos algoritmos RNA e ANFIS (na Subseção 4.3.1) afetaram na energia recuperada pelo sistema FV. A RNA mostrou, sob todas as condições ambientais analisadas, gerar mais energia que o ANFIS (mesmo que minimamente), quando utilizada como algoritmo de controle do MPPT de ambos os cenários.

De modo geral, a partir da análise das respostas dinâmicas e da geração de energia do sistema FV do cenário 1 e cenário 2, percebe-se que, ao utilizar os parâmetros ambientais G e T_{AMB} como variáveis de entrada dos algoritmos de controle do MPPT, o sistema FV pode rastrear o MPP rapidamente, com alta precisão e baixa oscilação em torno do MPP, especialmente se for utilizado os algoritmos inteligentes RNA ou ANFIS. Adicionalmente, o sistema FV consegue gerar mais energia que o sistema FV controlado pelo algoritmo clássico P&O, sob todas as condições ambientais submetidas.

No entanto, escolher esses parâmetros ambientais, G e T_{AMB} , como variáveis de entrada de um algoritmo de controle do MPPT, aumenta ainda mais o custo do sistema FV. Isso ocorre, pois torna-se fundamental a aquisição de sensores de irradiação e temperatura.

Quando se analisa a simplicidade de implementação, os algoritmos RNA e *fuzzy* apresentam complexidade média. Por outro lado, o algoritmo ANFIS possui alta complexidade e requer recursos como controladores de alto desempenho.

Em contrapartida, enquanto o *software* MATLAB/Simulink® é capaz de definir as funções de pertinência do ANFIS, o operador especialista é quem deve estabelecer as funções de pertinência do *fuzzy* a partir do seu conhecimento. Portanto, reduzir o número e alterar o tipo de MF do ANFIS foi mais fácil e rápido do que para estruturar a regra de base do *fuzzy*. Como resultado, a arquitetura ANFIS ficou mais compacta e precisou de menos esforço computacional para controlar o MPPT do sistema FV do que o algoritmo inteligente *fuzzy*.

Outro ponto analisado foi o treinamento da RNA e do ANFIS. Observou-se que eles não precisaram realizar muitos testes para encontrar suas estruturas ótimas. Ademais, no treinamento dos dois algoritmos inteligentes, percebeu-se que o conjunto de dados dos dois cenários apresentavam dados de entradas iguais e a saída D praticamente idênticas.

Assim sendo, a RNA e o ANFIS que foram treinados para o cenário 1 também foram utilizados no cenário 2 e não foi observado quaisquer prejuízos à potência de saída do sistema FV. Isto ocorreu, pois os demais componentes do sistema FV foram mantidos e apenas redimensionados respeitando a proporcionalidade do número de módulos FV alterado.

Ainda sobre os algoritmos RNA e ANFIS, ao optar pelo uso de um conjunto de dados simulados, é possível afirmar que, caso o sistema FV mude de localização geográfica, o algoritmo não precisa ser retreinado, como aconselhado na Subseção 2.7.2.1. Afinal, os algoritmos foram treinados para irradiações variando de 100 W/m^2 a 1100 W/m^2 e temperatura ambiente entre 15°C e 45°C . Além disso, apresentaram bom desempenho em encontrar o MPP sob baixas e altas irradiações (com erros inferiores à 1%, ou seja, eficiência superior a 99%).

Desta forma, quando se escolhe os parâmetros ambientais G e T_{AMB} como variáveis de entrada dos algoritmos RNA ou ANFIS, além de ser capaz de rastrear o MPP independentemente da localização geográfica do sistema FV, àqueles sistemas FV que se diferenciam apenas pelo número de módulos no arranjo FV podem utilizar o mesmo algoritmo treinado, não sendo necessário um novo treinamento.

A próxima análise, discutida na Seção 4.4, foi realizada no sistema FV composto por MPPT que tem os parâmetros G e $P_{FV}(t)$ como variáveis de entrada.

4.4 Avaliação dos algoritmos de MPPT da proposta 2: variáveis de entrada irradiação e potência de saída instantânea do arranjo FV

A presente seção realiza, separadamente, o estudo da resposta dinâmica (Subseção 4.4.1) e da geração de energia do sistema FV (Subseção 4.4.2), quando utiliza G e $P_{FV}(t)$ como variáveis de entrada dos MPPT inteligente.

4.4.1 Análise da resposta dinâmica

Após a modelagem e treinamento dos algoritmos de controle da proposta 2, os sistemas FV do cenário 1 e cenário 2 foram simulados com seus respectivos MPPT, sob as condições ambientais da Figura 3.9. Como resposta, o sinal da potência de saída do sistema FV do cenário 1 e do cenário 2 foram medidos e exibidos nas Figura 4.12 e Figura 4.13, respectivamente.

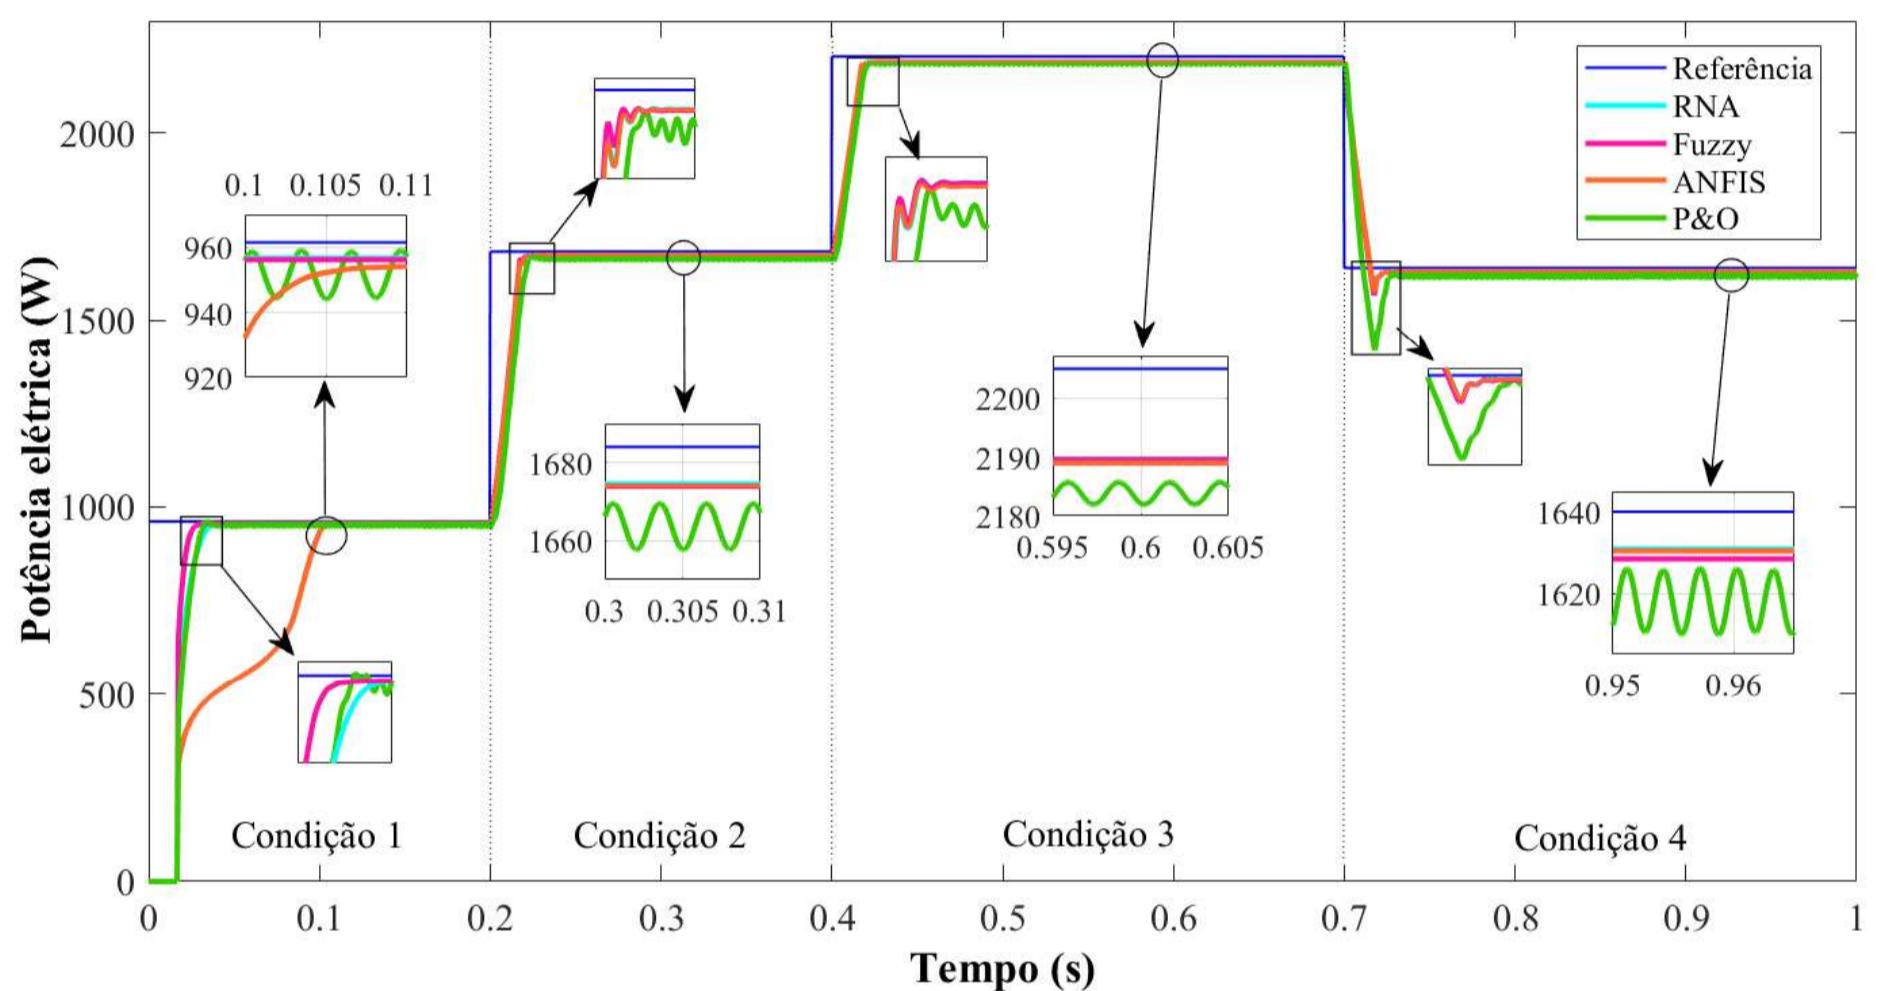


Figura 4.12. Potência de saída ao aplicar os algoritmos da proposta 2 no cenário 1
Fonte: Autoria própria

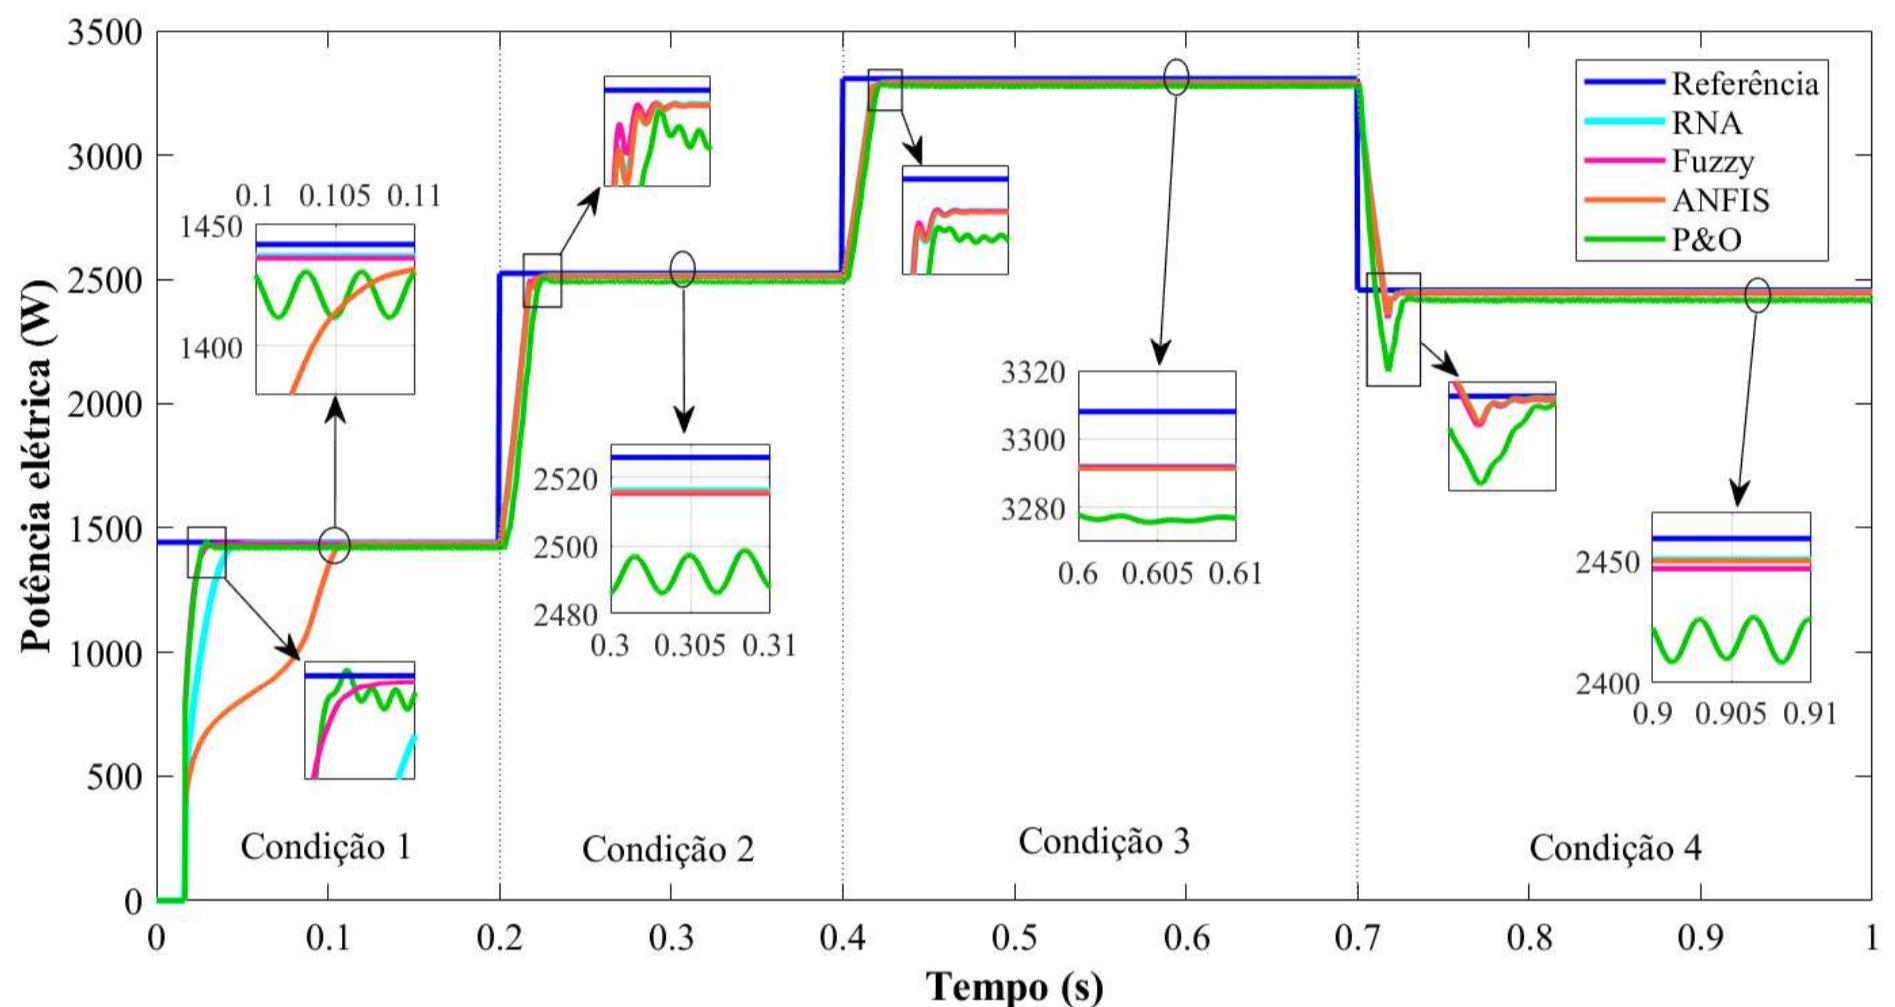


Figura 4.13. Potência de saída ao aplicar os algoritmos da proposta 2 no cenário 2
Fonte: Autoria própria

Mesmo alterando as variáveis de entrada dos algoritmos de controle inteligentes, a presença de o subsinal na transição da condição 3 para a condição 4 foi observada, embora ele seja de menor magnitude, como mostra as Figura 4.12 e Figura 4.13. É válido relembrar que os algoritmos apresentam maior dificuldade de rastreamento na mudança da condição 3 para a condição 4 em virtude de o sistema FV está submetido a uma transição mais brusca de condições ambientais.

Um ponto de destaque na análise das Figura 4.12 e Figura 4.13 está na resposta transitória do algoritmo ANFIS. Visivelmente, ele apresentou uma maior dificuldade em atingir o regime permanente (ou seja, seu MPP) na condição 1 em ambos os cenários. É possível afirmar que os algoritmos inteligentes RNA e *fuzzy* tiveram um amortecimento crítico, ao passo que o ANFIS mostrou um superamortecimento na condição 1. Nas demais condições, o algoritmo ANFIS apresentou respostas rápidas e com potência de saída bem próximas ao MPP.

Ainda observando a resposta do sistema FV ao utilizar um parâmetro ambiental e um parâmetro elétrico como dupla de variável de entrada, as Figura 4.12 e Figura 4.13 mostraram que, na condição 1, o algoritmo RNA apresentou um ts maior que os algoritmos P&O e *fuzzy*, sendo esse valor bem mais expressivo no cenário 2 (Figura 4.13). De todo modo, é importante destacar que essa dificuldade inicial não comprometeu a eficiência do algoritmo, nem a boa resposta dinâmica nas demais condições ambientais que o algoritmo foi submetido.

Com relação ao algoritmo inteligente *fuzzy*, a partir das Figura 4.12 e Figura 4.13, é possível afirmar que, visualmente, quando comparado com as saídas da proposta 1 (Subseção 4.3.1), o *fuzzy* apresentou um sinal de saída ainda mais próximo dos algoritmos inteligentes RNA e ANFIS.

De todo modo, para uma melhor avaliação do desempenho dos sistemas FV, as Tabela 4.9 e Tabela 4.10 expõem os parâmetros ts e ΔP extraídos da resposta dos sistemas FV, respectivamente, do cenário 1 e cenário 2, quando controlados por cada algoritmo da proposta 2 que foi treinado e simulado.

Tabela 4.9. Parâmetros ts e ΔP dos algoritmos da proposta 2 aplicados no cenário 1

Condição ambiental	ts (ms)				ΔP (W)			
	P&O	RNA	FUZZY	ANFIS	P&O	RNA	FUZZY	ANFIS
Condição 1	29,17	30,36	23,16	97,72	16,390	0,00443	0,00349	0,00356
Condição 2	18,70	15,92	15,82	16,00	12,020	0,01879	0,01217	0,06064
Condição 3	16,00	14,30	14,32	14,28	5,865	0,02492	0,02624	0,02847
Condição 4	22,10	13,00	12,77	12,80	18,010	0,00491	0,00538	0,00504

Fonte: Autoria própria

Tabela 4.10. Parâmetros ts e ΔP dos algoritmos da proposta 2 aplicados no cenário 2

Condição ambiental	ts (ms)				ΔP (W)			
	P&O	RNA	FUZZY	ANFIS	P&O	RNA	FUZZY	ANFIS
Condição 1	24,72	38,28	24,92	101,26	18,970	0,01017	0,00527	0,07090
Condição 2	20,00	16,08	15,92	16,13	14,490	0,05297	0,03761	0,02447
Condição 3	16,50	14,45	14,46	14,44	4,280	0,02759	0,01435	0,03127
Condição 4	22,50	15,07	12,68	12,98	22,400	0,00523	0,00755	0,00638

Fonte: Autoria própria

As Tabela 4.9 e Tabela 4.10 comprovam que o ts do algoritmo ANFIS, sob a condição 1, foi maior do que todos os outros algoritmos simulados (P&O, *fuzzy* e ANFIS). Para as demais condições ambientais, o P&O foi mais lento em rastrear o MPP.

É importante ressaltar que o ANFIS foi testado com outros tipos e quantidades de funções de pertinência, cujo objetivo era melhorar o regime transitório e reduzir o tempo que o sistema levava para atingir seu regime permanente. Entretanto, em todas as situações testadas, ao aperfeiçoar o regime transitório do ANFIS, os parâmetros do regime permanente avaliados ($e\%$ e ΔP) eram comprometidos.

Com relação as oscilações em torno do MPP (ΔP), as técnicas RNA, *fuzzy* e ANFIS tiveram oscilações quase indetectáveis no regime permanente, como aconteceu na Subseção 4.3.1. Afinal, dentre as técnicas inteligentes, o maior ΔP foi medido no sistema FV do cenário 2 quando controlado pelo ANFIS. Esse ΔP foi de 0,07090, o que corresponde a 0,00247% do sinal medido no regime permanente.

Com a resposta dinâmica também é possível analisar a eficiência que o algoritmo de controle teve em rastrear o MPP esperado por meio do $e\%$. A Tabela 4.11 mostra os erros relativos calculados para os cenários 1 e 2. As Figura 4.14 e Figura 4.15 exibem as potências de saída medidas (respectivamente, para o cenário 1 e cenário 2), a potência do MPP de cada condição ambiental, bem como ilustra o erro relativo entre essas potências.

Tabela 4.11. Parâmetro $e\%$ calculado para os algoritmos de controle da proposta 2

Condição ambiental	Cenário 1				Cenário 2			
	$e_{P&O\%}$	$e_{RNA\%}$	$e_{FUZZY\%}$	$e_{ANFIS\%}$	$e_{P&O\%}$	$e_{RNA\%}$	$e_{FUZZY\%}$	$e_{ANFIS\%}$
Condição 1	1,03	0,50	0,55	0,75	1,46	0,35	0,39	0,49
Condição 2	1,19	0,59	0,59	0,59	1,35	0,40	0,44	0,40
Condição 3	0,95	0,70	0,68	0,73	0,94	0,48	0,48	0,51
Condição 4	1,34	0,55	0,67	0,61	1,67	0,37	0,49	0,37

Fonte: Autoria própria

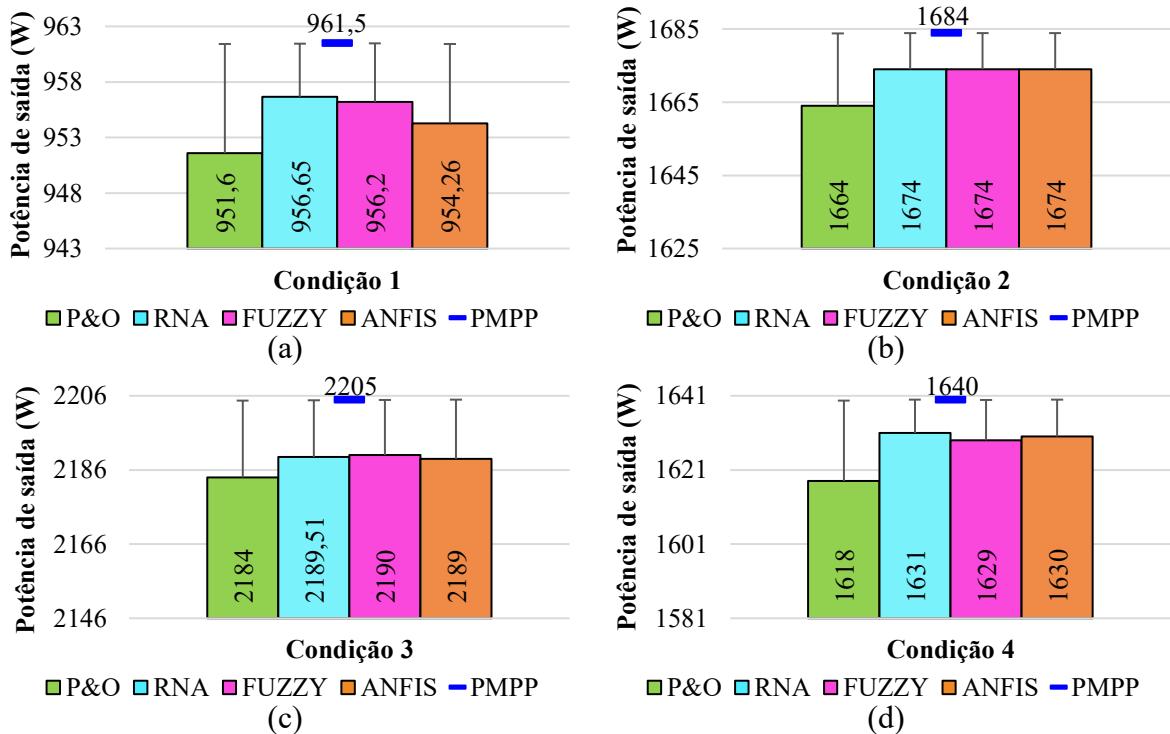


Figura 4.14. Potência de saída dos sistemas FV do cenário 1 e sua barra de erro em relação ao P_{MPP} , quando aplicado os algoritmos de controle da proposta 2 e submetidos à (a) condição 1, (b) condição 2, (c) condição 3 e (d) condição 4 do ambiente

Fonte: Autoria própria

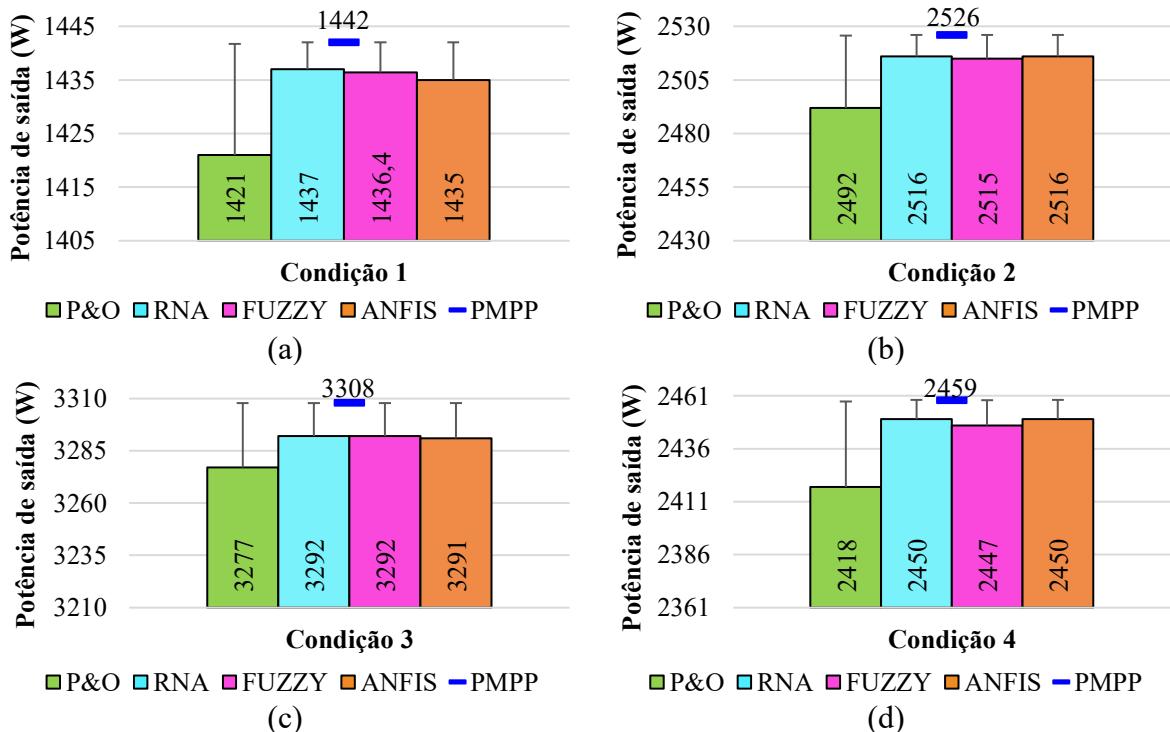


Figura 4.15. Potência de saída dos sistemas FV do cenário 2 e sua barra de erro em relação ao P_{MPP} , quando aplicado os algoritmos de controle da proposta 2 e submetidos à (a) condição 1, (b) condição 2, (c) condição 3 e (d) condição 4 do ambiente

Fonte: Autoria própria

A Tabela 4.11 mostra que o algoritmo clássico P&O permanece, no geral, com os maiores erros percentuais dentre as técnicas de controle simuladas. Assim sendo, é possível afirmar que, os algoritmos inteligentes apresentaram maior eficiência em rastrear o MPP mesmo substituindo os parâmetros ambientais pela combinação de um parâmetro ambiental e um elétrico como variáveis de entrada.

A Tabela 4.11 e as Figura 4.14 e Figura 4.15 também permitem concluir que, o projetista mostrou maior conhecimento ao projetar o controlador *fuzzy*, pois os erros relativos diminuíram consideravelmente, quando comparados com os resultados da Tabela 4.8. Além disso, na condição 3 de ambos os cenários (Tabela 4.11), o *fuzzy* foi o algoritmo de controle com menor erro relativo, ou seja, mais preciso.

Por outro lado, o algoritmo ANFIS, dentre os sistemas inteligentes, foi o algoritmo com menor eficiência na condição 1 (99,25% para o cenário 1 e 99,51% para o cenário 2) e condição 3 (99,27% para o cenário 1 e 99,49% para o cenário 2), ou seja, sendo superior apenas do algoritmo P&O, como mostrou a Tabela 4.11. Em contrapartida, na condição 2 e condição 4, o ANFIS mostrou resultados iguais ou bem próximos ao da RNA. A RNA, assim como na Subseção 4.3.1, permaneceu sendo o algoritmo de controle com melhor desempenho.

Para finalizar a análise do desempenho dos algoritmos de controle da proposta 2 que foram utilizados no MPPT dos sistemas FV do cenário 1 e cenário 2, a Subseção 4.4.2 avalia a energia gerada pelos sistemas FV sob condição normal (Subseção 3.4.2.1), condição de sombreamento (Subseção 3.4.2.2) e condição randômica (Subseção 3.4.2.3).

4.4.2 Análise da geração de energia do sistema FV

Assim como na Subseção 4.3.2, a estimativa de geração de energia dos algoritmos de controle da proposta 2 consideraram dez horas de sol pleno (das 6h às 16h) e três dias distintos de condições ambientais.

Na presente subseção, o algoritmo clássico P&O também foi utilizado como referência, ou seja, a energia gerada pelo sistema FV controlado pelo P&O corresponde a 100% da produção de energia e os sistemas FV controlados pelos algoritmos inteligentes mostrarão se perderam, mantiveram ou recuperaram a energia gerada pelo sistema FV com P&O.

A Figura 4.16 mostra a energia gerada pelo sistema FV do cenário 1, quando controlado por cada algoritmo da proposta 2 e simulados sob as três condições ambientais descritas na Subseção 3.4.2.

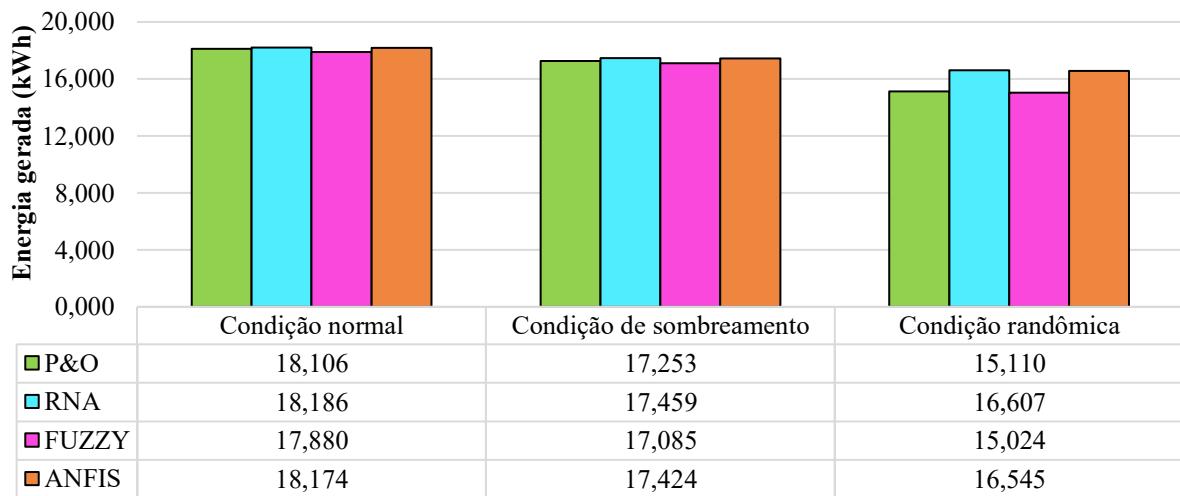


Figura 4.16. Energia gerada pelo sistema FV do cenário 1 quando aplicado os algoritmos de controle da proposta 2
Fonte: Autoria própria

A Figura 4.16 mostra que, sob condição normal, o sistema FV do cenário 1 gerou mais energia ao utilizar a RNA (18,186 kWh) e o ANFIS (18,174 kWh) como algoritmo de controle. Mesmo observando que a energia gerada em ambos os casos é relativamente próxima ao do sistema FV controlado pelo P&O, a troca do algoritmo de controle conseguiu, em percentual, recuperar 0,44% da energia ao utilizar o sistema FV com RNA e 0,38% quando o ANFIS foi aplicado como algoritmo de controle.

Resultados mais expressivos foram obtidos na condição de sombreamento e condição randômica. Na condição de sombreamento, o sistema FV do cenário 1 controlado pelo ANFIS gerou 0,993% mais energia do que com o P&O. Esse percentual corresponde a um aumento de 172 Wh na energia elétrica produzida pelo sistema FV. Quando a RNA foi utilizada para controlar o mesmo sistema FV, a produção de eletricidade aumentou 207 Wh, ou seja, uma recuperação de 1,194% na energia gerada pelo sistema FV.

Na condição randômica, o sistema FV controlado pelo ANFIS conseguiu extrair 16,545 kWh de energia elétrica, ou seja, 9,514% a mais do que o sistema com MPPT controlado pelo P&O. Quando o P&O foi substituído pela RNA, a energia gerada pelo sistema FV do cenário 1 foi de 16,607 kWh. Assim sendo, quando a RNA é utilizada como algoritmo de controle, ela consegue gerar 0,373% mais energia que o ANFIS ou 9,923% mais eletricidade que o P&O.

No caso da utilização do fuzzy como algoritmo de controle, a energia gerada foi menor, nas três condições ambientais que o sistema foi submetido, mesmo com os bons resultados de resposta dinâmica apresentados na Subseção 4.4.1. Na condição normal, a produção de eletricidade caiu 226 Wh que, em percentual, equivale a uma perda de 1,25% da energia gerada

pelo sistema FV, quando controlado pelo P&O. Na condição de sombreamento, a energia produzida foi de 17,085 kWh, ou seja, 168 Wh menor que a geração de 17,253 kWh do sistema FV controlado pelo P&O. Essa parcela, em percentual, corresponde a 0,97%.

Por último, na condição randômica, a energia produzida pelo sistema FV do cenário 1 controlado pelo *fuzzy* foi de 15,024 kWh. Em outras palavras, o *fuzzy* produziu 0,555% menos energia que o sistema FV, quando controlado pelo P&O.

Melhores resultados do *fuzzy* como algoritmo de controle são observados na avaliação da energia gerada pelo sistema FV do cenário 2, quando simulado sob as mesmas condições do cenário 1. A Figura 4.17 mostra a geração de energia do sistema FV do cenário 2 considerando os algoritmos RNA, *fuzzy* e ANFIS da proposta 2.

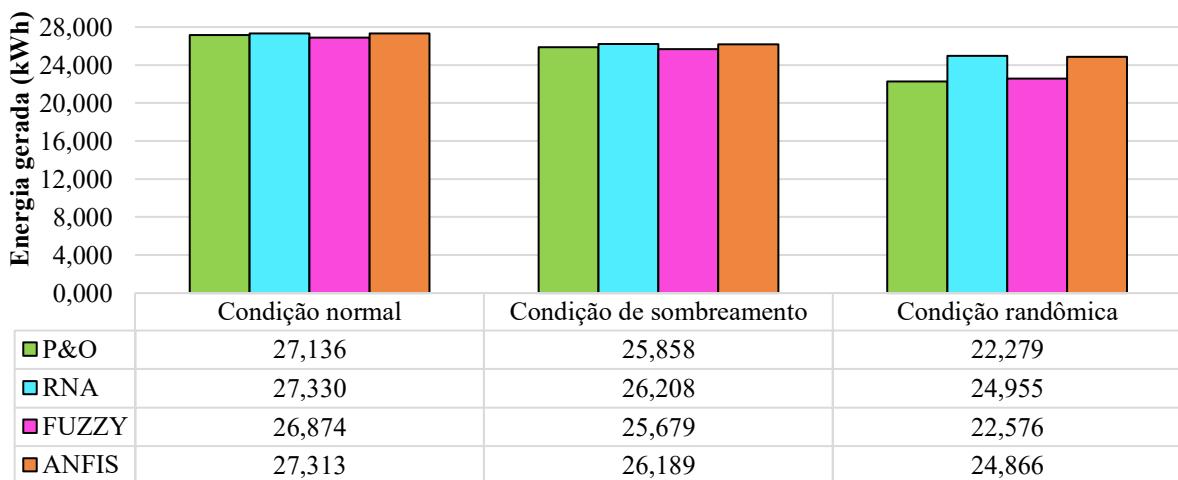


Figura 4.17. Energia gerada pelo sistema FV do cenário 2 quando aplicado os algoritmos de controle da proposta 2
Fonte: Autoria própria

Os resultados apresentados na Figura 4.17 apontam que, sob condição normal e de sombreamento, o *fuzzy* como algoritmo de controle permanecem com desempenho inferior ao P&O. Na condição normal, o *fuzzy* produziu 26,874 kWh de energia, o que corresponde a 0,966% (ou 262 Wh) a menos que o sistema FV controlado pelo P&O. Na condição de sombreamento, a produção de energia do sistema FV com *fuzzy* foi de 25,679 kWh, ou seja, uma queda de 0,692% (ou 179 Wh) na produção de eletricidade quando comparado com o P&O.

Por outro lado, sob condição randômica, o algoritmo *fuzzy* mostrou um desempenho superior ao do sistema FV controlado pelo P&O, visto que conseguiu aumentar 297 Wh (1,332%) na produção de eletricidade do sistema FV do cenário 2, como mostra a Figura 4.17.

Os resultados da Figura 4.17 também atestaram um bom aproveitamento dos algoritmos inteligentes RNA e ANFIS. Afinal, no cenário 2, ao substituir o algoritmo P&O pelo algoritmo

ANFIS, é observado um aumento de 177 Wh, 330,8 Wh e 2.587 Wh na energia gerada sob condição normal, de sombreamento e randômica, respectivamente. Em outras palavras, há, na devida ordem, uma recuperação de 0,652%, 1,279% e 11,611% na energia gerada.

Ao trocar o algoritmo P&O pela RNA, a energia recuperada é relativamente maior. Sob condição normal, condição de sombreamento e condição randômica, a energia recuperada é, respectivamente, de 0,714% (193,652 Wh), 1,354% (350,173 Wh) e 12,012% (2.276 Wh).

Em geral, avaliando as respostas dinâmicas e a geração de energia do sistema FV do cenário 1 e cenário 2, conclui-se que, ao utilizar os parâmetros G e $P_{FV}(t)$ como variáveis de entrada dos algoritmos inteligentes do MPPT, o sistema FV é capaz de rastrear o MPP mais rapidamente, com maior precisão e menor oscilação em torno do MPP, do que quando se utiliza o algoritmo clássico P&O como algoritmo de controle. Sobretudo, se for utilizado os algoritmos inteligentes RNA ou ANFIS, pois eles conseguiram fazer o sistema FV gerar mais energia durante as simulações, sob todas as condições ambientais submetidas.

Diante dos resultados avaliados, também é possível afirmar que, quando comparado com os resultados da resposta dinâmica na Subseção 4.3.1, o algoritmo inteligente *fuzzy* teve uma melhora na sua resposta dinâmica. Entretanto, esse aperfeiçoamento não foi suficiente para que, na geração de eletricidade, o desempenho do *fuzzy* fosse superior ao do P&O, exceto sob a condição randômica do cenário 2. Desse modo, um ajuste fino nas funções de pertinência e/ou nas regras *fuzzy* mostra-se pertinente de ser realizado pelo projetista.

Quando se analisa os parâmetros utilizados como variáveis de entrada do algoritmo de controle do MPPT da proposta 2, nota-se que a substituição do parâmetro ambiental T_{AMB} pelo parâmetro elétrico $P_{FV}(t)$ reduz a necessidade de aquisição de um sensor de temperatura. Isto porque, o algoritmo de controle passa a extrair o valor da $P_{FV}(t)$ por meio sensores de tensão e corrente elétrica presentes no próprio sistema FV em estudo.

Por outro lado, comparando apenas com a energia gerada pelos sistemas FV da proposta 1, essa troca dos parâmetros de entrada da proposta 2 também reduziram, mesmo que minimamente, a energia gerada pelos sistemas FV controlados por algoritmos inteligentes.

Outro ponto importante de ser avaliado é o treinamento dos algoritmos inteligentes. Assim como ocorreu nos algoritmos da proposta 1, nos algoritmos que utilizaram G e $P_{FV}(t)$ (proposta 2), o projetista teve menor dificuldade em variar o número e tipo de funções de pertinência do ANFIS, pois a combinação de RNA com *fuzzy* aumenta sua habilidade de aprendizagem. Desse modo, reduzir o número e alterar o tipo de MF do ANFIS, com o auxílio do software Matlab®, foi menos complexo e mais rápido do que para montar o banco de dados

do FLC. Consequentemente, a arquitetura ANFIS ficou mais compacta e precisou de menos esforço computacional para controlar o MPPT do sistema FV do que o FLC.

O algoritmo RNA também mostrou um treinamento relativamente simples, pois rapidamente conseguiu encontrar uma equação matemática que representasse com quase ou total fidelidade a relação entre os dados de entrada e saída disponíveis no banco de dados compilado na Seção 3.4.

Por outro lado, diferentemente dos algoritmos inteligentes da proposta 1, os algoritmos RNA, *fuzzy* e ANFIS da proposta 2 precisaram treinar algoritmos diferentes para cada cenário em estudo. Isso ocorreu, pois a entrada $P_{FV}(t)$ era diferente para cada um dos cenários.

Finalizada a avaliação da resposta dos algoritmos de MPPT da proposta 2, a Seção 4.5 analisa as respostas dos sistemas FV composto por MPPT controlados pelos algoritmos da proposta 3, ou seja, que têm os parâmetros elétricos $P_{FV}(t)$ e $P_{FV}(t-1)$ como variáveis de entrada.

4.5 Avaliação dos algoritmos de MPPT da proposta 3: variáveis de entrada potência de saída instantânea e do instante anterior do arranjo FV

Na proposta 3, os algoritmos inteligentes empregaram as variáveis elétricas potência de saída do arranjo FV instantânea e a mesma potência sendo que medida no instante anterior como variáveis de entrada. Para a análise do desempenho desses algoritmos, o estudo da resposta dinâmica (Subseção 4.5.1) e da geração de energia do sistema FV (Subseção 4.5.2) foram realizados.

4.5.1 Análise da resposta dinâmica

Para avaliar o comportamento da resposta dinâmica dos algoritmos da proposta 3, os sistemas FV do cenário 1 e cenário 2 foram modelados e simulados submetendo-os as condições ambientais da Figura 3.9. O sinal da potência de saída do sistema FV do cenário 1 e do cenário 2 obtido como resposta foram medidos e apresentados nas Figura 4.18 e Figura 4.19, respectivamente.

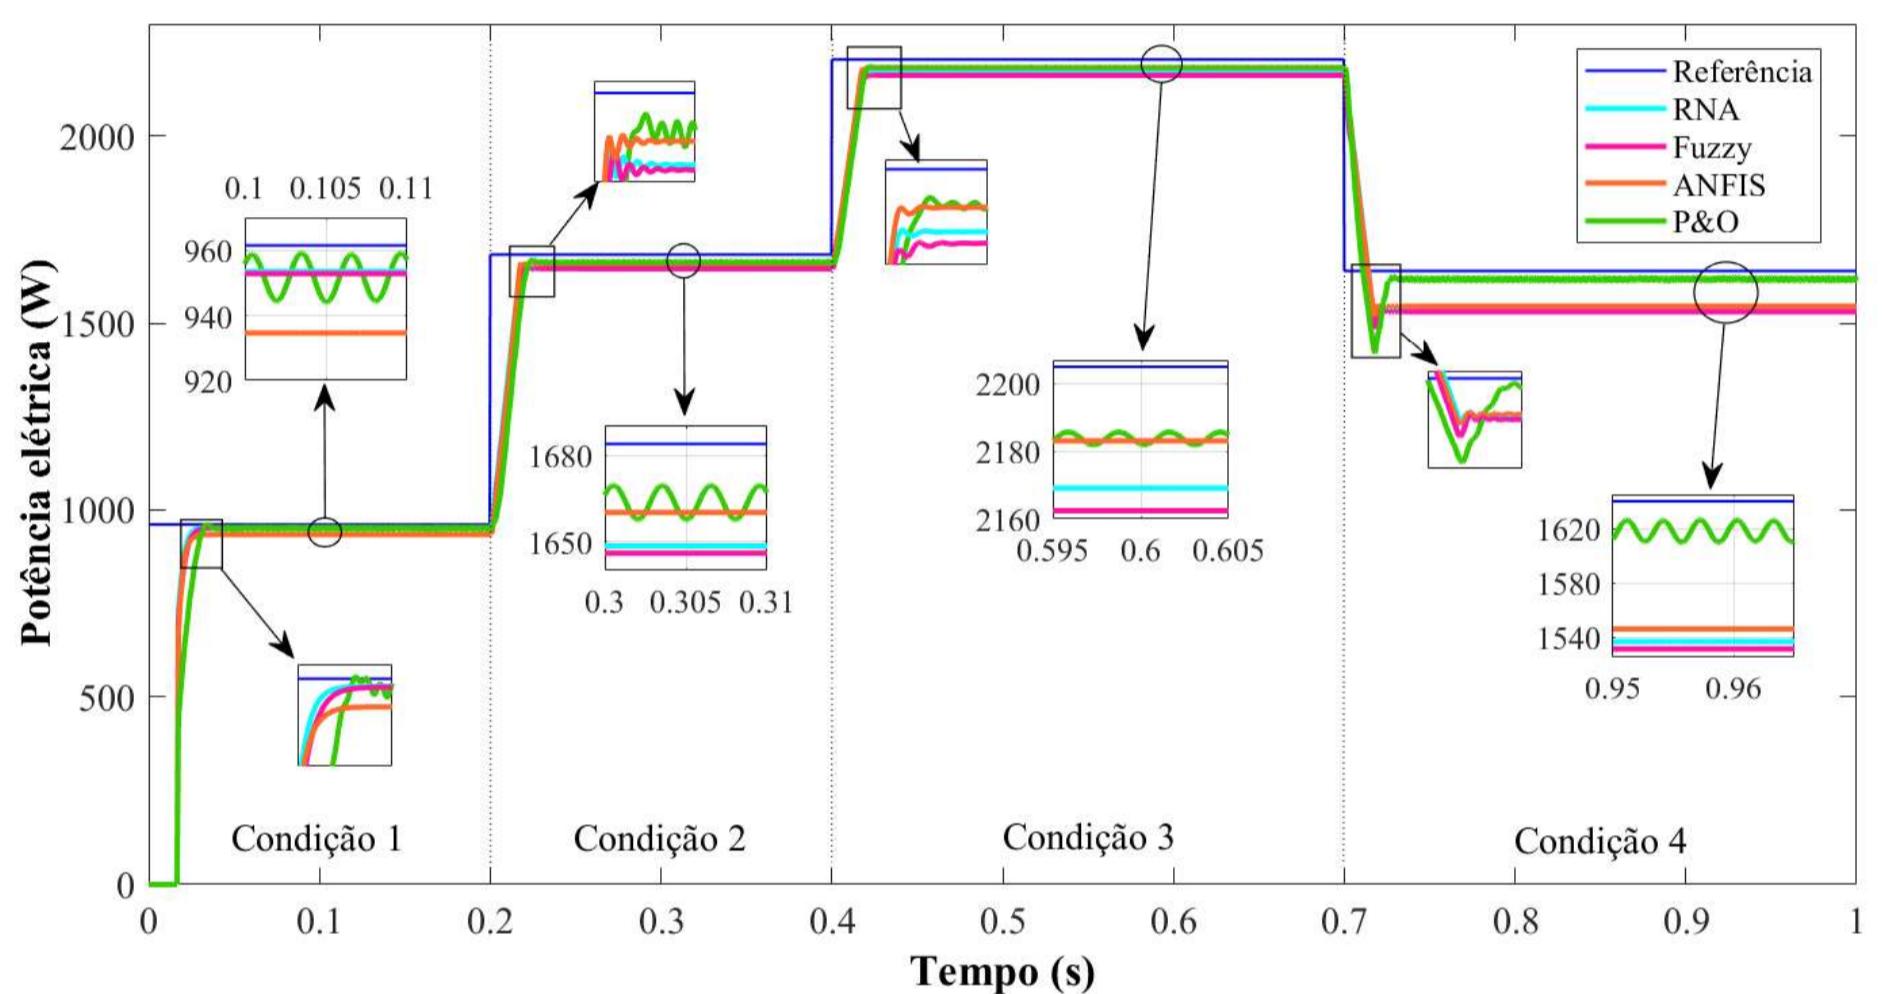


Figura 4.18. Potência de saída ao aplicar os algoritmos da proposta 3 no cenário 1
Fonte: Autoria própria

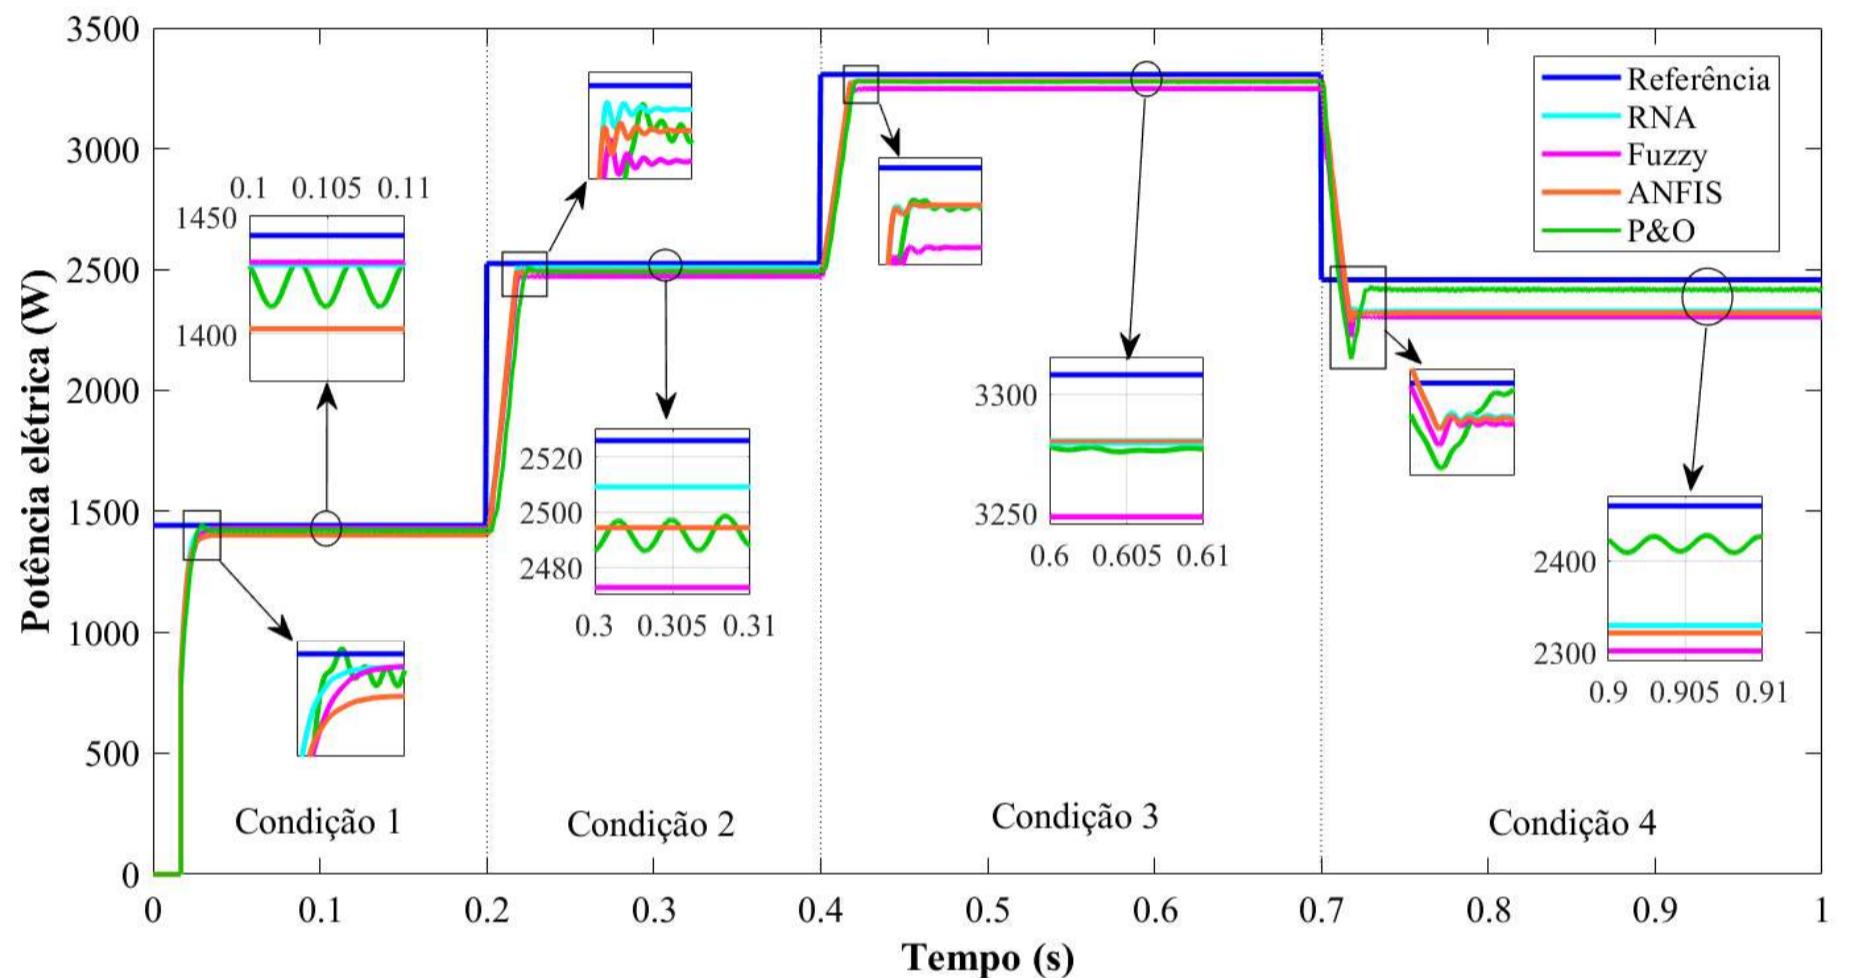


Figura 4.19. Potência de saída ao aplicar os algoritmos da proposta 3 no cenário 2
Fonte: Autoria própria

Fazendo uma análise geral das Figura 4.18 e Figura 4.19, os algoritmos de controle da proposta 3 foram os que proporcionaram a maior discrepância de comportamento entre os sinais de saída do sistema FV, ou seja, quase não foram constatadas sobreposições de sinais. Outra observação de relevância a ser pontuada, está no fato de todos os algoritmos inteligentes permaneceram menos oscilatórios que o algoritmo P&O no regime permanente.

Com relação ao subsinal presente na transição da condição 3 para a condição 4, e que foram observadas nas respostas dinâmicas da proposta 1 e proposta 2, elas ainda são vistas no cenário 1 (Figura 4.18) e cenário 2 (Figura 4.19) da proposta 3. Contudo, na proposta 3, os algoritmos inteligentes mostraram uma magnitude ainda menor desse subsinal.

Pelas Figura 4.18 e Figura 4.19, também foi percebido que os algoritmos inteligentes (RNA, *fuzzy* e ANFIS) foram menos precisos em rastrear o MPP na condição 4, sendo o *fuzzy*, o algoritmo com resposta mais distante do P_{MPP} almejado.

Doravante, foi averiguado o comportamento dos algoritmos da proposta 3 separadamente por condição do ambiente. Especificamente na condição 1 (Figura 4.18 e Figura 4.19), percebeu-se que o ANFIS conseguiu atingir o MPP mais rápido do que na proposta 2 (Figura 4.12 e Figura 4.13), visto que sua resposta passou a ser criticamente amortecida, como os algoritmos RNA e *fuzzy*. Em contrapartida, nessa condição e em ambos os cenários, houve um decaimento na eficiência do sinal do ANFIS. Os sistemas FV controlados pelos algoritmos RNA e *fuzzy* tiveram precisões próxima (no cenário 1) e superior (no cenário 2) ao P&O.

Analizando a condição 2 das Figura 4.18 e Figura 4.19, nota-se que os três algoritmos inteligentes tiveram menor eficiência que o P&O no cenário 1. Por outro lado, no cenário 2, a RNA e o ANFIS conseguiram ter, no regime permanente, um sinal mais próximo ao almejado, ao passo que o algoritmo inteligente *fuzzy* permaneceu menos eficiente que o P&O.

O comportamento menos satisfatório do *fuzzy* se manteve ao analisar a condição 3. Quando submetido a essa mesma condição do ambiente (condição 3), o algoritmo RNA proporcionou um sinal de saída para o sistema FV do cenário 1 menos preciso que o P&O (Figura 4.18). Em compensação, a RNA propiciou uma resposta mais acurada que a do P&O no cenário 2 (Figura 4.19), inclusive, com resposta idêntica ao sistema controlado pelo algoritmo ANFIS. No cenário 1, o ANFIS teve um desempenho melhor que os algoritmos RNA e *fuzzy*, mas não conseguiu ser superior ao P&O.

Para quantificar as análises supracitadas, as Tabela 4.12 e Tabela 4.13, com os parâmetros ts e ΔP de cada sinal, foram criadas, respectivamente, para os cenários 1 e 2.

Tabela 4.12. Parâmetros ts e ΔP dos algoritmos da proposta 3 aplicados no cenário 1

Condição ambiental	ts (ms)				ΔP (W)			
	P&O	RNA	FUZZY	ANFIS	P&O	RNA	FUZZY	ANFIS
Condição 1	29,17	22,00	23,18	21,86	16,390	0,00494	0,00577	0,00410
Condição 2	18,70	15,47	16,00	15,80	12,020	0,08668	0,03356	0,04735
Condição 3	16,00	14,22	14,15	14,38	5,865	0,02517	0,01315	0,01086
Condição 4	22,10	14,84	14,09	14,42	18,010	0,00600	0,00566	0,00909

Fonte: Autoria própria

Tabela 4.13. Parâmetros ts e ΔP dos algoritmos da proposta 3 aplicados no cenário 2

Condição ambiental	ts (ms)				ΔP (W)			
	P&O	RNA	FUZZY	ANFIS	P&O	RNA	FUZZY	ANFIS
Condição 1	24,72	23,35	25,28	23,46	18,970	0,00669	0,00705	0,00460
Condição 2	20,00	16,15	16,30	15,92	14,490	0,04993	0,04826	0,06556
Condição 3	16,50	14,51	14,48	14,52	4,280	0,04528	0,01436	0,02250
Condição 4	22,50	14,36	13,57	14,26	22,400	0,01059	0,00597	0,00865

Fonte: Autoria própria

Dentre os algoritmos inteligentes, a maior oscilação medida nas Tabela 4.12 e Tabela 4.13 foi no sinal da RNA. Um ΔP de 0,08668 W foi constatado, o que corresponde a quase 0,0026% da potência de saída medida. É importante frisar que esse valor ainda é consideravelmente inferior ao menor valor de ΔP medido no sinal de saída do P&O (Tabela 4.12 e Tabela 4.13), que foi de 4,28 W, o que equivale a 0,0653% do valor desse sinal medido no regime permanente.

Outrossim, o ts do algoritmo clássico P&O permanece maior do que todos os algoritmos inteligentes simulados (RNA, fuzzy e ANFIS). Em outras palavras, mesmo com a mudança nas variáveis de entrada dos algoritmos inteligentes, eles permanecem demorando menos tempo para atingir o regime permanente, ou seja, tiveram respostas mais rápidas às mudanças nas condições do ambiente. Em contrapartida, os algoritmos inteligentes reduziram sua capacidade de detectar e controlar o MPP, o que comprometeu a acuracidade do MPPT.

Revendo as Figura 4.18 e Figura 4.19, no cenário 1, por exemplo, os algoritmos inteligentes não conseguiram respostas mais acuradas que o P&O (como aconteceu nas propostas 1 e 2). No cenário 2, a RNA e o fuzzy mostraram ser mais eficientes na condição 1, ao passo que a RNA e o ANFIS tiveram eficiência superior ao do P&O nas condições 2 e 3.

De todo modo, para uma análise mais precisa, o $e\%$ de cada algoritmo simulado foi calculado para cada condição ambiental submetida. A Tabela 3.14 exibe os erros calculados

para ambos os cenários, ao passo que as Figura 4.20 e Figura 4.21 ilustram os resultados obtidos para o cenário 1 e cenário 2, respectivamente.

Tabela 4.14. Parâmetro $e\%$ calculado para os algoritmos de controle da proposta 3

Condição ambiental	Cenário 1				Cenário 2			
	$e_{P\&O}\%$	$e_{RNA}\%$	$e_{FUZZY}\%$	$e_{ANFIS}\%$	$e_{P\&O}\%$	$e_{RNA}\%$	$e_{FUZZY}\%$	$e_{ANFIS}\%$
Condição 1	1,03	0,78	0,88	2,76	1,46	0,83	0,76	2,77
Condição 2	1,19	2,08	2,26	1,43	1,35	0,63	2,10	1,27
Condição 3	0,95	1,63	1,95	1,00	0,94	0,85	1,81	0,85
Condição 4	1,34	6,28	6,65	5,73	1,67	5,25	6,43	5,57

Fonte: Autoria própria

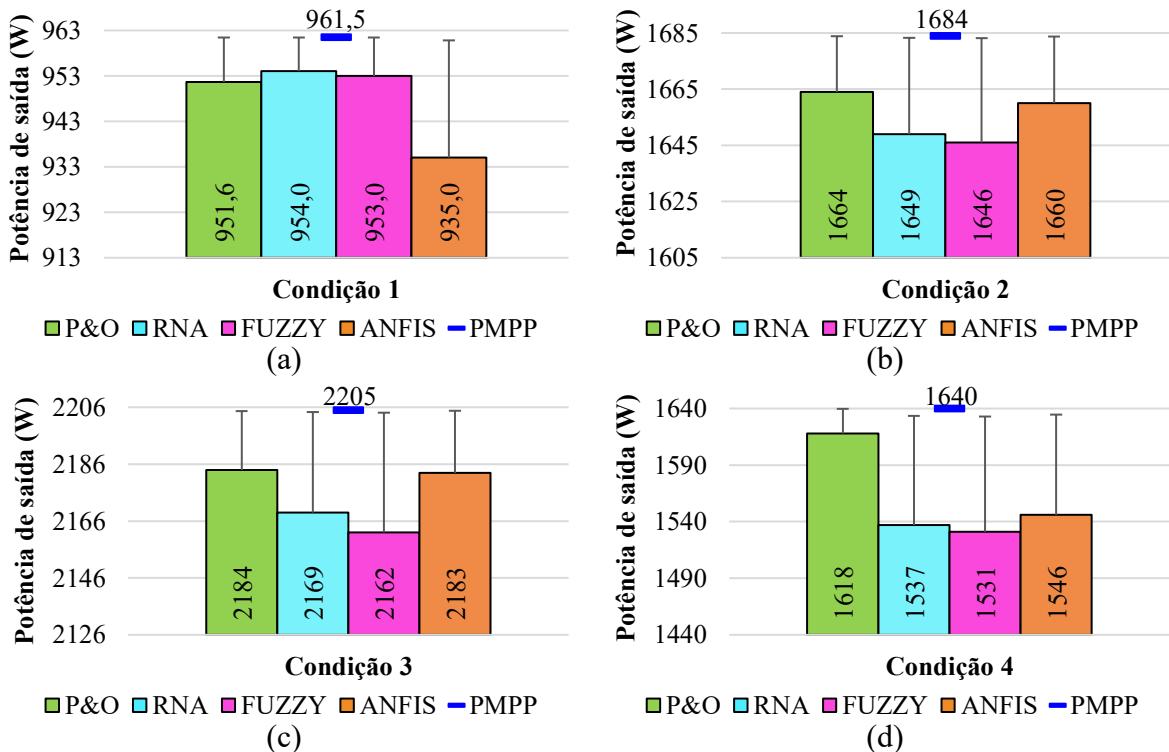
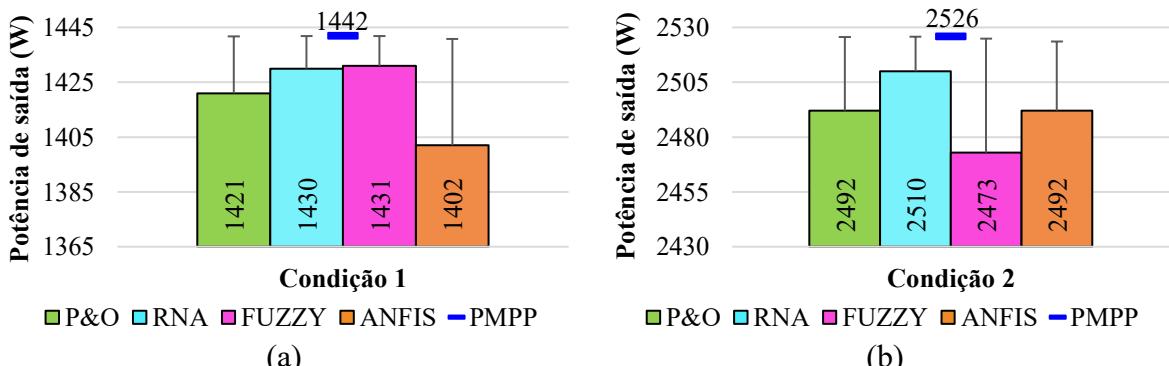


Figura 4.20. Potência de saída dos sistemas FV do cenário 1 e sua barra de erro em relação ao P_{MPP} , quando aplicado os algoritmos de controle da proposta 3 e submetidos à (a) condição 1, (b) condição 2, (c) condição 3 e (d) condição 4 do ambiente

Fonte: Autoria própria



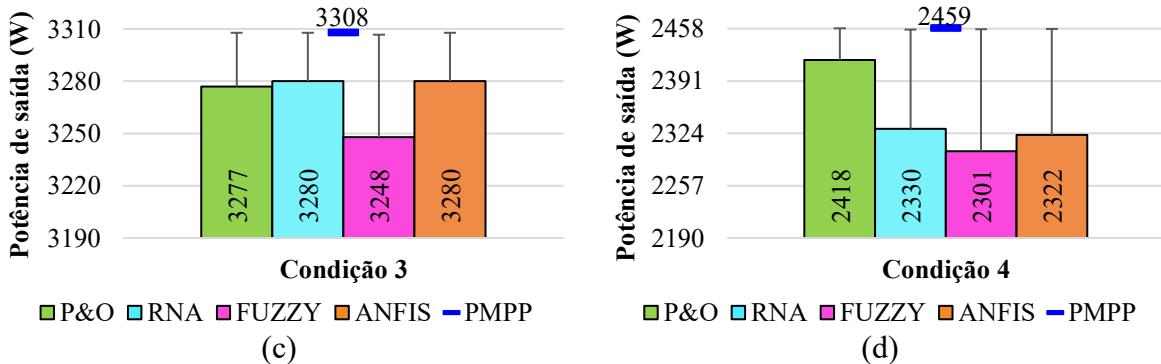


Figura 4.21. Potência de saída dos sistemas FV do cenário 2 e sua barra de erro em relação ao P_{MPP} , quando aplicado os algoritmos de controle da proposta 3 e submetidos à (a) condição 1, (b) condição 2, (c) condição 3 e (d) condição 4 do ambiente

Fonte: Autoria própria

Os resultados apresentados nas Tabela 3.14, Figura 4.20 e Figura 4.21 concordam com os sinais de saída mostrados nas Figura 4.18 e Figura 4.19, e já discutidos. Assim sendo, diferentemente das propostas 1 e 2, os resultados da Tabela 3.14, Figura 4.20 e Figura 4.21 confirmaram que o algoritmo P&O teve $e\%$ próximos (e, em alguns momentos até inferiores) aos calculados para os sinais de saída dos sistemas FV controlados por algoritmos inteligentes.

No cenário 1, o P&O foi o algoritmo que apresentou menores erros para as condições do ambiente 2, 3 e 4. Os valores de $e\%$ calculados foram, respectivamente, 1,19%, 0,95% e 1,34%. Na condição 1, a maior eficiência foi do sistema controlado pelo algoritmo RNA. O $e\%$ foi de 0,78%, o que corresponde a uma eficiência de 99,22%.

No cenário 2, o algoritmo clássico P&O foi o mais eficiente apenas na condição 4, quando atingiu uma eficiência de 98,33%. Para a condição 1, o menor erro calculado foi para o sistema FV controlado pelo algoritmo inteligente *fuzzy*, com valor de 0,76%. Para a condição 2, o algoritmo RNA foi quem proporcionou a maior eficiência, com seu $e\%$ de 0,63%. E, na condição 3, tanto a RNA quanto o ANFIS conseguiram uma eficiência de 99,15%, quando estimaram um $e\%$ de 0,85%.

Com relação à menor eficiência, na condição 1 do cenário 1 e cenário 2, o algoritmo inteligente ANFIS teve o maior $e\%$, com valor de 2,76% e 2,77%, respectivamente. Para as demais condições, o *fuzzy* mostrou ter um desempenho inferior, com erros entre 1,81% (condição 3 do cenário 2) e 6,65% (condição 4 do cenário 1). Outrossim, como observado nas Figura 4.18 e Figura 4.19, todos os algoritmos inteligentes foram menos eficientes ao detectar o MPP da Condição 4, quando comparado com o P&O.

Ainda sobre os erros calculados, durante a simulação foi observado uma grande relação entre a condição 2 e condição 4. Quando os algoritmos inteligentes tinham suas arquiteturas

ajustadas para minimizar o erro da condição 2, por exemplo, o erro calculado na condição 4 aumentava, e vice-versa. Desta forma, optou-se por manter a maior proximidade alcançada durante a simulação entre os dois erros.

Um problema similar foi detectado no ajuste das funções de pertinência do algoritmo inteligente ANFIS e *fuzzy*, que influenciavam na resposta do sinal, quando o sistema FV estava submetido à condição 3 do ambiente. Nesse caso, uma pequena variação no intervalo das funções de pertinência MH aumentava a eficiência do sinal no regime permanente, porém, um subsinal indesejado, na transição da condição 2 para a condição 3, era detectado. Como solução, foi realizado um ajuste na matriz de regra juntamente com um ajuste fino na base de dados, especificamente, no intervalo na MF MH.

Depois de pontuar as principais características observadas nas respostas dinâmicas dos algoritmos P&O, RNA, *fuzzy* e ANFIS, a Subseção 4.5.2 estima a energia gerada por cada sistema FV sob as condições ambientais discutidas na Subseção 3.4.2.

4.5.2 Análise da geração de energia do sistema FV

A geração de energia dos algoritmos de controle da proposta 3 foram estimadas considerando dez horas de sol pleno (das 6h às 16h) e os mesmos três dias distintos de condições ambientais usados na proposta 1 e proposta 2.

Semelhante à análise das subseções 4.3.2 e 4.4.2, o algoritmo clássico P&O foi utilizado como parâmetro de referência da produção de energia. Em outras palavras, a energia gerada pelo sistema FV controlado pelo P&O será 100% e os sistemas FV controlados pelos algoritmos inteligentes da proposta 3 mostraram se perderam, mantiveram ou recuperaram energia.

Na Figura 4.22 é mostrada a energia produzida pelo sistema FV do cenário 1, quando controlado por cada algoritmo da proposta 3.

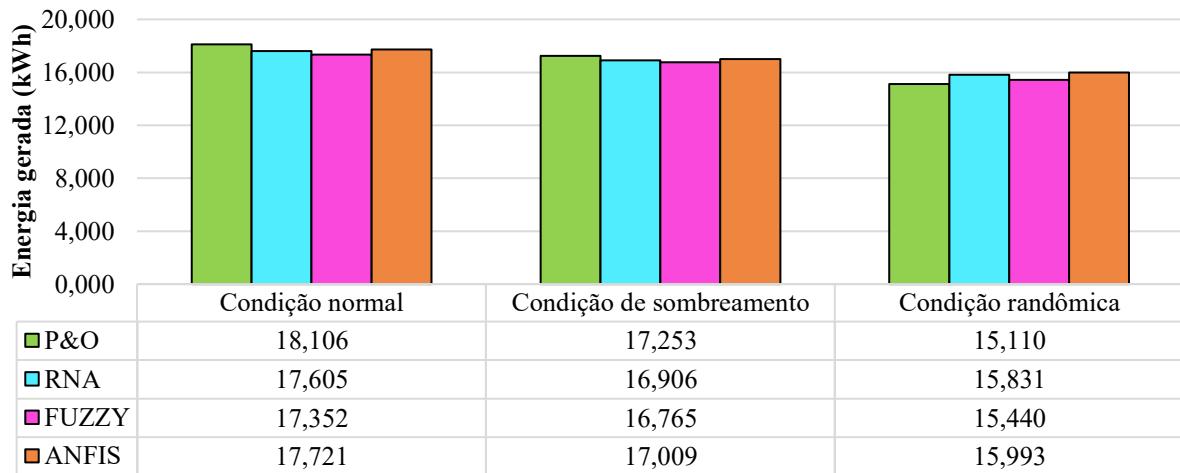


Figura 4.22. Energia gerada pelo sistema FV do cenário 1 quando aplicado os algoritmos de controle da proposta 3

Fonte: Autoria própria

Sob condição normal e condição de sombreamento, o sistema FV do cenário 1 gerou mais energia ao utilizar o P&O como algoritmo de controle. O ANFIS foi o algoritmo de controle que conseguiu uma produção de energia mais próxima do P&O, mas ainda gerou menos energia que o sistema controlado pelo P&O. Sob condição normal, a queda foi de 385,15 Wh (2,13%) e, sob condição de sombreamento, a redução foi de apenas 243,84 Wh (1,41%).

Para avaliar esse desempenho inferior dos algoritmos inteligentes, foram traçadas as curvas da potência de saída de todos os algoritmos de controle simulados. A Figura 4.23 refere-se à condição normal e a Figura 4.24 à condição sombreada.

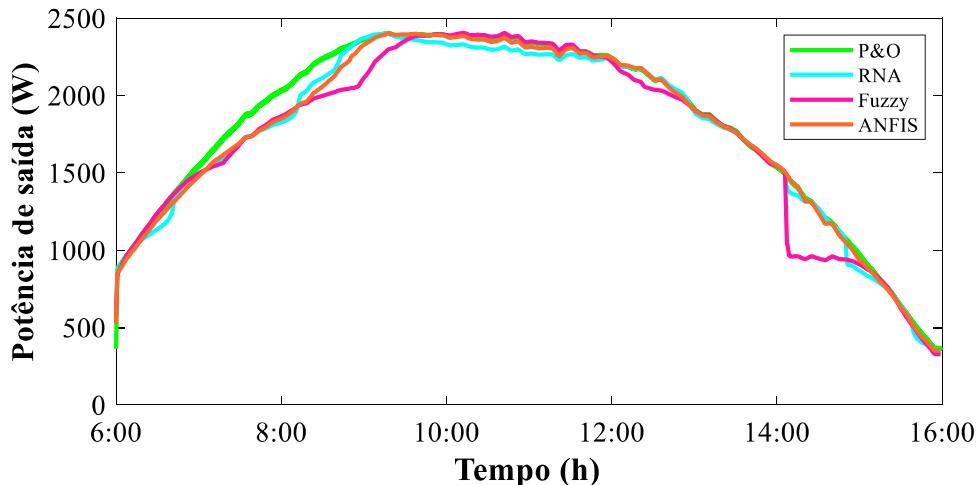


Figura 4.23. Potência de saída do sistema FV do cenário 1 quando aplicado os algoritmos de controle da proposta 3 e sob condição normal

Fonte: Autoria própria

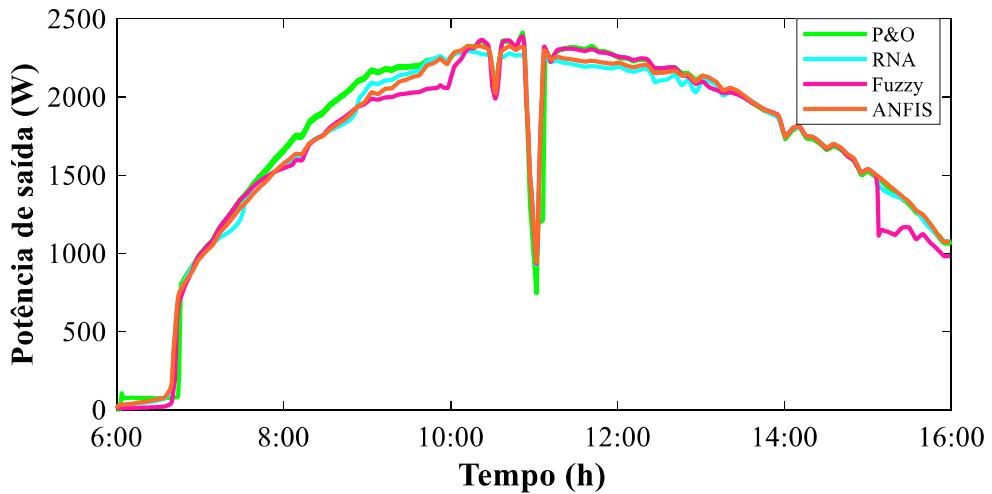


Figura 4.24. Potência de saída do sistema FV do cenário 1 quando aplicado os algoritmos de controle da proposta 3 e sob condição de sombreamento

Fonte: Autoria própria

Examinando as Figura 4.23 e Figura 4.24, percebe-se que os algoritmos inteligentes tiveram a mesma dificuldade de rastrear o MPP, entre as potências de 1500W e 2000W, que foi observada na resposta dinâmica, sobretudo durante a elevação da irradiância. Esse fator foi crucial para a redução do desempenho dos sistemas FV.

Dentre todos os algoritmos de controle analisados, o *fuzzy* foi o algoritmo responsável pela menor geração de eletricidade. Observando as Figura 4.23 e Figura 4.24, nota-se que a produção de energia elétrica do *fuzzy* foi a mais comprometida, pois o algoritmo também teve problemas em rastrear potências com valores acima de 2000W, bem como apresentou dificuldade em rastrear potências inferiores à 1500W durante a redução da irradiância. Isso pode ser ter ocorrido por uma regra *fuzzy* e/ou intervalo de MF errados.

Sob à condição randômica, os algoritmos inteligentes mostraram resultados mais satisfatórios. O *fuzzy* conseguiu gerar 331,61 Wh a mais de energia que o sistema FV controlado pelo P&O. Em percentual, esse valor corresponde a uma recuperação de, aproximadamente, 2,19%. O algoritmo RNA elevou 723,13 Wh da energia gerada pelo sistema FV, o que representou um aumento de quase 4,79% na geração de eletricidade. O algoritmo inteligente ANFIS conseguiu um resultado ainda melhor. O sistema FV, quando controlado por ele, gerou 884,77 Wh (5,86%) a mais de energia que o sistema controlado pelo P&O.

A Figura 4.25 representa a curva da potência dos sistemas FV, quando controlados pelos algoritmos P&O, RNA, *fuzzy* e ANFIS, e estão sob a condição ambiental randômica.

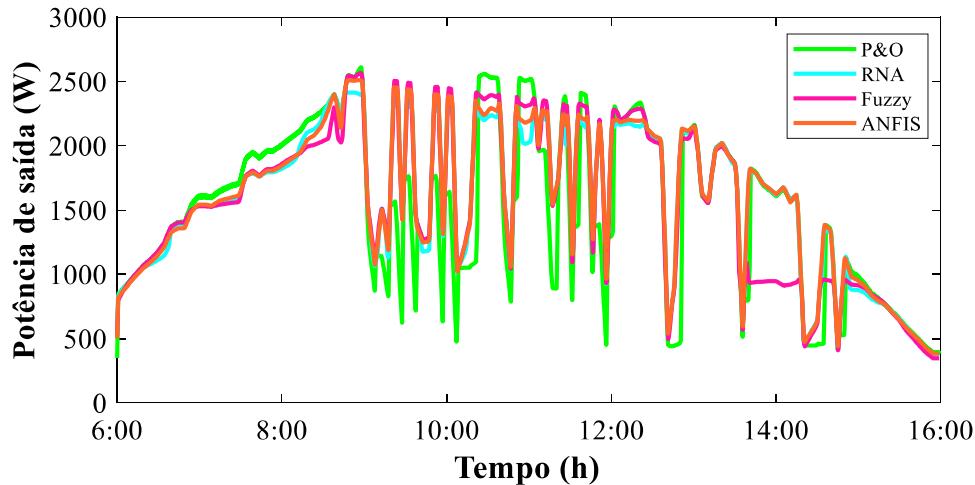


Figura 4.25. Potência de saída do sistema FV do cenário 1 quando aplicado os algoritmos de controle da proposta 3 e sob condição randômica

Fonte: Autoria própria

Na Figura 4.25 ainda é perceptível a dificuldade que os algoritmos inteligentes apresentam em rastrear o MPP, entre os valores de 1500W e 2000W, próximo às 8:00h. Contudo, esse problema é minimizado com a rapidez que os algoritmos inteligentes apresentam em detectar e rastrear o MPP durante as mudanças bruscas da irradiância.

Diante dos resultados apresentados, se os sistemas FV forem avaliados separadamente, a escolha de o melhor algoritmo da proposta 3, considerando a geração de eletricidade, vai depender das condições ambientais do local em que o sistema FV será instalado.

Se, ao longo do ano, a região apresentar condições atmosféricas que se aproximam da condição normal, é prudente optar pelo algoritmo de controle P&O. A mesma escolha deve ser feita para locais em que o sistema FV será instalado onde já se sabe que, em pelo menos uma época do ano, parte desse sistema será sombreado. Em contrapartida, em regiões com consideráveis variações ambientais, como na condição randômica, escolher o algoritmo inteligente ANFIS é o mais acertado.

Por outro lado, se for avaliado o sistema FV considerando os três dias de análise juntos, ou seja, dia 1 sob a condição normal, dia 2 sob a condição de sombreamento e dia 3 sob a condição randômica, estimou-se que o algoritmo ANFIS consegue a maior produção de eletricidade dentre os quatro algoritmos de controle avaliados. Foi contabilizado que o ANFIS gera 255,77 Wh a mais de energia que o P&O, o que equivale à uma recuperação de 0,50%.

Como foi observado nas análises das da proposta 1 e proposta 2, resultados ainda melhores são observados na geração de eletricidade, quando se eleva a potência do sistema FV.

Para verificar se esse comportamento também acontece com os algoritmos da proposta 3, a geração de energia do cenário 2 foi calculada, como mostra a Figura 4.26.

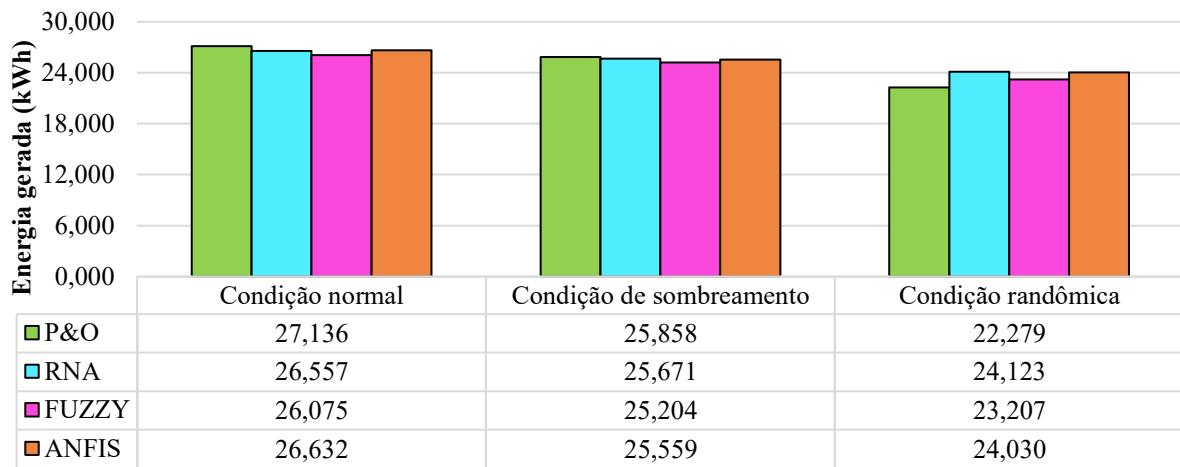


Figura 4.26. Energia gerada pelo sistema FV do cenário 2 quando aplicado os algoritmos de controle da proposta 3

Fonte: Autoria própria

Mesmo com a elevação da potência elétrica do sistema FV, no cenário 1, os algoritmos inteligentes não mostraram uma produção de eletricidade superior ao do algoritmo P&O, sob à condição normal e condição de sombreamento, como mostra a Figura 4.26.

Entretanto, sob a condição normal, o sistema controlado pelo ANFIS produziu uma quantidade de energia ainda mais próxima ao do sistema controlado pelo P&O. A geração foi 504,157 Wh a menos que a produzida pelo P&O. Em percentual, essa parcela equivale a uma perda de apenas 1,86%. Ou seja, uma perda inferior à apresentada pelo ANFIS no cenário 1.

A curva de potência dos sistemas FV foram traçadas na Figura 4.27, considerando que, ao longo do dia, o sistema foi submetido à condição normal.

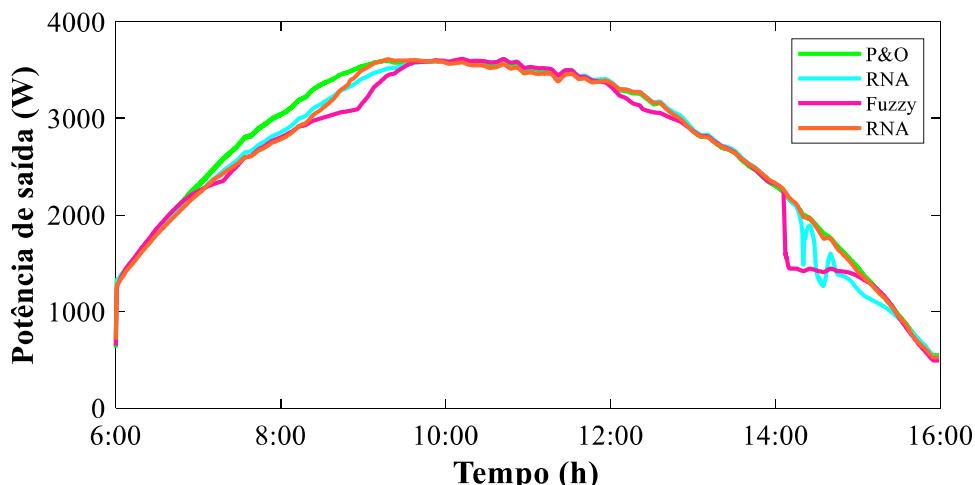


Figura 4.27. Potência de saída do sistema FV do cenário 2 quando aplicado os algoritmos de controle da proposta 3 e sob condição normal

Fonte: Autoria própria

Como esperado, a Figura 4.27 teve um comportamento parecido com o da Figura 4.23. Uma exceção foi detectada na potência gerada pelo sistema FV controlado pelo RNA, que apresentou um comportamento irregular após às 14:00h. Nesse horário, a irradiância está em queda e a potência deveria cair gradativamente de 2000 W para 1000 W, em um intervalo superior a uma hora, como aconteceu com o sistema FV controlado pelo P&O e ANFIS.

Sob a condição de sombreamento, foi o algoritmo RNA que proporcionou a produção de eletricidade mais próxima ao do sistema FV controlado pelo P&O. A perda de geração foi de somente 187,367 Wh, ou seja, de 0,72%.

A curva da potência sob condição de sombreamento é mostrada na Figura 4.28.

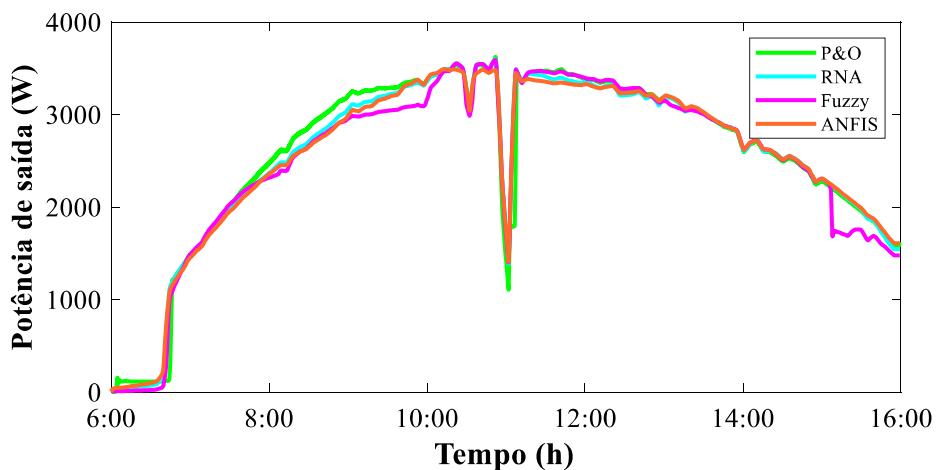


Figura 4.28. Potência de saída do sistema FV do cenário 2 quando aplicado os algoritmos de controle da proposta 3 e sob condição de sombreamento

Fonte: Autoria própria

Na Figura 4.28, nota-se que a diferença de 112,21 Wh entre as energias geradas pelos sistemas FV controlados pelo RNA e pelo ANFIS ocorre devido à superioridade, mesmo que ínfima, do desempenho da RNA entre às 08:00h e 10:00h, bem como no pico da irradiância (próximo ao meio-dia). Ademais, a irregularidade observada na curva da RNA da Figura 4.27, após às 14:00h, não foram mais percebidas na Figura 4.28.

O RNA da proposta 3 também foi o algoritmo que proporcionou a maior produção de eletricidade para o sistema FV sob a condição randômica. A geração foi 1.843,314 Wh superior que a do sistema controlado pelo P&O. Desse modo, é possível afirmar que o RNA propiciou uma recuperação de 8,27% de energia produzida.

Resultados parecidos foram obtidos com o sistema FV controlado pelo ANFIS. A energia produzida foi de 24,030 kWh (Figura 4.26), ou seja, 1751,125 Wh (7,86%) a mais que a do sistema FV, quando controlado pelo P&O.

O algoritmo *fuzzy* da proposta 3 também mostrou uma performance melhor que o do algoritmo P&O, quando eles foram usados para controlar o sistema FV do cenário 2. A energia produzida elevou 927,495 Wh, ou seja, 4,16% de recuperação.

Essa energia que foi gerada a mais pelos sistemas FV controlados pelos algoritmos inteligentes, quando estão sob condição randômica, é esperada. Isto porque, a rapidez que os algoritmos inteligentes têm em detectar mudanças bruscas das condições do ambiente suprem a desvantagem de, em alguns momentos, serem menos preciso em rastrear o MPP que o P&O. A Figura 4.29 mostra essas características através da curva da potência dos sistemas FV, ao longo de um dia sob condição randômica.

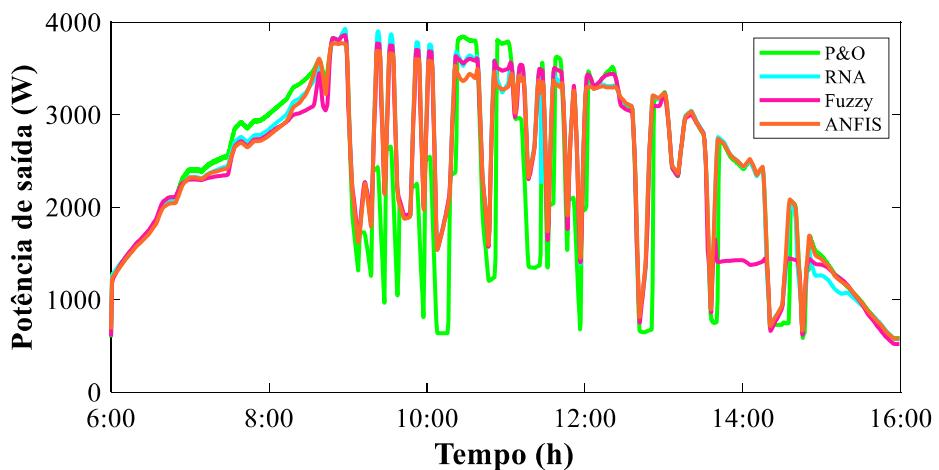


Figura 4.29. Potência de saída do sistema FV do cenário 2 quando aplicado os algoritmos de controle da proposta 3 e sob condição randômica

Fonte: Autoria própria

Com os resultados apresentados no cenário 2, se for considerado como energia produzida o somatório da geração dos três dias de análises, verificou-se que o RNA é algoritmo que proporcionou maior produção de eletricidade. A estimativa de energia produzida é de 76,350 kWh, especificamente, 1,076 kWh (1,43%) a mais que a do P&O.

O algoritmo ANFIS também gerou mais eletricidade que o P&O, quando se considera a soma dos três dias de análises. A produção total de eletricidade é de 76,221 kWh, ou seja, 0,947 kWh (1,26%) maior que a do P&O.

Por outro lado, quando se considera a geração dos três dias de análises juntas, o algoritmo inteligente *fuzzy* produz 1,048% menos energia que o P&O. Sendo assim, o sistema FV perde 0,788 kWh da energia que consegue produzir, quando é controlado pelo P&O.

Fazendo uma avaliação geral do desempenho dos sistemas FV do cenário 1 e cenário 2, quando controlados pelos algoritmos da proposta 3, constatou-se que, ao comparar com a

proposta 1 e proposta 2, a rapidez e estabilidade do sistema FV não foi prejudicada, logo, não ocasionou efeitos negativos na geração de eletricidade. Em contrapartida, a redução na eficiência dos algoritmos inteligentes afetou negativamente na produção de eletricidade do sistema FV, especialmente quando submetidos às condições normal e de sombreamento.

Ao avaliar as variáveis de entrada do algoritmo de controle do MPPT da proposta 3, percebe-se que, ao utilizar apenas parâmetros elétricos como variáveis de entrada dos algoritmos inteligentes, foi eliminada a necessidade de sensores de irradiação e temperatura. Dessa forma, uma vantagem dessa troca está no aproveitamento dos sensores de tensão e corrente, que normalmente vem junto do sistema FV. Contudo, os MPPT inteligentes da proposta 3 mostraram uma maior dificuldade em rastrear o MPP, reduzindo a energia gerada.

Com relação ao treinamento dos algoritmos inteligentes, devido a sobreposição de valores de D , principalmente entre 1500W e 2000W (cenário 1) e 2000W e 3500W (cenário 2), o projetista teve maior dificuldade para estruturar e treinar todas as arquiteturas desses algoritmos inteligentes. Esse fato contribuiu para a considerável redução na eficiência.

Por fim, após avaliar a resposta dos algoritmos de MPPT da proposta 3, a Seção 4.6 compara os resultados obtidos no presente estudo com os resultados levantados de outros trabalhos. Esses trabalhados também utilizaram os algoritmos inteligentes RNA, *fuzzy* ou ANFIS para controle do chaveamento de um conversor CC-CC *buck-boost*.

4.6 Comparativo com outros trabalhos

Na literatura, foram encontrados poucos estudos usando o *buck-boost* como conversor CC-CC do bloco de condicionamento de potência do sistema FV. De todo modo, a Tabela 4.15 faz uma razoável análise comparativa entre os resultados dos estudos publicados anteriormente e a Tabela 4.16 mostra os resultados obtidos com o estudo proposto.

Na Tabela 4.15 e Tabela 4.16 são descritos os trabalhos publicados, o algoritmo de controle usado, as entradas e saída do modelo, o número de regras *fuzzy* e do conjunto de banco de dados, o tempo de acomodação, a eficiência e informa se foi desenvolvido um trabalho experimental. Todos os dados ausentes nos artigos foram hifenizados nas tabelas.

Tabela 4.15. Resultados de trabalhos publicados que utilizaram os algoritmos inteligentes RNA, *fuzzy* ou ANFIS como controle do MPPT

Referência	Algoritmo	Entradas	Saída	Número de regras <i>fuzzy</i>	Conjunto de dados	t_s (ms)	Eficiência (%)	Experimental
Aldobhani (2008) e Aldobhani e John (2007, 2008)	ANFIS	I_{CC} e V_{OC}	V_{MPP}	4	39	-	98-99	Não
Otiene, Nyakoe e Wekesa (2009)	ANFIS	G e T_{AMB}	V_{MPP}	21	-	-	-	Não
Panda, Pathak, and Srivastava (2011)	<i>Fuzzy</i>	E e dE	D	25	-	12,20	-	Não
Shiau <i>et al.</i> (2014)	<i>Fuzzy</i>	E e dE	D	25	-	-	-	Não
Arora e Gaur (2015)	ANFIS	E e dE	D	81	300.001	105,0	100	Não
	RNA	V_{FV} e I_{FV}		-		125,0	99,83	
Martin and Vazquez (2015)	ANFIS	G e T	V_{MPP}	-	-	-	98,2	Sim
	<i>Fuzzy</i>	V_{MPP} e V_{FV}	D				98,2	
Makhlofi, Abdessemed e Khireddine (2016)	RNA	P_{FV}	D	-	-	10 - 40	-	Não
Belhachat e Larbes (2017)	ANFIS	V_{FV} e I_{FV}	P_{MPP}	9	-	-	99,92	Não
Andrew-Cotter, Uddin e Amin (2019)	ANFIS	V_{FV} e I_{FV}	D	-	-	-	97	Não
Kumar, Rathor e Bahrani (2019)	<i>Fuzzy</i>	E e dE	D	25	-	15	97	Não
Islam <i>et al.</i> (2020)	RNA	G e T_{AMB}	V_{MPP}	-	590	50	-	Não
Rajavel e Rathina (2021)	<i>Fuzzy</i>	E e dE	D	25	-	100	-	Não

Fonte: Autoria própria

Tabela 4.16. Resultados do estudo proposto

Referência	Algoritmo	Entradas	Saída	Número de regras fuzzy	Conjunto de dados	t_s (ms)	Eficiência (%)	Experimental
Proposta 1 Guerra <i>et al.</i> (2021)	ANFIS	G e T_{AMB}	D	25	77	13,00–23,54	99,32–99,49	Não
	Fuzzy			77		13,20–22,24	96,19–99,41	
	RNA			-		13,40–23,44	99,32–99,48	
Proposta 2	ANFIS	G e $P_{FV}(t)$	D	25	77	12,80–101,26	99,25–99,63	Não
	Fuzzy			55		12,68–24,92	99,32–99,61	
	RNA			-		13,00–38,28	99,30–99,65	
Proposta 3	ANFIS	$P_{FV}(t)$ e $P_{FV}(t-1)$	D	25	77	14,26–23,46	94,27–99,15	Não
	Fuzzy			25		13,57–25,28	93,35–99,24	
	RNA			-		14,22–23,35	93,72–99,37	

Fonte: Autoria própria

Entre as pesquisas que utilizaram o *buck-boost* como conversor do MPPT, apenas dois trabalhos efetivamente mediram o tempo de acomodação (Panda, Pathak, and Srivastava (2011) e Arora e Gaur (2015)). Os outros quatro valores de t_S mostrados na Tabela 4.15 foram extraídos observando os gráficos das potências de saída apresentados pelos autores.

Os estudos de Panda, Pathak, and Srivastava (2011), Makhlofi, Abdessemed e Khireddine (2016) e Kumar, Rathor e Bahrani (2019) (todos da Tabela 4.15) alcançaram t_S próximo ao dos métodos proposto no presente trabalho (Tabela 4.16). No trabalho de Panda, Pathak, and Srivastava (2011), o valor do t_S é ainda menor devido às menores variações de condições ambientais que o sistema fotovoltaico foi submetido.

Em contrapartida, o t_S dos sistemas de Arora e Gaur (2015), Islam *et al.* (2020) e Rajavel e Rathina (2021) foram consideravelmente maiores do que o da pesquisa proposta. No trabalho de Arora e Gaur (2015), a diferença pode ser explicada devido ao fato de o sistema ser conectado à rede e submetido a uma lenta e gradual variação de níveis de irradiação solar. Rajavel e Rathina (2021) também tiveram seu sistema submetido a uma elevação gradativa de irradiância, o que pode ter proporcionado um t_S maior do que os apresentados na Tabela 4.16. No presente estudo, a medição de t_S foi realizada considerando o efeito borda de nuvem na mudança da irradiância.

Com relação a proposta de Islam *et al.* (2020), optar pela saída V_{MPP} para o algoritmo RNA, pode ter feito o sistema FV atingir o regime permanente próximo à 50 ms. Na Tabela 4.16, o maior valor de t_S medido para uma RNA, quando optou-se pelas entradas G e T_{AMB} (iguais ao do trabalho de Islam *et al.* (2020)), foi 23,44 ms, ou seja, nem a metade do tempo medido por Islam *et al.* (2020). Por outro lado, quando as entradas propostas para a RNA da Tabela 4.16 foram G e $P_{FV}(t)$, o valor de t_S medido subiu para 38,28 ms, isto é, apenas 11,72 ms menor que o t_S medido por Islam *et al.* (2020).

Desta forma, só é justo utilizar o parâmetro t_S para comparar a velocidade de rastreamento entre os sistemas FV dos trabalhos publicados e os do estudo proposto caso seja garantido que todos os sistemas FV sejam idênticos e tenham sido submetidos as mesmas condições ambientais.

Em relação à eficiência, tanto na Tabela 4.15 como na Tabela 4.16, os algoritmos de controle proporcionaram uma eficiência maior que 90% para o sistema FV. Sendo assim, os resultados mostram a alta capacidade que os algoritmos inteligentes têm em seguir, com acurácia, o MPP do arranjo FV. Conforme discutido nas Seção 2.7, esse resultado era esperado, devido a habilidade que os algoritmos inteligentes têm, em trabalhar com sistemas não lineares.

Especificamente, avaliando os resultados de Arora e Gaur (2015), eles calcularam a eficiência com base na máxima potência obtida na saída do sistema fotovoltaico do seu estudo. Por conta disso, o ANFIS apresentou uma eficiência de 100%. Os demais trabalhos da Tabela 4.15 e Tabela 4.16 tiveram a eficiência avaliada com base no MPP da curva característica P–V do seu arranjo FV.

Conduzindo às análises para os resultados obtidos na Tabela 4.16, dentre as técnicas inteligentes simuladas no presente estudo, os algoritmos RNA e ANFIS tiveram respostas dinâmicas parecidas, principalmente na proposta 1 e proposta 2. Por outro lado, o *fuzzy* foi o algoritmo que teve a menor eficiência, sobretudo na proposta 1 e proposta 3 da Tabela 4.16. Isso significa que a base de dados e a matriz de regra do *fuzzy* precisam ser ajustadas novamente.

Assim sendo, os resultados também mostraram que o desempenho dos algoritmos inteligentes de MPPT dependem mais da qualidade do que da quantidade dos dados de treinamento. Do mesmo modo, a performance do algoritmo é influenciada pelo conhecimento do projetista ao modelar e treinar esse algoritmo.

Com os resultados da presente pesquisa, a Seção 5 discorre sobre as principais conclusões obtidas, bem como algumas sugestões para possíveis trabalhos futuros.

5. Conclusões

O estudo de algoritmos inteligentes aplicados no controle do MPPT de sistemas FV mostram que os algoritmos inteligentes têm sido fundamentais para minimizar os efeitos negativos ocasionados, especialmente, pelas alterações ambientais imprevisíveis.

Também foi observado que o uso de conversores CC-CC *buck-boost*, como componente do sistema de controle, não é o mais comum. Entretanto, eles são importantes para regiões com clima tropical seco e ensolarado, como a da presente pesquisa.

Sabendo disso, o presente estudo se propôs a utilizar os algoritmos inteligentes RNA, *fuzzy* e ANFIS para controlar o chaveamento do conversor CC-CC *buck-boost* do MPPT de dois sistemas FV distintos, denominados de cenário 1 e cenário 2. Além disso, três propostas de arquiteturas foram desenvolvidas. Elas diferenciavam-se pelas variáveis de entrada e foram denominadas de proposta 1, proposta 2 e proposta 3.

Com o intuito de avaliar e comparar o desempenho dos algoritmos modelados, o presente trabalho também se dispôs a analisar a resposta dinâmica do sistema FV quando controlado por cada algoritmo. Os parâmetros avaliados foram tempo de acomodação, oscilação em torno do MPP e erro relativo percentual. Adicionalmente, o estudo estimou a energia gerada por cada um desses sistemas FV. Para fins comparativo, o algoritmo clássico P&O também foi modelado. Afinal, como foi visto no levantamento bibliográfico e discutido na Subseção 2.7.1, ele é o algoritmo mais utilizado para controlar o MPPT dos sistemas FV.

De modo geral, as simulações demonstraram a alta eficiência dos sistemas FV quando utilizam os algoritmos inteligentes como controlador do MPPT. Ao considerar a planta FV de maior potência (cenário 2), a aumento da eficiência foi ainda mais significativo nas três arquiteturas propostas. Adicionalmente, como os algoritmos inteligentes localizaram rapidamente o verdadeiro P_{MPP} em cada mudança de irradiação, pode-se concluir que os algoritmos inteligentes possuem uma alta velocidade de rastreamento.

Além disso, quando comparadas com o algoritmo clássico P&O, os algoritmos inteligentes de todas as propostas apresentaram oscilações desprezíveis em torno do valor médio da potência em regime permanente. A amplitude da oscilação é refletida na estabilidade do sistema. Assim sendo, o sistema FV controlado por algoritmos inteligentes são mais estáveis.

Fazendo uma análise do desempenho do sistema FV quando utilizou as variáveis de entrada G e T_{AMB} (proposta 1), o MPPT mostrou ser o mais preciso dentre as três propostas, ou seja, o sistema FV alcançou valores mais próximos ao P_{MPP} esperado. Isso ocorreu, porque os

parâmetros G e T_{CELL} são os fatores que afetam diretamente na potência de saída do arranjo FV. Outra vantagem observada nessa proposta, foi a capacidade do sistema de controle rastrear o MPP independentemente da localização geográfica do sistema FV. Em contrapartida, utilizar G e T_{AMB} como parâmetros de entrada, requer a aquisição de sensores e isso torna o sistema FV mais onerosos e o projeto mais complexo.

Ainda avaliando os algoritmos inteligentes da proposta 1, quando submetido a condições ambientais dos três dias distintos de análise, o sistema FV gerou mais energia ao utilizar os algoritmos RNA e ANFIS. Quando comparado com o P&O, a recuperação de energia ficou entre 0,40% e 9,9% para o cenário 1, e entre 0,74% e 12,05% para o cenário 2.

Com relação aos sistemas FV que utilizaram os parâmetros G e $P_{FV}(t)$ como variáveis de entrada dos algoritmos inteligentes do MPPT (proposta 2), o sistema FV continuou a rastrear o MPP com rapidez e eficiência. Entretanto, no estudo da resposta dinâmica, foi constatado uma dificuldade do algoritmo ANFIS em atingir o regime permanente na condição 1 do ambiente. Especificamente para essa condição, a resposta dos algoritmos RNA e *fuzzy* tiveram um amortecimento crítico, enquanto o ANFIS mostrou um superamortecimento.

De todo modo, como discutido no Capítulo 4, esse problema não prejudicou o desempenho do sistema FV, pois ele conseguiu eficiências entre 99,25% e 99,63% quando utilizou o algoritmo ANFIS. Na estimativa da energia gerada, o ANFIS permitiu que o sistema FV produzisse até 11,61% a mais de energia que o P&O. Esses valores foram próximos ao do sistema controlado pelo RNA. O RNA foi o algoritmo que proporcionou melhor desempenho ao sistema FV. A eficiência esteve entre 99,30% e 99,65%, ao passo que a energia gerada alcançou seus 12% de recuperação.

No tocante do algoritmo inteligente *fuzzy*, tanto para a proposta 1, como para a proposta 2, o *fuzzy* apresentou resultados menos satisfatórios que os algoritmos RNA e ANFIS. Dessa forma, em ambas as propostas, mais conhecimento dos operadores especialistas deve ser requerido, assim como deve ser realizado um ajuste fino nos parâmetros do FLC. Ambos os aperfeiçoamentos têm o intuito de melhorar o desempenho do sistema fotovoltaico controlado pelo algoritmo *fuzzy*, sobretudo sob a condição normal e condição de sombreamento.

Acerca do sistema FV controlado pelos algoritmos inteligentes da proposta 3, verificou-se que a velocidade da resposta não foi prejudicada. Entretanto, a redução na eficiência provocou efeitos negativos na geração de eletricidade do sistema FV, especialmente quando submetidos à condição normal e condição de sombreamento.

No cenário 1 e cenário 2, apenas na condição randômica, os algoritmos inteligentes propiciaram uma geração de energia ao sistema FV maior que a do P&O. Em percentuais, o cenário 1 teve recuperação entre 2,19% (para o *fuzzy*) e 5,86% (para o ANFIS) e, no cenário 2, a recuperação ficou entre 4,16% (para o *fuzzy*) e 8,27% (para a RNA).

Se considerar como energia produzida o somatório dos três dias de análise, no cenário 1, o ANFIS foi o único algoritmo de controle da proposta 3 que mostrou ser superior o P&O, com um valor ínfimo de 255,77 Wh, o que corresponde a 0,5% de recuperação. No caso do cenário 2, tanto o ANFIS, como o RNA mostraram-se ser melhor que o P&O. O ANFIS recuperou 1,25% de energia, ao passo que o RNA gerou 1,43% mais eletricidade que o P&O.

Desta forma, como cada proposta modelada diferencia-se pelos parâmetros de entrada utilizado, é possível concluir que à escolha por cada algoritmo proposto está diretamente relacionada à quanto o pesquisador ou proprietário se propõe a investir, em tempo e/ou capital, para ter um sistema mais eficiente.

Ao optar pela proposta 1, os parâmetros de entrada G e T_{AMB} requerem a aquisição de sensores que deixam o sistema FV mais custosos e com projeto e operação mais complexos. Por outro lado, foi o sistema mais robusto e que conseguiu produzir mais energia. Assim, é importante ressaltar que, se considerar plantas FV de larga escala, esse custo adicional se torna irrisório perto da recuperação de energia que o sistema FV podem conseguir.

Ao escolher a proposta 2, a substituição do parâmetro T_{AMB} pelo parâmetro $P_{FV}(t)$ reduziu a aquisição de um sensor, no caso o de temperatura, e os sensores de tensão e corrente, que normalmente vem junto do sistema FV, podem ser aproveitados. Em contrapartida, a recuperação de energia também sofreu uma pequena queda, mas ainda superou o P&O.

Utilizando a proposta 3, a necessidade de sensores de irradiância e temperatura é eliminada, pois os sensores de tensão e corrente do sistema FV podem ser utilizados. No entanto, os MPPT inteligentes da proposta 3 mostraram uma maior dificuldade em rastrear o MPP, o que reduziu a energia gerada pelos sistemas FV.

Assim sendo, após todas as análises realizadas, é possível afirmar que o algoritmo ideal para um sistema FV irá depender de diversos fatores, tais como: tamanho do arranjo FV a ser utilizado; local em que o sistema FV será instalado; conjunto de dados que o projetista tem posse para treinar os algoritmos inteligentes; conhecimento do projetista, valor orçamentário que se têm à disposição para aquisição dos equipamentos do sistema; complexidade esperada, entre outros. Esses fatores também precisam ser pontuados em nível de relevância.

Finalmente, de acordo com os resultados obtidos no presente trabalho, dentre as técnicas inteligentes simuladas, os algoritmos RNA e ANFIS foram àqueles que proporcionaram ao sistema FV respostas mais parecidas. No entanto, o RNA ainda foi o algoritmo que garantiu a maior geração de energia, dentre todas as técnicas desenvolvidas e simuladas. Além disso, de acordo com os estudos levantados, o algoritmo RNA tem a vantagem de apresentar uma implementação menos complexa e ser mais robusta à ruídos.

Dessa forma, os algoritmos de controle inteligentes com diferentes variáveis de entrada que foram desenvolvidos na presente pesquisa, bem como seus satisfatórios resultados, mostraram a capacidade que esses algoritmos têm em controlar o D de um conversor *buck-boost* do MPPT de um sistema FV. Assim sendo, o presente estudo contribuiu para o avanço nas pesquisas a respeito de técnicas inteligentes de MPPT aplicadas à sistemas FV.

A partir das conclusões obtidos com o presente estudo, a Seção 5.1 estabelece sugestões para trabalhos que poderão ser desenvolvidos no futuro e que sigam a mesma linha de pesquisa.

5.1 Sugestões para trabalhos futuros

Com base no estudo desenvolvido, algumas recomendações para trabalhos futuros podem ser pontuadas, são elas:

- Confeccionar e realizar um estudo experimental dos algoritmos inteligentes da proposta 1 aplicados à um sistema FV;
- Construir e desenvolver uma análise experimental dos algoritmos inteligentes da proposta 2 aplicados como controladores do MPPT de um sistema FV;
- Implementar os algoritmos inteligentes da proposta 3 em uma planta fotovoltaica e realizar as medições cabíveis;
- Alterar os parâmetros elétricos da proposta 3, com o objetivo de obter um conjunto de dados menos sobrepostos e, consequente, respostas mais satisfatórias;
- Realizar a medição da geração de energia do sistema FV controlado por cada algoritmo inteligente, considerando um intervalo de dias maior, tais como: sete dias (uma semana), trinta dias (um mês) ou trezentos e sessenta e cinco dias (um ano);
- Orçar o custo para implementar cada algoritmo inteligente proposto e projetar o retorno de investimento ao aplica-los no sistema FV;
- Desenvolver um tomador de decisão com uma base de conhecimento capaz de ajustar o controlador do MPPT que mais se adeque a situação que o sistema FV está submetido.

Referências

- ABNT. **NBR 10899: Energia solar fotovoltaica - Terminologia.** Rio de Janeiro: [s.n.].
- AGUIAR, H. L. **Modelagem de sombreamento da planta fotovoltaica do LEA-UFC.** [s.l.] UFC, 2018.
- AHMED, A. **Eletronica de Potencia.** São Paulo: Prentice Hall, 2000.
- ALDOBHANI, A. **Maximum Power Point Tracking of PV System Using ANFIS Prediction and Fuzzy Logic Tracking.** [s.l.] Faculty of Computing Sciences and Engineering, 2008.
- ALDOBHANI, A. M. S.; JOHN, R. Maximum Power Point tracking under Different Environment Conditions for Solar Photovoltaic Panels Using ANFIS Model. **Journal of Science & Technology**, v. 12, n. 1, p. 31–47, 2007.
- ALDOBHANI, A. M. S.; JOHN, R. Maximum Power Point Tracking of PV System Using ANFIS Prediction and Fuzzy Logic Tracking. **International MultiConference of Engineers and Computer Scientists (IMECS)**, v. 2, p. 19–21, 2008.
- ALONSO, A. E. G. **Maximum Power Point Tracking Algorithms for Photovoltaic Applications.** [s.l.] Universidade Politécnica de Madri, 2017.
- ANDREW-COTTER, J.; UDDIN, M. N.; AMIN, I. K. Particle swarm optimization based adaptive neuro-fuzzy inference system for MPPT control of a three-phase grid-connected photovoltaic system. **IEEE International Electric Machines and Drives Conference, IEMDC 2019**, p. 2089–2094, 2019.
- ARORA, A. Comparison of f ANN and ANFIS bas ed MPPT controller fo or grid connected PV Systems. p. 1–6, 2015.
- AYOP, R.; TAN, C. W. Design of boost converter based on maximum power point resistance for photovoltaic applications. **Solar Energy**, v. 160, p. 322–335, 2018.
- BELHACHAT, F.; LARBES, C. Global maximum power point tracking based on ANFIS approach for PV array configurations under partial shading conditions. **Renewable and Sustainable Energy Reviews**, v. 77, p. 875–889, 2017.
- BOLLIPO, R. B.; MIKKILI, S.; BONTHAGARLA, P. K. A Critical Review on PV MPPT Techniques : Classical, Intelligent and Optimization. **IET Renewable Power Generation**, 2020.
- CARVALHO NETO, J. T. DE. **Controle de um ciclo aplicado em sistemas fotovoltaicos autônomos em um microgrid de corrente contínua.** [s.l.] UFRN, 2016.
- CHEKIRED, F. et al. Intelligent maximum power point trackers for photovoltaic applications using FPGA chip: A comparative study. **Solar Energy**, v. 101, p. 83–99, 2014.
- CHEKIRED, F.; LARBES, C.; MELLIT, A. Comparative study between two intelligent MPPT-controllers implemented on FPGA: application for photovoltaic systems. **International Journal of Sustainable Energy**, 2012.
- COELHO, R. F. **Estudo dos conversores buck e boost aplicados ao rastreamento de máxima potência de sistemas solares fotovoltaicos.** [s.l.] UFSC, 2008.
- COELHO, R. F.; DOS SANTOS, W. M.; MARTINS, D. C. Influence of power converters on PV maximum power point tracking efficiency. **Brazilian Power Electronics Journal**, v. 19, n. 1, p. 72–79, 2014.

- COELHO, R. F.; MARTINS, D. C. An Optimized Maximum Power Point Tracking Method Based on PV Surface Temperature Measurement. In: **Sustainable Energy - Recent Studies.** [s.l.] InTech, 2012. p. 89–114.
- DESIKAN, A.; KALAIACHELVI, V. **ANFIS modeling of photovoltaic systems to mitigate partially shaded conditions.** Proceedings of IEEE International Conference on Innovations in Electrical, Electronics, Instrumentation and Media Technology, ICIEEIMT 2017. **Anais...IEEE,** 2017
- DIXIT, T. V. et al. Power extraction from PV module using hybrid ANFIS controller. In: PRECUP, R.-E.; KAMAL, T.; HASSAN, S. Z. (Eds.). **Solar photovoltaic power plants: Advanced Control and Optimization Techniques.** [s.l.] Springer, 2019. p. 209–232.
- ENRIQUE, J. M. et al. Theoretical assessment of the maximum power point tracking efficiency of photovoltaic facilities with different converter topologies. **Solar Energy,** v. 81, n. 1, p. 31–38, 2007.
- FARAJDADIAN, S.; HOSSEINI, S. M. H. Design of an optimal fuzzy controller to obtain maximum power in solar power generation system. **Solar Energy,** v. 182, p. 161–178, 2019.
- GUERRA, M. I. S. et al. Assessing maximum power point tracking intelligent techniques on a pv system with a buck-boost converter. **Energies,** v. 14, n. 22, 2021.
- GUPTA, A.; CHAUHAN, Y. K.; PACHAURI, R. K. A comparative investigation of maximum power point tracking methods for solar PV system. **Solar Energy,** v. 136, p. 236–253, 2016.
- HAJI, D.; GENC, N. Dynamic Behaviour Analysis of ANFIS Based MPPT Controller for Standalone Photovoltaic Systems. **International Journal of Renewable Energy Research,** v. 10, 2020.
- HANZAEI, S. H.; GORJI, S. A.; EKTESABI, M. A Scheme-Based Review of MPPT Techniques With Respect to Input Variables Including Solar Irradiance and PV Arrays' Temperature. **IEEE Access,** v. 8, p. 182229–182239, 2020.
- HART, D. W. **Eletrônica de Potência: análise e projetos de circuitos.** Porto Alegre: AMGH, 2012.
- HIYAMA, T. et al. Evaluation of Neural Network Based Real Time Maximum Power Tracking Controller for PV System. **IEEE Transactions on Energy Conversion,** v. 10, n. 3, p. 543–548, 1995.
- IEA. **International Energy Outlook 2021.** Disponível em: <<https://iea.blob.core.windows.net/assets/88dec0c7-3a11-4d3b-99dc-8323ebfb388b/WorldEnergyOutlook2021.pdf>>. Acesso em: 14 out. 2021a.
- IEA. **Snapshot of Global PV Markets 2021.** Disponível em: <http://www.ieapvps.org/fileadmin/dam/public/report/technical/PVPS_report_-_A_Snapshot_of_Global_PV_-_1992-2014.pdf>. Acesso em: 14 out. 2021b.
- IQBAL, A.; ABU-RUB, H.; AHMED, S. M. Adaptive neuro-fuzzy inference system based maximum power point tracking of a solar PV module. **2010 IEEE International Energy Conference and Exhibition, EnergyCon 2010,** p. 51–56, 2010.
- ISHAQUE, K.; SALAM, Z.; SYAFARUDDIN. A comprehensive MATLAB Simulink PV system simulator with partial shading capability based on two-diode model. **Solar Energy,** v. 85, n. 9, p. 2217–2227, 2011.
- ISLAM, O. K. et al. A Comprehensive Comparison between Boost and Buck-Boost Converters

- in Solar MPPT with ANN. **ETCCE 2020 - International Conference on Emerging Technology in Computing, Communication and Electronics**, 2020.
- JANG, J.-S. R. ANFIS: adaptive-network-based fuzzy inference system. **IEEE Transactions on Systems, Man, and Cybernetics**, v. 23, n. 3, p. 665–685, 1993.
- JOSHI, P.; ARORA, S. Maximum power point tracking methodologies for solar PV systems – A review. **Renewable and Sustainable Energy Reviews**, v. 70, p. 1154–1177, 2017.
- JUSTO, D. A. R. et al. **Cálculo numérico: um livro colaborativo**. Porto Alegre: UFRGS, 2018.
- KALOGIROU, S. A. **Solar Energy Engineering: Processes and Systems**. 2. ed. San Diego: Elsevier, 2014.
- KAMARZAMAN, N. A.; TAN, C. W. A comprehensive review of maximum power point tracking algorithms for photovoltaic systems. **Renewable and Sustainable Energy Reviews**, v. 37, p. 585–598, 2014.
- KARANKAR, D. S. et al. Real time simulation and analysis of maximum power point tracking (MPPT) techniques for solar photo-voltaic system. **Recent Advances in Engineering and Computational Sciences, RAECS 2014**, 2014.
- KHAEHINTUNG, N.; SIRISUK, P.; KURUTACH, W. **A Novel ANFIS Controller for Maximum Power Point Tracking**. The Fifth International Conference on Power Electronics and Drive Systems. **Anais...** Singapura: 2003Disponível em: <<https://ieeexplore.ieee.org/abstract/document/1283074>>
- KHANAM, J.; FOO, S. Modeling of a Photovoltaic Array in MATLAB Simulink and Maximum Power Point Tracking Using Neural Network. **Journal of Electrical & Electronic Systems**, v. 07, n. 03, p. 1–8, 2018.
- KHATIB, T.; ELMENREICH, W. **Modeling of Photovoltaic Systems using MATLAB®: simplified green codes**. New Jersey: John Wiley & Sons, 2016.
- KUMAR, A.; GUPTA, N.; GUPTA, V. A Comprehensive Review on Grid-Tied Solar Photovoltaic System. **Journal of Green Engineering**, v. 7, n. 1, p. 213–254, 2017.
- KUMAR, J.; RATHOR, B.; BAHRANI, P. Fuzzy and P&O MPPT techniques for stabilized the efficiency of solar PV system. **2018 International Conference on Computing, Power and Communication Technologies, GUCON 2018**, n. Dc, p. 259–264, 2019.
- LASHEEN, M.; ABDEL-SALAM, M. Maximum power point tracking using Hill Climbing and ANFIS techniques for PV applications: A review and a novel hybrid approach. **Energy Conversion and Management**, v. 171, p. 1002–1019, 2018.
- LUQUE, A.; HEGEDUS, S. **Handbook of Photovoltaic Science and Engineering**. Chennai: Wiley, 2003.
- MAKHLOUFI, M. T.; ABDESSEMED, Y.; KHIREDDINE, M. S. A neural network MPP tracker using a Buck-Boost DC/DC converter for photovoltaic systems. **2016 5th International Conference on Systems and Control, ICSC 2016**, p. 72–77, 2016.
- MARTIN, A. D.; VAZQUEZ, J. R. MPPT algorithms comparison in PV systems: P&O, PI, neuro-fuzzy and backstepping controls. **Proceedings of the IEEE International Conference on Industrial Technology**, v. 2015-June, n. June, p. 2841–2847, 2015.
- MASTERS, G. M. **Renewable and Efficient Electric Power Systems**. [s.l.] Wiley-Interscience, 2004.

- MCEVOY, A.; MARKVART, T.; CASTAÑER, L. **Practical Handbook of Photovoltaics: Fundamentals and Applications**. 2. ed. [s.l.] Elsevier, 2012.
- MELLIT, A.; KALOGIROU, S. A. MPPT-based artificial intelligence techniques for photovoltaic systems and its implementation into field programmable gate array chips: Review of current status and future perspectives. **Energy**, v. 70, p. 1–21, 2014.
- NABIPOUR, M. et al. A new MPPT scheme based on a novel fuzzy approach. **Renewable and Sustainable Energy Reviews**, v. 74, n. October 2016, p. 1147–1169, 2017.
- OTIENO, C. A.; NYAKOE, G. N.; WEKESA, C. W. **A neural fuzzy based maximum power point tracker for a photovoltaic system**. IEEE AFRICON Conference. Anais...Nairobi: IEEE, 2009
- PANDA, A.; PATHAK, M. K.; SRIVASTAVA, S. P. Fuzzy Intelligent Controller for the Maximum Power Point Tracking of a Photovoltaic Module at Varying Atmospheric Conditions. v. 1, n. 2, p. 6–9, 2011.
- PEARSALL, N. **The Performance of Photovoltaic (PV) Systems: Modelling, Measurement and Assessment**. 1. ed. Cambridge: Woodhead Publishing, 2017.
- PINHO, J. T.; GALDINO, M. A. **Manual de engenharia para sistemas fotovoltaicos**. Rio de Janeiro: GTES/CEPEL, 2014.
- RAJAVEL, A.; RATHINA PRABHA, N. Fuzzy logic controller-based boost and buck-boost converter for maximum power point tracking in solar system. **Transactions of the Institute of Measurement and Control**, v. 43, n. 4, p. 945–957, 2021.
- RAJESH, R.; CAROLIN MABEL, M. A comprehensive review of photovoltaic systems. **Renewable and Sustainable Energy Reviews**, v. 51, p. 231–248, 2015.
- RESHMA GOPI, R.; SREEJITH, S. Converter topologies in photovoltaic applications – A review. **Renewable and Sustainable Energy Reviews**, v. 94, n. May, p. 1–14, 2018.
- REZVANI, A. et al. Implementing GA-ANFIS for maximum power point tracking in PV system. **Indian Journal of Science and Technology**, v. 8, n. 10, p. 982–991, 2015.
- RIZZO, S. A.; SCELBA, G. ANN based MPPT method for rapidly variable shading conditions. **Applied Energy**, v. 145, p. 124–132, 2015.
- ROCHA, A. S. F.; GUERRA, F. K. DE O. M. V.; VALE, M. R. B. G. Forecasting the Performance of a Photovoltaic Solar System Installed in other Locations using Artificial Neural Networks. **Electric Power Components and Systems**, v. 48, n. 1–2, p. 201–212, 2020.
- SANDRI, S.; CORREA, C. Lógica Nebulosa. **Instituto Tecnológico da Aeronáutica - ITA. V Escola de Redes Neurais.**, p. 73–90, 1999.
- SENJYU, T.; UEZATO, K. Maximum power point tracker using fuzzy control for photovoltaic arrays. p. 143–147, 1994.
- SHIAU, J. K. et al. Circuit Simulation for Solar Power Maximum Power Point Tracking with Different Buck-Boost Converter Topologies. **Energies**, v. 7, n. 8, p. 5027–5046, 2014.
- SIDDIQUE, N.; ADELI, H. **Computational intelligence: synergies of fuzzy logic, neural networks, and evolutionary computing**. Reino Unido: Wiley, 2013.
- SILVA, I. N.; SPATTI, D. H.; FLAUZINO, R. A. **Redes Neurais Artificiais Para Engenharia e Ciências Aplicadas**. 2. ed. São Paulo: Artliber, 2016.
- SILVA, L. R. C. **Utilização de Redes Neurais Artificiais para Rastreamento de Máxima**

- Potência de Sistemas Fotovoltaicos Parcialmente Sombreados.** [s.l.] UFU, 2019.
- SIMÕES, M. G.; SHAW, I. S. **Controle e Modelagem Fuzzy**. 2. ed. São Paulo: Blucher, 2007.
- SMA. **PV inverter: Sunny Boy 2000HF-US / 2500HF-US / 3000HF-US** DenverSMA, , 2008.
- SMETS, A. H. et al. **Solar energy: The physics and engineering of photovoltaic conversion, technologies and systems**. Cambridge: UIT Cambridge Ltd., 2016. v. 1
- SUMATHI, S.; ASHOK KUMAR, L.; SUREKHA, P. **Solar PV and Wind Energy Conversion Systems: An Introduction to Theory, Modeling with MATLAB/SIMULINK, and the Role of Soft Computing Techniques**. [s.l.] Springer, 2015.
- TAGHVAEE, M. H. et al. A current and future study on non-isolated DC-DC converters for photovoltaic applications. **Renewable and Sustainable Energy Reviews**, v. 17, p. 216–227, 2013.
- UDDIN, N.; ISLAM, M. S. **Optimization of PV Energy Generation based on ANFIS**. International Conference on Innovations in Science, Engineering and Technology, ICISET 2018. **Anais...**Chitagongue: IEEE, 2018
- VILLALVA, M. G.; GAZOLI, J. R. **Energia solar fotovoltaica: conceitos e aplicações**. 1. ed. São Paulo: Érica, 2012.
- VILLALVA, M. G.; GAZOLI, J. R.; RUPPERT FILHO, E. Comprehensive Approach to Modeling and Simulation of Photovoltaic Arrays. **IEEE Transactions on Power Electronics**, v. 24, n. 5, p. 1198–4237, 2009.
- VILLEGRAS-MIER, C. G.; RODRIGUEZ-RESENDIZ, J.; ÁLVAREZ-ALVARADO, J. M. Artificial Neural Networks in MPPT Algorithms for Optimization of Photovoltaic Power Systems : A Review. p. 1–19, 2021.
- XIAO, W. **Photovoltaic power system : modeling, design, and control**. Chennai: Wiley, 2017.
- YAHYOUI, I. **Advances in Renewable Energies and Power Technologies**. [s.l.] Elsevier, 2018.
- YAP, K. Y.; SARIMUTHU, C. R.; LIM, J. M. Y. Artificial Intelligence Based MPPT Techniques for Solar Power System: A review. **Journal of Modern Power Systems and Clean Energy**, v. 8, n. 6, p. 1043–1059, 2020.
- YINGLI SOLAR. **Datasheet YGE 60 células série 2**, 2015.
- YOUSSEF, A.; EL-TELBANY, M.; ZEKRY, A. The role of artificial intelligence in photovoltaic systems design and control: A review. **Renewable and Sustainable Energy Reviews**, v. 78, p. 72–79, 2017.